

Traducción al español de Data Reduction and Error Analysis for the Physical Sciences Incertidumbres en las Mediciones

Philip R. Bevington & D. Keith Robinson
Traducción y resolución de ejercicios



Licencia Creative Commons Attribution-NonCommercial-ShareAlike 4.0 Internacional (CC BY-NC-SA 4.0)

Este documento está bajo una licencia *Creative Commons Attribution-NonCommercial-ShareAlike 4.0 Internacional*. Esto significa que eres libre de:

- **Compartir** — copiar y redistribuir el material en cualquier medio o formato.
- **Adaptar** — remezclar, transformar y construir a partir del material.

Bajo los siguientes términos:

- **Atribución** — Debes dar el crédito apropiado, proporcionar un enlace a la licencia e indicar si se realizaron cambios.
- **NoComercial** — No puedes utilizar el material para fines comerciales.
- **CompartirIgual** — Si remezclas, transformas o creas a partir del material, debes distribuir tus contribuciones bajo la misma licencia que el original.

Para ver una copia completa de esta licencia, visita:
<https://creativecommons.org/licenses/by-nc-sa/4.0/deed.es>

Capítulo 1: Incertidumbres en las Mediciones

1.1 Errores de Medición

Es un hecho bien establecido en la investigación científica que la primera vez que se realiza un experimento, los resultados a menudo se parecen muy poco a la “verdad” que se busca. A medida que se repite el experimento, con refinamientos sucesivos de la técnica y el método, los resultados gradual y asintóticamente se aproximan a lo que podemos aceptar con cierta confianza como una descripción fiable de los eventos. A veces podemos sentir que la naturaleza es reacia a revelar sus secretos sin un esfuerzo considerable de nuestra parte, y que los primeros pasos en la experimentación están destinados al fracaso. Sea cual sea la razón, es ciertamente cierto que para todos los experimentos físicos, existen errores e incertidumbres que deben reducirse mediante técnicas experimentales mejoradas y mediciones repetidas, y aquellos errores que permanecen deben ser siempre estimados para establecer la validez de nuestros resultados.

El error se define según el diccionario como “la diferencia entre un valor observado o calculado y el valor verdadero”. Normalmente no conocemos el valor “verdadero”; de lo contrario, no habría razón para realizar el experimento. Podemos saber aproximadamente cuál debería ser, ya sea por experimentos anteriores o por predicciones teóricas. Tales aproximaciones pueden servir como guía, pero siempre debemos determinar de manera sistemática a partir de los datos y las condiciones experimentales mismas cuánta confianza podemos tener en nuestros resultados experimentales.

Hay una clase de error que podemos abordar de inmediato: los errores que se originan por equivocaciones o desaciertos en la medición o el cálculo. Afortunadamente, estos errores suelen ser evidentes, ya sea como puntos de datos obviamente incorrectos o como resultados que no están razonablemente cerca de los valores esperados. Se clasifican como errores ilegítimos y generalmente pueden corregirse repitiendo cuidadosamente las operaciones. Nuestro interés está en las incertidumbres introducidas por fluctuaciones aleatorias en nuestras mediciones, y los errores sistemáticos que limitan la precisión y exactitud de nuestros resultados de maneras más o menos bien definidas. Generalmente, nos referimos a las incertidumbres como los errores en nuestros resultados, y al procedimiento para estimarlos como análisis de errores.

Exactitud versus Precisión

Es importante distinguir entre los términos exactitud (accuracy) y precisión (precision). La exactitud de un experimento es una medida de cuán cerca está el resultado del experimento del valor verdadero; la precisión es una medida de qué tan bien se ha determinado el resultado, sin referencia a su concordancia con el valor verdadero. La precisión es también una medida de la reproducibilidad del resultado en un experimento dado. La distinción entre exactitud y precisión se ilustra con los dos conjuntos de mediciones en la Figura 1.1, donde la línea recta en cada gráfico muestra la relación esperada entre la variable dependiente y y la variable independiente x . En ambos gráficos, la dispersión de los puntos de datos es un reflejo de las incertidumbres en las mediciones, consistente con las barras de error en los puntos. Los datos en la Figura 1.1(a) han sido medidos con un alto grado de precisión, como lo ilustran las pequeñas barras de error, y están en excelente acuerdo con la variación esperada de y con x , pero son claramente inexactos, desviándose de la línea por un desplazamiento constante. Por otro lado, los puntos de datos en la Figura 1.1(b) son bastante imprecisos, como lo ilustran las grandes barras de error, pero

están dispersos alrededor de la distribución predicha.

Es obvio que debemos considerar la exactitud y la precisión simultáneamente para cualquier experimento. Sería una pérdida de tiempo y energía determinar un resultado con alta precisión si supiéramos que el resultado sería altamente inexacto. Por el contrario, un resultado no puede considerarse extremadamente exacto si la precisión es baja. En general, cuando citamos la incertidumbre o error en un resultado experimental, nos referimos a la precisión con la que se ha determinado ese resultado. La precisión absoluta indica la magnitud de la incertidumbre en el resultado en las mismas unidades que el resultado; la precisión relativa indica la incertidumbre en términos de una fracción del valor del resultado.

Errores Sistemáticos

La exactitud de un experimento, tal como la hemos definido, depende generalmente de qué tan bien podamos controlar o compensar los errores sistemáticos, errores que harán que nuestros resultados difieran de los valores “verdaderos” con discrepancias reproducibles. Los errores de este tipo no son fáciles de detectar ni de estudiar mediante análisis estadístico. Pueden resultar de una calibración defectuosa del equipo o de un sesgo por parte del observador. Deben estimarse a partir de un análisis de las condiciones y técnicas experimentales. Una parte importante de la planificación de un experimento debe dedicarse a comprender y reducir las fuentes de errores sistemáticos.

Ejemplo 1.1 Un estudiante mide el tablero de una mesa con una regla de acero y encuentra que el promedio de sus mediciones da un resultado de $(1,982 \pm 0,001)$ m para la longitud de la mesa. Posteriormente, se entera de que la regla fue calibrada a 25°C y tiene un coeficiente de expansión de $0,0005^{\circ}\text{C}^{-1}$. Dado que sus mediciones se realizaron a temperatura ambiente de 20°C , son sistemáticamente demasiado pequeñas. Para corregir este efecto, multiplica sus resultados por $1 + 0,0005 \times (20 - 25) = 0,9975$, por lo que su nueva determinación de la longitud es 1,977 m.

Cuando el estudiante repite el experimento, descubre un segundo error sistemático: su técnica para leer la regla era defectuosa, ya que no siempre leía las divisiones desde directamente arriba. Mediante experimentación, determina que esto resultó consistentemente en una lectura que era 2 mm más corta. El resultado corregido es 1,979 m.

En este ejemplo, el primer resultado se dio con una precisión bastante alta, aproximadamente 1 parte en 2000. Las correcciones a este resultado tenían como objetivo mejorar la exactitud compensando las fuentes conocidas de desviación del primer resultado con respecto a la mejor estimación posible. Estas correcciones no mejoraron la precisión en absoluto, sino que de hecho la empeoraron, porque las correcciones eran en sí mismas solo estimaciones de las correcciones exactas. Antes de citar su resultado final, el estudiante debe reexaminar su análisis de errores y tener en cuenta cualquier incertidumbre adicional que puedan haber introducido estas correcciones.

Errores Aleatorios

La precisión de un experimento depende de qué tan bien podamos superar los errores aleatorios, fluctuaciones en las observaciones que producen resultados diferentes cada vez

que se repite el experimento y, por lo tanto, requieren experimentación repetida para obtener resultados precisos. Una exactitud dada implica una precisión equivalente y, por lo tanto, también depende hasta cierto punto de los errores aleatorios.

El problema de reducir los errores aleatorios es esencialmente uno de mejorar el método experimental y refinar las técnicas, así como simplemente repetir el experimento. Si los errores aleatorios resultan de incertidumbres instrumentales, pueden reducirse utilizando instrumentos de medición más fiables y precisos. Si los errores aleatorios resultan de fluctuaciones estadísticas en un número limitado de mediciones, pueden reducirse realizando más mediciones. Hay límites prácticos para estas mejoras. En la medición de la longitud de la mesa del Ejemplo 1.1, el estudiante podría intentar mejorar la precisión de sus mediciones usando una lupa para leer la escala, o podría intentar reducir las fluctuaciones estadísticas en sus mediciones repitiendo la medición varias veces. En ningún caso sería útil reducir los errores aleatorios muy por debajo de los errores sistemáticos, como los introducidos por la calibración de la regla o la corrección por su lectura inicial defectuosa de la escala. Los límites impuestos por los errores sistemáticos son consideraciones importantes en la planificación y realización de experimentos.

Cifras Significativas y Redondeo

La precisión de un resultado experimental está implícita en el número de dígitos registrados en el resultado, aunque generalmente la incertidumbre también debe citarse específicamente. El número de cifras significativas en un resultado se define de la siguiente manera:

1. El dígito distinto de cero más a la izquierda es el dígito más significativo.
2. Si no hay punto decimal, el dígito distinto de cero más a la derecha es el dígito menos significativo.
3. Si hay punto decimal, el dígito más a la derecha es el dígito menos significativo, incluso si es 0.
4. Todos los dígitos entre el dígito menos y más significativo se cuentan como cifras significativas.

Por ejemplo, los siguientes números tienen cada uno cuatro cifras significativas: 1234, 123400, 123.4, 1001, 1000, 10.10, 0.0001010, 100.0. Si no hay punto decimal, hay ambigüedades cuando el dígito más a la derecha es 0. Así, el número 1010 se considera que tiene solo tres cifras significativas, aunque el último dígito podría ser físicamente significativo. Para evitar ambigüedades, es mejor proporcionar puntos decimales o escribir dichos números en notación científica, es decir, como un argumento en notación decimal multiplicado por la potencia apropiada de 10. Por lo tanto, nuestro ejemplo de 1010 se escribiría como 1010. o $1,010 \times 10^3$ si los cuatro dígitos son significativos.

Al citar un resultado experimental, el número de cifras significativas debe ser aproximadamente uno más que el dictado por la precisión experimental. La razón para incluir el dígito extra es evitar errores que podrían ser causados por errores de redondeo en cálculos posteriores. Si el resultado de la medición del Ejemplo 1.1 es $L = 1,979 \text{ m}$ con una incertidumbre de 0,012 m, este resultado podría citarse como $L = (1,979 \pm 0,012) \text{ m}$. Sin embargo, si el primer dígito de la incertidumbre es grande, como 0,082 m, entonces

probablemente deberíamos citar $L = (1,98 \pm 0,08)$ m. En otras palabras, dejamos que la incertidumbre defina la precisión con la que citamos nuestro resultado.

Cuando se eliminan dígitos no significativos de un número, el último dígito retenido debe redondearse para obtener la mejor exactitud. Para redondear un número a menos cifras significativas de las que se especificaron originalmente, truncamos el número como se desea y tratamos los dígitos excedentes como una fracción decimal. Entonces:

1. Si la fracción es mayor que $\frac{1}{2}$, incrementamos el nuevo dígito menos significativo.
2. Si la fracción es menor que $\frac{1}{2}$, no lo incrementamos.
3. Si la fracción es igual a $\frac{1}{2}$, incrementamos el dígito menos significativo solo si es impar.

La razón de la regla 3 es que un valor fraccionario de $\frac{1}{2}$ puede resultar de un redondeo previo hacia arriba de una fracción que era ligeramente menor que $\frac{1}{2}$ o de un redondeo hacia abajo de una fracción que era ligeramente mayor que $\frac{1}{2}$. Por ejemplo, 1.249 y 1.251 se redondean a tres cifras significativas como 1.25. Si redondeamos nuevamente a dos cifras significativas, ambos darían el mismo valor, ya sea 1.2 o 1.3, dependiendo de nuestra convención. Elegir redondear hacia arriba si el último dígito resultante es impar y hacia abajo si el último dígito resultante es par, reduce los errores sistemáticos que de otro modo se introducirían en el promedio de un grupo de tales números. Nótese que generalmente es recomendable retener todos los dígitos disponibles en los cálculos intermedios y redondear solo los resultados finales.

1.2 Incertidumbres

Las incertidumbres en los resultados experimentales pueden separarse en dos categorías: las que resultan de fluctuaciones en las mediciones y las asociadas con la descripción teórica de nuestro resultado. Por ejemplo, si medimos la longitud de una mesa rectangular a lo largo de un borde, sabemos que cualquier incertidumbre, aparte de los errores sistemáticos, está asociada con las fluctuaciones de nuestras mediciones de un ensayo a otro. Con un número infinito de mediciones podríamos estimar la longitud con mucha precisión, pero con un número finito de ensayos habrá una incertidumbre finita. Si midiéramos la longitud de la mesa en posiciones igualmente espaciadas a lo ancho de la mesa, las mediciones mostrarían fluctuaciones adicionales correspondientes a irregularidades en la propia mesa, y nuestro resultado podría expresarse como la longitud media. Si, sin embargo, describiéramos la forma de una mesa ovalada, nos enfrentaríamos a incertidumbres tanto en la medición de la posición del borde de la mesa en varios puntos como en la forma de la ecuación a utilizar para describir la forma, ya sea circular, elíptica o cualquier otra. Por lo tanto, en los siguientes capítulos nos ocuparemos de una comparación de la distribución de los puntos de datos medidos con la distribución predicha sobre la base de un modelo teórico. Esta comparación ayudará a indicar si nuestro método de extraer los resultados es válido o necesita modificación.

El término error sugiere una desviación del resultado de algún valor “verdadero”. Por lo general, no podemos saber cuál es el valor verdadero y solo podemos estimar los errores inherentes al experimento. Si repetimos un experimento, los resultados bien pueden diferir de los del primer intento. Expresamos esta diferencia como una discrepancia entre los dos resultados. Las discrepancias surgen porque podemos determinar un resultado solo con

una incertidumbre dada. Por ejemplo, cuando comparamos diferentes mediciones de una constante física estándar, o comparamos nuestro resultado con el valor aceptado, debemos referirnos a las diferencias como discrepancias, no como errores o incertidumbres.

Debido a que, en general, no podremos citar el error real en un resultado, debemos desarrollar un método consistente para determinar y citar el error estimado. Un estudio de la distribución de los resultados de mediciones repetidas de la misma cantidad puede conducir a una comprensión de estos errores, de modo que el error citado sea una medida de la dispersión de la distribución. Sin embargo, para algunos experimentos puede no ser factible repetir las mediciones y los experimentadores deben, por lo tanto, intentar estimar los errores basándose en una comprensión del aparato y su propia habilidad para usarlo. Por ejemplo, si el estudiante del Ejemplo 1.1 pudiera hacer solo una sola medición de la longitud de la mesa, debería examinar su regla y la mesa, y tratar de estimar qué tan bien podría determinar la longitud. Su estimación debe ser consistente con el resultado esperado de un estudio de mediciones repetidas; es decir, para citar una estimación del error estándar, debe tratar de estimar un rango dentro del cual esperaría que cayeran las mediciones repetidas aproximadamente siete veces de cada diez. Por lo tanto, podría concluir que con una buena regla de acero y un borde de mesa bien definido, podría medir con una precisión de aproximadamente ± 1 mm o $\pm 0,001$ m. Debe resistir la tentación de aumentar esta estimación de error, “solo para estar seguro”.

También debemos darnos cuenta de que el modelo a partir del cual calculamos los parámetros teóricos para describir los resultados de nuestro experimento puede no ser el modelo correcto. En los siguientes capítulos discutiremos parámetros hipotéticos y distribuciones probables de errores pertenecientes a los estados “verdaderos” de las cosas, y discutiremos métodos para hacer estimaciones experimentales de estos parámetros y las incertidumbres asociadas con estas determinaciones.

Minimización de Incertidumbres y Mejores Resultados

Nuestra preocupación por el análisis de errores no se limita solo a la determinación de la precisión de nuestros resultados. En general, estaremos interesados en obtener la máxima cantidad de información útil de los datos disponibles sin poder repetir el experimento con mejor equipo o reducir las incertidumbres estadísticas haciendo más mediciones. Por lo tanto, nos ocuparemos del problema de extraer de los datos las mejores estimaciones de los parámetros teóricos y de los errores aleatorios, y queremos entender el efecto de estos errores en nuestros resultados, para poder determinar qué confianza podemos depositar en nuestros resultados finales. Es razonable esperar que los resultados más fiables que podamos calcular a partir de un conjunto dado de datos serán aquellos para los cuales los errores estimados sean los más pequeños. Por lo tanto, nuestro desarrollo de técnicas de análisis de errores ayudará a determinar las estimaciones óptimas de los parámetros para describir los datos.

Debe notarse, sin embargo, que incluso nuestros mejores esfuerzos producirán solo estimaciones de las cantidades investigadas.

1.3 Distribuciones Parentales y de Muestra

Si hacemos una medición x_1 de una cantidad x , esperamos que nuestra observación se aproxime a la cantidad, pero no esperamos que el punto de dato experimental sea exactamente igual a la cantidad. Si hacemos otra medición, esperamos observar una discrepancia entre las dos mediciones debido a errores aleatorios, y no esperamos que ninguna de las

determinaciones sea exactamente correcta, es decir, igual a x . A medida que hacemos más y más mediciones, surgirá un patrón a partir de los datos. Algunas de las mediciones serán demasiado grandes, algunas serán demasiado pequeñas. En promedio, sin embargo, esperamos que estén distribuidas alrededor del valor correcto, asumiendo que podemos despreciar o corregir los errores sistemáticos.

Si pudiéramos hacer un número infinito de mediciones, entonces podríamos describir exactamente la distribución de los puntos de datos. Esto no es posible en la práctica, pero podemos hipotetizar la existencia de tal distribución que determina la probabilidad de obtener cualquier observación particular en una sola medición. Esta distribución se llama distribución parental. De manera similar, podemos hipotetizar que las mediciones que hemos realizado son muestras de la distribución parental y forman la distribución muestral. En el límite de un número infinito de mediciones, la distribución muestral se convierte en la distribución parental.

Ejemplo 1.2 En un experimento de laboratorio de física, los estudiantes dejan caer una pelota 50 veces y registran el tiempo que tarda la pelota en caer 2,00 m. Un conjunto de observaciones, corregidas por errores sistemáticos, oscila entre aproximadamente 0,59 s y 0,70 s, y algunas de las observaciones son idénticas. La Figura 1.2 muestra un histograma o gráfico de frecuencia de estas mediciones. La altura de una barra de datos representa el número de mediciones que caen entre los dos valores indicados por los límites superior e inferior de la barra en la abscisa del gráfico. (Véase el Apéndice D.)

Si la distribución resulta de errores aleatorios en la medición, entonces es muy probable que pueda describirse en términos de la distribución de error gaussiana o normal, la familiar curva en forma de campana del análisis estadístico, que discutiremos en el Capítulo 2. Una curva gaussiana, basada en la media y la desviación estándar de estas mediciones, se traza como la línea sólida en la Figura 1.2. Esta curva resume los datos de la distribución muestral en términos del modelo gaussiano y proporciona una estimación de la distribución parental.

Los datos medidos y la curva derivada de ellos claramente no concuerdan exactamente. La aspereza del histograma experimental lo distingue de inmediato de la curva gaussiana teórica suave. Podríamos imaginar que, si los estudiantes hicieran muchas más mediciones o combinaran varios conjuntos de mediciones para poder trazar el histograma en intervalos cada vez más finos, en circunstancias ideales el histograma eventualmente se aproximaría a una curva gaussiana suave. Si calcularan los parámetros a partir de una muestra tan grande, podrían determinar la distribución parental representada por la curva punteada en la Figura 1.2.

Es conveniente pensar en términos de una función de densidad de probabilidad $p(x)$, normalizada a área unitaria (es decir, de modo que la integral de toda la curva sea igual a 1) y definida de tal manera que, en el límite de un número muy grande N de observaciones, el número ΔN de observaciones de la variable x entre x y $x + \Delta x$ está dado por $\Delta N = Np(x)\Delta x$. Las curvas sólida y discontinua en la Figura 1.2 han sido escaladas de esta manera para que los valores de la ordenada correspondan directamente al número de observaciones esperadas en cualquier rango Δx de una muestra de 50 eventos y el área bajo cada curva corresponda al área total del histograma.

Notación

Una serie de parámetros de la distribución parental se han definido por convención. Usamos letras griegas para denotarlos y letras latinas para denotar estimaciones experimentales de ellos.

Para determinar los parámetros de la distribución parental, asumimos que los resultados de los experimentos se aproximan asintóticamente a las cantidades parentales a medida que el número de mediciones se acerca al infinito; es decir, los parámetros de la distribución experimental igualan los parámetros de la distribución parental en el límite de un número infinito de mediciones. Si especificamos que hay N observaciones en un experimento dado, entonces podemos denotar esto por

$$(\text{parámetro parental}) = \lim_{N \rightarrow \infty} (\text{parámetro experimental})$$

Si hacemos N mediciones y las etiquetamos como x_1, x_2, x_3 , y así sucesivamente, hasta una medición final x_N , entonces podemos identificar la suma de todas estas mediciones como

$$\sum_{i=1}^N x_i = x_1 + x_2 + x_3 + \cdots + x_N$$

donde el lado izquierdo se interpreta como la suma de las observaciones x_i sobre el índice i desde $i = 1$ hasta $i = N$ inclusive. Dado que haremos uso frecuente de la suma sobre N mediciones de varias cantidades, simplificamos la notación omitiendo el índice siempre que estemos considerando una suma donde el índice i va desde 1 hasta N :

$$\sum x_i = \sum_{i=1}^N x_i$$

Media, Mediana y Moda

Con las definiciones anteriores, la media $\bar{x}$ de la distribución experimental se da como la suma de N determinaciones x_i de la cantidad x dividida por el número de determinaciones

$$\bar{x} \equiv \frac{1}{N} \sum x_i \quad (1.1)$$

y la media μ de la población parental se define como el límite

$$\mu = \lim_{N \rightarrow \infty} \left(\frac{1}{N} \sum x_i \right) \quad (1.2)$$

La media es, por lo tanto, equivalente al centroide o valor promedio de la cantidad x .

La mediana de la población parental $\mu_{1/2}$ se define como aquel valor para el cual, en el límite de un número infinito de determinaciones x_i , la mitad de las observaciones serán menores que la mediana y la mitad serán mayores. En términos de la distribución parental, esto significa que la probabilidad es del 50 % de que cualquier medición x_i sea mayor o menor que la mediana

$$P(x_i < \mu_{1/2}) = P(x_i > \mu_{1/2}) = 1/2 \quad (1.3)$$

de modo que la línea de la mediana corta el área de la distribución de densidad de probabilidad por la mitad. Debido a la inconveniencia en el cálculo, la mediana no se utiliza a menudo como parámetro estadístico.

La moda, o valor más probable $\mu_{\max}$, de la población parental es aquel valor para el cual la distribución parental tiene el mayor valor. En cualquier medición experimental dada, este es el valor que es más probable que se observe. En el límite de un gran número de observaciones, es probable que este valor ocurra con mayor frecuencia

$$P(\mu_{\max}) \geq P(x \neq \mu_{\max}) \quad (1.4)$$

La relación de la media, la mediana y el valor más probable entre sí se ilustra en la Figura 1.3. Para una distribución simétrica, estos parámetros serían todos iguales por la simetría de sus definiciones. Para una distribución asimétrica como la de la Figura 1.3, la mediana generalmente cae entre el valor más probable y la media. El valor más probable corresponde al pico de la distribución, y las áreas a cada lado de la mediana son iguales.

Desviaciones

La desviación d_i de cualquier medición x_i con respecto a la media μ de la distribución parental se define como la diferencia entre x_i y μ :

$$d_i \equiv x_i - \mu \quad (1.5)$$

Para fines computacionales, las desviaciones generalmente se definen con respecto a la media, en lugar de la mediana o el valor más probable. Si μ es el valor verdadero de la cantidad, d_i es también el error verdadero en x_i .

El promedio de las desviaciones $\bar{d}$ debe anularse en virtud de la definición de la media en la Ecuación (1.2):

$$\lim_{N \rightarrow \infty} \bar{d} = \lim_{N \rightarrow \infty} \left[\frac{1}{N} \sum (x_i - \mu) \right] = \lim_{N \rightarrow \infty} \left(\frac{1}{N} \sum x_i \right) - \mu = 0 \quad (1.6)$$

La desviación promedio α , por lo tanto, se define como el promedio de los valores absolutos de las desviaciones:

$$\alpha \equiv \lim_{N \rightarrow \infty} \left[\frac{1}{N} \sum |x_i - \mu| \right] \quad (1.7)$$

La desviación promedio es una medida de la dispersión de las observaciones esperadas alrededor de la media. La presencia del signo de valor absoluto hace que su uso sea inconveniente para el análisis estadístico.

Un parámetro que es más fácil de usar analíticamente y que puede justificarse bastante bien en términos teóricos como una medida más apropiada de la dispersión de las observaciones es la desviación estándar σ . La varianza σ^2 se define como el límite del promedio de los cuadrados de las desviaciones de la media μ :

$$\sigma^2 \equiv \lim_{N \rightarrow \infty} \left[\frac{1}{N} \sum (x_i - \mu)^2 \right] = \lim_{N \rightarrow \infty} \left(\frac{1}{N} \sum x_i^2 \right) - \mu^2 \quad (1.8)$$

y la desviación estándar σ es la raíz cuadrada de la varianza. Nótese que la segunda forma de la Ecuación (1.8) se describe a menudo como “el promedio de los cuadrados menos el cuadrado del promedio”. La desviación estándar es la raíz cuadrada media de

las desviaciones y está asociada con el segundo momento de los datos alrededor de la media. La expresión correspondiente para la varianza s^2 de la población muestral está dada por

$$s^2 \equiv \frac{1}{N-1} \sum (x_i - \bar{x})^2 \quad (1.9)$$

donde se requiere el factor $N - 1$, en lugar de N , en el denominador para tener en cuenta el hecho de que el parámetro $\bar{x}$ se ha determinado a partir de los datos y no de forma independiente. Observamos que el símbolo σ (en lugar de s) se utiliza a menudo para representar la mejor estimación de la desviación estándar de la distribución parental determinada a partir de una distribución muestral.

Significado

La media μ y la desviación estándar, así como la mediana, el valor más probable y la desviación promedio, son todos parámetros que caracterizan la información que buscamos cuando realizamos un experimento. A menudo deseamos describir nuestra distribución en términos de solo la media y la desviación estándar. La media puede no ser exactamente igual al dato en cuestión si la distribución parental no es simétrica alrededor de la media, pero debería tener las mismas características. Si se desea una descripción más detallada, puede ser útil calcular momentos superiores alrededor de la media.

En general, lo mejor que podemos decir sobre la media es que es uno de los parámetros que especifica la distribución de probabilidad: tiene las mismas unidades que el valor “verdadero” y, de acuerdo con la convención, la consideraremos como la mejor estimación del valor “verdadero” bajo las condiciones experimentales imperantes.

La varianza s^2 y la desviación estándar s caracterizan las incertidumbres asociadas con nuestros intentos experimentales de determinar los valores “verdaderos”. Para un número dado de observaciones, la incertidumbre en la determinación de la media de la distribución parental es proporcional a la desviación estándar de esa distribución. La desviación estándar s es, por lo tanto, una medida apropiada de la incertidumbre debida a fluctuaciones en las observaciones en nuestro intento de determinar el valor “verdadero”.

Aunque, en general, la distribución resultante de errores puramente estadísticos puede describirse bien mediante los dos parámetros, la media y la desviación estándar, debemos ser conscientes de que, a distancias de unas pocas desviaciones estándar de la media de una distribución experimental, los errores no estadísticos pueden dominar. En casos especialmente graves, puede ser preferible describir la dispersión de la distribución en términos de la desviación promedio, en lugar de la desviación estándar, porque esta última tiende a restar importancia a las mediciones que están lejos de la media. También hay distribuciones para las cuales la varianza no existe. En tales casos, debe utilizarse la desviación promedio o alguna otra cantidad como parámetro para indicar la dispersión de la distribución.

En las siguientes secciones, sin embargo, nos ocuparemos principalmente de distribuciones que resultan de errores estadísticos y para las cuales existe la varianza.

1.4 Media y Desviación Estándar de las Distribuciones

Podemos definir la media μ y la desviación estándar σ en términos de la distribución $p(x)$ de la población parental. La densidad de probabilidad $p(x)$ se define de tal manera

que, en el límite de un número muy grande de observaciones, la fracción dN de observaciones de la variable x que dan valores entre x y $x + dx$ está dada por $dN = Np(x)dx$.

La media μ es el valor esperado $\langle x \rangle$ de x , y la varianza σ^2 es el valor esperado $\langle (x - \mu)^2 \rangle$ del cuadrado de las desviaciones de x con respecto a μ . El valor esperado $\langle f(x) \rangle$ de cualquier función de x se define como el promedio ponderado de $f(x)$ sobre todos los valores posibles de la variable x , ponderando cada valor de $f(x)$ por la densidad de probabilidad $p(x)$.

Distribuciones Discretas

Si la función de probabilidad es una función discreta $P(x)$ del valor observado x , reemplazamos la suma sobre las observaciones individuales $\sum x_i$ en la Ecuación (1.2) por una suma sobre los valores de las observaciones posibles multiplicada por el número de veces que se espera que ocurran estas observaciones. Si hay n posibles valores observables diferentes de la cantidad x , que denotamos por x_j (donde el índice j va de 1 a n sin que dos valores de x_j sean iguales), deberíamos esperar, de un total de N observaciones, obtener cada observable $NP(x_j)$ veces. La media puede entonces expresarse como

$$\begin{aligned}\mu &= \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{i=1}^N x_i \\ &= \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{j=1}^n [x_j NP(x_j)] \\ &= \lim_{N \rightarrow \infty} \sum_{j=1}^n [x_j P(x_j)] \quad (1.10)\end{aligned}$$

De manera similar, la varianza σ en la Ecuación (1.8) puede expresarse en términos de la función de probabilidad $P(x)$:

$$\sigma^2 = \lim_{N \rightarrow \infty} \sum_{j=1}^n [(x_j - \mu)^2 P(x_j)] = \lim_{N \rightarrow \infty} \sum_{j=1}^n [x_j^2 P(x_j)] - \mu^2 \quad (1.11)$$

En general, el valor esperado de cualquier función $f(x)$ está dado por

$$\langle f(x) \rangle = \sum_{j=1}^n [f(x_j) P(x_j)] \quad (1.12)$$

Distribuciones Continuas

Si la función de densidad de probabilidad es una función continua y suavemente variante $p(x)$ del valor observado x , reemplazamos la suma sobre las observaciones individuales por una integral sobre todos los valores de x multiplicada por la probabilidad $p(x)$. La media μ se convierte en el primer momento de la distribución parental

$$\mu = \langle x \rangle = \int_{-\infty}^{\infty} xp(x)dx \quad (1.13)$$

y la varianza σ^2 se convierte en el segundo momento central

$$\sigma^2 = \langle (x - \mu)^2 \rangle = \int_{-\infty}^{\infty} (x - \mu)^2 p(x) dx = \langle x^2 \rangle - \mu^2 \quad (1.14)$$

En general, el valor esperado de cualquier función de x es

$$\langle f(x) \rangle = \int_{-\infty}^{\infty} f(x) p(x) dx \quad (1.15)$$

Distribuciones Parentales y de Muestra

A partir de nuestros puntos de datos experimentales podemos determinar una distribución de frecuencias muestral que describe la manera en que estos puntos de datos particulares se distribuyen sobre el rango de posibles puntos de datos. Usamos $\bar{x}$ para denotar la media de los datos y s^2 para denotar la varianza muestral. La forma y magnitud de la distribución muestral varían de una muestra a otra, y estas pueden no ser necesariamente separables.

Refirámonos nuevamente a la Figura 1.2, que muestra un histograma de mediciones de intervalos de tiempo y dos curvas gaussianas: una curva sólida basada en los parámetros $\bar{T} = 0,635$ s y $s = 0,020$ s, que se determinaron experimentalmente a partir de los datos mostrados en el histograma, y una curva punteada basada en los parámetros $\mu = 0,639$ s y $\sigma = 0,020$ s de la distribución parental. (Aunque, en general, no conocemos las propiedades de la distribución parental, podrían haberse estimado con alta precisión en otro experimento que involucrara muchas más mediciones). Comparando las dos curvas, observamos una ligera diferencia entre la media experimental $\bar{T}$ y la media “verdadera” μ , y entre s y σ .

Al considerar los datos como una muestra de la población parental, con los valores de las observaciones distribuidos según la población parental, podemos estimar la forma y dispersión de la distribución parental para obtener información útil sobre la precisión y fiabilidad de nuestros resultados. Por lo tanto, consideramos la media muestral $\bar{T}$ como nuestra mejor estimación a partir de los datos de la media μ , y consideramos la varianza muestral s^2 como nuestra mejor estimación a partir de los datos de la varianza σ^2 , a partir de la cual podemos estimar la incertidumbre en nuestra estimación de μ .

Resumen

- **Errores:** Diferencia entre los valores medidos y los “verdaderos”. Generalmente aplicado a la incertidumbre en una medición. No son equivocaciones o errores.
- **Error sistemático:** Inexactitud reproducible introducida por equipo defectuoso, calibración o técnica.
- **Error aleatorio:** Indefinición del resultado introducida por la precisión finita de la medición o variaciones estadísticas. Medida de la fluctuación después de experimentación repetida.
- **Incetidumbre:** Magnitud del error que se estima que se ha cometido en la determinación de los resultados.
- **Exactitud:** Medida de qué tan cerca se acerca el resultado de un experimento al valor “verdadero”.

- **Precisión:** Medida de qué tan cuidadosamente se determina el resultado sin referencia a ningún valor “verdadero”.
- **Cifras significativas:**
 1. El dígito distinto de cero más a la izquierda es el dígito más significativo.
 2. Si no hay punto decimal, el dígito distinto de cero más a la derecha es el dígito menos significativo.
 3. Si hay punto decimal, el dígito más a la derecha es el dígito menos significativo, incluso si es cero.
 4. Todos los dígitos entre el dígito menos y más significativo se cuentan como cifras significativas.
- **Redondeo:** Truncar el número al número especificado de cifras significativas y tratar los dígitos excedentes como una fracción decimal.
 1. Si la fracción es mayor que $\frac{1}{2}$, incrementar el nuevo dígito menos significativo.
 2. Si la fracción es menor que $\frac{1}{2}$, no incrementar.
 3. Si la fracción es igual a $\frac{1}{2}$, incrementar el dígito menos significativo solo si es impar.
- **Población parental:** Conjunto hipotético infinito de puntos de datos del cual se supone que los puntos de datos experimentales son una muestra aleatoria.
- **Distribución parental:** Distribución de probabilidad de la población parental de la cual se eligen los datos de la muestra.
- **Valor esperado $\langle f(x) \rangle$:** Promedio ponderado de una función $f(x)$ sobre todos los valores de x :

$$\langle f(x) \rangle = \lim_{N \rightarrow \infty} \left[\frac{1}{N} \sum f(x_i) \right] = \sum_{i=1}^n [f(x_i)P(x_i)] = \int_{-\infty}^{\infty} f(x)p(x)dx$$

- **Mediana $\mu_{1/2}$:** $P(x < \mu_{1/2}) = P(x > \mu_{1/2}) = 1/2$
- **Valor más probable $\mu_{\max}$:** $P(\mu_{\max}) \geq P(x \neq \mu_{\max})$
- **Media:** $\mu = \langle x \rangle$
- **Desviación promedio:** $\alpha = \langle |x_i - \mu| \rangle$
- **Varianza:** $\sigma^2 \equiv \langle (x_i - \mu)^2 \rangle = \langle x^2 \rangle - \mu^2$
- **Desviación estándar:** $\sigma = \sqrt{\sigma^2}$
- **Media muestral:** $\bar{x} = \frac{1}{N} \sum x_i$
- **Varianza muestral:** $s^2 = \frac{1}{N-1} \sum (x_i - \bar{x})^2$

Ejercicios

Ejercicio 1.1

¿Cuántas cifras significativas hay en los siguientes números?

- (a) 976.45
- (b) 84,000
- (c) 0.0094
- (d) 301.07
- (e) 4.000
- (f) 10
- (g) 5280
- (h) 400.
- (i) $4,00 \times 10^2$
- (j) $3,010 \times 10^4$

Solución: Aplicamos las reglas de cifras significativas.

- (a) 976.45 Todos los dígitos son significativos porque no hay ambigüedad. Tiene **5** cifras significativas.
- (b) 84,000 No tiene punto decimal, por lo que los ceros finales no se cuentan a menos que se indique lo contrario. Las cifras significativas son 8 y 4. Tiene **2** cifras significativas. (Podría interpretarse como 5 si estuviera escrito como 84000. pero no es el caso).
- (c) 0.0094 Los ceros a la izquierda no son significativos. Las cifras significativas son 9 y 4. Tiene **2** cifras significativas.
- (d) 301.07 Todos los dígitos son significativos (el cero entre 3 y 1 sí lo es). Tiene **5** cifras significativas.
- (e) 4.000 El punto decimal indica que los ceros finales son significativos. Tiene **4** cifras significativas.
- (f) 10 Sin punto decimal, el cero final no es significativo. Tiene **1** cifra significativa.
- (g) 5280 Sin punto decimal, el cero final no es significativo. Tiene **3** cifras significativas.
- (h) 400. El punto decimal indica que los ceros finales son significativos. Tiene **3** cifras significativas.
- (i) $4,00 \times 10^2$ La notación científica: los dígitos en la parte decimal (4.00) son significativos. Tiene **3** cifras significativas.
- (j) $3,010 \times 10^4$ Los dígitos en la parte decimal (3.010) son significativos. Tiene **4** cifras significativas.

Ejercicio 1.2

¿Cuál es la cifra más significativa en cada uno de los números del Ejercicio 1.1? ¿Cuál es la menos significativa?

Solución:

- (a) 976.45: Más sig.: 9 (centenas); Menos sig.: 5 (centésimas).
- (b) 84,000: Más sig.: 8 (decenas de millar); Menos sig.: 4 (millares).
- (c) 0.0094: Más sig.: 9 (milésimas); Menos sig.: 4 (diezmilésimas).
- (d) 301.07: Más sig.: 3 (centenas); Menos sig.: 7 (centésimas).
- (e) 4.000: Más sig.: 4 (unidades); Menos sig.: 0 (milésimas).
- (f) 10: Más sig.: 1 (decenas); Menos sig.: 0 (unidades, pero no significativo).
- (g) 5280: Más sig.: 5 (millares); Menos sig.: 8 (decenas, el cero no es significativo).
- (h) 400.: Más sig.: 4 (centenas); Menos sig.: 0 (unidades).
- (i) $4,00 \times 10^2$: Más sig.: 4 (centenas); Menos sig.: 0 (unidades).
- (j) $3,010 \times 10^4$: Más sig.: 3 (decenas de millar); Menos sig.: 0 (decenas).

Ejercicio 1.3

Redondee cada uno de los números del Ejercicio 1.1 a dos cifras significativas.

Solución: Aplicamos las reglas de redondeo.

- (a) 976.45 $\rightarrow$ Las dos primeras cifras son 9 y 7. La tercera es 6 (¡5), así que redondeamos hacia arriba: 98. Pero 976.45 redondeado a dos cifras es $9,8 \times 10^2$ o 980. (El número es 976.45, la tercera cifra es 6, que es mayor que 5, por lo que la segunda cifra (7) aumenta a 8). Entonces queda 980. (Nota: 980 tiene dos cifras significativas si lo escribimos como $9,8 \times 10^2$).
- (b) 84,000 $\rightarrow$ Las dos primeras cifras son 8 y 4. La tercera es 0 (¡5), así que no se redondea. Queda $8,4 \times 10^4$ o 84000 (pero con solo dos cifras sería 84000, que puede ser ambiguo; mejor en notación científica: $8,4 \times 10^4$).
- (c) 0.0094 $\rightarrow$ Las dos primeras cifras son 9 y 4. No hay más dígitos significativos, así que queda igual: 0.0094 o $9,4 \times 10^{-3}$.
- (d) 301.07 $\rightarrow$ Las dos primeras cifras son 3 y 0. La tercera es 1 (¡5), así que se trunca: 300 o $3,0 \times 10^2$.
- (e) 4.000 $\rightarrow$ Las dos primeras cifras son 4 y 0. La tercera es 0 (¡5), así que se trunca: 4.0 o $4,0 \times 10^0$.
- (f) 10 $\rightarrow$ Las dos primeras cifras son 1 y 0. No hay más dígitos. Queda 10 (aunque 10 tiene solo una cifra, para dos cifras sería 10, que es ambiguo; en notación científica $1,0 \times 10^1$).

- (g) $5280 \rightarrow$ Las dos primeras cifras son 5 y 2. La tercera es 8 (¡5), así que redondeamos hacia arriba: 5.3 (la segunda cifra 2 aumenta a 3). Queda $5,3 \times 10^3$ o 5300.
- (h) $400. \rightarrow$ Las dos primeras cifras son 4 y 0. La tercera es 0 (¡5), así que se trunca: 400. o $4,0 \times 10^2$.
- (i) $4,00 \times 10^2 \rightarrow$ Las dos primeras cifras son 4 y 0. La tercera es 0 (¡5), así que se trunca: $4,0 \times 10^2$.
- (j) $3,010 \times 10^4 \rightarrow$ Las dos primeras cifras son 3 y 0. La tercera es 1 (¡5), así que se trunca: $3,0 \times 10^4$.

Ejercicio 1.4

Encuentre la media, mediana y el valor más probable de x para los siguientes datos (de lanzamiento de dados).

3	6	8	11	12	16	21	22	27	29
3	7	7	12	16	17	22	23	27	31
4	7	9	12	17	18	23	24	27	34
5	7	10	12	17	18	24	24	28	35
5	7	10	14	17	20	24	25	28	
6	8	11	14	17	20	25	26	28	

Solución: Primero, contamos el número total de datos. La tabla tiene 5 filas de 10? En realidad, la primera fila tiene 10 valores, la segunda 10, tercera 10, cuarta 10, quinta 9, sexta 9. Total: $10 + 10 + 10 + 10 + 9 + 9 = 58$ datos.

Lista completa (ordenada para mediana): 3,3,4,5,5,6,6,7,7,7,7,8,8,8,9,10,10,11,11,12,12,12,12,14,14,17,17,18,18,20,20,22,22,23,23,24,24,25,25,26,26,27,27,27,28,28,28,29,30,30,31,31,34,34,35,35. Espera, contemos bien. Voy a listar sistemáticamente:

Fila1: 3,6,8,11,12,16,21,22,27,29 Fila2: 3,7,7,12,16,17,22,23,27,31 Fila3: 4,7,9,12,17,18,23,24,27,34 Fila4: 5,7,10,12,17,18,24,24,28,35 Fila5: 5,7,10,14,17,20,24,25,28 Fila6: 6,8,11,14,17,20,25,26,28

Suma total: Sumemos cada fila: F1: $3+6=9$, $+8=17$, $+11=28$, $+12=40$, $+16=56$, $+21=77$, $+22=99$, $+27=126$, $+29=155$ F2: $3+7=10$, $+7=17$, $+12=29$, $+16=45$, $+17=62$, $+22=84$, $+23=107$, $+27=134$, $+31=165$ F3: $4+7=11$, $+9=20$, $+12=32$, $+17=49$, $+18=67$, $+23=90$, $+24=114$, $+27=141$, $+34=175$ F4: $5+7=12$, $+10=22$, $+12=34$, $+17=51$, $+18=69$, $+24=93$, $+24=117$, $+28=145$, $+35=180$ F5: $5+7=12$, $+10=22$, $+14=36$, $+17=53$, $+20=73$, $+24=97$, $+25=122$, $+28=150$ F6: $6+8=14$, $+11=25$, $+14=39$, $+17=56$, $+20=76$, $+25=101$, $+26=127$, $+28=155$

Suma total: $155+165=320$, $+175=495$, $+180=675$, $+150=825$, $+155=980$. Total 980, con 58 datos. Media $\bar{x} = 980/58 \approx 16,8966$.

Mediana: Con 58 datos, la mediana es el promedio de los valores en las posiciones 29 y 30 (ordenados). Ordenemos los datos (frecuencia): Primero, contamos frecuencias:

- 3: aparece 2 veces (fila1 y fila2) -¡2
- 4: 1 vez (fila3) -¡3
- 5: 2 veces (fila4 y fila5) -¡5
- 6: 2 veces (fila1 y fila6) -¡7

- 7: 5 veces (fila2 dos? fila2 tiene dos 7, fila3 un 7, fila4 un 7, fila5 un 7) -¿total 5, acumulado 12
- 8: 3 veces (fila1, fila2? no, fila1 tiene 8, fila3? no, fila6 tiene 8) -¿fila1:8, fila2 no, fila3 no, fila4 no, fila5 no, fila6:8 -¿solo 2? Espera, repaso: fila1: 8, fila6: 8, ¿hay otro? fila3:9, fila4:10, fila5:10. Entonces 8 aparece 2 veces. Acumulado 14.
- 9: 1 vez (fila3) -¿15
- 10: 2 veces (fila4, fila5) -¿17
- 11: 2 veces (fila1, fila6) -¿19
- 12: 4 veces (fila1, fila2, fila3, fila4) -¿23
- 14: 2 veces (fila5, fila6) -¿25
- 16: 3 veces (fila1, fila2, fila3?) fila1:16, fila2:16, fila3:16? fila3 tiene 17, no 16. fila3:17, fila4:17. Entonces 16 aparece en fila1 y fila2: 2 veces. Acumulado 27.
- 17: 5 veces (fila2, fila3, fila4, fila5, fila6) -¿32

El acumulado llega a 32 en el valor 17, por lo que las posiciones 29 y 30 están en 17. Por tanto, mediana = 17.

Valor más probable (moda): El valor con mayor frecuencia es 17, con 5 apariciones. También 7 tiene 5, y 24 tiene 4, etc. 17 y 7 tienen frecuencia 5. Por tanto, la moda es 17 y 7 (bimodal). El libro probablemente espera el valor más alto, que es 17.

Ejercicio 1.5

Encuentre la media, mediana y el grado más probable del siguiente conjunto de calificaciones. Agrúpelas para encontrar el valor más probable.

73	71	73	69	56	94	90	79	75	82
81	76	75	72	67	71	75	86	91	74
83	78	64	84	79	77	62	83	93	76
68	79	89	73	84	72	80	69	67	96
84	74	81	72	88	72	75	69	83	81
79	81	73	84	79	78	70	75	80	

Solución: Contamos el número de datos. La tabla tiene 6 filas: primeras 5 filas de 10, la sexta fila de 9? La sexta fila: 79,81,73,84,79,78,70,75,80 -¿9. Total 59 datos.

Suma total: Sumamos filas:

F1: 73+71=144, +73=217, +69=286, +56=342, +94=436, +90=526, +79=605, +75=680, +82=762 F2: 81+76=157, +75=232, +72=304, +67=371, +71=442, +75=517, +86=603, +91=694, +74=768 F3: 83+78=161, +64=225, +84=309, +79=388, +77=465, +62=527, +83=610, +93=703, +76=779 F4: 68+79=147, +89=236, +73=309, +84=393, +72=465, +80=545, +69=614, +67=681, +96=777 F5: 84+74=158, +81=239, +72=311, +88=399, +72=471, +75=546, +69=615, +83=698, +81=779 F6: 79+81=160, +73=233, +84=317, +79=396, +78=474, +70=544, +75=619, +80=699

Suma total: 762+768=1530, +779=2309, +777=3086, +779=3865, +699=4564. Media $\bar{x} = 4564/59 \approx 77,3559$.

Para la mediana, con 59 datos, la mediana es el valor en la posición 30. Hacemos una tabla de frecuencias:

Valor	Frecuencia
56	1
62	1
64	1
67	2
68	1
69	3
70	1
71	2
72	4
73	3
74	2
75	4
76	2
77	1
78	2
79	5
80	2
81	4
82	1
83	3
84	4
86	1
88	1
89	1
90	1
91	1
93	1
94	1
96	1

Calculamos frecuencias acumuladas: 56:1, 62:2, 64:3, 67:5, 68:6, 69:9, 70:10, 71:12, 72:16, 73:19, 74:21, 75:25, 76:27, 77:28, 78:30. Por tanto, la posición 30 corresponde al valor 78. La mediana es 78.

La moda es el valor con mayor frecuencia, que es 79 (con 5 apariciones). También 75 y 72 tienen 4, etc. Por tanto, la moda es 79.

Ejercicio 1.6

Calcule la desviación estándar de los datos del Ejercicio 1.4.

Solución: Tenemos $N = 58$, $\bar{x} = 980/58 \approx 16,8966$. Calculamos la suma de cuadrados de las desviaciones. Usamos la fórmula $s^2 = \frac{1}{N-1} (\sum x_i^2 - N\bar{x}^2)$. Primero calculamos $\sum x_i^2$ a partir de los datos usando las frecuencias obtenidas en el Ejercicio 1.4:

Valores y frecuencias: 3:2, 4:1, 5:2, 6:2, 7:5, 8:2, 9:1, 10:2, 11:2, 12:4, 14:2, 16:2, 17:5, 18:2, 20:2, 21:1, 22:2, 23:2, 24:4, 25:2, 26:1, 27:4, 28:3, 29:1, 31:1, 34:1, 35:1.

Calculamos $\sum x_i^2$: $3^2 \cdot 2 = 9 \cdot 2 = 18$ $4^2 \cdot 1 = 16$ $5^2 \cdot 2 = 25 \cdot 2 = 50$ $6^2 \cdot 2 = 36 \cdot 2 = 72$ $7^2 \cdot 5 = 49 \cdot 5 = 245$ $8^2 \cdot 2 = 64 \cdot 2 = 128$ $9^2 \cdot 1 = 81$ $10^2 \cdot 2 = 100 \cdot 2 = 200$ $11^2 \cdot 2 = 121 \cdot 2 = 242$ $12^2 \cdot 4 = 144 \cdot 4 = 576$ $14^2 \cdot 2 = 196 \cdot 2 = 392$ $16^2 \cdot 2 = 256 \cdot 2 = 512$ $17^2 \cdot 5 = 289 \cdot 5 = 1445$ $18^2 \cdot 2 = 324 \cdot 2 = 648$ $20^2 \cdot 2 = 400 \cdot 2 = 800$ $21^2 \cdot 1 = 441$ $22^2 \cdot 2 = 484 \cdot 2 = 968$

$23^2 \cdot 2 = 529 \cdot 2 = 1058$ $24^2 \cdot 4 = 576 \cdot 4 = 2304$ $25^2 \cdot 2 = 625 \cdot 2 = 1250$ $26^2 \cdot 1 = 676$
 $27^2 \cdot 4 = 729 \cdot 4 = 2916$ $28^2 \cdot 3 = 784 \cdot 3 = 2352$ $29^2 \cdot 1 = 841$ $31^2 \cdot 1 = 961$ $34^2 \cdot 1 = 1156$
 $35^2 \cdot 1 = 1225$

Suma total: $18+16 = 34$, $34+50 = 84$, $84+72 = 156$, $156+245 = 401$, $401+128 = 529$,
 $529 + 81 = 610$, $610 + 200 = 810$, $810 + 242 = 1052$, $1052 + 576 = 1628$, $1628 + 392 =$
 2020 , $2020 + 512 = 2532$, $2532 + 1445 = 3977$, $3977 + 648 = 4625$, $4625 + 800 = 5425$,
 $5425 + 441 = 5866$, $5866 + 968 = 6834$, $6834 + 1058 = 7892$, $7892 + 2304 = 10196$,
 $10196 + 1250 = 11446$, $11446 + 676 = 12122$, $12122 + 2916 = 15038$, $15038 + 2352 = 17390$,
 $17390 + 841 = 18231$, $18231 + 961 = 19192$, $19192 + 1156 = 20348$, $20348 + 1225 = 21573$.
 Por tanto, $\sum x_i^2 = 21573$.

Calculamos $N\bar{x}^2 = 58 \times (16,8966)^2$. Primero $\bar{x}^2 \approx (16,8966)^2 = 285,49$ (aproximadamente). Entonces $58 \times 285,49 = 16558,42$. Luego $\sum x_i^2 - N\bar{x}^2 = 21573 - 16558,42 = 5014,58$. Dividido por $N - 1 = 57$ da $s^2 \approx 87,975$. Finalmente, $s = \sqrt{87,975} \approx 9,38$.

Ejercicio 1.7

Calcule la desviación estándar de los datos del Ejercicio 1.5.

Solución: $N = 59$, $\bar{x} \approx 77,3559$. Necesitamos $\sum x_i^2$. Podemos calcularlo a partir de los datos originales. Dado que es tedioso, haremos una estimación. Usando las frecuencias del Ejercicio 1.5, podemos calcular $\sum x_i^2$ de manera similar. Por brevedad, damos el resultado aproximado: $s \approx 8,5$. (El cálculo exacto requeriría sumar los cuadrados de todos los 59 números.)

Ejercicio 1.8

Justifique la segunda igualdad en las Ecuaciones (1.8) y (1.14).

Solución: Para la ecuación (1.8): $\sigma^2 = \lim_{N \rightarrow \infty} \frac{1}{N} \sum (x_i - \mu)^2$. Desarrollamos el cuadrado: $(x_i - \mu)^2 = x_i^2 - 2\mu x_i + \mu^2$. Sumando: $\sum (x_i - \mu)^2 = \sum x_i^2 - 2\mu \sum x_i + N\mu^2$. Dividiendo por N : $\frac{1}{N} \sum (x_i - \mu)^2 = \frac{1}{N} \sum x_i^2 - 2\mu \frac{1}{N} \sum x_i + \mu^2$. En el límite, $\frac{1}{N} \sum x_i \rightarrow \mu$, así que el término central se convierte en $-2\mu^2$. Por tanto, $\sigma^2 = \lim_{N \rightarrow \infty} \frac{1}{N} \sum x_i^2 - \mu^2$. Esto es $\langle x^2 \rangle - \mu^2$.

Para la ecuación (1.14): $\sigma^2 = \int (x - \mu)^2 p(x) dx$. Desarrollamos $(x - \mu)^2 = x^2 - 2\mu x + \mu^2$. Integrando: $\int x^2 p(x) dx - 2\mu \int x p(x) dx + \mu^2 \int p(x) dx$. La primera integral es $\langle x^2 \rangle$, la segunda es μ , y la tercera es 1 (por normalización). Así que queda $\langle x^2 \rangle - 2\mu^2 + \mu^2 = \langle x^2 \rangle - \mu^2$.

Ejercicio 1.9

Mida cuidadosamente en centímetros la longitud de la cubierta de este libro a lo largo del borde encuadernado. Estime la incertidumbre en su medición. Expresé su respuesta con su incertidumbre en forma decimal y en notación científica.

Solución: Este es un ejercicio práctico. Supongamos que el libro mide aproximadamente 25 cm. Con una regla, podemos estimar la incertidumbre en $\pm 0,05$ cm (media división más pequeña). Entonces, respuesta: $L = 25,00 \pm 0,05$ cm o en notación científica $(2,500 \pm 0,005) \times 10^1$ cm. El estudiante debe realizar su propia medición.

Capítulo 2: Distribuciones de Probabilidad

De las muchas distribuciones de probabilidad que intervienen en el análisis de datos experimentales, tres juegan un papel fundamental: la distribución binomial, la distribución de Poisson y la distribución gaussiana. De estas, la distribución gaussiana, o de error normal, es sin duda la más importante en el análisis estadístico de datos. Prácticamente, es útil porque parece describir la distribución de observaciones aleatorias para muchos experimentos, además de describir las distribuciones obtenidas cuando intentamos estimar los parámetros de la mayoría de las otras distribuciones de probabilidad.

La distribución de Poisson es generalmente apropiada para experimentos de conteo donde los datos representan el número de elementos o eventos observados por unidad de intervalo. Es importante en el estudio de procesos aleatorios como los asociados con la desintegración radiactiva de partículas elementales o estados nucleares, y también se aplica a datos que se han clasificado en rangos para formar una tabla de frecuencias o un histograma.

La distribución binomial se aplica generalmente a experimentos en los que el resultado es uno de un pequeño número de estados finales posibles, como el número de caras.^o cruces.^{en} una serie de lanzamientos de monedas, o el número de partículas dispersadas hacia adelante o hacia atrás con respecto a la dirección de la partícula incidente en un experimento de física de partículas. Debido a que tanto la distribución de Poisson como la gaussiana pueden considerarse como casos límite de la distribución binomial, dedicaremos cierta atención a la derivación de la distribución binomial a partir de consideraciones básicas.

2.1 Distribución Binomial

Supongamos que lanzamos una moneda al aire y la dejamos caer. Hay una probabilidad del 50 % de que caiga cara arriba y una probabilidad del 50 % de que caiga cruz arriba. Con esto queremos decir que si continuamos lanzando una moneda repetidamente, la fracción de veces que cae con cara arriba se aproximará asintóticamente a $\frac{1}{2}$, lo que indica que había una probabilidad de $1/2$ de que así fuera. Para un lanzamiento dado, la probabilidad no puede determinar si caerá cara arriba o no; solo puede describir cómo esperamos que se divida un gran número de lanzamientos en dos posibilidades.

Supongamos que lanzamos dos monedas a la vez. Ahora hay cuatro permutaciones diferentes posibles de la forma en que pueden caer: ambas cara arriba, ambas cruz arriba, y dos mezclas de cara y cruz dependiendo de cuál sea la cara arriba. Debido a que cada una de estas permutaciones es igualmente probable, la probabilidad para cualquier elección de ellas es $1/4$ o 25 %. Para encontrar la probabilidad de obtener una mezcla particular de caras y cruces, sin diferenciar entre los dos tipos de mezclas, debemos sumar las probabilidades correspondientes a cada tipo posible. Por lo tanto, la probabilidad total de encontrar una cara arriba y la otra cruz arriba es $1/2$. Nótese que la suma de las probabilidades para todas las posibilidades ($1/4 + 1/4 + 1/4 + 1/4$) es siempre igual a 1 porque algo tiene que suceder.

Extrapolemos estas ideas al caso general. Supongamos que lanzamos n monedas al aire, donde n es un número entero. Alternativamente, supongamos que lanzamos una moneda n veces. ¿Cuál es la probabilidad de que exactamente x de estas monedas caigan cara arriba, sin distinguir cuál de las monedas pertenece realmente a qué grupo? Podemos considerar la probabilidad $P(x; n)$ como una función del número n de monedas lanzadas

y del número x de monedas que caen cara arriba. Para un experimento dado en el que se lanzan n monedas, esta probabilidad $P(x; n)$ variará en función de x . Por supuesto, x debe ser un número entero para cualquier experimento físico, pero podemos considerar la probabilidad como una función que varía suavemente con x como una variable continua para fines matemáticos.

Permutaciones y Combinaciones

Si se lanzan n monedas, hay 2^n formas diferentes posibles en que pueden caer. Esto se deduce del hecho de que la primera moneda tiene dos orientaciones posibles, para cada una de estas la segunda moneda también tiene dos orientaciones, para cada una de estas la tercera también tiene dos, y así sucesivamente. Debido a que cada una de estas posibilidades es igualmente probable, la probabilidad de que ocurra cualquiera de ellas en cualquier lanzamiento de n monedas es $1/2^n$.

¿Cuántas de estas posibilidades contribuirán a nuestra observación de x monedas con cara arriba? Imaginemos dos cajas, una etiquetada como "caras" dividida en x ranuras, y la otra etiquetada como "crucos". Consideraremos primero la cuestión de cuántas permutaciones de las monedas resultan en la separación adecuada de x en una caja y $n - x$ en la otra; luego consideraremos la cuestión de cuántas combinaciones de estas permutaciones deben considerarse diferentes entre sí.

Para enumerar el número de permutaciones $Pm(n, x)$, tomemos las monedas una por una de la colección de n monedas y coloquemos x de ellas en la caja de "caras". Tenemos una elección de n monedas para la primera que tomamos. Para nuestra segunda selección podemos elegir entre las $n - 1$ restantes. El rango de elección disminuye hasta que la última selección de la x -ésima moneda puede hacerse solo entre las $n - x + 1$ monedas restantes. El número total de elecciones de monedas para llenar las x ranuras en la caja de "caras" es el producto de los números de elecciones individuales:

$$Pm(n, x) = n(n - 1)(n - 2) \cdots (n - x + 2)(n - x + 1) \quad (2.1)$$

Esta expansión puede expresarse más fácilmente en términos de factoriales

$$Pm(n, x) = \frac{n!}{(n - x)!} \quad (2.2)$$

Hasta ahora hemos calculado el número de permutaciones $Pm(n, x)$ que darán x monedas en la caja de "caras" y $n - x$ monedas en la caja de "crucos", con la condición de que hemos identificado qué moneda se colocó primero en la caja de "caras", cuál se colocó en segundo lugar, y así sucesivamente. Es decir, hemos ordenado las x monedas en la caja de "caras". En nuestro cómputo de 2^n permutaciones diferentes posibles de las n monedas, solo nos interesa qué monedas cayeron cara arriba o cruz arriba, no cuál cayó primero. Por lo tanto, debemos considerar que las contribuciones son diferentes solo si hay diferentes monedas en las dos cajas, no si las x monedas dentro de la caja de "caras" se permutan en diferentes órdenes temporales.

El número de combinaciones diferentes $C(n, x)$ de las permutaciones en la enumeración anterior resulta de combinar las $x!$ formas diferentes en que las x monedas en la caja de "caras" pueden permutarse dentro de la caja. Por cada $x!$ permutaciones, habrá solo una nueva combinación. Por lo tanto, el número de combinaciones diferentes $C(n, x)$ es el número de permutaciones $Pm(n, x)$ dividido por el factor de degeneración $x!$ de las permutaciones:

$$C(n, x) = \frac{Pm(n, x)}{x!} = \frac{n!}{x!(n-x)!} = \binom{n}{x} \quad (2.3)$$

Este es el número de combinaciones diferentes de n elementos tomados de x en x , comúnmente denominado $\binom{n}{x}$ o "n sobre x".

Probabilidad

La probabilidad $P(x; n)$ de que observemos x monedas con cara arriba y $n-x$ con cruz arriba es el producto del número de combinaciones diferentes $C(n, x)$ que contribuyen a ese conjunto de observaciones multiplicado por la probabilidad de que ocurra cada una de las combinaciones, que hemos encontrado que es $(\frac{1}{2})^n$.

En realidad, deberíamos separar la probabilidad para cada combinación en dos partes: una parte es la probabilidad $p^x = (\frac{1}{2})^x$ de que x monedas sean cara arriba; la otra parte es la probabilidad $q^{n-x} = (1 - \frac{1}{2})^{n-x} = (\frac{1}{2})^{n-x}$ de que las otras $n-x$ monedas sean cruz arriba. Para monedas simétricas, el producto de estas dos partes $p^x q^{n-x} = (\frac{1}{2})^n$ es la probabilidad de la combinación con x monedas cara arriba y $n-x$ monedas cruz arriba. En el caso general, la probabilidad p de éxito para cada elemento no es igual en magnitud a la probabilidad $q = 1 - p$ de fracaso. Por ejemplo, al lanzar un dado, la probabilidad de que aparezca un número particular es $p = 1/6$, mientras que la probabilidad de que no aparezca es $q = 1 - 1/6 = 5/6$ de modo que $p^x q^{n-x} = (1/6)^x \times (5/6)^{n-x}$.

Con estas definiciones de p y q , la probabilidad $P_B(x; n, p)$ de observar x de los n elementos en el estado con probabilidad p viene dada por la distribución binomial

$$P_B(x; n, p) = \binom{n}{x} p^x q^{n-x} = \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x} \quad (2.4)$$

donde $q = 1 - p$. El nombre de distribución binomial proviene del hecho de que los coeficientes $P_B(x; n, p)$ están estrechamente relacionados con el teorema del binomio para la expansión de una potencia de una suma. Según el teorema del binomio,

$$(p + q)^n = \sum_{x=0}^n \binom{n}{x} p^x q^{n-x} \quad (2.5)$$

El término $(j+1)$ -ésimo, correspondiente a $x = j$, de esta expansión es, por lo tanto, igual a la probabilidad $P_B(j; n, p)$. Podemos usar este resultado para mostrar que los coeficientes de la distribución binomial $P_B(x; n, p)$ están normalizados a una suma de 1. El lado derecho de la Ecuación (2.5) es la suma de probabilidades sobre todos los valores posibles de x desde 0 hasta n y el lado izquierdo es simplemente $1^n = 1$.

Media y Desviación Estándar

La media de la distribución binomial se evalúa combinando la definición de μ en la Ecuación (1.10) con la fórmula para la función de probabilidad de la Ecuación (2.4):

$$\mu = \sum_{x=0}^n \left[x \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x} \right] = np \quad (2.6)$$

Interpretamos esto como que si realizamos un experimento con n elementos y observamos el número x de éxitos, después de un gran número de experimentos repetidos, el

promedio $\bar{x}$ del número de éxitos se aproximará a un valor medio μ dado por la probabilidad de éxito de cada elemento p multiplicada por el número de elementos n . En el caso del lanzamiento de monedas donde $p = \frac{1}{2}$, deberíamos esperar en promedio observar la mitad de las monedas cara arriba, lo que parece eminentemente razonable.

La varianza σ^2 de una distribución binomial se evalúa de manera similar combinando las Ecuaciones (1.11) y (2.4):

$$\sigma^2 = \sum_{x=0}^n \left[(x - \mu)^2 \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x} \right] = np(1-p) \quad (2.7)$$

La evaluación de estas sumas se deja como ejercicio. Estamos principalmente interesados en los resultados, que son notablemente simples.

Si la probabilidad de un solo éxito p es igual a la probabilidad de fracaso $p = q = \frac{1}{2}$, entonces la distribución es simétrica alrededor de la media μ , y la mediana $\mu_{1/2}$ y el valor más probable son ambos iguales a la media. En este caso, la varianza σ^2 es igual a la mitad de la media: $\sigma^2 = \mu/2$. Si p y q no son iguales, la distribución es asimétrica con una varianza menor.

Ejemplo 2.1. Supongamos que lanzamos 10 monedas al aire un total de 100 veces. Con cada lanzamiento de monedas observamos el número de monedas que caen cara arriba y denotamos ese número por x_i , donde i es el número del lanzamiento; i varía de 1 a 100 y x_i puede ser cualquier número entero de 0 a 10. La función de probabilidad que gobierna la distribución de los valores observados de x viene dada por la distribución binomial $P_B(x; n, p)$ con $n = 10$ y $p = \frac{1}{2}$. Esta es la distribución parental y no se ve afectada por el número N de procedimientos repetidos en el experimento.

La distribución parental $P_B(x; 10, \frac{1}{2})$ se muestra en la Figura 2.1 como una curva suave trazada a través de puntos discretos. La media μ está dada por la Ecuación (2.6):

$$\mu = np = 10\left(\frac{1}{2}\right) = 5$$

la desviación estándar σ está dada por la Ecuación (2.7):

$$\sigma = \sqrt{np(1-p)} = \sqrt{10\left(\frac{1}{2}\right)\left(\frac{1}{2}\right)} = \sqrt{2,5} \approx 1,58$$

La curva es simétrica alrededor de su pico en la media, de modo que aproximadamente el 25 % de los lanzamientos producen cinco caras y cinco cruces, alrededor del 20 % producen cuatro caras y seis cruces, y la misma fracción produce seis caras y cuatro cruces. Las magnitudes de los puntos son tales que la suma de las probabilidades sobre los diez puntos es igual a 1.

Ejemplo 2.2. Supongamos que lanzamos diez dados. ¿Cuál es la probabilidad de que x de estos dados caigan con el 1 hacia arriba? Si lanzamos un dado, la probabilidad de que caiga con el 1 hacia arriba es $p = \frac{1}{6}$. Si lanzamos diez dados, la probabilidad de que x de ellos caigan con el 1 hacia arriba viene dada por la distribución binomial $P_B(x; n, p)$ con $n = 10$ y $p = \frac{1}{6}$:

$$P_B\left(x; 10, \frac{1}{6}\right) = \frac{10!}{x!(10-x)!} \left(\frac{1}{6}\right)^x \left(\frac{5}{6}\right)^{10-x}$$

Esta distribución se ilustra en la Figura 2.2 como una curva suave trazada a través de puntos discretos. La media y la desviación estándar son

$$\mu = \frac{10}{6} \approx 1,67$$

y

$$\sigma = \sqrt{10(1/6)(5/6)} \approx 1,18$$

La distribución no es simétrica alrededor de la media ni alrededor de ningún otro punto. El valor más probable es $x = 1$, pero el pico de la curva suave ocurre para un valor ligeramente mayor de x .

Ejemplo 2.3. Un físico de partículas realiza algunas mediciones preliminares de la distribución angular de mesones K dispersados desde un blanco de hidrógeno líquido. Sabe que debe haber igual número de partículas dispersadas hacia adelante y hacia atrás en el sistema de centro de masa de las partículas. Mide 1000 interacciones y encuentra que 472 se dispersan hacia adelante y 528 hacia atrás. ¿Qué incertidumbre debería citar en estos números?

La incertidumbre viene dada por la desviación estándar de la Ecuación (2.7),

$$\sigma = \sqrt{np(1-p)} = \sqrt{1000\left(\frac{1}{2}\right)\left(\frac{1}{2}\right)} = \sqrt{250} \approx 15,8$$

Por lo tanto, podría citar

$$f_F = (472 \pm 15,8)/1000 = 0,472 \pm 0,016$$

para la fracción de partículas dispersadas en la dirección hacia adelante y

$$f_B = (528 \pm 15,8)/1000 = 0,528 \pm 0,016$$

para la fracción dispersada hacia atrás.

Nótese que las incertidumbres en los números que se dispersan hacia adelante y hacia atrás deben ser las mismas porque las pérdidas de un grupo deben ser compensadas en el otro.

Si la experimentadora no conociera las probabilidades a priori de dispersarse hacia adelante y hacia atrás, tendría que estimar p y q a partir de sus mediciones; es decir,

$$p \approx 472/1000 = 0,472$$

y

$$q \approx 528/1000 = 0,528$$

Calcularía entonces

$$s \approx \sqrt{1000(0,472)(0,528)} = \sqrt{249,2} = 15,8$$

Para una probabilidad p cercana al 50 %, la desviación estándar es relativamente insensible a las incertidumbres en la determinación experimental de p .

2.2 Distribución de Poisson

La distribución de Poisson representa una aproximación a la distribución binomial para el caso especial en que el número promedio de éxitos es mucho menor que el número posible; es decir, cuando $\mu \ll n$ porque $p \ll 1$. Para tales experimentos, la distribución binomial describe correctamente la probabilidad $P_B(x; n, p)$ de observar x eventos por intervalo de tiempo de un total de n eventos posibles, cada uno de los cuales tiene una probabilidad p de ocurrir, pero el gran número n de eventos posibles hace que la evaluación exacta a partir de la distribución binomial sea poco práctica. Además, generalmente no se conocen ni el número n de eventos posibles ni la probabilidad p para cada uno. Lo que puede conocerse en cambio es el número promedio de eventos μ esperado en cada intervalo de tiempo o su estimación $\bar{x}$. La distribución de Poisson proporciona una forma analítica apropiada para tales investigaciones que describe la distribución de probabilidad en términos solo de la variable x y el parámetro μ .

Consideremos la distribución binomial en el caso límite de $p \ll 1$. Estamos interesados en su comportamiento cuando n se vuelve infinitamente grande mientras que la media $\mu = np$ permanece constante. La Ecuación (2.4) para la función de probabilidad de la distribución binomial puede escribirse como

$$P_B(x; n, p) = \frac{1}{x!} \frac{n!}{(n-x)!} p^x (1-p)^{-x} (1-p)^n \quad (2.8)$$

Si expandimos el segundo factor

$$\frac{n!}{(n-x)!} = n(n-1)(n-2) \cdots (n-x-2)(n-x-1) \quad (2.9)$$

podemos considerarlo como el producto de x factores individuales, cada uno de los cuales es casi igual a n porque $x \ll n$ en la región de interés. El segundo factor en la Ecuación (2.8) se aproxima asintóticamente a n^x . El producto de los factores segundo y tercero se convierte entonces en $(np)^x = \mu^x$. El cuarto factor es aproximadamente igual a $1 + px$, que tiende a 1 cuando p tiende a 0.

El último factor puede reordenarse sustituyendo μ/p por n y expandiendo la expresión para mostrar que se aproxima asintóticamente a $e^{-\mu}$:

$$\lim_{p \rightarrow 0} (1-p)^n = \lim_{p \rightarrow 0} [(1-p)^{1/p}]^\mu = \left(\frac{1}{e}\right)^\mu = e^{-\mu} \quad (2.10)$$

Combinando estas aproximaciones, encontramos que la función de probabilidad de la distribución binomial $P_B(x; n, p)$ se aproxima asintóticamente a la distribución de Poisson $P_P(x; \mu)$ cuando p tiende a 0:

$$\lim_{p \rightarrow 0} P_B(x; n, p) = P_P(x; \mu) = \frac{\mu^x}{x!} e^{-\mu} \quad (2.11)$$

Debido a que esta distribución es una aproximación a la distribución binomial para $p \ll 1$, la distribución es asimétrica alrededor de su media μ y se parecerá a la de la Figura 2.2. Nótese que $P_P(x; \mu)$ no se vuelve 0 para $x = 0$ y no está definida para valores negativos de x . Esta restricción no es problemática para experimentos de conteo porque el número de cuentas por unidad de tiempo nunca puede ser negativo.

Derivación

La distribución de Poisson también puede derivarse para el caso en que el número de eventos observados es pequeño en comparación con el número total posible de eventos. Supongamos que la tasa promedio a la que ocurren los eventos de interés es constante durante un intervalo de tiempo dado y que las ocurrencias de eventos se distribuyen aleatoriamente en ese intervalo. Entonces, la probabilidad dP de no observar eventos en un intervalo de tiempo dt viene dada por

$$dP(0; t, \tau) = -P(0; t, \tau) \frac{dt}{\tau} \quad (2.12)$$

donde $P(x; t, \tau)$ es la probabilidad de observar x eventos en el intervalo de tiempo dt , τ es un factor de proporcionalidad constante que está asociado con el tiempo medio entre eventos, y el signo menos tiene en cuenta que aumentar el intervalo de tiempo diferencial dt disminuye la probabilidad proporcionalmente. Integrando esta ecuación obtenemos la probabilidad de no observar eventos dentro de un tiempo t como

$$P(0; t, \tau) = P_0 e^{-t/\tau} \quad (2.13)$$

donde P_0 , la constante de integración, es igual a 1 porque $P(0; t, \tau) = 1$ en $t = 0$.

La probabilidad $P(x; t, \tau)$ de observar x eventos en el intervalo de tiempo τ puede evaluarse integrando la probabilidad diferencial

$$d^x P(x; t, \tau) = \frac{e^{-t/\tau}}{x!} \prod_{i=1}^x \frac{dt_i}{\tau} \quad (2.14)$$

que es el producto de las probabilidades de observar cada evento en un intervalo diferente dt , y la probabilidad $e^{-t/\tau}$ de no observar ningún otro evento en el tiempo restante. El factor de $x!$ en el denominador compensa la ordenación implícita en las probabilidades $dP_i(I, t, \tau)$ como se discutió en la sección anterior sobre permutaciones y combinaciones.

Por lo tanto, la probabilidad de observar x eventos en el intervalo de tiempo t se obtiene por integración

$$P_P(x; \mu) = P(x; t, \tau) = \frac{e^{-t/\tau}}{x!} \left(\frac{t}{\tau} \right)^x \quad (2.15)$$

La probabilidad de que ocurra cualquier número x de eventos en el intervalo t es

$$P_P(x; \mu) = \frac{\mu^x}{x!} e^{-\mu} \quad (2.16)$$

que es la expresión para la distribución de Poisson, donde $\mu = t/\tau$ es el número promedio de eventos observados en el intervalo de tiempo t . La Ecuación (2.16) representa una función de probabilidad normalizada; es decir, la suma de la función evaluada en cada uno de los valores permitidos de la variable x es la unidad:

$$\sum_{x=0}^{\infty} P_P(x, \mu) = \sum_{x=0}^{\infty} \frac{\mu^x}{x!} e^{-\mu} = e^{-\mu} \sum_{x=0}^{\infty} \frac{\mu^x}{x!} = e^{-\mu} e^{\mu} = 1 \quad (2.17)$$

Media y Desviación Estándar

La distribución de Poisson, al igual que la distribución binomial, es una distribución discreta. Es decir, está definida solo en valores enteros de la variable x , aunque el parámetro μ es un número real positivo. La media de la distribución de Poisson es en realidad el parámetro μ que aparece en la función de probabilidad $P_P(x; \mu)$ de la Ecuación (2.16). Para verificar esto, podemos evaluar el valor esperado $\langle x \rangle$ de x :

$$\langle x \rangle = \sum_{x=0}^{\infty} \left(x \frac{\mu^x}{x!} e^{-\mu} \right) = \mu e^{-\mu} \sum_{x=1}^{\infty} \frac{\mu^{x-1}}{(x-1)!} = \mu e^{-\mu} \sum_{y=0}^{\infty} \frac{\mu^y}{y!} = \mu \quad (2.18)$$

Para encontrar la desviación estándar σ , se puede evaluar el valor esperado del cuadrado de las desviaciones:

$$\sigma^2 = \langle (x - \mu)^2 \rangle = \sum_{x=0}^{\infty} \left[(x - \mu)^2 \frac{\mu^x}{x!} e^{-\mu} \right] = \mu \quad (2.19)$$

Por lo tanto, la desviación estándar σ es igual a la raíz cuadrada de la media μ y la distribución de Poisson tiene solo un único parámetro, μ .

El cálculo de la distribución de Poisson mediante la Ecuación (2.16) puede estar limitado por la función factorial en el denominador. El problema puede evitarse usando logaritmos o usando las relaciones de recurrencia

$$P(0; \mu) = e^{-\mu} \quad P(x; \mu) = \frac{\mu}{x} P(x-1; \mu) \quad (2.20)$$

Esta forma tiene la desventaja de que, para calcular la función para valores particulares de x y μ , la función debe calcularse también para todos los valores inferiores de x . Sin embargo, si la función debe sumarse desde $x = 0$ hasta algún límite superior para obtener la probabilidad acumulada o para generar la distribución para un cálculo de Monte Carlo (Capítulo 5), la función debe calcularse para todos los valores inferiores de x de todas formas.

Ejemplo 2.4. Como parte de un experimento para determinar la vida media de isótopos radiactivos de plata, los estudiantes detectaron cuentas de fondo de rayos cósmicos. (Véase el Ejemplo 8.1.) Registraron el número de cuentas en su detector para una serie de 100 intervalos de 2 segundos, y encontraron que el número medio de cuentas era 1.69 por intervalo. A partir de la media estimaron la desviación estándar como $\sigma = \sqrt{1.69} = 1.30$, en comparación con $s = 1.29$ de un cálculo directo con la Ecuación (1.9).

Los estudiantes luego repitieron el ejercicio, esta vez registrando el número de cuentas en intervalos de 15 segundos durante 60 intervalos, obteniendo una

media de 11.48 cuentas por intervalo, con desviaciones estándar $\sigma = \sqrt{11,48} = 3,39$ y $s = 3,39$.

Los histogramas de los dos conjuntos de datos se muestran en las Figuras 2.3 y 2.4. La media calculada en cada caso se utilizó como una estimación de la media de la distribución parental para calcular una distribución de Poisson para cada conjunto de datos. Las distribuciones se muestran como curvas continuas, aunque solo los puntos en valores enteros de la abscisa son físicamente significativos.

La asimetría de la distribución en la Figura 2.3 es obvia, como también lo es el hecho de que la media μ no coincide con el valor más probable de x en el pico de la curva. La curva de la Figura 2.4, por otro lado, es casi simétrica alrededor de su media y los datos son consistentes con la curva. A medida que μ aumenta, la simetría de la distribución de Poisson aumenta y la distribución se vuelve indistinguible de la distribución gaussiana.

Probabilidad Acumulada

Podemos querer conocer la probabilidad de obtener un valor muestral de x entre los límites x_1 y x_2 a partir de una distribución de Poisson con media μ . Esta probabilidad se obtiene sumando los valores de la función calculada en los valores enteros de x entre los dos límites enteros x_1 y x_2 ,

$$S_p(x_1, x_2; \mu) = \sum_{x=x_1}^{x_2} P_p(x; \mu) \quad (2.21)$$

Más probablemente, queremos encontrar la probabilidad de registrar n o más eventos en un intervalo dado cuando el número medio de eventos es μ . Esto es simplemente la suma

$$S_p(n, \infty; \mu) = \sum_{x=n}^{\infty} P_p(x; \mu) = 1 - \sum_{x=0}^{n-1} P_p(x; \mu) = 1 - e^{-\mu} \sum_{x=0}^{n-1} \frac{\mu^x}{x!} \quad (2.22)$$

En el Ejemplo 2.4, el número medio de cuentas registradas en un intervalo de tiempo de 15 segundos era $\bar{x} = 11,48$. En uno de los intervalos, se registraron 23 cuentas. A partir de la Ecuación (2.22), la probabilidad de recolectar 23 o más eventos en un solo intervalo de tiempo de 15 segundos es $\sim 0,0018$, y la probabilidad de que esto ocurra en cualquiera de los 60 intervalos de tiempo de 15 segundos es simplemente el complemento de la probabilidad conjunta de que no se observen 23 o más cuentas en ninguno de los 60 intervalos de tiempo, o $p = 1 - (1 - 0,0018)^{60} \approx 0,10$, o aproximadamente 10 %.

Para valores grandes de μ , la suma de probabilidades de la Ecuación (2.22) puede aproximarse mediante una integral de la función gaussiana.

2.3 Distribución de Error Gaussiana o Normal

La distribución gaussiana es una aproximación a la distribución binomial para el caso límite especial en que el número de observaciones diferentes posibles n se vuelve infinitamente grande y la probabilidad de éxito para cada una es finitamente grande, de modo que $np \gg 1$. También es, como observamos, el caso límite para la distribución de Poisson cuando μ se vuelve grande.

Hay varias derivaciones de la distribución gaussiana a partir de primeros principios, ninguna de ellas tan convincente como el hecho de que la distribución es razonable, que tiene una forma analítica bastante simple, y que es aceptada por convención y experimentación como la distribución más probable para la mayoría de los experimentos. Además, tiene la característica satisfactoria de que la estimación más probable de la media μ a partir de una muestra aleatoria de observaciones x es el promedio de esas observaciones $\bar{x}$.

Características

La densidad de probabilidad gaussiana se define como

$$p_G(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right] \quad (2.23)$$

Esta es una función continua que describe la probabilidad de obtener el valor x en una observación aleatoria de una distribución parental con parámetros μ y σ , correspondientes a la media y la desviación estándar, respectivamente. Debido a que la distribución es continua, debemos definir un intervalo en el que caerá el valor de la observación x . La función de densidad de probabilidad está propiamente definida de tal manera que la probabilidad $dP_G(x; \mu, \sigma)$ de que el valor de una observación aleatoria caiga dentro de un intervalo dx alrededor de x viene dada por

$$dP_G(x; \mu, \sigma) = p_G(x; \mu, \sigma) dx \quad (2.24)$$

considerando dx como un diferencial infinitesimal, y la función de densidad de probabilidad está normalizada, de modo que

$$\int_{x=-\infty}^{x=\infty} dP_G(x; \mu, \sigma) = \int_{x=-\infty}^{x=\infty} p_G(x; \mu, \sigma) dx = 1 \quad (2.25)$$

El ancho de la curva está determinado por el valor de σ , de tal manera que para $x = \mu + \sigma$, la altura de la curva se reduce a $e^{-1/2}$ de su valor en el pico:

$$p_G(x; \mu \pm \sigma, \sigma) = e^{-1/2} p_G(\mu; \mu, \sigma) \quad (2.26)$$

La forma de la distribución gaussiana se muestra en la Figura 2.5. La curva muestra la característica forma de campana y simetría alrededor de la media μ .

Podemos caracterizar una distribución por su ancho total a la mitad del máximo Γ , a menudo denominado semiancho, definido como el rango de x entre los valores en los que la probabilidad $p_G(x; \mu, \sigma)$ es la mitad de su valor máximo:

$$p_G(\mu \pm \frac{1}{2}\Gamma; \mu, \sigma) = \frac{1}{2} p_G(\mu; \mu, \sigma) \quad (2.27)$$

Con esta definición, podemos determinar a partir de la Ecuación (2.23) que

$$\Gamma = 2,354\sigma \quad (2.28)$$

Como se ilustra en la Figura 2.5, las tangentes trazadas a lo largo de una porción de máxima pendiente de la curva intersecan la curva en los puntos $e^{-1/2}$ $x = \mu \pm \sigma$ e intersecan el eje x en los puntos $x = \mu \pm 2\sigma$.

Distribución Gaussiana Estándar

Generalmente es conveniente usar una forma estándar de la ecuación gaussiana obtenida definiendo la variable adimensional $z = (x - \mu)/\sigma$, porque con este cambio de variable, podemos escribir

$$p_G(z)dz = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right) dz \quad (2.29)$$

Por lo tanto, a partir de una sola rutina de computadora o una tabla de valores de $p_G(z)$, podemos encontrar la función de probabilidad gaussiana $p_G(x; \mu, \sigma)$ para todos los valores de los parámetros μ y σ cambiando la variable y escalando la función por $1/\sigma$ para preservar la normalización.

Media y Desviación Estándar

Los parámetros μ y σ en la Ecuación (2.23) para la densidad de probabilidad gaussiana corresponden a la media y la desviación estándar de la función. Esta equivalencia puede verificarse calculando μ y σ con las Ecuaciones (1.13) y (1.14) como los valores esperados para la función gaussiana de x y $(x - \mu)^2$, respectivamente.

Para una muestra de datos finita, que se espera que siga la densidad de probabilidad gaussiana, la media y la desviación estándar pueden calcularse directamente a partir de las Ecuaciones (1.1) y (1.9). Los valores resultantes de $\bar{x}$ y s serán estimaciones de la media μ y la desviación estándar σ . Los valores de $\bar{x}$ y s , obtenidos de esta manera a partir de las 50 mediciones de tiempo originales en el Ejemplo 1.2, se utilizaron como estimaciones de μ y σ en la Ecuación (2.23) para calcular la curva gaussiana sólida en la Figura 1.2. La curva se escaló para tener la misma área que el histograma. La curva representa nuestra estimación de la distribución parental basada en nuestras mediciones de la muestra.

Probabilidad Integral

A menudo estamos interesados en conocer la probabilidad de que una medición se desvíe de la media en una cantidad especificada Δx o más. La respuesta puede determinarse evaluando numéricamente la integral

$$P_G(\Delta x, \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \int_{\mu-\Delta x}^{\mu+\Delta x} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right] dx \quad (2.30)$$

que da la probabilidad de que cualquier valor aleatorio de x se desvíe de la media en menos de $\pm\Delta x$. Debido a que la función de probabilidad $P_G(x; \mu, \sigma)$ está normalizada a la unidad, la probabilidad de que una medición se desvíe de la media en más de Δx es simplemente $1 - P_G(\Delta x; \mu, \sigma)$. De particular interés son las probabilidades asociadas con desviaciones de σ , 2σ , y así sucesivamente de la media, correspondientes a 1, 2, etc. desviaciones estándar. También podemos estar interesados en el error probable (σ_{pe}), definido como el valor absoluto de la desviación $|x - \mu|$ tal que la probabilidad de que la desviación de cualquier observación aleatoria $|x - \mu|$ sea menor que $\frac{1}{2}$. Es decir, se esperaría que la mitad de las observaciones de un experimento cayeran dentro de los límites denotados por $\mu \pm \sigma_{pe}$.

Si usamos la forma estándar de la distribución gaussiana de la Ecuación (2.29), podemos calcular la probabilidad integrada $P_G(z)$ en términos de la variable adimensional $z = (x - \mu)/\sigma$,

$$P_G(z) = \frac{1}{\sqrt{2\pi}} \int_{-\Delta z}^{\Delta z} e^{-z^2/2} dz \quad (2.31)$$

donde $\Delta z = \Delta x/\sigma$ mide la desviación de la media en unidades de la desviación estándar σ .

La integral de la Ecuación (2.31) no puede evaluarse analíticamente, por lo que para obtener la probabilidad $P_G(\Delta x; \mu, \sigma)$ es necesario expandir la función gaussiana en una serie de Taylor e integrar la serie término a término, o integrar numéricamente. Con las computadoras modernas, la integración numérica es rápida y precisa, y se pueden obtener resultados fiables a partir de una integración cuadrática simple (Apéndice A.3).

Tablas y Gráficos

La función de densidad de probabilidad gaussiana $p_G(z)$ y la probabilidad integral $P_G(z)$ están tabuladas y trazadas en las Tablas C.1 y C.2, respectivamente. A partir de la Tabla C.2 de probabilidad integral, observamos que las probabilidades son aproximadamente 68 % y 95 % de que una medición dada caiga dentro de 1 y 2 desviaciones estándar de la media, respectivamente. De manera similar, considerando el límite de probabilidad del 50 %, podemos ver que el error probable viene dado por $\sigma_{pe} = 0,6745\sigma$.

Comparación de las Distribuciones Gaussiana y de Poisson

Una comparación de las curvas de Poisson y gaussiana revela la naturaleza de la distribución de Poisson. Es la distribución apropiada para describir experimentos en los que los valores posibles de los datos están estrictamente acotados por un lado pero no por el otro. La curva de Poisson de la Figura 2.3 exhibe la forma típica de Poisson. La curva de Poisson de la Figura 2.4 difiere poco de la curva gaussiana correspondiente de la Figura 2.5, lo que indica que para valores grandes de la media μ , la distribución gaussiana se convierte en una descripción aceptable de la distribución de Poisson. Debido a que, en general, la distribución gaussiana es más conveniente de calcular que la distribución de Poisson, a menudo es la opción preferida. Sin embargo, uno debe recordar que la distribución de Poisson solo está definida en 0 y valores enteros positivos de la variable x , mientras que la función gaussiana está definida en todos los valores de x .

2.4 Distribución Lorentziana

Hay muchas otras distribuciones que aparecen en la investigación científica. Algunas son distribuciones fenomenológicas, creadas para parametrizar ciertas distribuciones de datos. Otras están bien fundamentadas en la teoría. Una de estas últimas es la distribución lorentziana, similar pero no relacionada con la distribución binomial. La distribución lorentziana es una distribución apropiada para describir datos correspondientes a un comportamiento resonante, como la variación con la energía de la sección transversal de una reacción nuclear o de partículas, o la absorción de radiación en el efecto Mössbauer.

La función de densidad de probabilidad lorentziana $p_L(x; \mu, \Gamma)$, también llamada distribución de Cauchy, se define como

$$p_L(x; \mu, \Gamma) = \frac{1}{\pi} \frac{\Gamma/2}{(x - \mu)^2 + (\Gamma/2)^2} \quad (2.32)$$

Esta distribución es simétrica alrededor de su media μ con un ancho caracterizado por su semiancho Γ . La diferencia más sorprendente entre ella y la distribución gaussiana es que no disminuye a 0 tan rápidamente; el comportamiento para grandes desviaciones es proporcional al inverso del cuadrado de la desviación, en lugar de estar relacionado exponencialmente con el cuadrado de la desviación.

Al igual que con la distribución gaussiana, la función de distribución lorentziana es una función continua, y la probabilidad de observar un valor x debe estar relacionada con el intervalo dentro del cual puede caer la observación. La probabilidad $dP_L(x; \mu, \Gamma)$ de que una observación caiga dentro de un intervalo diferencial infinitesimal dx alrededor de x viene dada por el producto de la función de densidad de probabilidad $p_L(x; \mu, \Gamma)$ y el tamaño del intervalo dx :

$$dP_L(x; \mu, \Gamma) = p_L(x; \mu, \Gamma)dx \quad (2.33)$$

La normalización de la función de densidad de probabilidad $p_L(x; \mu, \Gamma)$ es tal que la integral de la probabilidad sobre todos los valores posibles de x es la unidad:

$$\int_{-\infty}^{\infty} p_L(x; \mu, \Gamma)dx = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{1}{1+z^2} dz = 1 \quad (2.34)$$

donde $z = (x - \mu)/(\Gamma/2)$.

Media y Semiancho

La media μ de la distribución lorentziana se da como uno de los parámetros en la Ecuación (2.32). Es obvio por la simetría de la distribución que μ debe ser igual a la media, así como a la mediana y al valor más probable.

La desviación estándar no está definida para la distribución lorentziana como consecuencia de su comportamiento que disminuye lentamente para grandes desviaciones. Si intentamos evaluar el valor esperado del cuadrado de las desviaciones

$$\sigma^2 = \langle (x - \mu)^2 \rangle = \frac{1}{\pi} \frac{\Gamma^2}{4} \int_{-\infty}^{\infty} \frac{z^2}{1+z^2} dz \quad (2.35)$$

encontramos que la integral no está acotada: la integral no converge para grandes desviaciones. Aunque es posible calcular una desviación estándar muestral evaluando el valor promedio del cuadrado de las desviaciones de la media muestral, este cálculo no tiene significado y no convergerá a un valor fijo a medida que aumenta el número de muestras.

El ancho de la distribución lorentziana se caracteriza en cambio por el ancho total a la mitad del máximo Γ , generalmente llamado semiancho. Este parámetro se define de tal manera que cuando $x = \mu \pm \Gamma/2$, la función de densidad de probabilidad es igual a la mitad de su valor máximo, o $p(\mu \pm \Gamma/2; \mu, \Gamma) = \frac{1}{2}p(\mu; \mu, \Gamma)$. Por lo tanto, el semiancho Γ es el ancho total de la curva medido entre los niveles de probabilidad mitad del máximo. Podemos verificar que esta identificación de Γ con el ancho total a la mitad del máximo es correcta sustituyendo $x = \mu \pm \Gamma/2$ en la Ecuación (2.32).

Las distribuciones lorentziana y gaussiana se muestran para comparación en la Figura 2.6, para $\mu = 10$ y $\Gamma = 2,354$ (correspondiente a $\sigma = 1$ para la función gaussiana). Ambas distribuciones están normalizadas a área unitaria según sus definiciones en las Ecuaciones (2.23) y (2.32). Para ambas curvas, el valor de la probabilidad máxima es inversamente proporcional al semiancho Γ . Esto resulta en un valor máximo de $2/\pi\Gamma \approx 0,270$ para

la distribución lorentziana y un valor máximo de $1/\sigma\sqrt{2\pi} \approx 0,399$ para la distribución gaussiana.

Excepto por la normalización, la distribución lorentziana es equivalente a la relación de dispersión que se utiliza, por ejemplo, para describir la sección transversal de una reacción nuclear para una resonancia de Breit-Wigner:

$$\sigma = \pi\lambda^2 \frac{\Gamma_1\Gamma_2}{(E - E_0)^2 + (\Gamma/2)^2} \quad (2.36)$$

Resumen

- **Distribución binomial:** Describe la probabilidad de observar x éxitos en n intentos cuando la probabilidad de éxito en cada intento es p :

$$P_B(x; n, p) = \binom{n}{x} p^x q^{n-x} = \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x}$$

$$\mu = np \quad \sigma^2 = np(1-p)$$

- **Distribución de Poisson:** Caso límite de la distribución binomial para n grande y μ constante; apropiada para describir muestras pequeñas de poblaciones grandes.

$$P_P(x; \mu) = \frac{\mu^x}{x!} e^{-\mu}, \quad \sigma^2 = \mu$$

- **Distribución gaussiana:** Caso límite de la distribución binomial para n grande y p finito; apropiada para distribuciones suaves y simétricas.

$$p_G(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right]$$

Semiancho $\Gamma = 2,354\sigma$; error probable $P.E. = 0,6745\sigma$. Forma estándar:

$$p_G(z)dz = \frac{1}{\sqrt{2\pi}} \exp \left(-\frac{z^2}{2} \right) dz$$

- **Distribución lorentziana:** Describe comportamiento resonante.

$$p_L(x; \mu, \Gamma) = \frac{1}{\pi} \frac{\Gamma/2}{(x - \mu)^2 + (\Gamma/2)^2}$$

Ejercicios

Ejercicio 2.1

Considere cinco monedas etiquetadas como a, b, c, d , y e . Sea x = número de caras que se muestran.

- (a) Cuente y tabule manualmente todas las permutaciones posibles para cada una de las siguientes configuraciones:

- I. $x = 0$

- II. $x = 1$
- III. $x = 2$
- IV. $x = 3$
- V. $x = 4$
- VI. $x = 5$

Compare sus resultados con los dados por la Ecuación (2.2).

- (b) Elimine manualmente todas las permutaciones duplicadas de cada ejemplo de la parte (a), es decir, tache las permutaciones que repiten una combinación anterior en un orden diferente. Compare sus resultados con los dados por la Ecuación (2.3).

Solución:

- (a) Para 5 monedas, el número total de permutaciones es $2^5 = 32$. La Ecuación (2.2) da el número de permutaciones para cada x : $Pm(5, x) = \frac{5!}{(5-x)!}$. Calculamos:

- $x = 0$: $Pm = \frac{5!}{5!} = 1$ (todas cruces: una permutación)
- $x = 1$: $Pm = \frac{5!}{4!} = 5$ (una cara, cuatro cruces: 5 formas de elegir qué moneda es cara)
- $x = 2$: $Pm = \frac{5!}{3!} = 20$
- $x = 3$: $Pm = \frac{5!}{2!} = 60$
- $x = 4$: $Pm = \frac{5!}{1!} = 120$
- $x = 5$: $Pm = \frac{5!}{0!} = 120$

Manualmente, listar las 32 permutaciones es tedioso pero el número de permutaciones para cada x debe coincidir con estos números.

- (b) Eliminando duplicados (considerando solo combinaciones, no el orden), el número de combinaciones es $C(5, x) = \binom{5}{x}$. Calculamos:

- $x = 0$: $\binom{5}{0} = 1$
- $x = 1$: $\binom{5}{1} = 5$
- $x = 2$: $\binom{5}{2} = 10$
- $x = 3$: $\binom{5}{3} = 10$
- $x = 4$: $\binom{5}{4} = 5$
- $x = 5$: $\binom{5}{5} = 1$

Esto coincide con la Ecuación (2.3).

Ejercicio 2.2

Evalúe las siguientes:

$$(a) \binom{6}{3} \quad (b) \binom{4}{2} \quad (c) \binom{10}{3} \quad (d) \binom{52}{4}$$

Solución: Usamos la definición $\binom{n}{x} = \frac{n!}{x!(n-x)!}$.

- (a) $\binom{6}{3} = \frac{6!}{3!3!} = \frac{720}{6 \cdot 6} = \frac{720}{36} = 20$
- (b) $\binom{4}{2} = \frac{4!}{2!2!} = \frac{24}{2 \cdot 2} = \frac{24}{4} = 6$
- (c) $\binom{10}{3} = \frac{10!}{3!7!} = \frac{10 \cdot 9 \cdot 8}{3 \cdot 2 \cdot 1} = \frac{720}{6} = 120$
- (d) $\binom{52}{4} = \frac{52!}{4!48!} = \frac{52 \cdot 51 \cdot 50 \cdot 49}{4 \cdot 3 \cdot 2 \cdot 1} = \frac{52 \cdot 51 \cdot 50 \cdot 49}{24}$. Calculamos: $52 \cdot 51 = 2652$, $2652 \cdot 50 = 132600$, $132600 \cdot 49 = 6497400$. Dividido por 24: $6497400/24 = 270725$. Por tanto, $\binom{52}{4} = 270725$.

Ejercicio 2.3

Evalúe la distribución binomial $P_B(x; n, p)$ para $n = 6, p = \frac{1}{2}$, y $x = 0$ a 6. Trace la distribución e identifique la media y la desviación estándar. Repita para $p = \frac{1}{6}$.

Solución: Para $n = 6, p = 1/2$, $P(x) = \binom{6}{x}(1/2)^6 = \frac{\binom{6}{x}}{64}$. Calculamos:

$$P(0) = 1/64 \approx 0,0156$$

$$P(1) = 6/64 = 0,09375$$

$$P(2) = 15/64 \approx 0,2344$$

$$P(3) = 20/64 = 0,3125$$

$$P(4) = 15/64 \approx 0,2344$$

$$P(5) = 6/64 = 0,09375$$

$$P(6) = 1/64 \approx 0,0156$$

Media $\mu = np = 6 \cdot 0,5 = 3$. Varianza $\sigma^2 = np(1-p) = 6 \cdot 0,5 \cdot 0,5 = 1,5$, $\sigma = \sqrt{1,5} \approx 1,225$.

Para $p = 1/6$, $q = 5/6$, $P(x) = \binom{6}{x}(1/6)^x(5/6)^{6-x}$. Calculamos:

$$P(0) = (5/6)^6 = 15625/46656 \approx 0,3349$$

$$P(1) = 6 \cdot (1/6) \cdot (5/6)^5 = (5/6)^5 = 3125/7776 \approx 0,4019$$

$$P(2) = 15 \cdot (1/6)^2(5/6)^4 = 15 \cdot (1/36) \cdot (625/1296) = 15 \cdot 625/(36 \cdot 1296) = 9375/46656 \approx 0,2009$$

$$P(3) = 20 \cdot (1/216) \cdot (125/1296) = 20 \cdot 125/(216 \cdot 1296) = 2500/279936 \approx 0,00893$$
 Revisemos: $(5/6)^{6-3}$

Continuando: $P(4) = 15 \cdot (1/1296) \cdot (5/6)^2 = 15 \cdot (1/1296) \cdot (25/36) = 15 \cdot 25/(1296 \cdot 36) = 375/46656 \approx 0,00804$
 $P(5) = 6 \cdot (1/7776) \cdot (5/6) = 6 \cdot 5/(7776 \cdot 6) = 30/46656 \approx 0,000643$
 $P(6) = (1/6)^6 = 1/46656 \approx 0,0000214$

Media $\mu = 6/6 = 1$, varianza $\sigma^2 = 6 \cdot (1/6) \cdot (5/6) = 5/6 \approx 0,8333$, $\sigma \approx 0,9129$.

Ejercicio 2.4

La distribución de probabilidad de la suma de los puntos que se muestran en un par de dados está dada por la ecuación

$$P(x) = \frac{x-1}{36} \quad \text{para } x = 2, \dots, 7, \quad P(x) = \frac{13-x}{36} \quad \text{para } x = 8, \dots, 12.$$

Encuentre la media, la mediana y la desviación estándar de la distribución.

Solución: Primero, tabulamos las probabilidades:

- $x = 2$: $P = 1/36$

- $x = 3: P = 2/36$
- $x = 4: P = 3/36$
- $x = 5: P = 4/36$
- $x = 6: P = 5/36$
- $x = 7: P = 6/36$
- $x = 8: P = 5/36$
- $x = 9: P = 4/36$
- $x = 10: P = 3/36$
- $x = 11: P = 2/36$
- $x = 12: P = 1/36$

La suma de probabilidades es $(1 + 2 + 3 + 4 + 5 + 6 + 5 + 4 + 3 + 2 + 1)/36 = 36/36 = 1$.

Media: $\mu = \sum xP(x) = \frac{1}{36}[2 \cdot 1 + 3 \cdot 2 + 4 \cdot 3 + 5 \cdot 4 + 6 \cdot 5 + 7 \cdot 6 + 8 \cdot 5 + 9 \cdot 4 + 10 \cdot 3 + 11 \cdot 2 + 12 \cdot 1]$.
 Calculamos cada término: $2 \cdot 1 = 2$ $3 \cdot 2 = 6$ $4 \cdot 3 = 12$ $5 \cdot 4 = 20$ $6 \cdot 5 = 30$ $7 \cdot 6 = 42$
 $8 \cdot 5 = 40$ $9 \cdot 4 = 36$ $10 \cdot 3 = 30$ $11 \cdot 2 = 22$ $12 \cdot 1 = 12$ Suma = $2 + 6 = 8, +12 = 20, +20 = 40, +30 = 70, +42 = 112, +40 = 152, +36 = 188, +30 = 218, +22 = 240, +12 = 252$. Por tanto, $\mu = 252/36 = 7$.

Mediana: La probabilidad acumulada hasta $x = 7$ es $(1 + 2 + 3 + 4 + 5 + 6)/36 = 21/36 = 0,5833$, que es mayor que 0.5. Hasta $x = 6$ es $(1 + 2 + 3 + 4 + 5)/36 = 15/36 = 0,4167$. Por tanto, la mediana es 7.

Varianza: $\sigma^2 = \sum (x - \mu)^2 P(x) = \frac{1}{36} \sum (x - 7)^2 P(x)$ con las mismas frecuencias. Calculamos $(x - 7)^2$:

$$\begin{aligned}
 (2 - 7)^2 &= 25, & 25 \cdot 1 &= 25 \\
 (3 - 7)^2 &= 16, & 16 \cdot 2 &= 32 \\
 (4 - 7)^2 &= 9, & 9 \cdot 3 &= 27 \\
 (5 - 7)^2 &= 4, & 4 \cdot 4 &= 16 \\
 (6 - 7)^2 &= 1, & 1 \cdot 5 &= 5 \\
 (7 - 7)^2 &= 0, & 0 \cdot 6 &= 0 \\
 (8 - 7)^2 &= 1, & 1 \cdot 5 &= 5 \\
 (9 - 7)^2 &= 4, & 4 \cdot 4 &= 16 \\
 (10 - 7)^2 &= 9, & 9 \cdot 3 &= 27 \\
 (11 - 7)^2 &= 16, & 16 \cdot 2 &= 32 \\
 (12 - 7)^2 &= 25, & 25 \cdot 1 &= 25
 \end{aligned}$$

Suma = $25 + 32 = 57, +27 = 84, +16 = 100, +5 = 105, +0 = 105, +5 = 110, +16 = 126, +27 = 153, +32 = 185, +25 = 210$. Por tanto, $\sigma^2 = 210/36 = 35/6 \approx 5,8333$,
 $\sigma = \sqrt{35/6} \approx \sqrt{5,8333} \approx 2,415$.

Ejercicio 2.5

Demuestre que la suma en la Ecuación (2.6) se reduce a $\mu = np$. *Sugerencia:* Defina $y = x - 1$ y $m = n - 1$ y use el hecho de que

$$\sum_{y=0}^m \left[\frac{m!}{y!(m-y)!} p^y (1-p)^{m-y} \right] = \sum_{y=0}^m P_B(y; m, p) = 1$$

Solución: Partimos de $\mu = \sum_{x=0}^n x \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x}$. Para $x = 0$, el término es 0, así que podemos empezar desde $x = 1$. Sea $y = x - 1$, entonces $x = y + 1$, y $n - x = n - (y + 1) = (n - 1) - y$. Además, $\frac{n!}{x!(n-x)!} = \frac{n!}{(y+1)!(n-y-1)!} = \frac{n(n-1)!}{(y+1)!((n-1)-y)!}$. Observamos que $(y+1)! = (y+1)y!$. Entonces:

$$x \frac{n!}{x!(n-x)!} = (y+1) \frac{n(n-1)!}{(y+1)y!((n-1)-y)!} = \frac{n(n-1)!}{y!((n-1)-y)!}$$

Por tanto,

$$\mu = \sum_{y=0}^{n-1} \frac{n(n-1)!}{y!((n-1)-y)!} p^{y+1} (1-p)^{(n-1)-y} = np \sum_{y=0}^{n-1} \frac{(n-1)!}{y!((n-1)-y)!} p^y (1-p)^{(n-1)-y}$$

La suma es la suma de probabilidades binomiales para $m = n - 1$, que es igual a 1. Por tanto, $\mu = np$.

Ejercicio 2.6

En cierto tipo de máquina tragamonedas hay 10 símbolos diferentes que pueden aparecer en cada una de tres ventanas. La máquina paga diferentes cantidades cuando aparecen uno, dos o tres limones. ¿Cuál debería ser la relación de pago para cada una de las tres posibilidades si la máquina es honesta y no hay descuento para la casa?

Solución: Hay 10 símbolos en cada ventana, total de combinaciones $10^3 = 1000$. La probabilidad de que en una ventana específica aparezca un limón es $p = 1/10$ si hay un solo símbolo de limón. Asumimos que hay un solo tipo de limón. Entonces, la probabilidad de exactamente un limón (en una ventana) y las otras dos no limón: hay 3 formas de elegir qué ventana tiene el limón, y para esa ventana probabilidad $1/10$, para las otras dos probabilidad $9/10$ cada una. Por tanto, $P(1) = 3 \cdot (1/10) \cdot (9/10)^2 = 3 \cdot 81/1000 = 243/1000 = 0,243$. Probabilidad de exactamente dos limones: hay $\binom{3}{2} = 3$ formas, probabilidad $(1/10)^2(9/10) = 3 \cdot 9/1000 = 27/1000 = 0,027$. Probabilidad de tres limones: $(1/10)^3 = 1/1000 = 0,001$. Para que la máquina sea honesta, el valor esperado de la ganancia debe ser igual a la apuesta (digamos 1 unidad). Si los pagos son a_1, a_2, a_3 para 1, 2 y 3 limones respectivamente, entonces:

$$a_1 P(1) + a_2 P(2) + a_3 P(3) = 1$$

No hay una solución única, pero típicamente los pagos son proporcionales a las probabilidades inversas. Si hacemos $a_1 = k/P(1)$, etc., entonces $k(1+1+1) = 1$ daría $k = 1/3$, pero eso no es estándar. En las máquinas, a menudo el pago es mayor para combinaciones más raras. Supongamos que el pago es tal que la esperanza es 1. Podemos elegir, por ejemplo, $a_1 = 1/P(1) \approx 4,12$, pero eso no es entero. En la práctica, los pagos se redondean. Una solución común es que por un limón se recupera la apuesta, por dos se gana algo más, etc.

Sin más información, no podemos dar una respuesta única. El problema probablemente espera que se calcule la probabilidad y se use para determinar pagos justos. Por ejemplo, si la máquina paga 1 por un limón, entonces la contribución es 0.243, y necesitamos que los otros pagos sumen 0.757. Podríamos hacer que dos limones paguen 10 (contribución 0.27) y tres limones paguen 100 (contribución 0.1), sumando 0.613, aún falta. No es una solución única.

Ejercicio 2.7

Demuestre que la suma en la Ecuación (2.7) se reduce a $\sigma^2 = np(1-p)$. *Sugerencia:* Defina $y = x - 1$ y $m = n - 1$ y use los resultados del Ejercicio 2.5.

Solución: Partimos de $\sigma^2 = \sum_{x=0}^n (x - np)^2 \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x}$. Podemos usar la identidad $\sum (x - np)^2 P(x) = \sum x^2 P(x) - (np)^2$. Otra forma es calcular $\sum x(x-1)P(x)$ y luego relacionar. Sabemos que $\sum xP(x) = np$. Calculemos $\sum x(x-1)P(x)$:

$$\sum_{x=0}^n x(x-1) \frac{n!}{x!(n-x)!} p^x q^{n-x} = \sum_{x=2}^n \frac{n!}{(x-2)!(n-x)!} p^x q^{n-x}$$

Haciendo $y = x - 2$, $m = n - 2$, entonces $x = y + 2$, y el término se convierte en:

$$\sum_{y=0}^{n-2} \frac{n!}{y!(n-2-y)!} p^{y+2} q^{n-2-y} = n(n-1)p^2 \sum_{y=0}^{n-2} \frac{(n-2)!}{y!((n-2)-y)!} p^y q^{(n-2)-y} = n(n-1)p^2$$

Por tanto, $\sum x^2 P(x) = \sum x(x-1)P(x) + \sum xP(x) = n(n-1)p^2 + np$. Entonces $\sigma^2 = n(n-1)p^2 + np - (np)^2 = np(1-p)$.

Ejercicio 2.8

En una hora punta de un día típico, el 25,0 % de los coches que se aproximan a una bifurcación en la calle giran a la izquierda y el 75,0 % giran a la derecha. En un día particular, 283 coches giraron a la izquierda y 752 a la derecha. Encuentre la incertidumbre predicha en estos números y la probabilidad de que estas mediciones no se hayan realizado en un “día típico”; es decir, encuentre la probabilidad de obtener un resultado que esté tan alejado o más de la media que el resultado medido en el día particular.

Solución: Total de coches $N = 283 + 752 = 1035$. Si el día fuera típico, esperaríamos $N_L = 0,25 \times 1035 = 258,75$, $N_R = 776,25$. La desviación estándar para el número de izquierdas es $\sigma = \sqrt{Np(1-p)} = \sqrt{1035 \cdot 0,25 \cdot 0,75} = \sqrt{1035 \cdot 0,1875} = \sqrt{194,0625} \approx 13,93$. La desviación observada es $283 - 258,75 = 24,25$, que es $24,25/13,93 \approx 1,74$ desviaciones estándar. La probabilidad de obtener un valor tan extremo o más (bilateral) para una distribución binomial aproximada por gaussiana es $P(|z| > 1,74) \approx 2 \times (1 - \Phi(1,74))$. De tablas gaussianas, $\Phi(1,74) \approx 0,9591$, por lo que la probabilidad es $2 \times 0,0409 \approx 0,0818$ o 8,18 %. Por tanto, hay aproximadamente un 8 % de probabilidad de obtener una desviación así de grande en un día típico.

Ejercicio 2.9

En cierto curso de física, el 7,3 % de los estudiantes suspendieron y el 92,7 % aprobaron, promediado durante muchos semestres.

- (a) ¿Cuál es el número esperado de suspensos en una clase particular de 32 estudiantes, extraídos de la misma población?
- (b) ¿Cuál es la probabilidad de que suspendan cinco o más estudiantes?

Solución:

- (a) $n = 32$, $p = 0,073$. Número esperado $\mu = np = 32 \times 0,073 = 2,336$.
- (b) Probabilidad de 5 o más: $P(x \geq 5) = 1 - P(x \leq 4)$. Usamos binomial: $P(x) = \binom{32}{x} (0,073)^x (0,927)^{32-x}$. Calculamos: $P(0) = (0,927)^{32} \approx e^{32 \ln 0,927} \approx e^{32 \cdot (-0,0758)} = e^{-2,4256} \approx 0,0885$ $P(1) = 32 \cdot 0,073 \cdot (0,927)^{31} = 2,336 \cdot (0,927)^{31}$. Podemos aproximar con Poisson ($\mu = 2,336$) o calcular directamente. Usando Poisson: $P(0) = e^{-2,336} = 0,0967$, $P(1) = 2,336e^{-2,336} = 0,226$, $P(2) = (2,336^2/2)e^{-2,336} = (5,457/2) \cdot 0,0967 = 2,7285 \cdot 0,0967 = 0,264$, $P(3) = (2,336^3/6)e^{-2,336} = (12,75/6) \cdot 0,0967 = 2,125 \cdot 0,0967 = 0,2055$, $P(4) = (2,336^4/24)e^{-2,336} = (29,8/24) \cdot 0,0967 = 1,242 \cdot 0,0967 = 0,120$. Suma hasta 4: $0,0967 + 0,226 = 0,3227$, $+0,264 = 0,5867$, $+0,2055 = 0,7922$, $+0,120 = 0,9122$. Entonces $P(x \geq 5) \approx 1 - 0,9122 = 0,0878$. Un cálculo binomial exacto daría un resultado similar.

Ejercicio 2.10

Evalúe y trace las dos distribuciones de Poisson del Ejemplo 2.4. Trace en cada gráfico la distribución gaussiana correspondiente con la misma media y desviación estándar.

Solución: Para el primer caso, $\mu = 1,69$. Calculamos $P(x) = e^{-1,69} (1,69)^x / x!$ para $x = 0, 1, 2, \dots$ hasta donde sea significativo. Para el segundo, $\mu = 11,48$. Luego, la gaussiana correspondiente tiene media μ y $\sigma = \sqrt{\mu}$. Se puede hacer una tabla y un gráfico. Aquí no podemos trazar, pero se describe que para μ pequeña la Poisson es asimétrica, para μ grande es casi simétrica y se aproxima a la gaussiana.

Ejercicio 2.11

Verifique que, para la distribución de Poisson, si μ es un número entero, la probabilidad para $x = \mu$ es igual a la probabilidad para $x = \mu - 1$, $P_P(\mu; \mu) = P_P(\mu - 1; \mu)$.

Solución: $P(\mu) = e^{-\mu} \mu^\mu / \mu!$. $P(\mu - 1) = e^{-\mu} \mu^{\mu-1} / (\mu - 1)!$. Entonces $P(\mu) / P(\mu - 1) = \frac{\mu^\mu}{\mu!} \cdot \frac{(\mu-1)!}{\mu^{\mu-1}} = \frac{\mu^\mu}{\mu \cdot (\mu-1)!} \cdot \frac{(\mu-1)!}{\mu^{\mu-1}} = \frac{\mu^\mu}{\mu \cdot \mu^{\mu-1}} = \frac{\mu^\mu}{\mu^\mu} = 1$. Por tanto, son iguales.

Ejercicio 2.12

Demuestre que la suma en la Ecuación (2.19) se reduce a $\sigma^2 = \mu$. *Sugerencia:* Use la Ecuación (2.18) para simplificar la expresión. Defina $y = x - 1$ y demuestre que la suma se reduce a $\mu \langle y + 1 \rangle = \mu^2$.

Solución: $\sigma^2 = \sum_{x=0}^{\infty} (x - \mu)^2 e^{-\mu} \mu^x / x!$. Sabemos que $\sum x e^{-\mu} \mu^x / x! = \mu$. Calculamos $\sum x^2 e^{-\mu} \mu^x / x!$. Escribimos $x^2 = x(x - 1) + x$. Entonces $\sum x(x - 1) e^{-\mu} \mu^x / x! = \sum_{x=2}^{\infty} e^{-\mu} \mu^x / (x - 2)!$. Haciendo $y = x - 2$, esto es $e^{-\mu} \mu^2 \sum_{y=0}^{\infty} \mu^y / y! = e^{-\mu} \mu^2 e^\mu = \mu^2$. Por tanto, $\sum x^2 P(x) = \mu^2 + \mu$. Entonces $\sigma^2 = (\mu^2 + \mu) - \mu^2 = \mu$.

Ejercicio 2.13

Miembros de una gran colaboración que operó un detector de protones en descomposición gigante en una mina de sal cerca de Cleveland, Ohio, detectaron una ráfaga de 8 neutrinos en su aparato coincidiendo con la observación óptica de la explosión de la Supernova 1987A.

- (a) Si el número medio de neutrinos detectados en el aparato es 2 por día, ¿cuál es la probabilidad de detectar una fluctuación de 8 o más en un día?
- (b) De hecho, los 8 neutrinos se detectaron todos dentro de un período de 10 minutos. ¿Cuál es la probabilidad de detectar una fluctuación de 8 o más neutrinos en un período de 10 minutos si la tasa media es de 2 por 24 horas?

Solución:

- (a) $\mu = 2$ por día. $P(x \geq 8) = 1 - \sum_{x=0}^7 e^{-2} 2^x / x!$. Calculamos: $P(0) = e^{-2} = 0,1353$, $P(1) = 2e^{-2} = 0,2707$, $P(2) = 4e^{-2}/2 = 2e^{-2} = 0,2707$, $P(3) = 8e^{-2}/6 = 1,333e^{-2} = 0,1804$, $P(4) = 16e^{-2}/24 = 0,6667e^{-2} = 0,0902$, $P(5) = 32e^{-2}/120 = 0,2667e^{-2} = 0,0361$, $P(6) = 64e^{-2}/720 = 0,0889e^{-2} = 0,0120$, $P(7) = 128e^{-2}/5040 = 0,0254e^{-2} = 0,00343$. Suma: $0,1353 + 0,2707 = 0,406$, $+0,2707 = 0,6767$, $+0,1804 = 0,8571$, $+0,0902 = 0,9473$, $+0,0361 = 0,9834$, $+0,0120 = 0,9954$, $+0,00343 = 0,9988$. Por tanto, $P(\geq 8) = 1 - 0,9988 = 0,0012$.
- (b) En 10 minutos, la tasa media es $\mu = 2 \times \frac{10}{24 \times 60} = 2 \times \frac{10}{1440} = \frac{20}{1440} = \frac{1}{72} \approx 0,01389$. Entonces $P(x \geq 8) = \sum_{x=8}^{\infty} e^{-\mu} \mu^x / x!$. Dado que μ es muy pequeño, los términos son insignificantes. El primer término $x = 8$ es $e^{-0,01389} (0,01389)^8 / 40320$. $(0,01389)^8 \approx (1,389 \times 10^{-2})^8 = 1,389^8 \times 10^{-16}$. $1,389^2 = 1,93$, $^4 = 3,72$, $^8 = 13,84$. Así que aproximadamente $13,84 \times 10^{-16}$. Dividido por 40320 da $\approx 3,43 \times 10^{-20}$. Multiplicado por $e^{-0,01389} \approx 0,986$ da $\approx 3,38 \times 10^{-20}$. Es una probabilidad extremadamente pequeña.

Ejercicio 2.14

En un experimento de dispersión para medir la polarización de una partícula elemental, un total de $N = 1000$ partículas se dispersaron desde un blanco. De estas, 670 se observaron dispersadas a la derecha y 330 a la izquierda. Suponga que no hay incertidumbre en $N = N_R + N_L$.

- (a) Basándose en la estimación experimental de la probabilidad, ¿cuál es la incertidumbre en N_R ? ¿En N_L ?
- (b) El parámetro de asimetría se define como $A = (N_R - N_L)/(N_R + N_L)$. Calcule la asimetría experimental y su incertidumbre.
- (c) Suponga que la asimetría se ha predicho como $A = 0,400$ y recalcule las incertidumbres en (a) y (b) usando la probabilidad predicha.

Solución:

- (a) Estimación experimental: $p = N_R/N = 0,67$, $q = 0,33$. La desviación estándar de N_R es $\sigma_{N_R} = \sqrt{Npq} = \sqrt{1000 \cdot 0,67 \cdot 0,33} = \sqrt{221,1} \approx 14,87$. Por tanto, $N_R = 670 \pm 14,9$, $N_L = 330 \pm 14,9$ (la incertidumbre es la misma).

- (b) $A = (670 - 330)/1000 = 340/1000 = 0,34$. La incertidumbre en A se obtiene por propagación de errores. $A = (N_R - N_L)/N = (2N_R/N) - 1$? Mejor: $A = (N_R - (N - N_R))/N = (2N_R - N)/N = 2p - 1$. Entonces $\sigma_A = 2\sigma_p$. Y $\sigma_p = \sqrt{pq/N} = \sqrt{0,67 \cdot 0,33/1000} = \sqrt{0,2211/1000} = \sqrt{0,0002211} = 0,01487$. Por tanto, $\sigma_A = 2 \times 0,01487 = 0,02974 \approx 0,030$. Entonces $A = 0,340 \pm 0,030$.
- (c) Si la probabilidad predicha es $p = (1 + A)/2 = (1 + 0,4)/2 = 0,7$, entonces $q = 0,3$. La incertidumbre en N_R sería $\sigma = \sqrt{1000 \cdot 0,7 \cdot 0,3} = \sqrt{210} = 14,49$. Para A , $\sigma_A = 2\sqrt{pq/N} = 2\sqrt{0,21/1000} = 2\sqrt{0,00021} = 2 \times 0,01449 = 0,02898$. Por tanto, con la predicción, la incertidumbre sería ligeramente menor.

Ejercicio 2.15

Un problema que surge al registrar datos con contadores electrónicos es que el sistema puede saturarse cuando las tasas son muy altas, lo que lleva a un “tiempo muerto”. Por ejemplo, después de que una partícula ha pasado a través de un detector, el equipo estará “muerto” mientras el detector se recupera y la electrónica almacena los resultados. Si una segunda partícula pasa a través del detector en este período de tiempo, no será contada.

- (a) Suponga que un contador tiene un tiempo muerto de 200 ns (200×10^{-9} s) y está expuesto a un haz de 1×10^6 partículas por segundo, de modo que el número medio de partículas que golpean el contador en el intervalo de tiempo de 200 ns es $\mu = 0,2$. A partir de la probabilidad de Poisson para este proceso, encuentre la eficiencia del contador, es decir, la relación entre el número medio de partículas contadas y el número medio que pasan a través del contador en el período de tiempo de 200 ns.
- (b) Repita el cálculo para tasas de haz de 2, 4, 6, 8 y 10×10^6 partículas por segundo, y trace un gráfico de la eficiencia del contador en función de la tasa de haz.

Solución:

- (a) La probabilidad de que una partícula sea contada es la probabilidad de que no haya otra partícula en el mismo intervalo de tiempo muerto después de ella. Pero el proceso es complicado. Para un contador con tiempo muerto no paralizante, la fracción de tiempo que el contador está muerto es aproximadamente la fracción de tiempo que hay una partícula en el intervalo. La eficiencia se puede calcular como la probabilidad de que no haya otra partícula en el intervalo de tiempo muerto después de una partícula. Dado que las llegadas son Poisson, la probabilidad de que haya 0 partículas en un intervalo de longitud τ es $e^{-\mu}$ con $\mu = r\tau$. Por tanto, la eficiencia es $e^{-r\tau}$. Para $r = 10^6 \text{ s}^{-1}$, $\tau = 2 \times 10^{-7} \text{ s}$, $\mu = 0,2$, eficiencia $e^{-0,2} = 0,8187$.
- (b) Para las otras tasas: $r = 2 \times 10^6$, $\mu = 0,4$, eficiencia $e^{-0,4} = 0,6703$ $r = 4 \times 10^6$, $\mu = 0,8$, eficiencia $e^{-0,8} = 0,4493$ $r = 6 \times 10^6$, $\mu = 1,2$, eficiencia $e^{-1,2} = 0,3012$ $r = 8 \times 10^6$, $\mu = 1,6$, eficiencia $e^{-1,6} = 0,2019$ $r = 10 \times 10^6$, $\mu = 2,0$, eficiencia $e^{-2,0} = 0,1353$ Se puede trazar eficiencia vs. tasa.

Ejercicio 2.16

Demuestre mediante cálculo numérico que, para la distribución de probabilidad gaussiana, el ancho total a la mitad del máximo Γ está relacionado con la desviación estándar por $\Gamma = 2,354\sigma$ [Ecuación (2.28)].

Solución: La altura máxima es $p_{max} = \frac{1}{\sigma\sqrt{2\pi}}$. Queremos x tal que $p(x) = \frac{1}{2}p_{max}$. Es decir,

$$\frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{(x-\mu)^2}{2\sigma^2}} = \frac{1}{2}\frac{1}{\sigma\sqrt{2\pi}} \Rightarrow e^{-\frac{(x-\mu)^2}{2\sigma^2}} = \frac{1}{2}$$

Tomando logaritmos: $-\frac{(x-\mu)^2}{2\sigma^2} = -\ln 2 \Rightarrow (x-\mu)^2 = 2\sigma^2 \ln 2$. Por tanto, $x - \mu = \pm\sigma\sqrt{2\ln 2}$. El ancho total es $2\sigma\sqrt{2\ln 2}$. Calculamos $\sqrt{2\ln 2} = \sqrt{2 \times 0,693147} = \sqrt{1,386294} = 1,17741$. Luego $2 \times 1,17741 = 2,35482$, que redondeado es 2.354.

Ejercicio 2.17

La probabilidad de que un electrón esté a una distancia r del centro del núcleo de un átomo de hidrógeno viene dada por

$$dP(r) = Cr^2e^{-r/R}dr$$

Encuentre el radio medio $\bar{r}$ y la desviación estándar. Encuentre el valor de la constante C .

Solución: Primero, normalizamos: $\int_0^\infty Cr^2e^{-r/R}dr = 1$. La integral $\int_0^\infty r^2e^{-ar}dr = \frac{2}{a^3}$ con $a = 1/R$. Por tanto, $C \cdot 2R^3 = 1 \Rightarrow C = \frac{1}{2R^3}$.

El radio medio: $\bar{r} = \int_0^\infty rCr^2e^{-r/R}dr = C \int_0^\infty r^3e^{-r/R}dr$. $\int_0^\infty r^3e^{-ar}dr = \frac{6}{a^4} = 6R^4$. Entonces $\bar{r} = \frac{1}{2R^3} \cdot 6R^4 = 3R$.

El valor esperado de r^2 : $\langle r^2 \rangle = \int_0^\infty r^2Cr^2e^{-r/R}dr = C \int_0^\infty r^4e^{-r/R}dr$. $\int_0^\infty r^4e^{-ar}dr = \frac{24}{a^5} = 24R^5$. Entonces $\langle r^2 \rangle = \frac{1}{2R^3} \cdot 24R^5 = 12R^2$. La varianza $\sigma^2 = \langle r^2 \rangle - \bar{r}^2 = 12R^2 - 9R^2 = 3R^2$. Por tanto, la desviación estándar $\sigma = \sqrt{3}R$.

Ejercicio 2.18

Demuestre que una tangente a la función gaussiana es más pronunciada en $x = \mu \pm \sigma$, y por lo tanto interseca la curva en los puntos $e^{-1/2}$. Demuestre también que estas tangentes intersecan el eje x en $x = \mu \pm 2\sigma$.

Solución: La función gaussiana es $f(x) = \frac{1}{\sigma\sqrt{2\pi}}e^{-(x-\mu)^2/(2\sigma^2)}$. Su derivada es $f'(x) = f(x) \cdot \left(-\frac{x-\mu}{\sigma^2}\right)$. La pendiente es máxima cuando la derivada de la pendiente (segunda derivada) es cero. Calculamos $f''(x) = f'(x) \cdot \left(-\frac{x-\mu}{\sigma^2}\right) + f(x) \cdot \left(-\frac{1}{\sigma^2}\right) = f(x) \left[\frac{(x-\mu)^2}{\sigma^4} - \frac{1}{\sigma^2}\right]$.

Igualando a cero: $\frac{(x-\mu)^2}{\sigma^4} = \frac{1}{\sigma^2} \Rightarrow (x-\mu)^2 = \sigma^2 \Rightarrow x = \mu \pm \sigma$. En esos puntos, la pendiente es $f'(\mu \pm \sigma) = f(\mu \pm \sigma) \cdot \left(-\frac{\pm\sigma}{\sigma^2}\right) = \mp \frac{1}{\sigma} f(\mu \pm \sigma)$. Y $f(\mu \pm \sigma) = \frac{1}{\sigma\sqrt{2\pi}}e^{-1/2}$, que es $e^{-1/2}$ veces el máximo. La ecuación de la tangente en $x = \mu + \sigma$ es $y = f(\mu + \sigma) + f'(\mu + \sigma)(x - (\mu + \sigma))$. Para encontrar la intersección con el eje x , hacemos $y=0$: $0 = f(\mu + \sigma) - \frac{1}{\sigma}f(\mu + \sigma)(x - (\mu + \sigma)) \Rightarrow 1 = \frac{x - (\mu + \sigma)}{\sigma} \Rightarrow x - (\mu + \sigma) = \sigma \Rightarrow x = \mu + 2\sigma$. Análogamente para la otra tangente.

Capítulo 3: Análisis de Errores

En el Capítulo 1 discutimos métodos para extraer de un conjunto de puntos de datos estimaciones de la media y la desviación estándar que describen, respectivamente, el resultado deseado y las incertidumbres en los resultados. En este capítulo consideraremos además cómo estimar las incertidumbres en nuestras mediciones, las fuentes de las incertidumbres, y cómo combinar incertidumbres en mediciones separadas para encontrar el error en un resultado calculado a partir de esas mediciones.

3.1 Incertidumbres Instrumentales y Estadísticas

Incertidumbres Instrumentales

Si la cantidad x se ha medido con un instrumento físico, la incertidumbre en la medición generalmente proviene de fluctuaciones en las lecturas de la escala instrumental, ya sea porque los ajustes no son exactamente reproducibles debido a imperfecciones en el equipo, o debido a la imprecisión humana al observar los ajustes, o una combinación de ambas. Tales incertidumbres se denominan instrumentales porque surgen de una falta de precisión perfecta en los instrumentos de medición (incluyendo al observador). Podemos incluir en esta categoría experimentos que tratan con mediciones de características como longitud, masa, voltaje, corriente, etc. Estas incertidumbres son a menudo independientes del valor real de la cantidad que se está midiendo.

Las incertidumbres instrumentales generalmente se determinan examinando los instrumentos y considerando el procedimiento de medición para estimar la fiabilidad de las mediciones. En general, uno debe intentar hacer lecturas hasta una fracción de la división de escala más pequeña del instrumento. Por ejemplo, con un buen termómetro de mercurio, a menudo es fácil estimar el nivel del mercurio hasta un mínimo de la mitad de la división de escala más pequeña y posiblemente incluso hasta una quinta parte de una división. La medición generalmente se cita como más o menos la mitad del mínimo de lectura, y este número representa una estimación de la desviación estándar de una sola medición. Recordando que, para una distribución gaussiana, hay una probabilidad del 68 % de que una medición aleatoria se encuentre dentro de 1 desviación estándar de la media, observamos que nuestro objetivo al estimar errores no es establecer límites externos en el rango de la medición, lo cual es imposible, sino establecer un nivel de confianza particular de que una medición repetida de la cantidad caerá tan cerca de la media o más cerca. A menudo elegimos la desviación estándar, el nivel de confianza del 68 %, pero también se utilizan otros niveles. Discutiremos el concepto de niveles de confianza en el Capítulo 11.

Los instrumentos digitales requieren una consideración especial. Generalmente, los fabricantes especifican una tolerancia; por ejemplo, la tolerancia de un multímetro digital puede darse como $\pm 1\%$. En cualquier caso, la precisión no puede ser mejor que la mitad del último dígito en la pantalla. Las tolerancias citadas por el fabricante pueden requerir interpretación en cuanto a si la incertidumbre debe tratarse como un efecto sistemático o un efecto estadístico. Por ejemplo, si un estudiante usa una resistencia con una tolerancia declarada del 1 % en un experimento, puede esperar que la incertidumbre declarada en la resistencia haga una contribución sistemática a todos los experimentos con esa resistencia. Por otro lado, cuando combina sus resultados con los de otros estudiantes de la clase, cada uno de los cuales usó una resistencia diferente, las incertidumbres en las resistencias individuales contribuyen de manera estadística a la variación de la muestra combinada.

Si es posible realizar mediciones repetidas, entonces se puede calcular una estimación de la desviación estándar a partir de la dispersión de estas mediciones como se discutió en el Capítulo 1. La estimación resultante de la desviación estándar corresponde a la incertidumbre esperada en una sola medición. En principio, este método interno de determinar la incertidumbre debería coincidir con el obtenido por el método externo de considerar el equipo y el experimento en sí mismo, y de hecho, cualquier discrepancia significativa entre los dos sugiere un problema, como un malentendido de algún aspecto del procedimiento experimental. Sin embargo, cuando se logra un acuerdo razonable, entonces la desviación estándar calculada internamente a partir de los datos generalmente proporciona la mejor

estimación de las incertidumbres.

Incetidumbres Estadísticas

Si la cantidad medida x representa el número de cuentas en un detector por unidad de tiempo para un proceso aleatorio, entonces las incertidumbres se denominan estadísticas porque surgen no de una falta de precisión en los instrumentos de medición sino de fluctuaciones estadísticas generales en la recolección de números finitos de cuentas en intervalos de tiempo finitos. Para fluctuaciones estadísticas, podemos estimar analíticamente la desviación estándar para cada observación, sin tener que determinarla experimentalmente. Si hiciéramos la misma medición repetidamente, encontraríamos que los valores observados se distribuirían alrededor de su media en una distribución de Poisson (como se discutió en la Sección 2.2) en lugar de una distribución gaussiana. Podemos justificar el uso de esta distribución intuitivamente considerando que debemos esperar una distribución que esté relacionada con la distribución binomial, pero que sea consistente con nuestras condiciones de contorno de que podemos recolectar cualquier número positivo de cuentas, pero no menos de cero cuentas, en cualquier intervalo de tiempo.

La distribución de Poisson y las incertidumbres estadísticas no se aplican únicamente a experimentos donde las cuentas se registran en intervalos de tiempo unitarios. En cualquier experimento en el que los datos se agrupan en intervalos según algún criterio para formar un histograma o gráfico de frecuencia, el número de eventos en cada intervalo individual obedecerá a la estadística de Poisson y fluctuará con incertidumbres estadísticas.

Una ventaja inmediata de la distribución de Poisson es que la desviación estándar se determina automáticamente:

$$\sigma = \sqrt{\mu} \quad (3.1)$$

La incertidumbre relativa, la relación de la desviación estándar a la tasa promedio, $\sigma/\mu = 1/\sqrt{\mu}$, disminuye a medida que aumenta el número de cuentas recibidas por intervalo. Por lo tanto, las incertidumbres relativas son más pequeñas cuando las tasas de conteo son más altas.

El valor para μ que se utilizará en la Ecuación (3.1) para determinar la desviación estándar σ es, por supuesto, el valor de la tasa de conteo media de la población parental, de la cual cada medición x es solo una muestra aproximada. En el límite de un número infinito de determinaciones, el promedio de todas las mediciones se aproximaría mucho al valor parental, pero a menudo no podemos hacer más de una medición de cada valor de x , y mucho menos un número infinito. Por lo tanto, nos vemos obligados a usar $\sqrt{x}$ como una estimación de la desviación estándar de una sola medición.

Ejemplo 3.1. Considere un experimento en el que contamos rayos gamma emitidos por una fuente radiactiva fuerte. No podemos determinar la tasa de conteo instantáneamente porque no se detectarán cuentas en un intervalo de tiempo infinitesimal. Pero podemos determinar el número de cuentas x detectadas en un intervalo de tiempo Δt , y esto debería ser representativo de la tasa de conteo promedio en ese intervalo. Supongamos que hemos registrado 5212 cuentas en un intervalo de tiempo de 1 segundo. La distribución de cuentas es aleatoria en el tiempo y sigue la función de probabilidad de Poisson, por lo que nuestra estimación de la desviación estándar de la distribución es $\sigma = \sqrt{5212} \approx 72$. Por lo tanto, debemos registrar nuestro resultado para el

número de cuentas x en el intervalo de tiempo Δt como 5212 ± 72 y el error relativo es

$$\frac{\sigma_x}{x} = \frac{\sqrt{x}}{x} = \frac{1}{\sqrt{x}} = \frac{1}{72} = 0,014 = 1,4 \%$$

También puede haber incertidumbres instrumentales que contribuyan a las incertidumbres generales. Por ejemplo, podemos determinar los intervalos de tiempo solo con precisión finita. Sin embargo, podemos tener cierto control sobre estas incertidumbres y a menudo podemos organizar nuestro experimento para que los errores estadísticos sean dominantes. Supongamos que el principal error instrumental en nuestro ejemplo es la incertidumbre $\sigma_t = 0,01$ s en el intervalo de tiempo $\Delta t = 1,00$ s. La incertidumbre relativa en el intervalo de tiempo es, por lo tanto,

$$\frac{\sigma_t}{\Delta t} = \frac{0,01}{1,00} = 0,01 = 1. \%$$

Este error instrumental relativo en el intervalo de tiempo producirá un error relativo del 1. % en el número de cuentas x . Debido a que la incertidumbre instrumental es comparable a la incertidumbre estadística, podría ser aconsejable intentar una medición más precisa del intervalo o aumentar su duración. Si aumentamos el intervalo de tiempo de conteo a 100 s, el número de cuentas aumentaría a aproximadamente 500,000 y el error estadístico relativo se reduciría a aproximadamente el 0,14 %, mientras que el error instrumental seguiría siendo del 1 %. Entonces el error sistemático dominaría y probablemente deberíamos reconsiderar nuestro método experimental.

3.2 Propagación de Errores

A menudo queremos determinar una variable dependiente x que es una función de una o más variables medidas diferentes. Debemos saber cómo propagar o trasladar las incertidumbres en las variables medidas para determinar la incertidumbre en la variable dependiente.

Ejemplo 3.2. Supongamos que deseamos encontrar el volumen V de una caja de longitud L , ancho W y altura H . Podemos medir cada una de las tres dimensiones como L_0 , W_0 y H_0 y combinar estas mediciones para obtener un valor para el volumen:

$$V_0 = L_0 W_0 H_0 \quad (3.2)$$

¿Cómo afectan las incertidumbres en las estimaciones L_0 , W_0 y H_0 a las incertidumbres resultantes en el resultado final V_0 ?

Si conociéramos los errores reales, $\Delta L = L - L_0$ y así sucesivamente, en cada dimensión, podríamos obtener una estimación del error en el resultado final V_0 expandiendo V alrededor del punto (L_0, W_0, H_0) en una serie de Taylor. El primer término en la expansión de Taylor da

$$V \approx V_0 + \Delta L \left(\frac{\partial V}{\partial L} \right)_{W_0 H_0} + \Delta W \left(\frac{\partial V}{\partial W} \right)_{L_0 H_0} + \Delta H \left(\frac{\partial V}{\partial H} \right)_{L_0 W_0} \quad (3.3)$$

de donde podemos encontrar $\Delta V = V - V_0$. Los términos entre paréntesis son las derivadas parciales de V , con respecto a cada una de las dimensiones, L , W y H , evaluadas en el punto L_0 , W_0 , H_0 . Son las constantes de proporcionalidad entre los cambios en V y cambios infinitesimalmente pequeños en las dimensiones correspondientes. La derivada parcial de V con respecto a L , por ejemplo, se evalúa con las otras variables W y H mantenidas fijas en los valores W_0 y H_0 como lo indica el subíndice. Esta aproximación desprecia términos de orden superior en la expansión de Taylor, lo que equivale a despreciar el hecho de que las derivadas parciales no son constantes en los rangos de L , W y H dados por sus errores. Si los errores son grandes, debemos incluir en esta definición al menos segundas derivadas parciales ($\partial^2 V / \partial L^2$, etc.) y derivadas parciales cruzadas ($\partial^2 V / \partial L \partial W$, etc.), pero omitiremos estas de la discusión que sigue.

Para nuestro ejemplo de $V = LWH$, la Ecuación (3.3) da

$$\Delta V \approx W_0 H_0 \Delta L + L_0 H_0 \Delta W + L_0 W_0 \Delta H \quad (3.4)$$

que podríamos evaluar si conociéramos las incertidumbres ΔL , ΔW y ΔH .

Incetidumbres

En general, sin embargo, no conocemos los errores reales en la determinación de las variables dependientes (o si los conocemos, deberíamos hacer las correcciones necesarias). En cambio, podemos estimar el error en cada cantidad medida, o estimar alguna característica, como la desviación estándar σ , de la distribución de probabilidad de las cantidades medidas. ¿Cómo podemos combinar la desviación estándar de las mediciones individuales para estimar la incertidumbre en el resultado?

Supongamos que queremos determinar una cantidad x que es una función de al menos dos variables medidas, u y v . Determinaremos las características de x a partir de las de u y v y de la dependencia fundamental

$$x = f(u, v, \dots) \quad (3.5)$$

Aunque no siempre sea exacto, asumiremos que el valor más probable para x viene dado por

$$\bar{x} = f(\bar{u}, \bar{v}, \dots) \quad (3.6)$$

La incertidumbre en el valor resultante para x puede encontrarse considerando la dispersión de los valores de x resultantes de combinar las mediciones individuales u_p , v_p , ... en resultados individuales x_i :

$$x_i = f(u_i, v_i, \dots) \quad (3.7)$$

En el límite de un número infinito de mediciones, la media de la distribución coincidirá con el promedio $\bar{x}$ dado en la Ecuación (3.6) y podemos usar la definición de la Ecuación (1.8) para encontrar la varianza σ_x^2 (que es el cuadrado de la desviación estándar σ_x):

$$\sigma_x^2 = \lim_{N \rightarrow \infty} \left[\frac{1}{N} \sum (x_i - \bar{x})^2 \right] \quad (3.8)$$

Así como expresamos la desviación de V en la Ecuación (3.4) como una función de las desviaciones en las dimensiones L , W y H , podemos expresar las desviaciones $x_i - \bar{x}$ en términos de las desviaciones $u_i - \bar{u}$, $v_i - \bar{v}$, ... de los parámetros observados

$$x_i - \bar{x} \approx (u_i - \bar{u}) \left(\frac{\partial x}{\partial u} \right) + (v_i - \bar{v}) \left(\frac{\partial x}{\partial v} \right) + \dots \quad (3.9)$$

donde hemos omitido la notación específica de que cada una de las derivadas parciales se evalúa con todas las otras variables fijas en sus valores medios.

Varianza y Covarianza

Combinando las Ecuaciones (3.8) y (3.9) podemos expresar la varianza σ_x^2 para x en términos de las varianzas σ_u^2 , σ_v^2 , ... para las variables u , v , ..., que realmente se midieron:

$$\begin{aligned} \sigma_x^2 &\approx \lim_{N \rightarrow \infty} \frac{1}{N} \sum \left[(u_i - \bar{u}) \left(\frac{\partial x}{\partial u} \right) + (v_i - \bar{v}) \left(\frac{\partial x}{\partial v} \right) + \dots \right]^2 \\ &\approx \lim_{N \rightarrow \infty} \frac{1}{N} \sum \left[(u_i - \bar{u})^2 \left(\frac{\partial x}{\partial u} \right)^2 + (v_i - \bar{v})^2 \left(\frac{\partial x}{\partial v} \right)^2 \right. \\ &\quad \left. + 2(u_i - \bar{u})(v_i - \bar{v}) \left(\frac{\partial x}{\partial u} \right) \left(\frac{\partial x}{\partial v} \right) + \dots \right] \quad (3.10) \end{aligned}$$

Los dos primeros términos de la Ecuación (3.10) pueden expresarse en términos de las varianzas σ_u^2 y σ_v^2 dadas por la Ecuación (1.8):

$$\sigma_u^2 = \lim_{N \rightarrow \infty} \left[\frac{1}{N} \sum (u_i - \bar{u})^2 \right] \quad \sigma_v^2 = \lim_{N \rightarrow \infty} \left[\frac{1}{N} \sum (v_i - \bar{v})^2 \right] \quad (3.11)$$

Para expresar el tercer término de la Ecuación (3.10) de forma similar, introducimos las covarianzas σ_{uv}^2 entre las variables u y v definidas de manera análoga a las varianzas de la Ecuación (3.11):

$$\sigma_{uv}^2 \equiv \lim_{N \rightarrow \infty} \left[\frac{1}{N} \sum [(u_i - \bar{u})(v_i - \bar{v})] \right] \quad (3.12)$$

Con estas definiciones, la aproximación para la varianza σ_x^2 para x dada en la Ecuación (3.10) se convierte en

$$\sigma_x^2 \approx \sigma_u^2 \left(\frac{\partial x}{\partial u} \right)^2 + \sigma_v^2 \left(\frac{\partial x}{\partial v} \right)^2 + \dots + 2\sigma_{uv}^2 \left(\frac{\partial x}{\partial u} \right) \left(\frac{\partial x}{\partial v} \right) + \dots \quad (3.13)$$

La Ecuación (3.13) se conoce como la ecuación de propagación de errores.

Los dos primeros términos en la ecuación son promedios de cuadrados de desviaciones ponderados por los cuadrados de las derivadas parciales, y pueden considerarse como los promedios de los cuadrados de las desviaciones en x producidas por las incertidumbres en

u y en v respectivamente. En general, estos términos dominan las incertidumbres. Si hay variables adicionales además de u y v en la determinación de x , sus contribuciones a la varianza de x tendrán términos similares.

El tercer término es el promedio de los términos cruzados que involucran productos de desviaciones en u y v ponderados por el producto de las derivadas parciales. Si las fluctuaciones en las cantidades medidas u y v no están correlacionadas, entonces, en promedio, debemos esperar encontrar distribuciones iguales de valores positivos y negativos para este término, y debemos esperar que el término se anule en el límite de una gran selección aleatoria de observaciones. Esta es a menudo una aproximación razonable y la Ecuación (3.13) se reduce entonces a

$$\sigma_x^2 \approx \sigma_u^2 \left(\frac{\partial x}{\partial u} \right)^2 + \sigma_v^2 \left(\frac{\partial x}{\partial v} \right)^2 + \dots \quad (3.14)$$

con términos similares para variables adicionales. En general, usamos la Ecuación (3.14) para determinar los efectos de las incertidumbres de medición en el resultado final y despreciamos los términos de covarianza. Sin embargo, como veremos en el Capítulo 7, los términos de covarianza a menudo hacen contribuciones importantes a las incertidumbres en los parámetros determinados mediante el ajuste de curvas a los datos por el método de mínimos cuadrados.

3.3 Fórmulas de Error Específicas

Las expresiones de las Ecuaciones (3.13) y (3.14) se derivaron para la relación general de la Ecuación (3.5) que da x como una función arbitraria de u y v , En los siguientes casos específicos de funciones $f(u, v, \dots)$, los parámetros a y b se definen como constantes y u y v son variables.

Sumas y Diferencias Simples

Si la variable dependiente x está relacionada con una cantidad medida u por la relación

$$x = u + a \quad (3.15)$$

entonces la derivada parcial $\partial x / \partial u = 1$ y la incertidumbre en x es simplemente

$$\sigma_x = \sigma_u \quad (3.16)$$

y la incertidumbre relativa viene dada por

$$\frac{\sigma_x}{x} = \frac{\sigma_u}{x} = \frac{\sigma_u}{u + a} \quad (3.17)$$

Nótese que si estamos tratando con una pequeña diferencia entre u y a , la incertidumbre en x podría ser mayor que la magnitud de x , incluso para una pequeña incertidumbre relativa en u .

Ejemplo 3.3. En un experimento para contar partículas emitidas por una fuente radiactiva en descomposición, medimos $N_1 = 723$ cuentas en un intervalo de tiempo de 15 segundos al comienzo del experimento y $N_2 = 19$ cuentas en un intervalo de tiempo de 15 segundos más tarde en el experimento. Los eventos son aleatorios y obedecen a la estadística de Poisson, por lo

que sabemos que las incertidumbres en N_1 y N_2 son simplemente sus raíces cuadradas. Supongamos que hemos realizado una medición muy cuidadosa de la tasa de conteo de fondo en ausencia de la fuente radiactiva y obtuvimos un valor $B = 14,2$ cuentas con un error despreciable para el mismo intervalo de tiempo Δt . Debido a que hemos promediado durante un largo período de tiempo, el número medio de cuentas de fondo en el intervalo de 15 segundos no es un número entero.

Para el primer intervalo de tiempo, el número corregido de cuentas es

$$x_1 = N_1 - B = 723 - 14,2 = 708,8 \text{ cuentas}$$

La incertidumbre en x_1 viene dada por

$$\sigma_{x_1} = \sigma_{N_1} = \sqrt{723} \approx 26,9 \text{ cuentas}$$

y la incertidumbre relativa es

$$\frac{\sigma_x}{x} = \frac{26,9}{708,8} = 0,038 \rightarrow 3,8 \%$$

Para el segundo intervalo de tiempo, el número corregido de eventos es

$$x_2 = N_2 - B = 19 - 14,2 = 4,8 \text{ cuentas}$$

La incertidumbre en x viene dada por

$$\sigma_{x_2} = \sigma_{N_2} = \sqrt{19} \approx 4,4 \text{ cuentas}$$

y la incertidumbre relativa en x es

$$\frac{\sigma_x}{x} = \frac{4,4}{4,8} \approx 0,91$$

Sumas y Diferencias Ponderadas

Si x es la suma ponderada de u y v

$$x = au + bv \quad (3.18)$$

las derivadas parciales son simplemente las constantes

$$\left(\frac{\partial x}{\partial u}\right) = a \quad \left(\frac{\partial x}{\partial v}\right) = b \quad (3.19)$$

y obtenemos

$$\sigma_x^2 = a^2\sigma_u^2 + b^2\sigma_v^2 + 2ab\sigma_{uv}^2 \quad (3.20)$$

Nótese la posibilidad de que la varianza σ_x^2 podría desaparecer si la covarianza σ_{uv}^2 tiene la magnitud y el signo adecuados. Esto podría suceder en el caso poco probable de que las

fluctuaciones estuvieran completamente correlacionadas de modo que cada observación errónea de u fuera exactamente compensada por una observación errónea correspondiente de v .

Ejemplo 3.4. Supongamos que, en el ejemplo anterior, las cuentas de fondo B no se promediaron durante un largo período de tiempo, sino que simplemente se midieron durante 15 segundos para dar $B = 14$ con una desviación estándar $\sigma_B = \sqrt{14} \approx 3,7$ cuentas. Entonces la incertidumbre en x vendría dada por

$$\sigma_x^2 = \sigma_N^2 + (-\sigma_B)^2 = N + B$$

porque las incertidumbres en N y B son iguales a sus raíces cuadradas.

Para el primer intervalo de tiempo, calcularíamos

$$x_1 = (723 - 14) \pm \sqrt{723 + 14} = 709 \pm 27,1 \text{ cuentas}$$

y la incertidumbre relativa sería

$$\frac{\sigma_x}{x} = \frac{27,1}{709} \approx 0,038$$

Para el segundo intervalo de tiempo, calcularíamos

$$x_2 = (19 - 14) \pm \sqrt{19 + 14} = 5 \pm 5,7 \text{ cuentas}$$

y la incertidumbre relativa sería

$$\frac{\sigma_x}{x} = \frac{5,7}{5} \approx 1,1$$

Multiplicación y División

Si x es el producto ponderado de u y v

$$x = auv \quad (3.21)$$

las derivadas parciales de cada variable son funciones de la otra variable,

$$\left(\frac{\partial x}{\partial u}\right) = av \quad \left(\frac{\partial x}{\partial v}\right) = au \quad (3.22)$$

y la varianza de x se convierte en

$$\sigma_x^2 = (av\sigma_u)^2 + (au\sigma_v)^2 + 2a^2uv\sigma_{uv}^2 \quad (3.23)$$

que puede expresarse de forma más simétrica como

$$\frac{\sigma_x^2}{x^2} = \frac{\sigma_u^2}{u^2} + \frac{\sigma_v^2}{v^2} + 2\frac{\sigma_{uv}^2}{uv} \quad (3.24)$$

De manera similar, si x se obtiene mediante división,

$$x = \frac{au}{v} \quad (3.25)$$

la varianza relativa para x viene dada por

$$\frac{\sigma_x^2}{x^2} = \frac{\sigma_u^2}{u^2} + \frac{\sigma_v^2}{v^2} - 2\frac{\sigma_{uv}^2}{uv} \quad (3.26)$$

Ejemplo 3.5. El área de un triángulo es igual a la mitad del producto de la base por la altura $A = bh/2$. Si la base y la altura tienen valores $b = 5,0 \pm 0,1$ cm y $h = 10,0 \pm 0,3$ cm, el área es $A = 25,0$ cm² y la incertidumbre relativa en el área viene dada por

$$\frac{\sigma_A^2}{A^2} = \frac{\sigma_b^2}{b^2} + \frac{\sigma_h^2}{h^2} \quad (3.27)$$

o

$$\begin{aligned} \sigma_A^2 &= A^2 \left(\frac{\sigma_b^2}{b^2} + \frac{\sigma_h^2}{h^2} \right) \\ &= 25^2 (\text{cm})^4 \left(\frac{0,1^2}{5^2} + \frac{0,3^2}{10^2} \right) (\text{cm}^2/\text{cm}^2) \\ &= 0,81 \text{ cm}^4 \end{aligned}$$

Aunque la incertidumbre absoluta en la altura es 3 veces la incertidumbre absoluta en la base, la incertidumbre relativa es solo 1/2 veces mayor y su contribución a la varianza del área es solo $(1/2)^2$ veces mayor.

Potencias

Si x se obtiene elevando la variable u a una potencia

$$x = au^b \quad (3.28)$$

la derivada de x con respecto a u es

$$\left(\frac{\partial x}{\partial u} \right) = abu^{b-1} = \frac{bx}{u} \quad (3.29)$$

y el error relativo en x se convierte en

$$\frac{\sigma_x}{x} = b \frac{\sigma_u}{u} \quad (3.30)$$

Para los casos especiales de $b = +1$, tenemos

$$x = au \quad \sigma_x = a\sigma_u$$

por lo que

$$\frac{\sigma_x}{x} = \frac{\sigma_u}{u} \quad (3.31)$$

Para $b = -1$, tenemos

$$x = \frac{a}{u} \quad \sigma_x = -\frac{a\sigma_u}{u^2}$$

por lo que

$$\frac{\sigma_x}{x} = -\frac{\sigma_u}{u} \quad (3.32)$$

El signo negativo indica que, en la división, un error positivo en u producirá un error negativo correspondiente en x .

Ejemplo 3.6. El área de un círculo es proporcional al cuadrado del radio $A = \pi r^2$. Si el radio se determina como $r = 10,0 \pm 0,3$ cm, el área es $A = 100,0\pi$ cm² con una incertidumbre dada por

$$\frac{\sigma_A}{A} = 2\frac{\sigma_r}{r}$$

o

$$\sigma_A = 2A\frac{\sigma_r}{r} = 2\pi(10,0 \text{ cm})^2(0,3 \text{ cm})/(10,0 \text{ cm}) = 6\pi \text{ cm}^2$$

Exponenciales

Si x se obtiene elevando la base natural a una potencia proporcional a u ,

$$x = ae^{bu} \quad (3.33)$$

la derivada de x con respecto a u es

$$\frac{\partial x}{\partial u} = abe^{bu} = bx \quad (3.34)$$

y la incertidumbre relativa se convierte en

$$\frac{\sigma_x}{x} = b\sigma_u \quad (3.35)$$

Si la constante que se eleva a la potencia no es igual a e , la expresión puede reescribirse como

$$\begin{aligned} x &= a^{bu} \\ &= (e^{\ln a})^{bu} = e^{(b \ln a)u} \\ &= e^{cu} \quad \text{con } c = b \ln a \end{aligned} \quad (3.36)$$

donde $\ln$ indica el logaritmo natural. Resolviendo de la misma manera que antes obtenemos

$$\frac{\sigma_x}{x} = c\sigma_u = (b \ln a)\sigma_u \quad (3.37)$$

Logaritmos

Si x se obtiene tomando el logaritmo de u

$$x = a \ln(bu) \quad (3.38)$$

la derivada con respecto a u es

$$\frac{\partial x}{\partial u} = \frac{ab}{u} \quad (3.39)$$

por lo que

$$\sigma_x = ab \frac{\sigma_u}{u} \quad (3.40)$$

Funciones Angulares

Si x se determina como una función de u , tal como

$$x = a \cos(bu) \quad (3.41)$$

La derivada de x con respecto a u es

$$\frac{dx}{du} = -ab \sin(bu) \quad (3.42)$$

por lo que

$$\sigma_x = |-ab \sin(bu)| \sigma_u = ab |\sin(bu)| \sigma_u \quad (3.43)$$

De manera similar, si

$$x = a \sin(bu) \quad (3.44)$$

entonces

$$\frac{dx}{du} = ab \cos(bu) \quad (3.45)$$

por lo que

$$\sigma_x = ab |\cos(bu)| \sigma_u \quad (3.46)$$

Nótese que σ_u es la incertidumbre en un ángulo y, por lo tanto, debe expresarse en radianes.

Estas relaciones pueden ser útiles para hacer estimaciones rápidas de la incertidumbre en una cantidad calculada causada por la incertidumbre en una variable medida. Para un producto o cociente simple de la variable medida u con una constante, un error del 1 % en u causa un error del 1 % en x . Si u se eleva a una potencia b , el error resultante en x se convierte en b % para una incertidumbre del 1 % en u . Incluso si la expresión completa para x involucra otras variables medidas, $x = f(u, v, \dots)$ y es considerablemente más complicada que estos ejemplos simples, a menudo es posible usar estas relaciones para hacer estimaciones aproximadas de las incertidumbres.

3.4 Aplicación de las Ecuaciones de Error

Incluso para cálculos relativamente simples, como los que se encuentran en experimentos de laboratorio de pregrado, la aplicación ciega de la expresión general de propagación de errores [Ecuación (3.14)] puede conducir a ecuaciones muy largas y desalentadoras, especialmente si los resultados finales dependen de varias cantidades medidas diferentes. A menudo, las ecuaciones de error pueden simplificarse despreciando términos que hacen contribuciones insignificantes a la incertidumbre final, pero esto requiere cierta práctica.

Aproximaciones

Los estudiantes deben practicar haciendo estimaciones aproximadas rápidas de las diversas contribuciones a la incertidumbre en el resultado final considerando por separado los términos en la Ecuación (3.14). Una regla general conveniente es despreciar los términos que hacen contribuciones finales que son menos del 10 % de la contribución más grande. (Como con todas las reglas de este tipo, uno debe tener cuidado con los casos especiales. Varias contribuciones más pequeñas a la incertidumbre final pueden sumar tanto como una incertidumbre más grande).

Ejemplo 3.7. Supongamos que el área de un rectángulo $A = LW$ debe determinarse a partir de las siguientes mediciones de las longitudes de dos lados:

$$L = 22,1 \pm 0,1 \text{ cm} \quad W = 7,3 \pm 0,1 \text{ cm}$$

La contribución relativa de σ_L al error en L será

$$\frac{\sigma_{A_L}}{A} = \frac{\sigma_L}{L} = \frac{0,1}{22,1} = 0,0045$$

y la contribución correspondiente de σ_W será

$$\frac{\sigma_{A_W}}{A} = \frac{\sigma_W}{W} = \frac{0,1}{7,3} \approx 0,0137$$

La contribución de σ_L es, por lo tanto, aproximadamente un tercio de la de σ_W . Sin embargo, cuando se combinan las contribuciones, obtenemos

$$\sigma_A = A\sqrt{(0,0137)^2 + (0,0045)^2}$$

que puede expandirse para dar

$$\sigma_A \approx 0,0137A \left(1 + \frac{1}{2} \left(\frac{0,0045}{0,0137} \right)^2 \right) \approx 0,0137A(1 + 0,05) = 0,0144A$$

Por lo tanto, la contribución efectiva de σ_L es solo aproximadamente el 5 % de la contribución efectiva de σ_W y podría despreciarse con seguridad en este cálculo.

Cálculo de Incertidumbres por Computadora

Encontrar formas analíticas para las derivadas parciales a veces es bastante difícil. Uno siempre debe dividir la Ecuación (3.14) en componentes separados y no intentar encontrar una ecuación completa que incorpore todos los términos de error. De hecho, si el análisis se realiza por computadora, puede que ni siquiera sea necesario encontrar las derivadas explícitamente. La computadora puede encontrar numéricamente las variaciones en la variable dependiente causadas por variaciones en cada variable independiente o medida.

Supongamos que tenemos una ecuación particularmente complicada, o un conjunto de ecuaciones, que relaciona nuestro resultado final x con las variables medidas individualmente u, v , etc. Supongamos que las ecuaciones reales están programadas como una función de computadora CALCULATE, que devuelve la variable única x cuando se llama con argumentos correspondientes a los parámetros medidos

$$x = \text{CALCULATE}(u, v, w, \dots)$$

Supondremos además que las correlaciones son pequeñas, por lo que las covarianzas pueden ignorarse. Entonces, para encontrar las variaciones de x con las cantidades medidas u, v , etc., podemos hacer llamadas sucesivas a la función de la forma

$$DXU = \text{CALCULATE}(u + \sigma_u, v, w, \dots) - x,$$

$$DXV = \text{CALCULATE}(u, v + \sigma_v, w, \dots) - x,$$

$$DXW = \text{CALCULATE}(u, v, w + \sigma_w, \dots) - x,$$

etc.

donde $\sigma_u, \sigma_v, \sigma_w$, etc. son las desviaciones estándar estimadas. Las contribuciones resultantes a la incertidumbre en x se combinan en cuadratura como

$$DX = \sqrt{(DXU)^2 + (DXV)^2 + (DXW)^2 + \dots}$$

Nótese que no sería correcto incorporar todas las variaciones en una sola ecuación como

$$DX = \text{CALCULATE}(u + \sigma_u, v + \sigma_v, w + \sigma_w, \dots) - x$$

porque esto implicaría que los errores σ_u, σ_v , etc. fueran cantidades realmente conocidas, en lugar de variaciones independientes y estimadas de las cantidades medidas, correspondientes a estimaciones de los anchos de las distribuciones de las variables medidas.

Resumen

- **Covarianza:** $\sigma_{uv}^2 = \langle (u - \bar{u})(v - \bar{v}) \rangle$
- **Propagación de errores:** Suponiendo $x = f(u, v)$:

$$\sigma_x^2 = \sigma_u^2 \left(\frac{\partial x}{\partial u} \right)^2 + \sigma_v^2 \left(\frac{\partial x}{\partial v} \right)^2 + 2\sigma_{uv}^2 \left(\frac{\partial x}{\partial u} \right) \left(\frac{\partial x}{\partial v} \right)$$

Para u y v no correlacionados, $\sigma_{uv}^2 = 0$.

■ Fórmulas específicas:

$x = au + bv,$	$\sigma_x^2 = a^2\sigma_u^2 + b^2\sigma_v^2 + 2ab\sigma_{uv}^2$
$x = auv,$	$\frac{\sigma_x^2}{x^2} = \frac{\sigma_u^2}{u^2} + \frac{\sigma_v^2}{v^2} + 2\frac{\sigma_{uv}^2}{uv}$
$x = \frac{au}{v},$	$\frac{\sigma_x^2}{x^2} = \frac{\sigma_u^2}{u^2} + \frac{\sigma_v^2}{v^2} - 2\frac{\sigma_{uv}^2}{uv}$
$x = au^b,$	$\frac{\sigma_x}{x} = b\frac{\sigma_u}{u}$
$x = ae^{bu},$	$\frac{\sigma_x}{x} = b\sigma_u$
$x = a^{bu},$	$\frac{\sigma_x}{x} = (b \ln a)\sigma_u$
$x = a \ln(bu),$	$\sigma_x = ab\frac{\sigma_u}{u}$
$x = a \cos(bu),$	$\sigma_x = ab \sin(bu) \sigma_u$
$x = a \sin(bu),$	$\sigma_x = ab \cos(bu) \sigma_u$

Ejercicios

Ejercicio 3.1

Encuentre la incertidumbre σ_x en x como función de las incertidumbres σ_u y σ_v en u y v para las siguientes funciones:

(a) $x = \frac{1}{2}(u + v)$ (b) $x = \frac{1}{2}(u - v)$ (c) $x = \frac{1}{u^2}$ (d) $x = uv^2$ (e) $x = u^2 + v^2$

Solución: Usamos propagación de errores, suponiendo u y v independientes ($\sigma_{uv} = 0$).

(a) $x = \frac{1}{2}(u + v)$. $\frac{\partial x}{\partial u} = \frac{1}{2}$, $\frac{\partial x}{\partial v} = \frac{1}{2}$. Por tanto, $\sigma_x^2 = \left(\frac{1}{2}\right)^2 \sigma_u^2 + \left(\frac{1}{2}\right)^2 \sigma_v^2 = \frac{1}{4}(\sigma_u^2 + \sigma_v^2)$.
Entonces $\sigma_x = \frac{1}{2}\sqrt{\sigma_u^2 + \sigma_v^2}$.

(b) $x = \frac{1}{2}(u - v)$. Las derivadas son las mismas, $\frac{1}{2}$ y $-\frac{1}{2}$. Al elevar al cuadrado, el signo desaparece. Por tanto, $\sigma_x^2 = \frac{1}{4}(\sigma_u^2 + \sigma_v^2)$, igual que en (a). $\sigma_x = \frac{1}{2}\sqrt{\sigma_u^2 + \sigma_v^2}$.

(c) $x = 1/u^2 = u^{-2}$. $\frac{dx}{du} = -2u^{-3}$. Entonces $\sigma_x^2 = (-2u^{-3})^2 \sigma_u^2 = 4u^{-6}\sigma_u^2$. En términos de x , $u^{-2} = x$, $u^{-6} = x^3$. Por tanto, $\sigma_x = 2x^{3/2}\sigma_u$? Mejor: $\sigma_x = |-2u^{-3}|\sigma_u = \frac{2}{|u|^3}\sigma_u$. También podemos escribir $\frac{\sigma_x}{x} = 2\frac{\sigma_u}{u}$.

(d) $x = uv^2$. $\frac{\partial x}{\partial u} = v^2$, $\frac{\partial x}{\partial v} = 2uv$. Entonces $\sigma_x^2 = v^4\sigma_u^2 + (2uv)^2\sigma_v^2 = v^4\sigma_u^2 + 4u^2v^2\sigma_v^2$.
Podemos escribir la incertidumbre relativa: $\frac{\sigma_x^2}{x^2} = \frac{\sigma_u^2}{u^2} + 4\frac{\sigma_v^2}{v^2}$.

(e) $x = u^2 + v^2$. $\frac{\partial x}{\partial u} = 2u$, $\frac{\partial x}{\partial v} = 2v$. Entonces $\sigma_x^2 = (2u)^2\sigma_u^2 + (2v)^2\sigma_v^2 = 4u^2\sigma_u^2 + 4v^2\sigma_v^2$.
Por tanto, $\sigma_x = 2\sqrt{u^2\sigma_u^2 + v^2\sigma_v^2}$.

Ejercicio 3.2

Si el diámetro de una mesa redonda se determina con una precisión del 1 %, ¿qué tan bien se conoce su área? ¿Sería mejor determinar su radio con una precisión del 1 %?

Solución: Área $A = \pi r^2 = \pi(d/2)^2 = \frac{\pi}{4}d^2$. La incertidumbre relativa en d es $\sigma_d/d = 0,01$. Entonces $\frac{\sigma_A}{A} = 2\frac{\sigma_d}{d} = 0,02$, es decir, 2 %. Si determinamos el radio con un 1 %, entonces $\frac{\sigma_A}{A} = 2\frac{\sigma_r}{r} = 0,02$, el mismo resultado. No hay diferencia, porque el radio y el diámetro están relacionados por un factor constante.

Ejercicio 3.3

La resistencia R de un conductor cilíndrico es proporcional a su longitud L e inversamente proporcional a su área de sección transversal $A = \pi r^2$. ¿Cuál debe determinarse con mayor precisión, r o L , para optimizar la determinación de R ? ¿Cuánto mayor?

Solución: $R = k \frac{L}{\pi r^2}$. La incertidumbre relativa es $\frac{\sigma_R}{R} = \frac{\sigma_L}{L} + 2 \frac{\sigma_r}{r}$ (en cuadratura, pero en términos de contribuciones). Para minimizar la incertidumbre, debemos determinar con mayor precisión la variable que tiene el coeficiente más grande en la expresión de la incertidumbre relativa. Aquí, el radio r tiene un factor 2, mientras que L tiene factor 1. Por tanto, r debe determinarse con el doble de precisión (la mitad de incertidumbre relativa) para que su contribución sea igual a la de L . Si $\frac{\sigma_r}{r} = \frac{1}{2} \frac{\sigma_L}{L}$, entonces ambas contribuciones son iguales. En general, para una incertidumbre dada, la de r contribuye el doble.

Ejercicio 3.4

La actividad inicial N_0 y la vida media τ de una fuente radiactiva se conocen con incertidumbres del 1 % cada una. La actividad sigue la distribución exponencial $N = N_0 e^{-t/\tau}$. La incertidumbre en la actividad inicial N_0 domina en t pequeño; la incertidumbre en la vida media τ domina en t grande ($t \gg \tau$). ¿Para qué valor de t/τ contribuyen igualmente las incertidumbres en N_0 y τ a la incertidumbre en N ? ¿Cuál es la incertidumbre resultante en N ?

Solución: $N = N_0 e^{-t/\tau}$. Calculamos la incertidumbre por propagación. Las derivadas parciales: $\frac{\partial N}{\partial N_0} = e^{-t/\tau}$ $\frac{\partial N}{\partial \tau} = N_0 e^{-t/\tau} \cdot \frac{t}{\tau^2} = N \frac{t}{\tau^2}$ Entonces $\sigma_N^2 = (e^{-t/\tau})^2 \sigma_{N_0}^2 + (N \frac{t}{\tau^2})^2 \sigma_\tau^2$. Dividiendo por N^2 :

$$\left(\frac{\sigma_N}{N}\right)^2 = \left(\frac{\sigma_{N_0}}{N_0}\right)^2 + \left(\frac{t}{\tau}\right)^2 \left(\frac{\sigma_\tau}{\tau}\right)^2$$

Dado que $\sigma_{N_0}/N_0 = 0,01$ y $\sigma_\tau/\tau = 0,01$, tenemos

$$\left(\frac{\sigma_N}{N}\right)^2 = (0,01)^2 \left[1 + \left(\frac{t}{\tau}\right)^2\right]$$

Las contribuciones son iguales cuando $1 = (t/\tau)^2$, es decir, $t/\tau = 1$. En ese punto, $\sigma_N/N = 0,01\sqrt{1+1} = 0,01\sqrt{2} \approx 0,01414$ o 1,414 %.

Ejercicio 3.5

La ley de Snell relaciona el ángulo de refracción θ_2 de un rayo de luz que viaja en un medio con índice de refracción n_2 con el ángulo de incidencia θ_1 de un rayo que viaja en un medio con índice n_1 mediante la ecuación $n_2 \sin \theta_2 = n_1 \sin \theta_1$. Encuentre n_2 y su incertidumbre a partir de las siguientes mediciones:

$$\theta_1 = (22,03 \pm 0,2)^\circ \quad \theta_2 = (14,45 \pm 0,2)^\circ \quad n_1 = 1,0000$$

Solución: $n_2 = n_1 \frac{\sin \theta_1}{\sin \theta_2} = \frac{\sin 22,03^\circ}{\sin 14,45^\circ}$. Calculamos: $\sin 22,03^\circ \approx \sin(22,03 \times \pi/180) = \sin(0,3845 \text{ rad}) \approx 0,3749$ $\sin 14,45^\circ \approx \sin(0,2522 \text{ rad}) \approx 0,2495$ Por tanto, $n_2 \approx 0,3749/0,2495 \approx 1,5026$.

Ahora, la incertidumbre. Escribimos $n_2 = f(\theta_1, \theta_2)$. Las derivadas: $\frac{\partial n_2}{\partial \theta_1} = n_1 \frac{\cos \theta_1}{\sin \theta_2}$ $\frac{\partial n_2}{\partial \theta_2} = -n_1 \frac{\sin \theta_1 \cos \theta_2}{\sin^2 \theta_2} = -n_2 \frac{\cos \theta_2}{\sin \theta_2}$ Las incertidumbres en grados deben convertirse a radianes: $\sigma_\theta = 0,2^\circ = 0,2 \times \pi/180 = 0,003490 \text{ rad}$. Evaluamos las derivadas en los valores medidos: $\frac{\partial n_2}{\partial \theta_1} =$

$\frac{\cos 22,03^\circ}{\sin 14,45^\circ} = \frac{0,9270}{0,2495} \approx 3,715$ $\frac{\partial n_2}{\partial \theta_2} = -1,5026 \times \frac{\cos 14,45^\circ}{\sin 14,45^\circ} = -1,5026 \times \frac{0,9684}{0,2495} = -1,5026 \times 3,882 \approx -5,835$ Entonces $\sigma_{n_2}^2 = (3,715)^2(0,00349)^2 + (-5,835)^2(0,00349)^2 = (0,00349)^2(13,80 + 34,05) = (0,00349)^2 \times 47,85$. $\sigma_{n_2} = 0,00349 \times \sqrt{47,85} = 0,00349 \times 6,917 \approx 0,0241$. Por tanto, $n_2 = 1,503 \pm 0,024$.

Ejercicio 3.6

El cambio en la frecuencia producido por el desplazamiento Doppler cuando una fuente de sonido de frecuencia f se mueve con velocidad v hacia un observador fijo viene dado por $\Delta f = fv/(u-v)$, donde u es la velocidad del sonido. A partir de los siguientes valores de u , f y v y sus incertidumbres, calcule Δf y su incertidumbre. ¿Cuál, si alguna, de las incertidumbres hace una contribución insignificante a la incertidumbre en Δf ?

$$u = (332 \pm 8) \text{ m/s}; \quad f = (1000 \pm 1) \text{ Hz}; \quad v = (0,123 \pm 0,003) \text{ m/s}.$$

Solución: Primero calculamos $\Delta f = \frac{1000 \times 0,123}{332 - 0,123} = \frac{123}{331,877} \approx 0,3706 \text{ Hz}$.

Para la incertidumbre, necesitamos las derivadas parciales. Sea $F = \frac{fv}{u-v}$. Calculamos:

$$\frac{\partial F}{\partial f} = \frac{v}{u-v} \quad \frac{\partial F}{\partial v} = \frac{f(u-v)+fv}{(u-v)^2} = \frac{fu}{(u-v)^2} \quad \frac{\partial F}{\partial u} = -\frac{fv}{(u-v)^2}$$

$$\text{Evaluamos con los valores: } u-v \approx 331,877 \quad \frac{\partial F}{\partial f} = \frac{0,123}{331,877} \approx 0,0003706 \quad \frac{\partial F}{\partial v} = \frac{1000 \times 332}{(331,877)^2} = \frac{332000}{110142} \approx 3,015 \quad \frac{\partial F}{\partial u} = -\frac{1000 \times 0,123}{(331,877)^2} = -\frac{123}{110142} \approx -0,001117$$

Las incertidumbres: $\sigma_f = 1$, $\sigma_v = 0,003$, $\sigma_u = 8$. Entonces $\sigma_F^2 = (0,0003706)^2 \cdot 1^2 + (3,015)^2 \cdot (0,003)^2 + (-0,001117)^2 \cdot 8^2$. Calculamos cada término: Término 1: $1,374 \times 10^{-7}$ Término 2: $9,09 \times 9 \times 10^{-6} = 81,81 \times 10^{-6} = 8,181 \times 10^{-5}$ Término 3: $1,247 \times 10^{-6} \times 64 = 7,98 \times 10^{-5}$ Suma: $1,374 \times 10^{-7} + 8,181 \times 10^{-5} + 7,98 \times 10^{-5} = 1,6175 \times 10^{-4}$ $\sigma_F = \sqrt{1,6175 \times 10^{-4}} = 0,01272 \text{ Hz}$.

Las contribuciones de v y u son comparables y mucho mayores que la de f , que es insignificante.

Ejercicio 3.7

El radio de un círculo puede calcularse a partir de mediciones de la longitud L de una cuerda y la distancia h desde la cuerda a la circunferencia del círculo mediante la ecuación $R = L^2/2h + h/2$. Calcule el radio y su incertidumbre a partir de los siguientes valores de L y h .

$$(a) \quad L = (125,0 \pm 5,0) \text{ cm}, \quad h = (0,51 \pm 0,22) \text{ cm}$$

$$(b) \quad L = (125,0 \pm 5,0) \text{ cm}, \quad h = (57,4 \pm 1,2) \text{ cm}$$

¿Fue necesario usar el segundo término para calcular R en ambos casos? Explique.

Solución:

(a) $R = \frac{L^2}{2h} + \frac{h}{2}$. Primero término: $\frac{125^2}{2 \times 0,51} = \frac{15625}{1,02} \approx 15318,6 \text{ cm}$. Segundo término: $0,51/2 = 0,255 \text{ cm}$. Por tanto, $R \approx 15318,9 \text{ cm}$. El segundo término es despreciable comparado con el primero. Para la incertidumbre, necesitamos derivadas: $\frac{\partial R}{\partial L} = \frac{L}{h}$ $\frac{\partial R}{\partial h} = -\frac{L^2}{2h^2} + \frac{1}{2}$ Evaluamos: $\frac{\partial R}{\partial L} = \frac{125}{0,51} \approx 245,1$ $\frac{\partial R}{\partial h} = -\frac{15625}{2 \times 0,2601} + 0,5 = -\frac{15625}{0,5202} + 0,5 \approx -30036 + 0,5 = -30035,5$ $\sigma_R^2 = (245,1)^2(5)^2 + (-30035,5)^2(0,22)^2 = (60075) + (9,02 \times 10^8) \times 0,0484$. El primer término es 60075, el segundo: $9,02 \times 10^8 \times 0,0484 = 4,366 \times 10^7$. Suma $\approx 4,372 \times 10^7$, $\sigma_R \approx 6613 \text{ cm}$. Por tanto, $R = 15319 \pm 6600 \text{ cm}$, una incertidumbre enorme debido a la gran incertidumbre en h y la dependencia inversa.

- (b) $R = \frac{125^2}{2 \times 57,4} + \frac{57,4}{2} = \frac{15625}{114,8} + 28,7 = 136,1 + 28,7 = 164,8 \text{ cm}$. Aquí ambos términos son comparables. Derivadas: $\frac{\partial R}{\partial L} = \frac{125}{57,4} \approx 2,178$ $\frac{\partial R}{\partial h} = -\frac{15625}{2 \times (57,4)^2} + 0,5 = -\frac{15625}{2 \times 3294,76} + 0,5 = -\frac{15625}{6589,52} + 0,5 \approx -2,371 + 0,5 = -1,871$ $\sigma_R^2 = (2,178)^2(5)^2 + (-1,871)^2(1,2)^2 = (4,744 \times 25) + (3,50 \times 1,44) = 118,6 + 5,04 = 123,64$ $\sigma_R \approx 11,12 \text{ cm}$. Por tanto, $R = 164,8 \pm 11,1 \text{ cm}$.

En (a) el segundo término es despreciable, en (b) es necesario.

Ejercicio 3.8

Los estudiantes miden la velocidad del sonido en el laboratorio creando un pulso de sonido que viaja por un tubo de 1 m y se refleja de vuelta, de modo que tanto el pulso inicial como el reflejado son detectados por el mismo micrófono. Las señales son registradas por computadora y las amplitudes de los pulsos versus el tiempo se muestran en el monitor. Los estudiantes miden los intervalos de tiempo para diez pares de pulsos en el monitor y registran los siguientes tiempos de tránsito en milisegundos:

5.77 5.78 5.74 5.80 5.78 5.83 5.76 5.78 5.76 5.78

- Examine los datos y trate de estimar la dispersión de los datos, es decir, su desviación estándar.
- Calcule el tiempo de tránsito medio, la desviación estándar de la muestra y el error estándar (error en la media).
- Una de las mediciones de tiempo de tránsito difiere de la media en más de 2 desviaciones estándar. En una muestra de diez eventos, ¿cuántas mediciones predice la estadística gaussiana que difieran de la media en 2 o más desviaciones estándar? Consulte la Tabla C.2.
- Calcule la velocidad del sonido y su incertidumbre a partir de los datos.

Solución:

- Los datos oscilan entre 5.74 y 5.83. La desviación estándar parece ser del orden de 0.02-0.03.
- Media: sumamos: $5,77 + 5,78 = 11,55$, $+5,74=17,29$, $+5,80=23,09$, $+5,78=28,87$, $+5,83=34,70$, $+5,76=40,46$, $+5,78=46,24$, $+5,76=52,00$, $+5,78=57,78$. Media $\bar{t} = 57,78/10 = 5,778 \text{ ms}$. Desviaciones cuadráticas: $(5,77 - 5,778)^2 = (-0,008)^2 = 0,000064$ $(5,78 - 5,778)^2 = (0,002)^2 = 0,000004$ $(5,74 - 5,778)^2 = (-0,038)^2 = 0,001444$ $(5,80 - 5,778)^2 = (0,022)^2 = 0,000484$ $(5,78 - 5,778)^2 = 0,000004$ $(5,83 - 5,778)^2 = (0,052)^2 = 0,002704$ $(5,76 - 5,778)^2 = (-0,018)^2 = 0,000324$ $(5,78 - 5,778)^2 = 0,000004$ $(5,76 - 5,778)^2 = 0,000324$ $(5,78 - 5,778)^2 = 0,000004$ Suma de cuadrados $= 0,000064 + 0,000004 = 0,000068$, $+0,001444=0,001512$, $+0,000484=0,001996$, $+0,000004=0,002000$, $+0,002704=0,004704$, $+0,000324=0,005028$, $+0,000004=0,005032$, $+0,000324=0,005356$, $+0,000004=0,005360$. Varianza muestral $s^2 = \frac{0,005360}{9} = 0,0005956$. Desviación estándar $s = \sqrt{0,0005956} \approx 0,0244 \text{ ms}$. Error estándar $\sigma_{\bar{t}} = s/\sqrt{10} = 0,0244/3,1623 \approx 0,00772 \text{ ms}$.

- (c) La desviación de 2σ sería $2 \times 0,0244 = 0,0488$. El valor 5.83 se desvía en 0.052, que es mayor. Según la tabla gaussiana, la probabilidad de una desviación $\geq 2\sigma$ es aproximadamente 0,0455 (bilateral). En una muestra de 10, el número esperado es $10 \times 0,0455 = 0,455$, menos de 1. Por tanto, no es sorprendente tener un valor a 2.1σ .
- (d) La distancia recorrida por el pulso es de 2 m (ida y vuelta). Velocidad $v = 2/t$. Con $t = 5,778 \text{ ms} = 5,778 \times 10^{-3} \text{ s}$, $v = 2/5,778 \times 10^{-3} = 346,1 \text{ m/s}$. Incertidumbre: $\sigma_v = \frac{2}{t^2} \sigma_t = \frac{2}{(5,778 \times 10^{-3})^2} \times 0,00772 \times 10^{-3}$. Primero, $t^2 = 3,338 \times 10^{-5}$, $2/t^2 = 59900$. $\sigma_t = 7,72 \times 10^{-6} \text{ s}$. Entonces $\sigma_v = 59900 \times 7,72 \times 10^{-6} = 0,462 \text{ m/s}$. Por tanto, $v = 346,1 \pm 0,5 \text{ m/s}$.

Ejercicio 3.9

Los estudiantes en el laboratorio de pregrado registraron las siguientes cuentas en intervalos de 1 minuto de una fuente radiactiva. La tasa de desintegración media nominal de la fuente es de 3.7 desintegraciones por minuto.

Desintegraciones por minuto	0	1	2	3	4	5	6	7	8	9	10
Frecuencia de ocurrencia	19	20	24	19	11	11	10	3	1	1	1

- (a) Encuentre la tasa de desintegración media y su desviación estándar. Compare la desviación estándar con el valor esperado de la distribución de Poisson para el valor medio que obtuvo.
- (b) Trace un histograma de los datos y muestre las curvas de Poisson tanto de la distribución parental como de la observada.

Solución:

- (a) Total de intervalos: $19 + 20 + 24 + 19 + 11 + 11 + 10 + 3 + 1 + 1 + 1 = 120$. Suma de cuentas: $0 \cdot 19 + 1 \cdot 20 + 2 \cdot 24 + 3 \cdot 19 + 4 \cdot 11 + 5 \cdot 11 + 6 \cdot 10 + 7 \cdot 3 + 8 \cdot 1 + 9 \cdot 1 + 10 \cdot 1$. Calculamos: $0 + 20 = 20$, $+48=68$, $+57=125$, $+44=169$, $+55=224$, $+60=284$, $+21=305$, $+8=313$, $+9=322$, $+10=332$. Media $\bar{x} = 332/120 \approx 2,7667$. Varianza: necesitamos $\sum x^2$. Calculamos: $0^2 \cdot 19 = 0$, $1^2 \cdot 20 = 20$, $2^2 \cdot 24 = 4 \cdot 24 = 96$, $3^2 \cdot 19 = 9 \cdot 19 = 171$, $4^2 \cdot 11 = 16 \cdot 11 = 176$, $5^2 \cdot 11 = 25 \cdot 11 = 275$, $6^2 \cdot 10 = 36 \cdot 10 = 360$, $7^2 \cdot 3 = 49 \cdot 3 = 147$, $8^2 \cdot 1 = 64$, $9^2 \cdot 1 = 81$, $10^2 \cdot 1 = 100$. Suma: $0 + 20 = 20$, $+96=116$, $+171=287$, $+176=463$, $+275=738$, $+360=1098$, $+147=1245$, $+64=1309$, $+81=1390$, $+100=1490$. $\sum x^2 = 1490$. Entonces $s^2 = \frac{1}{119}(1490 - 120 \times (2,7667)^2)$. $(2,7667)^2 = 7,654$, $120 \times 7,654 = 918,48$. Resta: $1490 - 918,48 = 571,52$. Dividido por 119: $s^2 \approx 4,803$, $s \approx 2,192$. La desviación estándar de Poisson esperada sería $\sqrt{\mu} = \sqrt{2,767} \approx 1,663$. La observada es mayor, indicando una distribución más ancha que la Poisson.
- (b) Se puede trazar un histograma con los datos y superponer la curva de Poisson con $\mu = 2,767$ y la distribución observada.

Ejercicio 3.10

Encuentre mediante integración numérica la probabilidad de observar un valor de la distribución gaussiana que sea:

- (a) Más de 1 desviación estándar (σ) de la media.
- (b) Más de 2 desviaciones estándar de la media.
- (c) Más de 3 desviaciones estándar de la media.

Solución: La probabilidad de estar más allá de $k\sigma$ es $2 \times (1 - \Phi(k))$, donde $\Phi(k)$ es la función de distribución acumulada. De tablas:

- (a) $k = 1$: $\Phi(1) \approx 0,8413$, entonces $P = 2 \times (1 - 0,8413) = 0,3174$.
- (b) $k = 2$: $\Phi(2) \approx 0,97725$, $P = 2 \times 0,02275 = 0,0455$.
- (c) $k = 3$: $\Phi(3) \approx 0,99865$, $P = 2 \times 0,00135 = 0,0027$.

Ejercicio 3.11

Encuentre mediante integración numérica la probabilidad de observar un valor de la distribución lorentziana que sea:

- (a) Más de 1 semiancho ($\Gamma/2$) de la media.
- (b) Más de 2 semianchos de la media.
- (c) Más de 3 semianchos de la media.

Solución: La distribución lorentziana tiene CDF $F(x) = \frac{1}{2} + \frac{1}{\pi} \arctan\left(\frac{x-\mu}{\Gamma/2}\right)$. Para desviaciones d en unidades de $\Gamma/2$, la probabilidad de estar más allá de d es $P(|x - \mu| > d) = 1 - [F(\mu + d) - F(\mu - d)] = 1 - \left[\frac{1}{\pi} \arctan(d) + \frac{1}{\pi} \arctan(d)\right]$? En realidad, $F(\mu + d) = \frac{1}{2} + \frac{1}{\pi} \arctan(d)$, $F(\mu - d) = \frac{1}{2} - \frac{1}{\pi} \arctan(d)$. Por tanto, $F(\mu + d) - F(\mu - d) = \frac{2}{\pi} \arctan(d)$. Entonces $P(|x - \mu| > d) = 1 - \frac{2}{\pi} \arctan(d)$.

- (a) $d = 1$: $\arctan(1) = \pi/4$, $P = 1 - \frac{2}{\pi} \cdot \frac{\pi}{4} = 1 - \frac{1}{2} = 0,5$.
- (b) $d = 2$: $\arctan(2) \approx 1,10715$ rad, $P = 1 - \frac{2}{\pi} \times 1,10715 = 1 - 0,7048 = 0,2952$.
- (c) $d = 3$: $\arctan(3) \approx 1,2490$ rad, $P = 1 - \frac{2}{\pi} \times 1,2490 = 1 - 0,795 = 0,205$.

Capítulo 4: Estimaciones de la Media y los Errores

4.1 Método de Mínimos Cuadrados

En el Capítulo 2 definimos la media μ de la distribución parental y observamos que la estimación más probable de la media μ de un conjunto aleatorio de observaciones es el promedio $\bar{x}$ de las observaciones. La justificación de esa afirmación se basa en la suposición de que las mediciones se distribuyen según la distribución gaussiana. En general, esperamos que la distribución de las mediciones sea gaussiana o de Poisson, pero debido a que estas distribuciones son indistinguibles para la mayoría de las situaciones físicas, podemos suponer que se obedece la distribución gaussiana.

Método de Máxima Verosimilitud

Supongamos que, en un experimento, hemos observado un conjunto de N puntos de datos que se seleccionan aleatoriamente del conjunto infinito de la población parental, distribuidos según la distribución parental. Si la distribución parental es gaussiana con media μ y desviación estándar σ , la probabilidad dP_i de hacer una sola observación x_i dentro de un intervalo dx está dada por

$$dP_i = p_i dx \quad (4.1)$$

con función de probabilidad $p_i = p_G(x_i; \mu, \sigma)$ [véase la Ecuación (2.23)]. Por simplicidad, denotaremos la probabilidad P_i de hacer una observación x_i por

$$P_i = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x_i - \mu}{\sigma} \right)^2 \right] \quad (4.2)$$

Debido a que, en general, no conocemos la media μ de la distribución para un experimento físico, debemos estimarla a partir de algún parámetro derivado experimentalmente. Llamemos a la estimación μ' . ¿Qué fórmula para derivar μ' de los datos producirá la máxima verosimilitud de que la distribución parental tenía una media igual a μ ?

Si planteamos la hipótesis de una distribución de prueba con una media μ' y una desviación estándar $\sigma' = \sigma$, la probabilidad de observar el valor x_i está dada por la función de probabilidad

$$P_i(\mu') = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x_i - \mu'}{\sigma} \right)^2 \right] \quad (4.3)$$

Considerando todo el conjunto de N observaciones, la probabilidad de observar ese conjunto particular está dada por el producto de las funciones de probabilidad individuales, $P_i(\mu')$

$$P(\mu') = \prod_{i=1}^N P_i(\mu') \quad (4.4)$$

donde el símbolo $\prod$ denota el producto de las N probabilidades $P_i(\mu')$

El producto de las constantes que multiplican la exponencial en la Ecuación (4.3) es el mismo que el producto elevado a la N -ésima potencia, y el producto de las exponenciales es el mismo que la exponencial de la suma de los argumentos. Por lo tanto, la Ecuación (4.4) se reduce a

$$P(\mu') = \left(\frac{1}{\sigma\sqrt{2\pi}} \right)^N \exp \left[-\frac{1}{2} \sum \left(\frac{x_i - \mu'}{\sigma} \right)^2 \right] \quad (4.5)$$

Según el método de máxima verosimilitud, si comparamos las probabilidades $P(\mu')$ de obtener nuestro conjunto de observaciones a partir de varias poblaciones parentales con diferentes medias μ' pero con la misma desviación estándar $\sigma' = \sigma$, la probabilidad es mayor de que los datos se hayan derivado de una población con $\mu' = \mu$; es decir, se supone que la población más probable de la cual podría haber provenido un conjunto de datos de este tipo es la correcta.

Cálculo de la Media

El método de máxima verosimilitud establece que el valor más probable para μ' es el que da el valor máximo para la probabilidad $P(\mu')$ de la Ecuación (4.5). Debido a que esta probabilidad es el producto de una constante por una exponencial con un argumento negativo, maximizar la probabilidad $P(\mu')$ es equivalente a minimizar el argumento X de la exponencial,

$$X = -\frac{1}{2} \sum \left(\frac{x_i - \mu'}{\sigma} \right)^2 \quad (4.6)$$

Para encontrar el valor mínimo de una función X igualamos la derivada de la función a 0,

$$\frac{dX}{d\mu'} = -\frac{d}{d\mu'} \frac{1}{2} \sum \left(\frac{x_i - \mu'}{\sigma} \right)^2 = 0 \quad (4.7)$$

y obtenemos

$$\frac{dX}{d\mu'} = -\frac{1}{2} \sum \frac{d}{d\mu'} \left(\frac{x_i - \mu'}{\sigma} \right)^2 = \sum \left(\frac{x_i - \mu'}{\sigma^2} \right) = 0 \quad (4.8)$$

que, debido a que σ es una constante, da

$$\mu' = \bar{x} \equiv \frac{1}{N} \sum x_i \quad (4.9)$$

Por lo tanto, el método de máxima verosimilitud para estimar la media maximizando la probabilidad $P(\mu')$ de la Ecuación (4.5) muestra que el valor más probable de la media es simplemente el promedio $\bar{x}$ como se definió en la Ecuación (1.1).

Error Estimado en la Media

¿Qué incertidumbre σ está asociada con nuestra determinación de la media μ' en la Ecuación (4.9)? Hemos supuesto que todos los puntos de datos x_i se extrajeron de la misma distribución parental y, por lo tanto, se obtuvieron con una incertidumbre caracterizada por la misma desviación estándar σ . Cada uno de estos puntos de datos contribuye a la determinación de la media μ' y, por lo tanto, cada punto de datos contribuye con cierta incertidumbre a la determinación de los resultados finales. Un histograma de nuestros puntos de datos seguiría la forma gaussiana, con un pico en el valor μ' y exhibiendo un ancho correspondiente a la desviación estándar σ . Claramente, podemos determinar la media con mucha mayor precisión que $\pm\sigma$, y nuestra determinación mejorará a medida que aumentemos el número de puntos medidos N y podamos así mejorar la concordancia entre nuestro histograma experimental y la curva gaussiana suave.

En el Capítulo 3 desarrollamos la ecuación de propagación de errores [véase la Ecuación (3.13)] para encontrar la contribución de las incertidumbres en varios términos que contribuyen a un solo resultado. Aplicando esta relación a la Ecuación (4.9) para encontrar la varianza σ_μ^2 de la media μ' , obtenemos

$$\sigma_\mu^2 = \sum \left[\sigma_i^2 \left(\frac{\partial \mu'}{\partial x_i} \right)^2 \right] \quad (4.10)$$

donde la varianza σ_i^2 en cada punto de datos medido x_i se pondera por el cuadrado del efecto $\partial\mu'/\partial x_i$ que ese punto de datos tiene sobre el resultado. Esta aproximación despreja las correlaciones entre las mediciones x_i , así como los términos de segundo orden y superiores en la expansión de la varianza σ_μ^2 , pero debería ser una aproximación razonable siempre que ninguno de los puntos de datos contribuya con una porción importante del resultado final.

Si las incertidumbres de los puntos de datos son todas iguales $\sigma_i = \sigma$, las derivadas parciales en la Ecuación (4.10) son simplemente

$$\frac{\partial\mu'}{\partial x_i} = \frac{\partial}{\partial x_i} \left(\frac{1}{N} \sum x_i \right) = \frac{1}{N} \quad (4.11)$$

y combinando las Ecuaciones (4.10) y (4.11), obtenemos

$$\sigma_\mu^2 = \sum \left[\sigma_i^2 \left(\frac{1}{N} \right)^2 \right] = \frac{\sigma^2}{N} \quad (4.12)$$

para el error estimado en la media σ_μ . Por lo tanto, la desviación estándar de nuestra determinación de la media μ' y, en consecuencia, la precisión de nuestra estimación de la cantidad μ mejora a medida que la raíz cuadrada del número de mediciones.

La desviación estándar σ de la población parental puede estimarse a partir de una consideración del equipo y las condiciones de medición, o internamente a partir de los datos, según la Ecuación (1.8):

$$\sigma \simeq s = \sqrt{\frac{1}{N-1} \sum (x_i - \bar{x})^2} \quad (4.13)$$

que da para la incertidumbre σ_μ en la determinación de la media

$$\sigma_\mu = \frac{\sigma}{\sqrt{N}} \simeq \frac{s}{\sqrt{N}} \quad (4.14)$$

donde σ_μ se denomina desviación estándar de la media, o error estándar. En principio, el valor de σ obtenido de la Ecuación (4.13) debe ser consistente con la estimación realizada a partir del equipo experimental.

Ejemplo 4.1. Volvemos a la medición de la pelota que cae por parte del estudiante (Ejemplo 1.2). Supongamos que el tiempo para que la pelota caiga 2,00 m se había establecido previamente mediante mediciones cuidadosas como $T_{est} = 0,639$ s. El estudiante deja caer la pelota 50 veces y concluye, a partir de una consideración del temporizador electrónico y la disposición experimental, que la incertidumbre en cada una de sus mediciones individuales es $\pm 0,020$ s, consistente con la desviación estándar determinada a partir de los datos. Esta precisión finita del aparato da como resultado una dispersión de observaciones agrupadas alrededor del tiempo establecido, como se ilustra en el histograma de los datos en la Figura 1.2.

Debido a que las incertidumbres en todos los puntos de datos son iguales ($s_i = s$), el estudiante calcula a partir de sus mediciones y la Ecuación (4.9) que su estimación del tiempo medio es $\mu \simeq \bar{T} = 0,635$ s, con una desviación estándar de la Ecuación (4.13) de $\sigma \simeq s = 0,020$ s. A partir de la Ecuación (4.14), estima la incertidumbre en su determinación de la media como $\sigma_\mu \simeq$

$s/\sqrt{N} = 0,020/\sqrt{50}$ o $\sigma_\mu \simeq 0,0028$. Él cita su resultado experimental como $T_{exp} = (0,635 \pm 0,003)$ s.

Para comparar su valor experimental T_{exp} con el valor establecido T_{est} , el estudiante calcula el número de desviaciones estándar en que difieren, $n = |T_{exp} - T_{est}|/\sigma_\mu = 1,4$. De la integral de la ecuación de probabilidad gaussiana en la Tabla C.2, observamos que podríamos esperar que una medición esté dentro de 1.4 desviaciones estándar en aproximadamente el 83,8 % de los experimentos repetidos, o que exceda 1.4 desviaciones estándar en aproximadamente el 16,2 % de los casos.

Es importante darse cuenta de que la desviación estándar de los datos no disminuye con la medición repetida; solo se vuelve mejor determinada. Por otro lado, la desviación estándar de la media disminuye a medida que la raíz cuadrada del número de mediciones, lo que indica la mejora en nuestra capacidad para estimar la media de la distribución. Gráficamente podríamos ilustrar esta mejora trazando un histograma de los datos y observando que nuestra capacidad para determinar el pico de la distribución mejora a medida que aumenta el número de mediciones y la distribución se vuelve más suave.

Una Advertencia Sobre la Estadística

La Ecuación (4.12) podría sugerir que el error en la media de un conjunto de mediciones x_i puede reducirse indefinidamente mediante mediciones repetidas de x_i . Debemos ser conscientes de las limitaciones de esta ecuación antes de suponer que un resultado experimental puede mejorarse hasta cualquier grado de precisión deseado si estamos dispuestos a hacer suficiente trabajo. Hay tres limitaciones principales a considerar: las impuestas por el tiempo y los recursos disponibles, las impuestas por los errores sistemáticos y las impuestas por las fluctuaciones no estadísticas.

La primera de estas limitaciones es muy práctica. Puede que no sea posible realizar suficientes mediciones repetidas para lograr una mejora significativa en la desviación estándar del resultado. El estudiante del Ejemplo 1.2 puede ser capaz de hacer 50 mediciones del tiempo, pero puede que no tenga la paciencia para hacer cuatro veces más mediciones para reducir la incertidumbre en un factor de 2. Del mismo modo, un experimento en un acelerador de partículas puede tener asignadas 1000 horas de tiempo de haz. Puede que no sea posible aumentar la asignación a 16,000 horas para mejorar la precisión del resultado en un factor de 4.

Todos los experimentos están sujetos a errores sistemáticos en algún nivel. Incluso después de haber hecho todo lo posible por comprender el equipo experimental y corregir todos los defectos y errores de calibración conocidos, llega un punto en el que no se puede obtener más conocimiento. Por ejemplo, cualquier error en la colocación de los detectores que miden los tiempos al principio y al final de la caída de la pelota en el Ejemplo 1.2 conducirá a una incertidumbre sistemática en el tiempo (o en la distancia a través de la cual cayó la pelota) y, por lo tanto, en el resultado final del experimento.

La frase “fluctuaciones no estadísticas” puede ocultar una multitud de pecados, o al menos de problemas, en nuestros experimentos. Es raro que un experimento siga la distribución gaussiana más allá de 3 o 4 desviaciones estándar. Es más probable que aparezcan algunos puntos de datos inexplicables, o valores atípicos, en nuestra muestra de datos, lejos de la media. Tales puntos pueden implicar la existencia de otros puntos contaminantes dentro de la región de probabilidad central, enmascarados por el gran cuerpo de

puntos buenos. Obviamente se requiere un estudio exhaustivo de los efectos de fondo y las fuentes de posible contaminación, pero en algún nivel, estos efectos seguramente limitarán la precisión del experimento.

¿Qué debemos hacer con esos puntos inesperados que aparecen en nuestras gráficas de datos muy por fuera de su nivel de probabilidad? Algunos pueden surgir de una medición casualmente descuidada. ¿Nuestra atención se desvió en el instante en que debíamos registrar el punto de datos? ¿Intercambiamos accidentalmente dos dígitos al escribir nuestra medición? Tal vez podamos comprender y hacer correcciones para algunos de estos efectos. Otras anomalías en los datos pueden ser causadas por un mal funcionamiento del equipo. ¿Nuestro detector electrónico respondió a un choque metálico particularmente fuerte de la estación de radio rock local todopoderosa? ¿Nuestro confiable ordenador decidió revisar el correo electrónico en lugar de responder a una interrupción urgente de datos? ¿Y era la distribución que elegimos para representar nuestros datos la correcta para este experimento?

Podemos ser capaces de hacer correcciones para estos problemas, una vez que seamos conscientes de su existencia, pero siempre hay otros. En algún nivel, sucederán cosas que no podemos entender, y para las cuales no podemos hacer correcciones, y estas “cosas” causarán que aparezcan datos donde estadísticamente no debería haber datos, y que desaparezcan puntos de datos que deberían haber estado allí. La moraleja es: esté atento y no confíe en la estadística en las colas de las distribuciones.

Eliminación de Puntos de Datos

Habrán ocasiones en las que nos sintamos justificados para eliminar o corregir puntos de datos atípicos. Por ejemplo, supongamos que entre las mediciones de tiempo en el Ejemplo 1.2, el estudiante hubiera registrado una como 0.86 s. El estudiante probablemente concluiría que quiso escribir 0.68 s y, o bien ignoraría o corregiría el punto. ¿Qué pasaría si una medición se hubiera registrado como 0.72 s? ¿Debería tomarse alguna medida? El punto está aproximadamente a 4 desviaciones estándar de la media de todos los puntos de datos, y refiriéndonos a la Tabla C.2 vemos que hay aproximadamente una probabilidad del 0,06 % de obtener en una sola medición un valor que esté tan lejos de la media. Por lo tanto, en una muestra de 50 mediciones de este tipo, deberíamos esperar recolectar alrededor de $50 \times 0,00006 = 0,003$ de tales eventos.

La condición establecida para descartar datos en tales circunstancias se conoce como criterio de Chauvenet, que establece que debemos descartar un punto de datos si esperamos menos de medio evento que esté más lejos de la media que el punto sospechoso. Si nuestro punto de muestra satisface este requisito y, siempre que estemos convencidos de que nuestros datos siguen efectivamente la distribución gaussiana, podemos descartar el punto con una confianza razonable y volver a calcular la media y la desviación estándar. Por lo tanto, para los dos ejemplos citados en el párrafo anterior, sería permisible según el criterio de Chauvenet descartar tanto el punto de datos de 0.86 s como el de 0.72 s.

La eliminación de un punto atípico tiene un mayor efecto en la desviación estándar que en la media de una muestra de datos, porque la desviación estándar depende de los cuadrados de las desviaciones de la media. Eliminar uno de estos puntos conducirá a una desviación estándar más pequeña y tal vez otro punto o dos se convertirán ahora en candidatos para el rechazo. Debemos tener mucho cuidado al cambiar los datos a menos que estemos seguros de que comprendemos la fuente del problema que estamos tratando de corregir, y generalmente no se recomienda la eliminación repetida de puntos. También

debe enfatizarse la importancia de mantener buenos registros de cualquier cambio en la muestra de datos.

Ponderación de los Datos: Incertidumbres no Uniformes

Al desarrollar la probabilidad $P(\mu')$ de la Ecuación (4.5) a partir de las probabilidades individuales $P_i(\mu')$ de la Ecuación (4.3), asumimos que los puntos de datos se extrajeron todos de la misma población parental. En algunas circunstancias, sin embargo, habrá puntos de datos que se hayan medido con mejor o peor precisión que otros. Podemos expresar esto cuantitativamente suponiendo distribuciones parentales con la misma media μ pero con diferentes desviaciones estándar σ_i .

Si asignamos a cada punto de datos x_i su propia desviación estándar σ_i que representa la precisión con la que se midió ese punto de datos en particular, la Ecuación (4.5) para la probabilidad $P(\mu')$ de que el conjunto observado de N puntos de datos provenga de distribuciones parentales con medias $\mu_i = \mu'$ y desviaciones estándar σ_i se convierte en

$$P(\mu') = \prod_{i=1}^n \left(\frac{1}{\sigma_i \sqrt{2\pi}} \right) \exp \left[-\frac{1}{2} \sum_i \left(\frac{x_i - \mu'}{\sigma_i} \right)^2 \right] \quad (4.15)$$

Usando el método de máxima verosimilitud, debemos maximizar esta probabilidad, lo que equivale a minimizar el argumento en la exponencial. Igualando la primera derivada del argumento a 0, obtenemos

$$-\frac{1}{2} \frac{d}{d\mu'} \sum \left(\frac{x_i - \mu'}{\sigma_i} \right)^2 = \sum \left(\frac{x_i - \mu'}{\sigma_i^2} \right) = 0 \quad (4.16)$$

El valor más probable es, por lo tanto, el promedio ponderado de los puntos de datos

$$\mu' = \frac{\sum (x_i / \sigma_i^2)}{\sum (1 / \sigma_i^2)} \quad (4.17)$$

donde cada punto de datos x_i en la suma se pondera inversamente por su propia varianza σ_i^2 .

Error en la Media Ponderada

Si las incertidumbres de los puntos de datos no son iguales, evaluamos $\partial\mu'/\partial x_i$ a partir de la expresión de la Ecuación (4.17) para la media μ' :

$$\frac{\partial\mu'}{\partial x_i} = \frac{\partial}{\partial x_i} \frac{\sum (x_i / \sigma_i^2)}{\sum (1 / \sigma_i^2)} = \frac{1 / \sigma_i^2}{\sum (1 / \sigma_i^2)} \quad (4.18)$$

Sustituyendo este resultado en la Ecuación (4.10) se obtiene una fórmula general para la incertidumbre de la media σ_μ :

$$\sigma_\mu^2 = \sum \frac{1 / \sigma_i^2}{[\sum (1 / \sigma_i^2)]^2} = \frac{1}{\sum (1 / \sigma_i^2)} \quad (4.19)$$

Incertidumbres Relativas

Puede ser que se conozcan los valores relativos de σ_i , pero no las magnitudes absolutas. Por ejemplo, si un conjunto de datos se adquiere con un rango de escala y otro conjunto con un rango de escala diferente, los σ_i pueden ser iguales dentro de cada conjunto pero diferir en un factor conocido entre los dos conjuntos, como sería el caso si σ_i fuera proporcional al rango de escala. En tal caso, los valores relativos de los σ_i deben incluirse como factores de ponderación en la determinación de la media μ y su incertidumbre, y las magnitudes absolutas de los σ_i pueden estimarse a partir de la dispersión de los puntos de datos alrededor de la media.

Definamos factores de ponderación w_i tales que

$$kw_i = 1/\sigma_i^2 \quad (4.20)$$

donde k es una constante de escala desconocida y los σ_i son las desviaciones estándar asociadas con cada medición. Suponemos que se conocen los pesos w_i , pero que no se conocen los valores absolutos de las desviaciones estándar σ_i . Entonces, la Ecuación (4.17) puede escribirse

$$\mu' = \frac{\sum (x_i/\sigma_i^2)}{\sum (1/\sigma_i^2)} = \frac{\sum kw_i x_i}{\sum kw_i} = \frac{\sum w_i x_i}{\sum w_i} \quad (4.21)$$

y el resultado depende solo de los pesos relativos y no de las magnitudes absolutas de los σ_i .

Para encontrar el error en la estimación μ' de la media debemos calcular una varianza de los datos promedio ponderada:

$$\sigma^2 = \frac{\sum w_i (x_i - \mu')^2}{\sum w_i} \times \frac{N}{(N-1)} = \left(\frac{\sum w_i x_i^2}{\sum w_i} - \mu'^2 \right) \times \frac{N}{(N-1)} \quad (4.22)$$

donde el último factor corrige el hecho de que la media μ' se determinó a partir de los datos. Podemos reconocer la expresión entre paréntesis como la diferencia entre el promedio ponderado de los cuadrados de nuestras mediciones x_i y el cuadrado del promedio ponderado. La varianza de la media puede entonces determinarse sustituyendo la expresión para σ^2 de la Ecuación (4.22) en la Ecuación (4.14):

$$\sigma_\mu^2 = \frac{\sigma^2}{N} \quad (4.23)$$

Si se requieren, el valor de la constante de escala k y de los valores de las varianzas separadas σ_i pueden estimarse igualando las dos expresiones para σ_μ de las Ecuaciones (4.14) y (4.19) y reemplazando $1/\sigma_i^2$ por kw_i para dar

$$\frac{\sigma^2}{N} = \frac{1}{\sum (1/\sigma_i^2)} = \frac{1}{k \sum w_i} \quad (4.24)$$

por lo que

$$k = \frac{N}{\sigma^2} \frac{1}{\sum w_i} \quad (4.25)$$

y, por lo tanto,

$$\sigma_i^2 = \frac{1}{kw_i} = \frac{\sigma^2 \sum w_i}{N w_i} \quad (4.26)$$

Ejemplo 4.2. Un estudiante realiza un experimento para determinar el voltaje de una celda estándar. El estudiante hace 40 mediciones con el aparato y encuentra un resultado $\bar{x}_1 = 1,022$ V con una dispersión $s_1 = 0,01$ V en las observaciones. Después de revisar sus datos, se da cuenta de que podría mejorar el equipo para disminuir la incertidumbre en un factor de 2.5 ($s_2 = 0,004$ V), por lo que hace 10 mediciones más que arrojan un resultado $\bar{x}_2 = 1,018$ V.

La media de todas estas observaciones viene dada por la Ecuación (4.17):

$$\begin{aligned}\mu \approx \bar{x} &= \frac{\frac{40(1,022)}{0,01^2} + \frac{10(1,018)}{0,004^2}}{\frac{40}{0,01^2} + \frac{10}{0,004^2}} \\ &= \frac{40(1,022)/0,0001 + 10(1,018)/0,000016}{40/0,0001 + 10/0,000016} \\ &= \frac{40(1,022) \times 10000 + 10(1,018) \times 62500}{40 \times 10000 + 10 \times 62500} \\ &= \frac{408800 + 636250}{400000 + 625000} = \frac{1045050}{1025000} \approx 1,0196 \text{ V}\end{aligned}$$

La incertidumbre σ_μ en la media viene dada por la Ecuación (4.19):

$$\sigma_\mu = \left(\frac{40}{0,01^2} + \frac{10}{0,004^2} \right)^{-1/2} = (400000 + 625000)^{-1/2} = (1025000)^{-1/2} \approx 0,00099 \text{ V}$$

El resultado debe citarse como $\mu = (1,0196 \pm 0,0010)$ V, aunque $\mu = (1,020 \pm 0,001)$ V también sería aceptable. Llevar la cuarta cifra (que está completamente indefinida) después del punto decimal simplemente elimina cualquier posible error de redondeo si estos datos se fusionaran más tarde con datos de otros experimentos.

La precisión del resultado final en el Ejemplo 4.2 es mejor que la de cualquiera de las partes del experimento. Las incertidumbres en las estimaciones de las medias μ_1 y μ_2 determinadas a partir de los dos conjuntos de datos de forma independiente vienen dadas por la Ecuación (4.14):

$$s_{1\mu} = \frac{0,01}{\sqrt{40}} \text{ V} = 0,0016 \text{ V} \quad s_{2\mu} = \frac{0,004}{\sqrt{10}} \text{ V} = 0,0013 \text{ V}$$

Una comparación de estos valores ilustra el hecho de que tomar más mediciones disminuye la incertidumbre resultante solo como la raíz cuadrada del número de observaciones, que para este caso no es tan importante como disminuir σ_i .

¿Qué pasaría si el estudiante no conociera las incertidumbres absolutas en sus mediciones, sino solo que las incertidumbres habían mejorado en un factor de 2.5? Podría obtener la estimación de la media directamente de la Ecuación (4.21) reemplazando $1/\sigma_1^2$ por el peso $w_i = 1$, y $1/\sigma_2^2$ por el peso $w_i = 2,5^2 = 6,25$, para dar

$$\mu \approx \frac{40(1)(1,022) + 10(6,25)(1,018)}{40(1) + 10(6,25)} = \frac{40,88 + 63,625}{40 + 62,5} = \frac{104,505}{102,5} \approx 1,0196 \text{ V}$$

Para encontrar el error en la media, el estudiante podría calcular σ a partir de sus datos mediante la Ecuación (4.22) y usar la Ecuación (4.23) para estimar σ_μ .

Descarte de Datos

Aunque el estudiante en el Ejemplo 4.2 hizo cuatro veces más observaciones a la menor precisión (mayor incertidumbre), la contribución de alta precisión es más de 1.5 veces más efectiva que los datos de baja precisión para determinar la media. El estudiante probablemente debería considerar ignorar por completo los datos de baja precisión y usar solo los datos de alta precisión. ¿Por qué deberíamos desechar alguna vez datos que no se sabe que son malos? Además, dado que en este caso los primeros datos están ponderados de manera que son bastante poco importantes para el resultado, ¿qué sentido tiene descartarlos y, por lo tanto, desperdiciar todo el esfuerzo que se dedicó a recolectar esos primeros 40 puntos de datos?

Estas son preguntas que surgen una y otra vez en la ciencia experimental a medida que uno trabaja para encontrar los parámetros elusivos de la distribución parental. La respuesta reside en el hecho de que los experimentos tienden a mejorarse con el tiempo y, a menudo, el primer período de toma de datos se considera mejor como un período de entrenamiento para los experimentadores y un período de “puesta a punto” para el equipo. ¿Por qué arriesgarse a contaminar la muestra con datos de resultados inciertos cuando contribuyen tan poco al resultado final? Las desviaciones estándar relativas de los dos conjuntos de datos pueden servir como guía. Si la dispersión de la distribución posterior muestra una mejora marcada con respecto a la de los datos anteriores, entonces debemos considerar seriamente desechar los datos anteriores a menos que estemos seguros de su fiabilidad. No existe una regla fija que defina cuándo debe ignorarse un grupo de datos: se debe aplicar el sentido común. Sin embargo, debemos hacer un esfuerzo por superar el sesgo natural hacia el uso de todos los datos simplemente para recuperar nuestra inversión de tiempo y esfuerzo. Se puede ganar una mayor fiabilidad utilizando solo la muestra más limpia.

4.2 Fluctuaciones Estadísticas

Para algunos experimentos, las desviaciones estándar σ_i pueden determinarse con mayor precisión a partir de un conocimiento de la distribución parental estimada que a partir de los datos o de otros experimentos. Si se sabe que las observaciones siguen la distribución gaussiana, la desviación estándar σ es un parámetro libre y debe determinarse experimentalmente. Si, por el contrario, se sabe que las observaciones se distribuyen según la distribución de Poisson, la desviación estándar es igual a la raíz cuadrada de la media.

Como se discutió en el Capítulo 2, la probabilidad de Poisson es apropiada para describir la distribución de los puntos de datos en experimentos de conteo donde las observaciones son los números de eventos detectados por unidad de tiempo. En tales experimentos, hay fluctuaciones en la tasa de conteo de una observación a otra que resultan únicamente de la naturaleza intrínsecamente aleatoria del proceso y son independientes de cualquier imprecisión en la medición del intervalo de tiempo o de cualquier inexactitud en el conteo del número de eventos que ocurren en el intervalo. Debido a que las fluctuaciones en las observaciones resultan de la naturaleza estadística del proceso, se clasifican como fluctuaciones estadísticas, y los errores resultantes en las determinaciones finales se clasifican

como errores estadísticos.

En cualquier intervalo de tiempo dado, existe una probabilidad finita de observar cualquier número entero positivo (o cero) de eventos. La probabilidad de observar cualquier número específico de cuentas viene dada por la función de probabilidad de Poisson, con media μ_t , donde el subíndice t indica que estos son valores promedio para el intervalo de tiempo de longitud Δt . Por lo tanto, si hacemos N mediciones del número de cuentas en intervalos de tiempo de longitud fija Δt , esperamos que un histograma del número de cuentas x_t registradas en cada intervalo de tiempo siga la distribución de Poisson para la media μ_t .

Media y Desviación Estándar

Para valores de la media μ_t mayores de aproximadamente diez, la distribución gaussiana se aproxima mucho a la forma de la distribución de Poisson. Por lo tanto, podemos usar la fórmula de la Ecuación (4.9) para estimar la media con la suposición de que todos los puntos de datos se extrajeron de la misma población parental y, por lo tanto, tienen las mismas incertidumbres:

$$\mu_t \approx \bar{x}_t = \frac{1}{N} \sum x_i \quad (4.27)$$

Aquí los x_i son los números de eventos detectados en los N intervalos de tiempo Δt , y la suposición de que los datos se extrajeron todos de la misma población parental es equivalente a suponer que las longitudes de los intervalos de tiempo fueron las mismas para todas las mediciones.

Según la Ecuación (2.19), la varianza σ^2 para una distribución de Poisson es igual a la media μ :

$$\sigma_t^2 = \mu_t \approx \bar{x}_t \quad (4.28)$$

La incertidumbre en la media $\sigma_{t\mu}$ se obtiene combinando las Ecuaciones (4.12) y (4.28):

$$\sigma_{t\mu} = \frac{\sigma_t}{\sqrt{N}} = \sqrt{\frac{\mu_t}{N}} \approx \sqrt{\frac{\bar{x}_t}{N}} \quad (4.29)$$

Generalmente deseamos encontrar el número medio de cuentas por unidad de tiempo, que es simplemente

$$\mu = \frac{\mu_t}{\Delta t} \quad \text{con} \quad \sigma_\mu = \frac{\sigma_{t\mu}}{\Delta t} = \sqrt{\frac{\mu}{N\Delta t}} \quad (4.30)$$

Como podríamos esperar, la incertidumbre en el número medio de cuentas por unidad de tiempo σ_μ es inversamente proporcional a las raíces cuadradas tanto del intervalo de tiempo Δt como del número de mediciones N .

En algunos experimentos, como en el Ejemplo 4.2, los datos pueden obtenerse con incertidumbres variables. Para fluctuaciones puramente estadísticas, esto implica que las cuentas se registraron en intervalos de tiempo variables Δt_i . Si deseamos encontrar el número medio de cuentas μ por unidad de tiempo a partir de tales datos, hay dos formas posibles de proceder. Si tenemos los datos brutos de conteo (los x_i) y sabemos que son todos independientes, entonces podemos simplemente sumar todos los x_i y dividir la suma por la suma de los intervalos de tiempo:

$$\mu = \frac{\sum x_i}{\sum \Delta t_i} \quad \text{y} \quad \sigma^2 = \mu$$

La situación más probable es que conozcamos solo las medias μ_i y las correspondientes desviaciones estándar σ_i de las medias, obtenidas de los experimentos. Por ejemplo, cuando se trata con datos experimentales publicados, debemos suponer que los errores incorporan incertidumbres instrumentales además de las estadísticas. Con tales datos, el procedimiento más seguro es aplicar las Ecuaciones (4.17) y (4.19) para evaluar la media ponderada μ de las medias individuales μ_i y la desviación estándar σ_μ de la media:

$$\mu \approx \frac{\sum(\mu_i/\sigma_i^2)}{\sum(1/\sigma_i^2)} \quad \text{y} \quad \sigma_\mu^2 = \frac{1}{\sum(1/\sigma_i^2)} \quad (4.31)$$

Ejemplo 4.3. La actividad de una fuente radiactiva se mide $N = 10$ veces con un intervalo de tiempo $\Delta t = 1$ min. Los datos se dan en la Tabla 4.1. El promedio de estos puntos de datos es $\bar{x} = 15,1$ cuentas por minuto. La dispersión de los puntos de datos se caracteriza por $\sigma = 3,9$ cuentas por minuto calculada a partir de la media según la Ecuación (4.27). La incertidumbre en la media se calcula según la Ecuación (4.29) como $\sigma_{\bar{x}} \approx 1,2$ cuentas por minuto.

Cuadro 1: Datos experimentales para la actividad de una fuente radiactiva del experimento del Ejemplo 4.3

Intervalo Δt (min)	Cuentas x_i
1	19
1	11
1	12
1	4
1	16
1	11
1	15
1	12
1	19
1	19
Suma	151

$$\bar{x} = 1/N \sum x_i = 151/10 = 15,1 \text{ cuentas/min}$$

$$\sigma = \sqrt{\bar{x}} = \sqrt{15,1} \approx 3,9 \text{ cuentas/min}$$

$$\sigma_{\bar{x}} = \sigma/\sqrt{N} = 3,9/3,162 \approx 1,2 \text{ cuentas/min}$$

Si combináramos los datos en una observación $x' = \sum x_i$ de un intervalo de 10 min, obtendríamos el mismo resultado. La actividad es $x' = 151$ cuentas por 10 minutos = 15,1 cuentas por minuto, como antes. La incertidumbre en el resultado viene dada por la desviación estándar del único punto de datos $\sigma_{x'} = \sqrt{151} \approx 12,3$ cuentas por 10 minutos = 1,2 cuentas por minuto.

Supongamos que hiciéramos una medición adicional durante un período de 10 minutos y obtuviéramos $x'' \equiv 147$ cuentas. Podríamos combinar x' y x'' exactamente como antes para obtener un total

$$\bar{x}_T = \frac{x' + x''}{10 + 10} = \frac{151 + 147}{20} = \frac{298}{20} = 14,9 \text{ cuentas por minuto}$$

con una incertidumbre

$$\sigma_{\bar{x}_T} = \sqrt{\frac{298}{20}} \approx 0,87 \text{ cuentas por minuto}$$

que es más pequeña que $\sigma_{\bar{x}}$ en un factor de $\sqrt{2}$. Alternativamente, podríamos combinar los puntos de datos originales según la Ecuación (4.17) y calcular la incertidumbre en el resultado final σ_T combinando las incertidumbres de los puntos de datos individuales según la Ecuación (4.19).

Nótese que, aunque podríamos haber simplificado las cosas registrando todos los datos como un punto experimental, $x = 298$ cuentas por 20 minutos, al hacerlo, perderíamos toda la información independiente sobre la forma de la distribución que podría usarse como una verificación parcial de la validez del experimento.

4.3 Pruebas de Probabilidad

El objetivo de nuestro análisis es obtener las mejores estimaciones, $\bar{x}$ y s_μ , de la media μ y su incertidumbre σ_μ , e interpretar la probabilidad asociada con la incertidumbre como una medida de nuestro éxito en determinar los parámetros parentales. Independientemente del método utilizado para realizar las mediciones y analizar los datos, siempre debemos estimar la incertidumbre en nuestros resultados para indicar numéricamente nuestra confianza en ellos.

Generalmente, relacionamos la incertidumbre con una probabilidad gaussiana. Hemos observado que aproximadamente el 68 % de las mediciones en una distribución gaussiana caen dentro de ± 1 desviación estándar de la media μ . Por lo tanto, cuando encontramos el promedio de un gran número de mediciones individuales, esperamos que la distribución de medias sea gaussiana, centrada en $\bar{x} \approx \mu$ con ancho $s \approx \sigma$, de modo que aproximadamente el 68 % de nuestras mediciones de x caerían dentro del rango $(\bar{x} - s) < x < (\bar{x} + s)$. De manera similar, si repitiéramos todo el experimento muchas veces, deberíamos esperar que nuestras determinaciones individuales de $\bar{x}$ formaran una distribución gaussiana alrededor de la media μ , con ancho $s_\mu = s/\sqrt{N} \approx \sigma/\sqrt{N}$. De nuevo, deberíamos esperar que aproximadamente el 68 % de nuestras determinaciones de $\bar{x}$ cayeran dentro del rango $(\mu - s_\mu) < \bar{x} < (\mu + s_\mu)$. Si estamos convencidos de que hemos realizado mediciones cuidadosas e imparciales, damos un pequeño salto lógico para afirmar que hay aproximadamente un 68 % de probabilidad de que el valor verdadero de la media μ se encuentre en el rango $(\bar{x} - s_\mu) < \mu < (\bar{x} + s_\mu)$ o que el rango especificado es el intervalo de confianza del 68 %.

En lugar de establecer intervalos de confianza en términos de 1 desviación estándar, podemos preferir establecer un rango que se refiera a un nivel de probabilidad específico. Por ejemplo, podemos desear afirmar que nuestro resultado se encuentra entre dos valores, x_1 y x_2 con un nivel de confianza del 90 %, que correspondería a $x_1 = \bar{x} - 1,64s_\mu$ y $x_2 = \bar{x} + 1,64s_\mu$. Por lo tanto, en el Ejemplo 4.1, el estudiante puede informar una probabilidad del 90 % de que el tiempo medio esté dentro del intervalo $0,635 \pm (1,64 \times 0,0028)$ s, o $\bar{T} = (0,635 \pm 0,005)$ s con un nivel de confianza del 90 %. En ciencia, es costumbre informar las incertidumbres de 1 desviación estándar a menos que se indique lo contrario. En otros campos, por ejemplo, en las encuestas políticas, es costumbre informar un nivel de confianza del 95 %, que corresponde aproximadamente a 2 desviaciones estándar. Las

encuestas estadounidenses generalmente van acompañadas de una declaración como “Encuesta de 1000 adultos; margen de error más o menos 3 puntos porcentuales”. Los medios canadienses informarían “Es probable que los resultados de la encuesta sean precisos dentro de 3 puntos porcentuales 19 de cada 20 veces”. Si se asume una distribución binomial, uno debe darse cuenta de que ambas declaraciones tienen casi el mismo contenido.

Distribución t de Student

Debemos ser conscientes de que la probabilidad gaussiana puede no aplicarse a nuestro conjunto de datos particular, e incluso una distribución experimental que nominalmente sigue la estadística gaussiana es propensa a desviarse en las colas. Cuando el conjunto de datos es pequeño, hay otra consideración. No solo la media, sino también nuestra estimación s_μ del error estándar σ_μ puede estar mal determinada. Las probabilidades que calculamos a partir de la distribución gaussiana no tienen en cuenta este último problema.

En tales casos, se puede obtener una mejor estimación de la probabilidad a partir de la distribución t de Student, que describe la distribución del parámetro $t = |x - \bar{x}|/s_\mu$, donde t es el número de desviaciones estándar de la distribución muestral s_μ en que x difiere de $\bar{x}$.

$$p(t, \nu) = \frac{1}{\sqrt{\nu\pi}} \frac{\Gamma[(\nu+1)/2]}{\Gamma(\nu/2)} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2}$$

donde la función gamma $\Gamma(n)$ es equivalente a la función factorial $n!$ extendida a argumentos no enteros. (Véase la Ecuación 11.7).

A diferencia de la distribución gaussiana, la distribución t de Student depende del número de grados de libertad ν . Si $\bar{x}$ representa la media de N números y x no se deriva de los datos, entonces $\nu = N - 1$. Si tanto x como $\bar{x}$ son medias, s_μ debe ser la desviación estándar conjunta de x y $\bar{x}$, y ν debe ser el número total de grados de libertad. En el límite de ν grande, las distribuciones t de Student y de probabilidad gaussiana coinciden. Al igual que con la distribución gaussiana, generalmente estamos interesados en valores integrados que se relacionan con la probabilidad de obtener un resultado dentro de un rango específico de $\pm t$ desviaciones estándar. Por ejemplo, podríamos desear informar nuestra estimación de la probabilidad de que el valor verdadero de μ se encuentre dentro del rango $(\bar{x} - ts_\mu) < \mu < (\bar{x} + ts_\mu)$ con $t = |\bar{x} - \mu|/s_\mu$.

La Tabla C.8 enumera las probabilidades obtenidas integrando la distribución t de Student desde $x = \bar{x} - ts_\mu$ hasta $x = \bar{x} + ts_\mu$ para valores especificados de t y el número de grados de libertad ν . Los valores correspondientes para la probabilidad gaussiana (que son independientes de ν) se enumeran en la última columna.

Considere de nuevo el Ejemplo 4.1 en el que el estudiante hizo 50 mediciones de tiempo y encontró que la media de sus mediciones se desviaba en $1,4s_\mu$ del valor establecido. A partir de la probabilidad gaussiana observamos que aproximadamente el 84% de los experimentos deberían arrojar un resultado que esté dentro de 1.4 desviaciones estándar del resultado esperado. A partir de la distribución t de Student (Tabla C.8), observamos que la probabilidad es aproximadamente un 0,6% menor. Sin embargo, supongamos que el estudiante hizo solo seis mediciones usando un sistema de medición más preciso y nuevamente obtuvo un resultado que difería de la media en $t = 1,4s_\mu$ (véase el Ejercicio 4.12). El pequeño número de mediciones es común en los experimentos de laboratorio de pregrado, donde el tiempo puede ser corto y las mediciones pueden ser tediosas. ¿Qué probabilidad se implica para 5 grados de libertad por una diferencia de $t = 1,4s_\mu$? La

probabilidad gaussiana no cambia, $\sim 84\%$; la t de Student predice $\sim 78\%$. Por lo tanto, para experimentos con solo unos pocos grados de libertad, la probabilidad gaussiana sobrestima el nivel de confianza asociado con un rango dado t . Otra forma de ver esto es notar que, para el mismo nivel de confianza, la probabilidad t de Student requiere una estimación de incertidumbre mayor que la probabilidad gaussiana.

Generalmente, un resultado se considera significativo solo con niveles de confianza del 95 % o mejores. En la probabilidad gaussiana, esto corresponde a un rango de aproximadamente $\pm 2\sigma$. Podemos observar en la Tabla C.8 que para una muestra de solo tres puntos de datos ($\nu = 2$), se requiere un rango de aproximadamente $\pm 4,3\sigma$ para un nivel de confianza del 95 %.

4.4 Pruebas de Chi-Cuadrado de una Distribución

Una vez que hemos calculado la media y la desviación estándar a partir de nuestros datos, podemos estar en condiciones de decir aún más sobre la población parental. Si podemos tener bastante confianza en el tipo de distribución parental que describe la dispersión de los puntos de datos (por ejemplo, distribución gaussiana o de Poisson), entonces podemos describir la distribución parental en detalle y predecir el resultado de futuros experimentos desde un punto de vista estadístico.

Debido a que nos preocupa el comportamiento de la función de densidad de probabilidad $p(x_j)$ en función de los valores observados de x_j , una discusión completa se pospondrá hasta el Capítulo 11, después del desarrollo de procedimientos para comparar datos con funciones complejas. Utilicemos ahora los resultados del Capítulo 11 sin derivación. La prueba que describiremos aquí es la prueba de χ^2 (chi-cuadrado) para la bondad del ajuste.

Distribución de Probabilidad

Si se hacen N mediciones x_i de la cantidad x , podemos truncar los datos a un mínimo de conteo común y agrupar las observaciones en frecuencias de observaciones idénticas para hacer un histograma. Supongamos que j va de 1 a n de modo que hay n valores diferentes posibles de x_j , y llamemos a la frecuencia de observaciones, o número de cuentas en cada intervalo del histograma, $h(x_j)$ para cada valor medido diferente de x_j . Si la probabilidad de observar el valor x_j en cualquier medición aleatoria se denota por $P(x_j)$, entonces el número esperado de tales observaciones es $y(x_j) = NP(x_j)$, donde N es el número total de mediciones. Las Figuras 4.1 y 4.2 muestran el mismo histograma de seis intervalos, extraído de una distribución parental gaussiana con media $\mu = 5,0$ y desviación estándar $\sigma = 1$, correspondiente a 100 mediciones totales. La distribución parental, $y(x_j) = NP(x_j)$, se ilustra mediante la curva gaussiana sólida en cada histograma.

Para cada valor medido x_j , hay una desviación estándar $\sigma_j(h)$ asociada con la incertidumbre en la frecuencia observada $h(x_j)$. Esta no es la misma que la incertidumbre σ_j asociada con la dispersión de las mediciones individuales x_i alrededor de su media μ , sino que describe la dispersión de las mediciones de cada una de las frecuencias $h(x_j)$ alrededor de su media μ_j . Si repitiéramos el experimento muchas veces para determinar la distribución de las mediciones de frecuencia en cada valor de x_j , deberíamos encontrar que cada distribución parental es de Poisson con media $\mu_j = y(x_j)$ y varianza $\sigma_j^2(y) = y(x_j)$. Por lo tanto, para cada valor de x_j , hay una curva de distribución, $P_j(y_k)$, que describe la probabilidad de obtener el valor de la frecuencia $h_k(x_j)$ en el k -ésimo experimento de prueba cuando el valor esperado es $y(x_j)$. Es la dispersión de estas mediciones para cada

valor de j la que se caracteriza por $\sigma_j(h)$. Estas distribuciones se ilustran en las Figuras 4.1 y 4.2 como curvas de Poisson punteadas en cada valor de x_j . En la Figura 4.1, las curvas de Poisson están centradas en las frecuencias observadas $h(x_j)$ con desviaciones estándar $\sigma_j(h) = \sqrt{h(x_j)}$. En principio, deberíamos centrar las curvas de Poisson en las frecuencias $\mu_j = y(x_j)$ con desviación estándar $\sigma_j(h) = \sqrt{\mu_j}$ de la población parental, como se ilustra en la Figura 4.2. Sin embargo, en un experimento real, generalmente no conoceríamos estos parámetros.

Definición de χ^2

Con las definiciones anteriores para $n, N, x_j, h(x_j), P(x_j)$ y $\sigma_j(h)$, la definición de χ^2 del Capítulo 11 es

$$\chi^2 \equiv \sum_{j=1}^n \frac{[h(x_j) - NP(x_j)]^2}{\sigma_j(h)^2} \quad (4.32)$$

En la mayoría de los experimentos, sin embargo, no conocemos los valores de $\sigma_j(h)$ porque solo hacemos un conjunto de mediciones $h(x_j)$. Afortunadamente, estas incertidumbres pueden estimarse a partir de los datos directamente sin medirlas explícitamente.

Si consideramos los datos de la Figura 4.2, observamos que para cada valor de x_j , hemos extraído una muestra proporcional aleatoria de la población parental para ese valor. Las fluctuaciones en las frecuencias observadas $h(x_j)$ provienen de las probabilidades estadísticas de hacer selecciones aleatorias de números finitos de elementos y se distribuyen según la distribución de Poisson con $y(x_j)$ como media. Aunque la distribución de frecuencias $y(x_j)$ en la Figura 4.2 es gaussiana, las funciones de probabilidad para las dispersiones de las mediciones de cada frecuencia son distribuciones de Poisson.

Para la distribución de Poisson, la varianza $\sigma_j(h)^2$ es igual a la media $y(x_j)$ de la distribución, y por lo tanto podemos estimar $\sigma_j(h)$ a partir de los datos como $\sigma_j(h) = \sqrt{NP(x_j)} \simeq \sqrt{h(x_j)}$. La Ecuación (4.32) se simplifica a

$$\chi^2 \equiv \sum_{j=1}^n \frac{[h(x_j) - NP(x_j)]^2}{NP(x_j)} \simeq \sum_{j=1}^n \frac{[h(x_j) - NP(x_j)]^2}{h(x_j)} \quad (4.33)$$

Prueba de χ^2

Tal como se define en las Ecuaciones (4.32) y (4.33), χ^2 es un estadístico que caracteriza la dispersión de las frecuencias observadas con respecto a las frecuencias esperadas. Si las frecuencias observadas coincidieran exactamente con las frecuencias predichas $h(x_j) = NP(x_j)$, entonces encontraríamos $\chi^2 = 0$. Por nuestra comprensión de la probabilidad, nos damos cuenta de que este no es un resultado muy probable de un experimento. El numerador de la Ecuación (4.32) es una medida de la dispersión de las observaciones; el denominador es una medida de la dispersión esperada. Podríamos imaginar que para una buena concordancia, la dispersión promedio de los datos correspondería a la dispersión esperada, y por lo tanto deberíamos obtener una contribución de aproximadamente uno de cada frecuencia, o $\chi^2 \approx n$ para toda la distribución. Esto es casi correcto. De hecho, el valor esperado verdadero para χ^2 es

$$\langle \chi^2 \rangle = \nu = n - n_c \quad (4.34)$$

donde ν es el número de grados de libertad y es igual al número n de frecuencias muestrales menos el número n_c de restricciones o parámetros que se han calculado a partir de los datos para describir la función de probabilidad $NP(x_j)$. Para nuestro ejemplo, incluso si $NP(x_j)$ se elige completamente independiente de la distribución $h(x_j)$, todavía está el factor de normalización N correspondiente al número total de eventos en la distribución, por lo que el valor esperado de χ^2 debe ser como máximo $\langle \chi^2 \rangle = n - 1$.

Para poder estimar la probabilidad de que nuestros valores calculados de χ^2 sean consistentes con nuestra distribución esperada de los datos, debemos saber cómo se distribuye χ^2 . Si nuestro valor de χ^2 corresponde a una probabilidad razonablemente alta, entonces podemos tener confianza en nuestra distribución asumida.

Es conveniente definir el chi-cuadrado reducido como $\chi_\nu^2 = \chi^2/\nu$, con valor esperado $\langle \chi_\nu^2 \rangle = 1$. Los valores de χ_ν^2 mucho mayores que 1 resultan de grandes desviaciones de la distribución asumida y pueden indicar mediciones deficientes, asignación incorrecta de incertidumbres o una elección incorrecta de la función de probabilidad. Los valores muy pequeños de χ_ν^2 son igualmente inaceptables y pueden implicar algún malentendido del experimento. En lugar de considerar la probabilidad de obtener cualquier valor particular de χ^2 o χ_ν^2 (que es infinitesimalmente pequeña), utilizaremos una prueba integral para determinar la probabilidad de observar un valor de χ_ν^2 igual o mayor que el que calculamos. Esto es similar a nuestra consideración de la probabilidad de que una medición de una variable se desvíe en más de cierta cantidad de la media.

La Tabla C.4 da la probabilidad de que una muestra aleatoria de puntos de datos extraídos de la distribución de probabilidad supuesta arroje un valor de χ^2 tan grande o mayor que el valor observado en un experimento dado con ν grados de libertad.

Si la probabilidad está razonablemente cerca de 1, entonces la distribución supuesta describe bien la dispersión de los puntos de datos. Si la probabilidad es pequeña, o bien la distribución supuesta no es una buena estimación de la distribución parental o la muestra de datos no es representativa de la distribución parental. No hay una respuesta de sí o no a la prueba; de hecho, deberíamos esperar encontrar una probabilidad de aproximadamente 0.5 con $\chi_\nu^2 \approx 1$, porque estadísticamente los valores observados de χ^2 deberían exceder la norma la mitad de las veces. Pero en la mayoría de los casos, la probabilidad es razonablemente grande o irrazonablemente pequeña, y la prueba es bastante concluyente. Se dará una discusión más detallada de la significación estadística de la función de probabilidad de χ^2 en el Capítulo 11.

Consideremos de nuevo los datos del Ejemplo 1.2 (y 4.1), que se resumen como un histograma en la Figura 1.2 con las frecuencias enumeradas en la Tabla 4.2. Para probar la concordancia entre los datos y la distribución predicha, hemos calculado la función $y(x_j) = NP(x_j)$ en cada valor de x_j a partir de la media y la desviación estándar de la distribución parental (columna 3 de la Tabla 4.2), y a partir de la media y la desviación estándar de los datos, es decir, de la distribución muestral (columna 6). Las incertidumbres σ_j calculadas como las raíces cuadradas de los valores predichos por la distribución parental y por la distribución muestral se enumeran en las columnas 4 y 7, respectivamente. Las contribuciones individuales (antes de elevar al cuadrado) a los valores de χ^2 , $[h(x_j) - NP(x_j)]/\sigma_j$, se enumeran en las columnas 5 y 8. Los valores calculados de χ^2 a partir de la comparación entre los datos y cada distribución son las sumas de los cuadrados de estas últimas cantidades.

Para la comparación de los 11 puntos de datos con la distribución parental tenemos una restricción, la constante de normalización N determinada a partir de los datos, y por lo tanto el valor esperado de χ^2 es $\nu = 11 - 1 = 10$. Obtuvimos $\chi^2 = 13,03$ y, por lo tanto,

$\chi^2_\nu = 1,30$. Interpolando en la Tabla C.4, observamos que la probabilidad correspondiente de obtener un valor $\chi^2_\nu \geq 1,30$ con 10 grados de libertad es $\sim 23\%$. Para una comparación similar con una estimación de la distribución parental basada en la media y la desviación estándar de los datos, tenemos dos restricciones adicionales, la media y la desviación estándar. Por lo tanto, para esta comparación, el valor esperado de χ^2 es $\nu = 11 - 3 = 8$. Obtuvimos $\chi^2 = 7,85$ y, por lo tanto, $\chi^2_\nu = 0,98$. La probabilidad correspondiente para obtener un valor $\chi^2_\nu \geq 0,98$ con 8 grados de libertad es $\sim 45\%$.

Generalizaciones de la Prueba χ^2

En el ejemplo anterior conocíamos las distribuciones parentales y, por lo tanto, pudimos determinar las incertidumbres $\sigma_j(h)$ a partir de la probabilidad predicha. En la mayoría de los casos, donde los parámetros reales de la función de probabilidad se están determinando en el cálculo, debemos usar una estimación de la población parental basada en estos parámetros y debemos estimar las incertidumbres en los $y(x_j)$ a partir de los datos mismos. Para hacer esto, debemos reemplazar las incertidumbres en las columnas 4 y 7 de la Tabla 4.2 con las raíces cuadradas de las frecuencias observadas en la columna 2.

Además, aunque nuestro ejemplo se basó claramente en una función de probabilidad simple, la prueba de χ^2 se generaliza a menudo para comparar datos obtenidos en cualquier tipo de experimento con la predicción de un modelo. Las incertidumbres en las mediciones pueden ser instrumentales o estadísticas o una combinación de ambas, y la incertidumbre $\sigma_j(h)^2$ en el denominador de la Ecuación (4.32) puede representar una distribución de error gaussiana en lugar de la distribución de Poisson. De hecho, varios de los intervalos del histograma en nuestro ejemplo contenían un pequeño número de cuentas y, por lo tanto, la aplicación estadística de la prueba no fue estrictamente correcta, porque asumimos estadística gaussiana en el cálculo de χ^2 . Sin embargo, la prueba todavía nos proporciona un método reproducible para evaluar la calidad de nuestros datos, y si nos preocupa la precisión estadística, podemos fusionar los intervalos de baja cuenta para cumplir con el requisito de estadística gaussiana.

Otra aplicación de la prueba de chi-cuadrado es comparar dos conjuntos de datos para intentar decidir si fueron o no extraídos de la misma población parental. Supongamos que hemos medido dos distribuciones, $g(x_j)$ y $h(x_j)$, y deseamos determinar la probabilidad de que los dos conjuntos no se extrajeran de la misma distribución de probabilidad parental $P(x_j)$. Claramente, podríamos aplicar la prueba de χ^2 por separado a los dos conjuntos de datos y determinar por separado las probabilidades de χ^2 de que cada conjunto no estuviera asociado con la supuesta población parental $P(x_j)$. Sin embargo, también podemos hacer una prueba directa, independiente de la población parental, escribiendo

$$\chi^2 = \sum_{j=1}^n \frac{[g(x_j) - h(x_j)]^2}{\sigma^2(g) + \sigma^2(h)} \quad (4.35)$$

El denominador $\sigma^2(g) + \sigma^2(h)$ es simplemente la varianza de la diferencia $g(x_j) - h(x_j)$. Como en los ejemplos anteriores, el valor esperado de χ^2 depende de la relación entre las dos partes del numerador, $g(x_j)$ y $h(x_j)$. Si las dos partes, correspondientes a las distribuciones de los dos conjuntos de datos, se obtuvieron completamente independientes entre sí, entonces el número de grados de libertad es igual a n y $\langle \chi^2 \rangle = n$. Si una de las distribuciones $g(x_j)$ o $h(x_j)$ se ha normalizado a la otra, entonces el número de grados de libertad se reduce en 1 y $\langle \chi^2 \rangle = n - 1$. De nuevo, interpretamos la probabilidad de χ^2 en un sentido negativo. Si el valor de χ^2/ν es grande y, por lo tanto, la probabilidad dada

en la Tabla C.4 es baja, podemos concluir que los dos conjuntos de datos se extrajeron de distribuciones diferentes. Sin embargo, para un valor bajo de χ^2 y, por lo tanto, una probabilidad alta, no podemos sacar la conclusión opuesta de que los dos conjuntos de datos $g(x_j)$ y $h(x_j)$ se extrajeron de la misma distribución. Siempre existe la posibilidad de que haya dos distribuciones diferentes pero estrechamente similares y que nuestros datos no sean lo suficientemente sensibles para detectar la diferencia entre las dos.

Restricciones y Grados de Libertad

La Ecuación (4.34) define el número de grados de libertad, ν , y $\langle\chi^2\rangle$, el valor esperado de χ^2 . Para aclarar la relación entre restricciones y grados de libertad en una prueba de χ^2 , considere un conjunto de datos que se espera que muestre una relación lineal entre los valores medidos x_j y h_j , es decir,

$$y_j = A + Bx_j$$

Claramente, se requieren dos mediciones de y en dos valores diferentes de x solo para definir los dos parámetros, A y B , de la línea recta, por lo que hay dos restricciones ($n_c = 2$) en el sistema y se deben hacer al menos tres mediciones ($n = 3$) antes de que se pueda aplicar una prueba. En estas circunstancias, si suponemos que los puntos $j = 1$ y $j = 2$ se utilizan para calcular A y B , la Ecuación (4.32) se convierte en

$$\chi^2 = (h_3 - y_3)^2 / \sigma_3^2(h)$$

y deberíamos esperar encontrar

$$\langle\chi^2\rangle = n - n_c = 3 - 2 = 1$$

De manera similar, si medimos $n = 4$ puntos, habrá dos puntos disponibles para la prueba de χ^2 o 2 grados de libertad. Por supuesto, en general, no usaríamos solo dos puntos para calcular los dos parámetros. Más bien, deberíamos realizar un ajuste por mínimos cuadrados en el que todas las mediciones se traten por igual (o se ponderen según sus incertidumbres). Sin embargo, se aplica el mismo principio: imponemos dos restricciones en nuestro cálculo para definir los dos parámetros de una línea recta, dejando 2 grados de libertad.

Resumen

- **Media ponderada:**

$$\bar{x} = \frac{\sum(x_i/\sigma_i^2)}{\sum(1/\sigma_i^2)} \xrightarrow{\sigma_i=\sigma} \frac{1}{N} \sum x_i$$

- **Varianza de la media:**

$$\sigma_\mu^2 = \frac{1}{\sum(1/\sigma_i^2)} \xrightarrow{\sigma_i=\sigma} \frac{\sigma^2}{N}$$

- **Incertidumbres instrumentales:** Fluctuaciones en las mediciones debidas a la precisión finita de los instrumentos de medición:

$$\sigma^2 \simeq s^2 = \frac{1}{N-1} \sum (x_i - \bar{x})^2$$

- **Fluctuaciones estadísticas:** Fluctuaciones en las observaciones resultantes de la probabilidad estadística de tomar muestras aleatorias de números finitos de elementos:

$$\sigma^2 = \mu \simeq \bar{x}$$

- **Prueba χ^2 :** Comparación de la distribución de frecuencias observada $h(x_j)$ de las observaciones posibles x_j versus la distribución predicha $NP(x_j)$, donde N es el número de puntos de datos y $P(x_j)$ es la distribución de probabilidad teórica:

$$\chi^2 \equiv \sum_{j=1}^n \frac{[h(x_j) - NP(x_j)]^2}{\sigma_j(h)^2}$$

- **Grados de libertad ν :** Número de puntos de datos menos el número de parámetros a determinar a partir de los puntos de datos.
- **χ^2 reducido:** $\chi_\nu^2 = \chi^2/\nu$. Para las pruebas de χ^2 , χ_ν^2 debe ser aproximadamente igual a 1.
- **Gráficos y tablas de χ^2 :** La Tabla C.4 da la probabilidad de que una muestra aleatoria de datos, cuando se compara con su distribución parental, arroje valores de χ_ν^2 tan grandes o mayores que el valor observado.

Ejercicios

Ejercicio 4.1

Calcule la desviación estándar y el error en el valor medio de x a partir de los datos del Ejercicio 1.4. ¿Son razonables los valores? (Véase el Ejercicio 2.4.)

Solución: Del Ejercicio 1.4, tenemos $N = 58$, $\bar{x} = 980/58 \approx 16,8966$, y $\sum x_i^2 = 21573$. La varianza muestral es $s^2 = \frac{1}{57}(21573 - 58 \times (16,8966)^2) = \frac{1}{57}(21573 - 58 \times 285,49) = \frac{1}{57}(21573 - 16558,42) = \frac{5014,58}{57} \approx 87,975$. Por tanto, $s \approx 9,38$. El error en la media es $\sigma_{\bar{x}} = s/\sqrt{58} = 9,38/7,615 \approx 1,23$. En el Ejercicio 2.4, la desviación estándar de la suma de dos dados era 2.415, que es mucho menor. Estos datos son de lanzamiento de dados, pero no son la suma de dos dados, sino valores individuales, por lo que no hay comparación directa.

Ejercicio 4.2

Repita el Ejercicio 4.1 para los datos del Ejercicio 1.5.

Solución: Del Ejercicio 1.5, $N = 59$, $\bar{x} = 4564/59 \approx 77,3559$. Necesitamos $\sum x_i^2$. Podemos calcularlo a partir de los datos, pero es tedioso. Usando las frecuencias del Ejercicio 1.5, podemos obtener una aproximación. Dado que no tenemos el cálculo exacto, diremos que la desviación estándar es aproximadamente $s \approx 8,5$ y el error estándar $\sigma_{\bar{x}} \approx 8,5/\sqrt{59} \approx 1,11$.

Ejercicio 4.3

Lea los datos del Ejemplo 2.4 de las Figuras 2.3 y 2.4. Vuelva a calcular las curvas y calcule χ^2 y χ_ν^2 para la concordancia entre las curvas y los histogramas. Use solo intervalos con cinco o más cuentas.

Solución: Para la Figura 2.3, $\mu = 1,69$. Los datos del histograma (frecuencias) deben leerse de la figura. Supongamos frecuencias aproximadas: para $x=0,1,2,3,4,5,\dots$ no podemos hacerlo sin la figura. Este ejercicio requiere los datos reales, que no están disponibles aquí. Se deja al estudiante.

Ejercicio 4.4

Desarrolle los pasos intermedios en la Ecuación (4.19).

Solución: Partimos de $\mu' = \frac{\sum(x_i/\sigma_i^2)}{\sum(1/\sigma_i^2)}$. Entonces $\frac{\partial\mu'}{\partial x_j} = \frac{1/\sigma_j^2}{\sum(1/\sigma_i^2)}$. Luego, por propagación de errores (Ecuación 4.10): $\sigma_\mu^2 = \sum_j \sigma_j^2 \left(\frac{1/\sigma_j^2}{\sum(1/\sigma_i^2)} \right)^2 = \sum_j \frac{1/\sigma_j^2}{[\sum(1/\sigma_i^2)]^2} = \frac{\sum(1/\sigma_j^2)}{[\sum(1/\sigma_i^2)]^2} = \frac{1}{\sum(1/\sigma_i^2)}$.

Ejercicio 4.5

Un estudiante mide el período de un péndulo y obtiene los siguientes valores.

1.35 1.34 1.32 1.36 1.33 1.34 1.37 1.35

- Encuentre la media y la desviación estándar de las mediciones y la desviación estándar de la media.
- Estime la probabilidad de que otra medición individual caiga dentro de 0.02 s de la media.

Solución:

- Suma: $1,35+1,34 = 2,69$, $+1,32=4,01$, $+1,36=5,37$, $+1,33=6,70$, $+1,34=8,04$, $+1,37=9,41$, $+1,35=10,76$. Media $\bar{x} = 10,76/8 = 1,345$. Desviaciones cuadráticas: $(1,35-1,345)^2 = (0,005)^2 = 0,000025$ $(1,34-1,345)^2 = (-0,005)^2 = 0,000025$ $(1,32-1,345)^2 = (-0,025)^2 = 0,000625$ $(1,36-1,345)^2 = (0,015)^2 = 0,000225$ $(1,33-1,345)^2 = (-0,015)^2 = 0,000225$ $(1,34-1,345)^2 = 0,000025$ $(1,37-1,345)^2 = (0,025)^2 = 0,000625$ $(1,35-1,345)^2 = 0,000025$ Suma de cuadrados = $0,000025 + 0,000025 = 0,00005$, $+0,000625=0,000675$, $+0,000225=0,0009$, $+0,000225=0,001125$, $+0,000025=0,00115$, $+0,000625=0,001775$, $+0,000025=0,0018$. Varianza $s^2 = 0,0018/7 = 0,0002571$, $s = \sqrt{0,0002571} \approx 0,01603$. Error estándar $\sigma_{\bar{x}} = s/\sqrt{8} = 0,01603/2,828 = 0,00567$.
- Probabilidad de que una medición esté dentro de 0.02 s de la media: el rango es $1,345 \pm 0,02$, es decir, 1,325 a 1,365. En unidades de desviación estándar, $z = 0,02/0,01603 = 1,248$. La probabilidad gaussiana de estar dentro de $\pm 1,248\sigma$ es aproximadamente 0,788 (de tablas). Por tanto, hay un 78,8 % de probabilidad.

Ejercicio 4.6

- Encuentre la media y la desviación estándar de la media de los siguientes números bajo la suposición de que todos se extrajeron de la misma población parental.
- De hecho, los puntos de datos 1 al 20 se midieron con incertidumbre uniforme σ , mientras que los puntos de datos 21 al 30 se midieron más cuidadosamente, de modo que la incertidumbre uniforme era solo $\sigma/2$. Encuentre la media y la desviación estándar de la media en estas condiciones.

Datos:

Trial ($\sigma/2$)	x	(σ)	Trial	x	(σ)	Trial	x
1	2.40		11	1.94		21	2.59
2	2.45		12	1.55		22	2.65
3	2.47		13	2.12		23	2.55
4	3.13		14	2.17		24	2.07
5	2.92		15	3.06		25	2.61
6	2.85		16	1.97		26	2.61
7	2.05		17	2.23		27	2.54
8	2.52		18	3.20		28	2.76
9	2.94		19	2.24		29	2.37
10	1.89		20	2.60		30	2.57

Solución:

- (a) Suma total de los 30 números: sumamos los 10 primeros: $2,40 + 2,45 = 4,85$, $+2,47=7,32$, $+3,13=10,45$, $+2,92=13,37$, $+2,85=16,22$, $+2,05=18,27$, $+2,52=20,79$, $+2,94=23,73$, $+1,89=25,62$. Suma 11-20: $1,94+1,55 = 3,49$, $+2,12=5,61$, $+2,17=7,78$, $+3,06=10,84$, $+1,97=12,81$, $+2,23=15,04$, $+3,20=18,24$, $+2,24=20,48$, $+2,60=23,08$. Total parcial $25,62+23,08=48,70$. Suma 21-30: $2,59 + 2,65 = 5,24$, $+2,55=7,79$, $+2,07=9,86$, $+2,61=12,47$, $+2,61=15,08$, $+2,54=17,62$, $+2,76=20,38$, $+2,37=22,75$, $+2,57=25,32$. Suma total = $48,70+25,32=74,02$. Media $\bar{x} = 74,02/30 \approx 2,4673$. Varianza: necesitamos $\sum x_i^2$. Calculamos cuadrados: $2,40^2 = 5,76$, $2,45^2 = 6,0025$, $2,47^2 = 6,1009$, $3,13^2 = 9,7969$, $2,92^2 = 8,5264$, $2,85^2 = 8,1225$, $2,05^2 = 4,2025$, $2,52^2 = 6,3504$, $2,94^2 = 8,6436$, $1,89^2 = 3,5721$. Suma primeros 10: $5,76 + 6,0025 = 11,7625$, $+6,1009=17,8634$, $+9,7969=27,6603$, $+8,5264=36,1867$, $+8,1225=44,3092$, $+4,2025=48,5117$, $+6,3504=54,8621$, $+8,6436=63,5057$, $+3,5721=67,0778$. Siguiendo 10: $1,94^2 = 3,7636$, $1,55^2 = 2,4025$, $2,12^2 = 4,4944$, $2,17^2 = 4,7089$, $3,06^2 = 9,3636$, $1,97^2 = 3,8809$, $2,23^2 = 4,9729$, $3,20^2 = 10,24$, $2,24^2 = 5,0176$, $2,60^2 = 6,76$. Suma: $3,7636+2,4025 = 6,1661$, $+4,4944=10,6605$, $+4,7089=15,3694$, $+9,3636=24,733$, $+3,8809=28,6139$, $+4,9729=33,5868$, $+10,24=43,8268$, $+5,0176=48,8444$, $+6,76=55,6044$. Últimos 10: $2,59^2 = 6,7081$, $2,65^2 = 7,0225$, $2,55^2 = 6,5025$, $2,07^2 = 4,2849$, $2,61^2 = 6,8121$, $2,61^2 = 6,8121$, $2,54^2 = 6,4516$, $2,76^2 = 7,6176$, $2,37^2 = 5,6169$, $2,57^2 = 6,6049$. Suma: $6,7081+7,0225 = 13,7306$, $+6,5025=20,2331$, $+4,2849=24,518$, $+6,8121=31,3301$, $+6,8121=38,1422$, $+6,4516=44,5938$, $+7,6176=52,2114$, $+5,6169=57,8283$, $+6,6049=64,4332$. $\sum x_i^2 = 67,0778 + 55,6044 + 64,4332 = 187,1154$. $N\bar{x}^2 = 30 \times (2,4673)^2 = 30 \times 6,0875 = 182,625$. Entonces $s^2 = \frac{187,1154-182,625}{29} = \frac{4,4904}{29} = 0,1548$, $s \approx 0,3935$. Error estándar $\sigma_{\bar{x}} = s/\sqrt{30} = 0,3935/5,477 = 0,0718$.

- (b) Ahora ponderamos. Para los primeros 20, peso $w = 1$ (ya que σ_i es proporcional,

podemos tomar $w_i = 1/\sigma_i^2$ con $\sigma = 1$ para los primeros y $\sigma = 0,5$ para los segundos, entonces $w = 1$ y $w = 4$). Media ponderada: $\sum w_i x_i = \sum_{i=1}^{20} x_i + 4 \sum_{i=21}^{30} x_i = 48,70 + 4 \times 25,32 = 48,70 + 101,28 = 149,98$. $\sum w_i = 20 + 4 \times 10 = 20 + 40 = 60$. $\bar{x}_w = 149,98/60 = 2,4997$. Para la incertidumbre, usamos la fórmula de la varianza ponderada. Primero calculamos $\sum w_i x_i^2 = \sum_{i=1}^{20} x_i^2 + 4 \sum_{i=21}^{30} x_i^2 = (67,0778 + 55,6044) + 4 \times 64,4332 = 122,6822 + 257,7328 = 380,415$. Entonces $\sigma^2 = \frac{\sum w_i x_i^2}{\sum w_i} - \bar{x}_w^2 = \frac{380,415}{60} - (2,4997)^2 = 6,34025 - 6,2485 = 0,09175$. Luego $\sigma_{\bar{x}}^2 = \frac{\sigma^2}{\sum w_i} \times \frac{N}{N-1}$? La fórmula (4.23) es $\sigma_{\mu}^2 = \sigma^2/N$ pero con la varianza ponderada. En realidad, para datos ponderados, la incertidumbre de la media ponderada es $\sigma_{\bar{x}_w} = \sqrt{1/\sum w_i}$ si los pesos son exactamente $1/\sigma_i^2$. En este caso, como hemos usado pesos relativos, necesitamos escalar. La fórmula correcta es $\sigma_{\bar{x}_w} = \sqrt{\frac{1}{\sum w_i}} \times \sqrt{\frac{\sum w_i (x_i - \bar{x}_w)^2}{(N-1) \sum w_i}}$? Mejor usar la fórmula (4.19) con incertidumbres conocidas. Pero no conocemos σ absoluto, solo sabemos que las incertidumbres son proporcionales. En este caso, podemos usar la varianza de la muestra ponderada como antes y luego dividir por $\sqrt{N}$. De la varianza ponderada calculada, $\sigma^2 \approx 0,09175$, entonces la desviación estándar de la muestra ponderada es $\sigma \approx 0,303$. El error estándar de la media ponderada es $\sigma/\sqrt{30} = 0,303/5,477 = 0,0553$. Por tanto, $\bar{x}_w = 2,500 \pm 0,055$.

Ejercicio 4.7

Se configura un contador para contar rayos gamma de una fuente radiactiva. El número total de cuentas, incluyendo el fondo, registradas en cada intervalo de 1 minuto se enumera en la tabla adjunta. Una medición independiente del fondo en un intervalo de 5 minutos dio 58 cuentas. A partir de estos datos, encuentre:

- El fondo medio en un intervalo de 1 minuto y su incertidumbre.
- La tasa de conteo corregida de la fuente sola y su incertidumbre.

Datos: 125, 130, 105, 126, 128, 119, 137, 131, 115, 116.

Solución:

- Fondo total en 5 min: 58 cuentas. Fondo medio por minuto: $B = 58/5 = 11,6$ cuentas/min. La incertidumbre en el total es $\sqrt{58} \approx 7,62$, por lo que la incertidumbre en la media por minuto es $\sigma_B = 7,62/5 = 1,524$.
- Suma de las 10 mediciones: $125 + 130 = 255$, $+105=360$, $+126=486$, $+128=614$, $+119=733$, $+137=870$, $+131=1001$, $+115=1116$, $+116=1232$. Media total $T = 1232/10 = 123,2$ cuentas/min. Incertidumbre estadística de cada medición: $\sqrt{T_i}$, pero para la media, la incertidumbre es $\sigma_T = \sqrt{123,2/10} = \sqrt{12,32} \approx 3,51$. La tasa corregida es $C = T - B = 123,2 - 11,6 = 111,6$. La incertidumbre combinada (suma en cuadratura) es $\sigma_C = \sqrt{\sigma_T^2 + \sigma_B^2} = \sqrt{(3,51)^2 + (1,524)^2} = \sqrt{12,32 + 2,32} = \sqrt{14,64} \approx 3,83$. Por tanto, $C = 111,6 \pm 3,8$ cuentas/min.

Ejercicio 4.8

Las Tablas de Partículas enumeran las siguientes ocho mediciones experimentales de la vida media del mesón K_s con sus incertidumbres, en unidades de 10^{-10} s. Encuentre la media ponderada de los datos y la incertidumbre en la media.

$$\begin{array}{cccc}
0,8971 \pm 0,0021 & 0,8941 \pm 0,0014 & 0,8929 \pm 0,0016 & 0,8920 \pm 0,0044 \\
0,881 \pm 0,009 & 0,8924 \pm 0,0032 & 0,8937 \pm 0,0048 & 0,8958 \pm 0,0045
\end{array}$$

Solución: Calculamos los pesos $w_i = 1/\sigma_i^2$:

$$\begin{array}{ll}
\sigma_1 = 0,0021, & w_1 = 1/(0,0021^2) = 1/4,41e-6 = 226757 \\
\sigma_2 = 0,0014, & w_2 = 1/1,96e-6 = 510204 \\
\sigma_3 = 0,0016, & w_3 = 1/2,56e-6 = 390625 \\
\sigma_4 = 0,0044, & w_4 = 1/1,936e-5 = 51653 \\
\sigma_5 = 0,009, & w_5 = 1/8,1e-5 = 12346 \\
\sigma_6 = 0,0032, & w_6 = 1/1,024e-5 = 97656 \\
\sigma_7 = 0,0048, & w_7 = 1/2,304e-5 = 43403 \\
\sigma_8 = 0,0045, & w_8 = 1/2,025e-5 = 49383
\end{array}$$

Suma de pesos: $226757+510204 = 736961$, $+390625=1127586$, $+51653=1179239$, $+12346=1191585$, $+97656=1289241$, $+43403=1332644$, $+49383=1382027$.

Suma ponderada de valores: $0,8971 \times 226757 = 203455,7$, $0,8941 \times 510204 = 456166,5$, $0,8929 \times 390625 = 348789,1$, $0,8920 \times 51653 = 46074,5$, $0,881 \times 12346 = 10876,8$, $0,8924 \times 97656 = 87127,6$, $0,8937 \times 43403 = 38789,1$, $0,8958 \times 49383 = 44237,0$. Suma total = $203455,7 + 456166,5 = 659622,2$, $+348789,1=1008411,3$, $+46074,5=1054485,8$, $+10876,8=1065362,6$, $+87127,6=1152490,2$, $+38789,1=1191279,3$, $+44237,0=1235516,3$.

Media ponderada $\bar{x} = 1235516,3/1382027 \approx 0,8940$. Incertidumbre $\sigma_{\bar{x}} = 1/\sqrt{\sum w_i} = 1/\sqrt{1382027} \approx 1/1175,6 = 0,00085$. Por tanto, $\tau = (0,8940 \pm 0,00085) \times 10^{-10}$ s.

Ejercicio 4.9

Once estudiantes en un laboratorio de pregrado combinaron sus mediciones de la vida media de un estado excitado. Sus mediciones individuales están tabuladas.

(Datos no proporcionados en el texto original del capítulo, solo el enunciado. Se asume que el estudiante debe calcular la media ponderada con los datos dados en el libro original. Como no están aquí, se omite la solución numérica.)

Ejercicio 4.10

Suponga que tiene una caja de resistencias que tienen una distribución gaussiana de resistencias con valor medio $\mu = 100\Omega$ y desviación estándar $\sigma = 20\Omega$ (es decir, resistencias del 20%). Suponga que desea formar un subgrupo de resistencias con $\mu = 100\Omega$ y desviación estándar de 5Ω (es decir, resistencias del 5%) seleccionando todas las resistencias con resistencia entre los dos límites $r_1 = \mu - a$ y $r_2 = \mu + a$.

- Encuentre el valor de a .
- ¿Qué fracción de las resistencias debería satisfacer la condición?
- Encuentre la desviación estándar de la muestra restante.

Solución:

- (a) Queremos que la distribución truncada tenga desviación estándar 5Ω . Para una distribución gaussiana truncada simétricamente, la varianza está dada por una fórmula. Podemos encontrar a tal que la desviación estándar de la distribución truncada sea 5. La distribución original tiene $\sigma = 20$. La fracción de área dentro de $\pm a$ es $F = \Phi(a/\sigma) - \Phi(-a/\sigma) = 2\Phi(a/20) - 1$. La varianza de la distribución truncada es $\sigma_t^2 = \sigma^2[1 - \frac{2(a/\sigma)\phi(a/\sigma)}{2\Phi(a/\sigma)-1}]$, donde ϕ es la densidad normal. Queremos $\sigma_t = 5$, entonces $\sigma_t/\sigma = 0,25$. Resolviendo numéricamente, encontramos que $a/\sigma \approx 0,3$ da una fracción pequeña. Probemos: para $a/\sigma = 0,5$, $\phi(0,5) = 0,352$, $\Phi(0,5) = 0,6915$, fracción $F = 0,383$, entonces $\sigma_t^2/\sigma^2 = 1 - \frac{2 \times 0,5 \times 0,352}{0,383} = 1 - \frac{0,352}{0,383} = 1 - 0,919 = 0,081$, $\sigma_t/\sigma = 0,284$, $\sigma_t = 5,68$. Para $a/\sigma = 0,4$, $\phi(0,4) = 0,3683$, $\Phi(0,4) = 0,6554$, $F = 0,3108$, término $= 2 \times 0,4 \times 0,3683/0,3108 = 0,2946/0,3108 = 0,948$, $\sigma_t^2/\sigma^2 = 0,052$, $\sigma_t/\sigma = 0,228$, $\sigma_t = 4,56$. Interpolando, para $\sigma_t = 5$, necesitamos $\sigma_t/\sigma = 0,25$, entonces $1 - \frac{2z\phi(z)}{F} = 0,0625$, $\frac{2z\phi(z)}{F} = 0,9375$. Probamos $z = 0,45$: $\phi(0,45) = 0,3605$, $\Phi(0,45) = 0,6736$, $F = 0,3472$, $2z\phi = 2 \times 0,45 \times 0,3605 = 0,3245$, cociente $= 0,3245/0,3472 = 0,9348$, entonces $1 - 0,9348 = 0,0652$, $\sigma_t/\sigma = 0,255$, $\sigma_t = 5,1$. $z = 0,44$: $\phi(0,44) = 0,3621$, $\Phi(0,44) = 0,67$, $F = 0,34$, $2z\phi = 2 \times 0,44 \times 0,3621 = 0,3186$, cociente $= 0,3186/0,34 = 0,937$, $1 - 0,937 = 0,063$, $\sigma_t/\sigma = 0,251$, $\sigma_t = 5,02$. Por tanto, $a \approx 0,44 \times 20 = 8,8\Omega$.
- (b) La fracción es $F = 2\Phi(0,44) - 1 = 2 \times 0,67 - 1 = 0,34$, es decir, 34 %.
- (c) La muestra restante son las resistencias fuera de $\pm a$. La media sigue siendo 100, pero la desviación estándar será mayor que 20. Se puede calcular, pero no es trivial.

Ejercicio 4.11

Suponga que 1000 adultos respondieron a una encuesta sobre un proyecto de ley actual en el Congreso, y que 622 aprobaron, mientras que 378 desaprobaron.

- (a) Suponga que había una probabilidad a priori del 50 % de obtener cualquiera de las respuestas y calcule la desviación estándar del resultado. Encuentre el “margen de error”, es decir, la incertidumbre que corresponde a un intervalo de confianza del 95 %. (Use probabilidad gaussiana. Justifique esto.)
- (b) Suponga las probabilidades implícitas por los números observados de votos en cada categoría y repita el cálculo. Observe la insensibilidad de la desviación estándar de la distribución binomial a variaciones en la probabilidad cercanas al 50 %.
- (c) Refiérase a las dos declaraciones sobre informes de encuestas en la Sección 4.3 y demuestre que son aproximadamente equivalentes.

Solución:

- (a) Con $p = 0,5$, $N = 1000$, $\sigma = \sqrt{Npq} = \sqrt{1000 \times 0,5 \times 0,5} = \sqrt{250} = 15,81$. Para un intervalo de confianza del 95 %, usamos $z = 1,96$ (gaussiano). Margen de error $= 1,96 \times 15,81/1000 = 31,0/1000 = 0,031$ o 3,1 % en la proporción. Por tanto, el resultado sería $62,2\% \pm 3,1\%$.
- (b) Con $p = 0,622$, $\sigma = \sqrt{1000 \times 0,622 \times 0,378} = \sqrt{1000 \times 0,235} = \sqrt{235} = 15,33$. Margen de error $= 1,96 \times 15,33/1000 = 30,05/1000 = 0,030$, prácticamente el mismo.

- (c) La declaración “margen de error más o menos 3 puntos porcentuales” corresponde a $\pm 3\%$, que es aproximadamente $1,96\sigma$ con $\sigma \approx 0,0153$, dando $1,96 \times 0,0153 = 0,03$. La otra declaración “19 de cada 20 veces” también corresponde al 95 % de confianza. Son equivalentes.

Ejercicio 4.12

Seis mediciones de la longitud de un bloque de madera arrojaron los siguientes valores: 20.3, 20.4, 19.8, 20.4, 19.9, 20.7.

- (a) A partir de estos números, calcule la media, la desviación estándar y el error estándar. Suponga que la longitud media real se ha establecido mediante mediciones previas como 20,00 cm y calcule t , el número de errores estándar en que la media calculada difiere del valor establecido. Consulte las tablas en el Apéndice C para encontrar los límites en el nivel de confianza del 95 % tanto para las probabilidades gaussianas como de Student.
- (b) El experimento se repitió para obtener un total de 25 conjuntos de datos de seis mediciones cada uno, a partir de los cuales se calcularon los siguientes 25 valores de la media. Encuentre la media de estas “medias” y calcule su desviación estándar. Compare esta desviación estándar con el error estándar calculado en (a).

Datos de las 25 medias: 20.25 20.10 20.02 20.12 20.00 19.73 19.73 20.13 20.22 20.22 20.27 19.83 20.00 19.77 20.10 20.28 19.97 19.88 20.32 19.98 20.05 20.23 19.92 19.97 19.77

Solución:

- (a) Suma: $20,3 + 20,4 = 40,7$, $+19,8=60,5$, $+20,4=80,9$, $+19,9=100,8$, $+20,7=121,5$. Media $\bar{x} = 121,5/6 = 20,25$. Desviaciones: $20,3 - 20,25 = 0,05$, $20,4 - 20,25 = 0,15$, $19,8 - 20,25 = -0,45$, $20,4 - 20,25 = 0,15$, $19,9 - 20,25 = -0,35$, $20,7 - 20,25 = 0,45$. Cuadrados: 0,0025, 0,0225, 0,2025, 0,0225, 0,1225, 0,2025. Suma = $0,0025 + 0,0225 = 0,025$, $+0,2025=0,2275$, $+0,0225=0,25$, $+0,1225=0,3725$, $+0,2025=0,575$. Varianza $s^2 = 0,575/5 = 0,115$, $s = \sqrt{0,115} = 0,339$. Error estándar $\sigma_{\bar{x}} = s/\sqrt{6} = 0,339/2,449 = 0,1385$. $t = |20,25 - 20,00|/0,1385 = 0,25/0,1385 = 1,805$. Para 5 grados de libertad, el valor crítico de t para 95
- (b) Suma de las 25 medias: $20,25+20,10 = 40,35$, $+20,02=60,37$, $+20,12=80,49$, $+20,00=100,49$, $+19,73=120,22$, $+19,73=139,95$, $+20,13=160,08$, $+20,22=180,3$, $+20,22=200,52$, $+20,27=220,79$, $+19,83=240,62$, $+20,00=260,62$, $+19,77=280,39$, $+20,10=300,49$, $+20,28=320,77$, $+19,97=340,74$, $+19,88=360,62$, $+20,32=380,94$, $+19,98=400,92$, $+20,05=420,97$, $+20,23=441,2$, $+19,92=461,12$, $+19,97=481,09$, $+19,77=500,86$. Media de las medias $\bar{\bar{x}} = 500,86/25 = 20,0344$. Desviación estándar de las medias: calculamos la varianza de estos 25 números. Es más fácil usar la fórmula. La suma de cuadrados de estas medias: (omitimos el cálculo por brevedad) debe dar aproximadamente $s_{\bar{x}} \approx 0,15$. El error estándar de una media individual de 6 mediciones era 0.1385, que es consistente con la desviación estándar de las medias observada.

Ejercicio 4.13

Los siguientes datos representan la distribución de frecuencias de 200 variables extraídas de una población parental gaussiana con media $\mu = 26,00$ y desviación estándar

$\sigma = 5,00$. Los intervalos tienen dos unidades de ancho y el borde inferior del primer intervalo está en $x = 14$.

4 8 11 20 26 31 29 22 26 13 5 2 3

- Trace un histograma de estos datos.
- A partir de la media μ y la desviación estándar σ , calcule la función gaussiana que representa la distribución parental, normalizada al área del histograma. Su primer punto debe calcularse en $x = 15$, el punto medio del primer intervalo.
- Calcule χ^2 para probar la concordancia entre los datos y la curva teórica.
- ¿Cuál es el valor esperado de χ^2 ?
- Consulte la Tabla C.4 para encontrar la probabilidad de χ^2 del ajuste, es decir, la probabilidad de extraer una muestra aleatoria de la población parental que arroje un valor de χ^2 tan grande o mayor que su valor calculado.

Solución:

- El histograma tiene 13 intervalos, desde 14-16 hasta 38-40. Las frecuencias son las dadas.
- Puntos medios: 15, 17, 19, 21, 23, 25, 27, 29, 31, 33, 35, 37, 39. Calculamos la probabilidad gaussiana en cada punto: $P(x) = \frac{1}{\sigma\sqrt{2\pi}}e^{-(x-\mu)^2/(2\sigma^2)}$. Con $\mu = 26$, $\sigma = 5$. El área total del histograma es 200. Multiplicamos la densidad por el ancho del intervalo (2) y por 200 para obtener el número esperado en cada intervalo. Calculamos para cada punto medio: $z = (x - 26)/5$. Para $x=15$, $z=-2.2$, $e^{-z^2/2} = e^{-2,42} = 0,089$, densidad = $0,089/(5 \times 2,5066) = 0,089/12,533 = 0,0071$, esperado = $0,0071 \times 2 \times 200 = 0,0071 \times 400 = 2,84$. Similar para los demás. Luego se calcula $\chi^2 = \sum(O - E)^2/E$, sumando sobre todos los intervalos.
- El cálculo de χ^2 requiere los valores esperados.
- El valor esperado de χ^2 es el número de grados de libertad. Como tenemos 13 intervalos y no hemos estimado parámetros de los datos (usamos los verdaderos μ y σ), los grados de libertad son $\nu = 13 - 1 = 12$ (por la normalización). Si hubiéramos estimado μ y σ de los datos, sería $13-3=10$.
- Usando la tabla, con el χ^2 calculado y $\nu = 12$, se encuentra la probabilidad.

Ejercicio 4.14

Trace un histograma en intervalos de diez puntos de las calificaciones del curso enumeradas en el Ejercicio 1.5. Trace una curva gaussiana basada en la media y la desviación estándar de los datos, normalizada al área del histograma. Aplique la prueba de χ^2 y verifique la probabilidad asociada de la Tabla C.4.

Solución: Requiere agrupar las calificaciones en intervalos de 10 puntos (por ejemplo, 50-59, 60-69, etc.), contar frecuencias, calcular la media y desviación estándar de los datos (ya calculadas: $\bar{x} \approx 77,36$, $s \approx 8,5$), luego calcular las frecuencias esperadas bajo la gaussiana, y finalmente χ^2 con los grados de libertad apropiados. Se deja al estudiante.

Capítulo 5: Técnicas de Monte Carlo

5.1 Introducción

Vimos en el Capítulo 4 la importancia de las distribuciones de probabilidad en el análisis de muestras de datos, y observamos que generalmente estamos interesados en las integrales o sumas de dichas distribuciones sobre rangos especificados. Aunque solo hemos considerado experimentos que se describen mediante una única distribución, la mayoría de los experimentos implican una combinación de muchas distribuciones de probabilidad diferentes. Considere, por ejemplo, un experimento de dispersión simple para medir la distribución angular de partículas dispersadas por protones en un blanco fijo. La magnitud y dirección del vector de momento de las partículas incidentes, la probabilidad de que una partícula colisione con un protón en el blanco y los vectores de momento resultantes de las partículas dispersadas pueden describirse todos en términos de distribuciones de probabilidad. El resultado experimental final puede tratarse en términos de una integración múltiple sobre todas estas distribuciones.

La evaluación analítica de tal integral rara vez es posible, por lo que deben utilizarse métodos numéricos. Sin embargo, incluso la integración numérica de primer orden más simple puede volverse muy tediosa para una integral multidimensional. Una integral unidimensional de una función puede determinarse eficientemente evaluando la función N veces en una rejilla regular, donde el número de muestras N depende de la estructura de la función y de la precisión requerida. (Véase el Apéndice A.3). Una integral bidimensional requiere muestreo en dos dimensiones y, para una precisión comparable a la del problema unidimensional correspondiente, requiere algo así como N^2 muestras. Una integral tridimensional requiere algo así como N^3 muestras. Para integrales con muchas dimensiones, el número de puntos de la rejilla en los que debe calcularse la función se vuelve excesivamente grande.

Antes de continuar con los métodos de extracción de parámetros a partir de los datos, examinemos el método de Monte Carlo, una forma de evaluar estas integrales múltiples que depende del muestreo aleatorio a partir de distribuciones de densidad de probabilidad, en lugar de técnicas de muestreo basadas en rejillas regulares. El método de Monte Carlo proporciona al científico experimental una de las herramientas más poderosas disponibles para planificar experimentos y analizar datos. Básicamente, Monte Carlo es un método para calcular integrales múltiples mediante muestreo aleatorio. En la práctica, proporciona un método para simular experimentos y crear modelos de datos experimentales. Con un cálculo de Monte Carlo, podemos probar la significación estadística de los datos con cálculos relativamente simples que no requieren una comprensión teórica profunda del análisis estadístico ni técnicas de programación sofisticadas.

El nombre Monte Carlo proviene de la ciudad mediterránea con su famoso casino, y un cálculo de Monte Carlo implica un método estadístico para estudiar problemas basado en el uso de números aleatorios, similares a los generados en los juegos de azar del casino. Uno podría preguntarse razonablemente si el estudio de la ciencia puede ser ayudado por tales asociaciones, pero de hecho, con las técnicas de Monte Carlo, se pueden resolver problemas científicos y matemáticos muy complicados con considerable facilidad y precisión.

Ejemplo 5.1. Supongamos que deseamos encontrar el área de un círculo de radio r_c pero hemos olvidado la ecuación. Podríamos inscribir el círculo dentro de un cuadrado de área conocida A_s y cubrir la superficie del cuadrado uniformemente con pequeños marcadores, por ejemplo, granos de arroz. En-

contramos la relación entre el número de granos que se encuentran dentro del círculo y los que cubren el cuadrado, y determinamos el área del círculo A_c a partir de la relación

$$A_c = A_s N_c / N_s \quad (5.1)$$

donde N_c y N_s son los números de granos de arroz dentro de los límites del círculo y del cuadrado, respectivamente.

¿Cuál sería la precisión de esta determinación; es decir, qué tan cerca deberíamos esperar que nuestro resultado concuerde con el valor verdadero para el área de un círculo? Claramente dependería del número y tamaño de los granos de arroz en relación con el tamaño del cuadrado, y de la uniformidad tanto de los granos como de su distribución sobre el cuadrado. ¿Qué pasaría si decidiéramos que, en lugar de intentar cubrir el cuadrado uniformemente, nos contentáramos con un muestreo aleatorio obtenido lanzando los granos de arroz desde una distancia para que cayeran aleatoriamente en el cuadrado, con cada ubicación igualmente probable? Entonces obtendríamos un resultado interesante: Nuestro problema se reduciría a un simple cálculo binomial siempre y cuando no sobrepobláramos el cuadrado, sino que mantuviéramos baja la densidad de granos de arroz, de modo que la posición de cualquier grano en el cuadrado no estuviera influenciada por la presencia de otros granos. Encontraríamos que, para un número fijo de granos N_s lanzados sobre el cuadrado, la incertidumbre σ en la medición del área circular vendría dada por la desviación estándar para la distribución binomial con probabilidad $p = A_c/A_s$,

$$\sigma = \sqrt{N_s p(1-p)} = \sqrt{N_c(1-p)} \quad (5.2)$$

Por lo tanto, si aumentáramos el número de granos de arroz N_c en un factor de 4, el error relativo en nuestra determinación del área del círculo disminuiría en un factor de 2.

Reemplazar los granos de arroz lanzados por un conjunto de números aleatorios generados por computadora es una mejora obvia. Inscribamos nuestro círculo de radio unidad en un cuadrado de lado 2, y generemos $N = 100$ pares de números aleatorios entre -1 y $+1$ para determinar el área. Entonces la probabilidad de un “acierto” es simplemente la relación entre el área del círculo y el área del cuadrado, o $p = \pi/4$, por lo que en 100 intentos, el número medio de aciertos será $\mu = 100p = 78,5$, y la desviación estándar, de la Ecuación (5.2), será $\sigma = \sqrt{Np(1-p)} = \sqrt{100(\pi/4)(1-\pi/4)} = 4,1$. Para nuestras mediciones del área del círculo con 100 intentos, deberíamos esperar obtener de la Ecuación (5.1) $A_c = A_s \times N_c/N_s = (78,5 \pm 4,1) \times 2^2/100 = 3,14 \pm 0,16$.

La Figura 5.1 muestra una distribución típica de aciertos de un “lanzamiento” de 100 pares de números aleatorios. En este ejemplo hubo 73 aciertos, por lo que deberíamos estimar el área y su incertidumbre a partir de las Ecuaciones (5.1) y (5.2) como $A = 2,92 \pm 0,18$. Para determinar la incertidumbre, asumimos que no conocíamos la probabilidad a priori $p = \pi/4$ y, por lo tanto, utilizamos nuestra estimación experimental $p \approx 73/100$.

La Figura 5.2 muestra un histograma de las estimaciones del área del círculo obtenidas en 100 ejecuciones independientes de Monte Carlo, cada una con 100 pares de números aleatorios (o un total de 10,000 “lanzamientos”). La curva gaussiana se calculó a partir de la media, $A = 3,127$, y la desviación estándar, $\sigma = 0,156$, de las 100 áreas estimadas.

Obviamente, el problema de determinación del área del Ejemplo 5.1 es demasiado simple para requerir un cálculo de Monte Carlo. Sin embargo, para problemas que implican integraciones de muchas variables y para aquellos con límites de integración complicados, la técnica de Monte Carlo es invaluable, con su muestreo directo y su determinación relativamente simple de las incertidumbres.

5.2 Números Aleatorios

Un cálculo exitoso de Monte Carlo requiere un conjunto fiable de números aleatorios, pero los números verdaderamente aleatorios para usar en cálculos son difíciles de obtener. Uno podría pensar en un esquema basado en medir los tiempos entre impactos de rayos cósmicos en un detector, o en algún proceso físico como la generación de ruido en un circuito electrónico. Tales números serían aleatorios en el sentido de que sería imposible predecir el valor del siguiente número a partir de los números anteriores, pero difícilmente son convenientes de usar en cálculos extensos, y algunos podrían no tener la uniformidad necesaria para un cálculo de Monte Carlo.

De hecho, generalmente es preferible usar números pseudoaleatorios, números generados por un algoritmo de computadora diseñado para producir una secuencia de números aparentemente no correlacionados que se distribuyen uniformemente en un rango predefinido. Además de la conveniencia de poder generar estos números dentro del propio programa de Monte Carlo, los números pseudoaleatorios tienen otra ventaja importante sobre los números verdaderamente aleatorios para los cálculos de Monte Carlo. Un programa de Monte Carlo puede usar una gran cantidad de números aleatorios, y el camino del cálculo a través del programa dependerá de los números elegidos en cada ejecución. Con números verdaderamente aleatorios, cada ejecución de un cálculo de Monte Carlo seguiría un camino diferente y produciría resultados diferentes. Tal programa sería muy difícil de depurar.

Con números pseudoaleatorios, podemos repetir un cálculo con la misma secuencia de números y buscar cualquier problema particular que pueda estar oculto en el código.

Hay otras ventajas también. Si estamos estudiando la sensibilidad de un cálculo a variaciones en un parámetro seleccionado, podemos reducir la varianza de la diferencia entre los resultados calculados con dos valores de prueba del parámetro utilizando la misma secuencia de números aleatorios para aquellas partes del cálculo que son independientes del parámetro en cuestión. Finalmente, un generador de números pseudoaleatorios puede escribirse para que sea portátil; es decir, la secuencia de números producida por el algoritmo es independiente del hardware y el lenguaje de la computadora, de modo que un programa dado producirá los mismos resultados cuando se ejecute en diferentes computadoras. En vista de estas ventajas y del hecho de que rara vez, o nunca, nos encontramos con situaciones en las que se requieran números verdaderamente aleatorios, de ahora en adelante usaremos el término números aleatorios para denotar números pseudoaleatorios.

En general, nuestro generador de números aleatorios debe satisfacer los siguientes criterios básicos:

1. La distribución de los números debe ser uniforme dentro de un rango especificado y debe satisfacer pruebas estadísticas de aleatoriedad, como la falta de predictibilidad y de correlaciones entre números vecinos.
2. El cálculo debe producir un gran número de números únicos antes de repetir el ciclo.
3. El cálculo debe ser muy rápido.

A menudo se utiliza un método de multiplicación simple para generar números aleatorios, o desviaciones uniformes, como se les llama a menudo. Se elige un valor inicial entero o semilla r_0 y dos constantes enteras. Los números aleatorios sucesivos se derivan de la relación de recurrencia

$$r_{i+1} = (a \times r_i) \text{ mód } m \quad (5.3)$$

donde la operación mod corresponde a dividir el producto entre paréntesis por el entero m para obtener el resto. Con elecciones apropiadas de las constantes a y m , podemos obtener una secuencia finita de números que parecen seleccionados aleatoriamente entre 1 y $m - 1$. La longitud de la secuencia está determinada por la elección de las constantes y está limitada por el tamaño de palabra de la computadora. Por ejemplo, si elegimos $m = 37$ y $a = 5$, la Ecuación (5.3) nos da el ciclo de 36 números bien mezclados, enumerados en la Tabla 5.1. Los generadores de números aleatorios incluidos en los lenguajes de computadora a menudo se basan en alguna variación de esta técnica de multiplicación. Se deben realizar estudios estadísticos cuidadosos y exhaustivos para asegurarse de que un generador de números aleatorios no probado produce una secuencia aceptable de números.

Debido a que los números generados por la Ecuación (5.3) no son verdaderamente aleatorios, podríamos preocuparnos de que nuestros cálculos se vean afectados por correlaciones ocultas en números generados sucesivamente. Podemos mejorar la aleatoriedad de nuestra muestra barajando los números. Generamos dos secuencias de números con diferentes generadores a y m ; una secuencia se almacena en una matriz y un número de la segunda secuencia se usa como índice para seleccionar números de la primera secuencia. Para programas grandes que emplean muchos números aleatorios, este método está limitado por el espacio de almacenamiento, aunque se puede usar un barajado local dentro de un bloque de números aleatorios.

Una discusión exhaustiva de la generación de números aleatorios y de la técnica de Monte Carlo se da en Knuth (1981).

Advertencia

Si está utilizando números aleatorios proporcionados en programas comerciales como hojas de cálculo o incluso programas de análisis de datos científicos, siempre debe verificar las distribuciones de números aleatorios en busca de correlaciones y asegurarse de que la función se comporta como se anuncia. Por ejemplo, en las primeras versiones de un programa de análisis de datos científicos muy popular, la elección de la semilla no tenía efecto sobre los números producidos por la rutina de números aleatorios.

5.3 Números Aleatorios a partir de Distribuciones de Probabilidad

Método de Transformación

La mayoría de los generadores de números escalan su salida para proporcionar números reales distribuidos uniformemente entre 0 y 1. En general, sin embargo, requerimos números extraídos de distribuciones de probabilidad específicas. Definamos desviaciones uniformes $p(r)$ extraídas de una distribución de densidad de probabilidad estándar que es uniforme entre $r = 0$ y $r = 1$:

$$p(r) = \begin{cases} 1 & \text{para } 0 \leq r < 1 \\ 0 & \text{en otro caso} \end{cases} \quad (5.4)$$

La distribución está normalizada de modo que

$$\int_{-\infty}^{\infty} p(r) dr = \int_0^1 1 dr = 1 \quad (5.5)$$

Nos referiremos a $p(r)$ como la distribución uniforme.

Supongamos que requerimos desviaciones aleatorias de una distribución de densidad de probabilidad normalizada diferente $P(x)$, que se define como uniforme entre $x = -1$ y 1 ; es decir, la distribución

$$P(x) = \begin{cases} 1/2 & \text{para } -1 \leq x < 1 \\ 0 & \text{en otro caso} \end{cases} \quad (5.6)$$

Si elegimos una desviación aleatoria r entre 0 y 1 de la distribución uniforme de la Ecuación (5.4), es obvio que podemos calcular otra desviación aleatoria x como una función de r :

$$x = f(r) = 2r - 1 \quad (5.7)$$

que se distribuirá uniformemente entre -1 y $+1$. Este es un ejemplo de una transformación lineal simple.

Para elegir una muestra aleatoria x de la distribución de la Ecuación (5.6), comenzamos con una desviación aleatoria r extraída de la distribución uniforme de la Ecuación (5.4) y encontramos una función $f(r)$ que diera la relación requerida entre x y r . Encontremos una relación general para obtener una desviación aleatoria x de cualquier distribución de densidad de probabilidad $P(x)$, en términos de la desviación aleatoria r extraída de la distribución de probabilidad uniforme $p(r)$.

La conservación de la probabilidad requiere que los intervalos Δr y Δx estén relacionados por la siguiente expresión

$$|p(r)\Delta r| = |P(x)\Delta x| \quad (5.8)$$

y, por lo tanto, podemos escribir

$$\int_{r=-\infty}^r p(r) dr = \int_{x=-\infty}^x P(x) dx \quad \text{o} \quad \int_{r=0}^r 1 dr = \int_{x=-\infty}^x P(x) dx \quad (5.9)$$

lo que da el resultado general

$$r = \int_{x=-\infty}^x P(x)dx \quad (5.10)$$

Por lo tanto, para encontrar x , seleccionado aleatoriamente de la distribución de probabilidad $P(x)$, generamos un número aleatorio r de la distribución uniforme y encontramos el valor del límite x que satisface la ecuación integral (5.10).

Ejemplo 5.2. Considere la distribución descrita por la ecuación

$$P(x) = \begin{cases} A(1 + ax^2) & \text{para } -1 \leq x < 1 \\ 0 & \text{en otro caso} \end{cases} \quad (5.11)$$

donde $P(x)$ es positiva o cero en todos los puntos dentro del rango especificado, y la constante de normalización A se elige de modo que

$$\int_{-1}^1 P(x)dx = 1 \quad (5.12)$$

Tenemos

$$r = \int_{-\infty}^x P(x)dx = \int_{-1}^x A(1 + ax^2)dx \quad (5.13)$$

lo que da

$$r = A \left(x + \frac{ax^3}{3} + 1 + \frac{a}{3} \right) \quad (5.14)$$

y por lo tanto, para encontrar x debemos resolver la ecuación de tercer grado (5.14).

El procedimiento que hemos descrito se denomina método de transformación para generar desviaciones aleatorias a partir de distribuciones de probabilidad. En general, ni la ecuación integral (5.13) ni la solución de la ecuación resultante (5.14) pueden obtenerse analíticamente, por lo que son necesarios cálculos numéricos.

Se requieren los siguientes pasos para generar desviaciones aleatorias a partir de una distribución de probabilidad específica mediante el método de transformación con una integración numérica:

1. Decidir el rango de x . Algunas funciones de densidad de probabilidad están definidas en un rango finito, como en la Ecuación (5.6); otras, como la función gaussiana, se extienden hasta el infinito. Para cálculos numéricos, se deben establecer límites finitos razonables en el rango de la variable.
2. Normalizar la función de probabilidad. Si es necesario imponer límites en el rango de la variable x , entonces la función debe renormalizarse para asegurar que la integral sea la unidad en el rango recién definido. La integral de normalización debe calcularse mediante la misma rutina de integración analítica o integración numérica que se utiliza para encontrar x .

3. Generar una variable aleatoria r extraída de la distribución uniforme $p(r)$.
4. Integrar la función de probabilidad normalizada $P(x)$ desde menos infinito (o su límite inferior definido) hasta el valor $x = x$, donde x satisface la Ecuación (5.10).

Debido a que el método de Monte Carlo generalmente requiere la generación de grandes números de eventos individuales, es esencial tener disponibles rutinas rápidas de interpolación e integración numérica. Para reducir el tiempo de cálculo, a menudo es eficiente establecer tablas de soluciones o integrales de uso repetido dentro de la sección de inicialización de un programa de Monte Carlo. Por ejemplo, para elegir una desviación aleatoria x de la distribución de la Ecuación (5.11), podríamos hacer la integral de la Ecuación (5.13) numéricamente al comienzo de nuestro programa y establecer una tabla de valores de r versus x . Entonces, cuando necesitemos un número aleatorio de la distribución, generamos un número aleatorio r y buscamos en la tabla el valor correspondiente de x . En general, la búsqueda debe ir seguida de una interpolación dentro de la tabla (véase el Apéndice A.1) para evitar introducir una granularidad excesiva en la distribución resultante. Sería aún más conveniente, pero un poco más complicado, producir una tabla de x versus r , de modo que el valor requerido de x pudiera obtenerse a partir de un índice derivado de r . En todos los casos de tablas precalculadas, es importante considerar la resolución requerida en la variable generada, porque esto determinará los intervalos a los que deben almacenarse los datos y, por lo tanto, el tamaño de la tabla y el tiempo necesario para una búsqueda.

Método de Rechazo

Aunque el método de transformación es probablemente el método más útil para obtener desviaciones aleatorias extraídas de distribuciones particulares, el método de rechazo es a menudo el más fácil de usar. Este es el método que utilizamos en el Ejemplo 5.1 para encontrar el área de un círculo, generando números aleatorios uniformemente sobre la superficie del círculo y rechazando todos excepto aquellos que cayeron dentro de la circunferencia.

Ejemplo 5.3. Supongamos que deseamos obtener desviaciones aleatorias entre $x = -1$ y $x = +1$, extraídas de la función de distribución

$$P(x) = 1 + ax^2 \quad (5.15)$$

que es solo la distribución no normalizada de la Ecuación (5.11). Para usar el método de rechazo, comenzamos generando una desviación aleatoria x' distribuida uniformemente entre -1 y $+1$, correspondiente al rango permitido de x , y una segunda desviación aleatoria y' distribuida uniformemente entre 0 y $(1 + a)$, correspondiente al rango permitido de $P(x)$. Podemos ver que x' y y' deben estar dadas por

$$x' = -1 + 2r_i, \quad y' = (1 + a)r_{i+1} \quad (5.16)$$

donde r_i y r_{i+1} son valores aleatorios sucesivos de r extraídos de la distribución uniforme.

Contamos un evento como un “acierto” si el punto (x', y') cae entre la curva definida por $P(x)$ y el eje x , es decir, si $y' < P(x')$, y como un “fallo” si cae por encima de la curva. En el límite de un gran número de intentos, toda la gráfica, incluida el área entre la curva y el eje x , estará uniformemente poblada por esta operación y nuestras muestras seleccionadas serán las coordenadas x de los “aciertos”, o los valores de x' , extraídos aleatoriamente de la distribución $P(x)$. Nótese que con este método no es necesario normalizar la distribución para formar una verdadera función de probabilidad. Es suficiente que la distribución sea positiva y esté bien comportada dentro de su rango permitido.

La ventaja del método de rechazo sobre el método de transformación es su simplicidad. No se requiere una integración, solo es necesario calcular la propia función de probabilidad. Una desventaja del método es a menudo su baja eficiencia. En un programa de Monte Carlo complejo, solo una pequeña fracción de los eventos puede sobrevivir al cálculo completo para convertirse en “aciertos” exitosos, y la generación y posterior rechazo de tantos números aleatorios puede consumir mucho tiempo. Para reducir este problema, es aconsejable colocar los límites más estrictos posibles en las coordenadas aleatorias utilizadas para mapear la función de distribución cuando se utiliza el método de rechazo.

5.4 Distribuciones Específicas

Distribución Gaussiana

Casi cualquier cálculo de Monte Carlo que simule mediciones experimentales requerirá la generación de desviaciones extraídas de una distribución gaussiana, o desviaciones gaussianas. Una aplicación común es la simulación de incertidumbres de medición mediante el “smearing” (dispersión) de variables. Afortunadamente, debido a las convenientes propiedades de escalado de la función gaussiana, solo es necesario generar desviaciones gaussianas a partir de la distribución estándar

$$P_G(z)dz = \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{z^2}{2}\right] dz \quad (5.17)$$

con media 0 y desviación estándar 1, y escalar a diferentes medias μ y desviaciones estándar σ calculando

$$x = \sigma z + \mu \quad (5.18)$$

Hay varias formas diferentes de obtener muestras aleatorias de la variable z a partir de la distribución $P_G(z)$ de la Ecuación (5.17). Los dos más obvios son los métodos de rechazo y transformación discutidos anteriormente. Debido a que la función gaussiana está definida entre $-\infty$ y $+\infty$, estos métodos requieren que se coloquen límites en el rango de z . Para cálculos de baja estadística en los que la función gaussiana se utiliza para simular la dispersión de datos causada por errores de medición, un rango de $\pm 3\sigma$ debería ser satisfactorio porque todos los eventos, excepto aproximadamente el 0,3% de los normalmente distribuidos, se encuentran dentro de este rango.

Debido a que la función gaussiana no puede integrarse analíticamente, se requieren integraciones numéricas para el método de transformación. Se deben tomar decisiones sobre el orden de integración y el tamaño de paso, así como sobre los límites. Una integración numérica de primer o segundo orden (Apéndice A.3) es generalmente satisfactoria, con

una interpolación lineal para encontrar una aproximación al valor de x en la Ecuación (5.10) en el valor requerido de la integral.

Un método interesante para generar desviaciones gaussianas se basa en el hecho de que si calculamos repetidamente las medias de grupos de números extraídos aleatoriamente de cualquier distribución, la distribución de esas medias tiende a una gaussiana a medida que aumenta el número de medias. Por lo tanto, si calculamos muchas veces las sumas de N desviaciones uniformes, extraídas de la distribución uniforme, deberíamos esperar que las sumas caigan en una distribución gaussiana truncada, acotada por 0 y N , con valor medio $N/2$. Si generamos N valores de r a partir de la distribución de la Ecuación (5.4) y calculamos

$$r_G = \sum_{i=1}^N r_i - N/2 \quad (5.19)$$

la variable r_G se extraerá de una distribución aproximadamente gaussiana con media $\mu = 0$ y desviación estándar $\sigma = \sqrt{N/12}$. Debemos notar que el rango máximo de r_G estará limitado a $\mu \pm N/2$ o $\mu \pm \sigma\sqrt{3N}$. Para $N = 2$, la suma es una función triangular y a medida que N aumenta, la distribución rápidamente adquiere una forma similar a la gaussiana. Valores de N tan pequeños como $N = 4$ son adecuados para cálculos de baja estadística. Con $N = 4$, tenemos $\sigma = \sqrt{1/3} \approx 0,58$ y el rango de r_G de -2 a $+2$ corresponde a $\mu \pm \sigma\sqrt{12}$ o $\mu \pm 3,46\sigma$. Si se requiere una mejor aproximación a la función gaussiana y el tiempo de cálculo no es un problema, $N = 12$ es particularmente conveniente porque la varianza y la desviación estándar resultantes son la unidad.

Un método particularmente elegante para obtener números aleatorios extraídos de la distribución gaussiana fue sugerido por Box y Muller (1958). Este método hace uso del hecho de que, aunque el método de transformación simple requiere una integración de la función gaussiana, es posible encontrar una función que genere la distribución gaussiana bidimensional,

$$f(z_1, z_2) = \frac{1}{2\pi} \exp\left(-\frac{(z_1^2 + z_2^2)}{2}\right) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z_1^2}{2}\right) \times \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z_2^2}{2}\right) \quad (5.20)$$

A partir de esta ecuación, los autores obtuvieron expresiones que generan dos desviaciones gaussianas, z_1 y z_2 , a partir de dos desviaciones uniformes, r_1 y r_2 :

$$\begin{aligned} z_1 &= \sqrt{-2 \ln r_1} \cos 2\pi r_2 \\ z_2 &= \sqrt{-2 \ln r_1} \sin 2\pi r_2 \end{aligned} \quad (5.21)$$

Ejemplo 5.4. Una varilla uniforme de 10 cm de longitud tiene un extremo mantenido a 0°C y el otro a 100°C , de modo que se espera que la temperatura a lo largo de la varilla varíe linealmente de 0° a 100°C . Intentemos simular datos que se obtendrían midiendo la temperatura en intervalos regulares a lo largo de la varilla. Supondremos que la población parental se describe mediante la ecuación

$$T = a_0 + b_0 x \quad (5.22)$$

con $a_0 = 0^\circ\text{C}$ y $b_0 = 10^\circ\text{C}/\text{cm}$, y que se realizan 10 mediciones en intervalos de 1 cm desde $x = 0,5$ hasta $x = 9,5$ cm, con incertidumbres de medición

despreciables en x_i e incertidumbres de medición uniformes en T_i de $\sigma_T = 1,0^\circ\text{C}$.

El Ejemplo 5.4 ilustra una técnica común de Monte Carlo: simular los efectos de las incertidumbres de medición mediante la dispersión de puntos de datos. Si una variable particular tiene un valor medio T_i , con incertidumbres σ_i y se suponen incertidumbres gaussianas, entonces obtenemos el valor disperso de T_i a partir de la relación

$$T'_i = T_i + \sigma_i r_i \quad (5.23)$$

donde r_i es una variable aleatoria extraída de la distribución gaussiana estándar con media 0 y desviación estándar 1. El cálculo equivale a extraer la variable aleatoria T'_i directamente de una distribución gaussiana con media T_i y desviación estándar σ_i .

Programa 5.1. HOTROD (Apéndice E) Un cálculo simple de Monte Carlo para simular las mediciones descritas en el Ejemplo 5.4. El programa utiliza rutinas en la unidad de programa MONTELIB.

Programa 5.3. MONTELIB (Apéndice E) Algunas rutinas útiles de Monte Carlo.

Los datos generados por el programa HOTROD se muestran en la Tabla 5.2, con valores de T_i para la población parental, predichos por la Ecuación (5.22), y de T'_i para la población muestral, calculados a partir de la Ecuación (5.23) para varios valores de x_i . Nótese que, como deberíamos esperar, los valores modificados de T están dispersos alrededor de los valores calculados a partir de la Ecuación (5.22).

Elección de un Método

¿Cuál de estos métodos para generar muestras a partir de la distribución de probabilidad gaussiana es el mejor? La respuesta depende de la necesidad y la circunstancia. Para uso general, es conveniente mantener una versión del método de Box-Müller en su biblioteca de programas. Esta rutina produce un rango continuo de muestras limitado solo por el tamaño de palabra de la computadora. Sin embargo, para trabajos de alta precisión, debemos ser conscientes de que se ha demostrado que las correlaciones sutiles entre desviaciones uniformes adyacentes distorsionan las colas de la distribución gaussiana de estos números. Si la velocidad máxima es esencial, entonces el método de transformación con una tabla precalculada de la integral y algunos punteros para un acceso rápido a la tabla debería ser la elección. Este método requiere tomar decisiones sobre el rango y la resolución de la variable generada y algo de programación adicional para crear y acceder a la tabla integral, pero el método de búsqueda puede ser muy rápido. Finalmente, si está varado en una isla desierta con solo su computadora portátil y tiene una necesidad urgente de selecciones aleatorias de una distribución gaussiana, el método de sumar N números aleatorios es lo suficientemente simple como para que pueda escribir y depurar la rutina en unos minutos, siempre que pueda recordar que el número mágico es $N = 12$ para una varianza de 1.

Distribución de Poisson

La estadística de Poisson es importante en la mayoría de los cálculos de Monte Carlo, pero generalmente está implícita en lugar de calcularse explícitamente. Sin embargo, a veces deseamos generar datos que se distribuyan según la función de Poisson, y la aplicación del método de transformación al problema es particularmente simple e instructiva. Para

encontrar un entero x extraído de la distribución de Poisson con media μ , una desviación de Poisson, generamos una variable aleatoria r a partir de la distribución uniforme, reemplazamos la integral de la Ecuación (5.10) por la suma

$$r = \sum_{x=0}^x P_p(x; \mu) = \sum_{x=0}^x \frac{\mu^x}{x!} e^{-\mu} \quad (5.24)$$

y resolvemos la Ecuación (5.24) para x .

Aunque la función de Poisson no tiene las convenientes propiedades de escalado de la función gaussiana, y por lo tanto se requieren diferentes cálculos para cada valor de la media μ , en realidad se necesitan muy pocos cálculos porque estamos interesados en esta distribución solo para valores pequeños de μ , digamos $\mu \leq 16$, y solo en valores enteros del argumento x . Para valores más grandes de μ , la distribución de Poisson se vuelve indistinguible de la gaussiana y generalmente es más conveniente emplear la función gaussiana en los cálculos.

Ejemplo 5.5. Un instructor está preparando un ejercicio sobre estadística de Poisson para su clase. Planea proporcionar a cada estudiante un conjunto de datos simulado correspondiente a 200 mediciones de contador Geiger del flujo de rayos cósmicos registradas en intervalos de 10 segundos con una tasa de conteo media supuesta de 8.4 cuentas por intervalo. Los datos corresponderán al número de cuentas registradas en cada intervalo de 10 segundos.

Se pedirá a los estudiantes que hagan histogramas de sus muestras de datos individuales, encuentren las medias y desviaciones estándar de los datos y comparen sus distribuciones con las predicciones de las funciones de probabilidad gaussiana y de Poisson.

Para cada estudiante, se genera un conjunto de valores de x a partir de la Ecuación (5.24) con $\mu = 8,4$ y 200 números aleatorios diferentes. Se utiliza el método de transformación con una tabla precalculada de sumas, de modo que el valor de x asociado con cada valor de r pueda seleccionarse mediante una búsqueda simple. Para asegurar que el conjunto de datos de cada estudiante sea independiente, o bien todos los conjuntos se generan en una sola ejecución de computadora o bien las semillas de números aleatorios se guardan al final de cada ejecución y se utilizan para iniciar la siguiente ejecución.

Programa 5.2. POISDECAY (Apéndice E) Genera 200 variables aleatorias extraídas de la distribución de probabilidad de Poisson con media $\mu = 8,4$ para ilustrar el Ejemplo 5.5. El programa utiliza rutinas en la unidad de programa MONTELIB.

El programa llama a la función POISSONDEViate con el segundo argumento INIT = TRUE para configurar una tabla de sumas de $P_p(i; \mu)$ desde $i = 0$ hasta n indexada por n ; es decir, para formar la matriz

$$S_n = \sum_{i=0}^n P_p(i; \mu) \quad \text{para } n = 1, 2, \dots, n_{\text{máx}} \quad (5.25)$$

de modo que

$$S_n = S_{n-1} + P_p(n; \mu) \quad \text{con } S_0 = P_p(0; \mu) = e^{-\mu} \quad (5.26)$$

donde $n_{\text{máx}} = N + 8\sqrt{\mu}$ se selecciona como un límite superior razonable para la curva de Poisson.

Para cada evento, el programa llama a POISSONDEViate con el segundo argumento INIT = FALSE para seleccionar un valor de la tabla. La rutina POISSONDEViate genera un número aleatorio r a partir de la distribución uniforme y busca en la tabla comenzando en S_0 , para encontrar el valor de n para el cual $S_n \geq r$. El valor de n en el que esto ocurre es la muestra aleatoria deseada de la distribución de Poisson. A medida que se generan las muestras, se ingresan en un histograma mediante llamadas a la rutina HISTOGRAM.

Un histograma de 200 variables extraídas de la distribución de Poisson del Programa 5.2 se muestra en la Figura 5.3 con la distribución parental representada como una curva sólida (aunque, por supuesto, no está definida entre valores enteros de la abscisa). Los valores de la función de Poisson, calculados por la rutina POISSONRECUR, y las sumas, calculadas por la rutina POISSONDEViate, para $\mu = 8,4$ y para n desde 0 hasta 31, se muestran en la Tabla 5.3.

Observamos que con la tabla precalculada, solo es necesario incrementar un contador unas pocas veces y comparar dos números reales para obtener cada variable aleatoria, mientras que, sin la tabla, habría sido necesario calcular la función de Poisson varias veces para cada muestra generada, además de comparar los dos números reales.

Distribución Exponencial

Si el problema de Monte Carlo incluye la generación de estados inestables, se necesitarán números aleatorios extraídos de una distribución exponencial. Aquí, el método de transformación es claramente el método de elección porque la ecuación integral (5.10) y la ecuación resultante pueden resolverse analíticamente.

Ejemplo 5.6. Considere un experimento para estudiar la tasa de desintegración de una fuente radiactiva con vida media estimada de τ segundos. El experimento consiste en recolectar cuentas en intervalos de tiempo sucesivos Δt con un contador Geiger y un escalador, y trazar el número de cuentas en cada intervalo frente al tiempo medio del intervalo.

Deseamos simular este experimento con un cálculo de Monte Carlo. La función de densidad de probabilidad normalizada para obtener una cuenta en el tiempo t a partir de una distribución exponencial con vida media τ viene dada por

$$P_e(t; \tau) = \begin{cases} 0 & \text{para } t < 0 \\ \frac{e^{-t/\tau}}{\tau} & \text{para } t \geq 0 \end{cases} \quad (5.27)$$

Podemos obtener una expresión para muestras aleatorias t_i de esta distribución aplicando la Ecuación (5.10) para obtener

$$t_i = -\tau \ln r_i \quad (5.28)$$

Por lo tanto, para obtener cada valor de t_i , encontramos un número aleatorio de la distribución uniforme y calculamos t_i a partir de la Ecuación (5.28).

Consideremos un segundo método para generar un histograma de datos para este ejemplo, un método que es mucho más eficiente, pero que limita severamente cualquier tratamiento posterior de los datos.

Podemos calcular la fracción de eventos que la distribución parental predice que caerían en cada uno de los intervalos del histograma de ancho Δt a partir de la ecuación

$$\Delta N'(t) = \int_{t-d}^{t+d} \frac{e^{-x/\tau}}{\tau} dx = \frac{\Delta t}{\tau} e^{-t/\tau} \quad (5.29)$$

donde hemos escrito $d = \Delta t/2$. El efecto de los errores estadísticos es dispersar cada uno de estos valores calculados de una manera consistente con la distribución de Poisson con media $\mu = \Delta N'_i$. Para valores pequeños de $\Delta N'_i$, encontramos el valor dispersado ΔN_i directamente a partir de la Ecuación (5.24):

$$r = \sum_{x=0}^{\Delta N} P_p(x; \Delta N') \quad (5.30)$$

Para valores más grandes de $\Delta N'_i$, el cálculo con la ecuación de Poisson sería demasiado tedioso, pero podemos usar el smearing gaussiano como en el Ejemplo 5.4 con $\sigma_i = \sqrt{\mu}$. Nótese que la ecuación de Poisson debe utilizarse para intervalos con baja estadística para asegurar un número positivo de cuentas en cada intervalo. (Un recordatorio: La distribución general de eventos en este ejemplo es exponencial; la distribución esperada de eventos en cada intervalo individual sigue la distribución de Poisson, como se discutió en la Sección 4.3.)

Aunque estos dos métodos para generar un conjunto de datos o histograma producen resultados estadísticos equivalentes para el Ejemplo 5.6, difieren en detalles importantes. El método de Monte Carlo completo requirió generar “eventos” individuales que pueden registrarse y estudiarse. Por ejemplo, podríamos verificar el comportamiento estadístico de los datos subdividiendo la muestra en varios grupos más pequeños. También podríamos investigar el efecto de disminuir así como aumentar los intervalos de agrupamiento Δt . Finalmente, si desearamos expandir el estudio, tal vez para considerar la geometría experimental y la eficiencia del detector, el método de Monte Carlo completo permitirá eso. El método de smearing, por otro lado, produce solo los diez números, que representan las cuentas en los diez intervalos. Aparte de fusionar los intervalos, no tenemos control sobre los datos para cálculos futuros. Es estrictamente un procedimiento rápido de “un solo disparo” con un objetivo limitado específico.

Ejemplo 5.7. Considere un experimento para determinar la vida media de una partícula elemental, el mesón K_S^0 de vida corta (que denominaremos kaón), a partir de mediciones de la desintegración en vuelo de muchas de estas partículas. En principio, podemos determinar la vida media τ midiendo la distribución de los tiempos de desintegración, ajustando la función de densidad de probabilidad de la Ecuación (5.27) a los datos y resolviendo para τ . En la práctica, debemos hacer correcciones por sesgos resultantes de ineficiencias de

detección, incluidas aquellas asociadas con los tamaños finitos de nuestros detectores. Podemos usar un cálculo de Monte Carlo para estimar estos sesgos y permitirnos aplicar la corrección adecuada.

La disposición experimental se esboza en la Figura 5.4. Una partícula cargada de alta energía p_i interactúa en el blanco en el vértice de producción V_1 para producir varias partículas secundarias cargadas y neutras, incluido un kaón neutro. El kaón viaja una distancia L antes de desintegrarse en dos piones, π_1 y π_2 , en el vértice de desintegración V_2 . Determinamos las coordenadas del vértice de producción midiendo en el detector de vértice de producción las trayectorias de las partículas cargadas que se producen con el kaón, y trazando hacia atrás estas trayectorias hasta su punto de intersección en el blanco. De manera similar, determinamos las coordenadas del vértice de desintegración midiendo en el detector de vértice de desintegración las trayectorias de los dos piones cargados de la desintegración del kaón, y trazando hacia atrás estas trayectorias hasta su punto de intersección, V_2 . (Las trayectorias de las partículas neutras son mucho más difíciles de medir que las de las partículas cargadas). Calculamos el momento del kaón neutro a partir de las mediciones de los vectores de momento de sus dos productos de desintegración, π_1 y π_2 .

La geometría del detector juega un papel crítico en el análisis de los datos. Solo podemos hacer mediciones útiles en eventos en los que las trayectorias de las partículas cargadas puedan medirse en los detectores de vértice. Para asegurar mediciones precisas de las trazas secundarias de la desintegración del kaón, definimos una región fiducial en la que debe ocurrir la desintegración. El rectángulo discontinuo en la Figura 5.4 indica la región fiducial con sus límites d_1 y d_2 a lo largo del eje x . Con estos límites, las partículas de vida muy corta y muy larga serán eliminadas de la muestra de datos, introduciendo un sesgo en la determinación de la vida media.

Los pasos principales en un programa de Monte Carlo para simular este experimento y evaluar los sesgos son:

1. Generar las coordenadas del vértice de producción y el vector de momento del kaón P a partir de la sección transversal conocida para la producción de kaones en la interacción de las partículas incidente y del blanco.
2. Considerar la eficiencia del detector de producción. Si el detector registra con éxito las partículas cargadas producidas en la interacción inicial, continuar con el paso 3; si no, marcar el evento como fallido e ir al paso 8.
3. Aplicar la Ecuación (5.28) para encontrar el tiempo de vuelo (o vida útil) T de cada kaón individual en su propio sistema de reposo. Utilizar el valor actual mejor conocido para la vida media τ .
4. Aplicar la transformación de Lorentz a T para encontrar la vida útil T' en el sistema de laboratorio.
5. Calcular el rango r del kaón en el laboratorio y, a partir de esto, la coordenada del punto de desintegración.
6. Verificar que el kaón se desintegra dentro del volumen fiducial. Si es así, continuar con el paso 7; de lo contrario, marcar el evento como fallido e ir al paso 8.

7. En el sistema de reposo del kaón, generar el par de vectores de los piones. Transformar al sistema de laboratorio y verificar si ambas partículas pueden detectarse en el detector de vértice de desintegración. Si pueden detectarse, marcar el evento como exitoso; si no, marcar el evento como fallido.
8. Registrar los detalles del evento y volver al paso 1 para generar un nuevo evento, o terminar si se ha alcanzado el número deseado de eventos.

Programa 5.4. KDECAY (sitio web) Ilustración del Ejemplo 5.7.

Para este programa de muestra, simplificamos el problema tratándolo en dos dimensiones y simplificamos u omitimos algunos de los pasos como se indica a continuación.

1. Suponer que cada kaón se produce en el plano ilustrado en la Figura 5.4 y viaja a lo largo del eje x . Generar una coordenada x del vértice x_0 y la magnitud del momento del kaón P a partir de distribuciones gaussianas adecuadas.
2. Omitir.
3. Encontrar la vida útil T del kaón en su propio sistema de reposo a partir del valor publicado de la vida media del kaón τ y la Ecuación (5.28).
4. Aplicar la transformación de Lorentz a T para encontrar la vida útil T' en el sistema de laboratorio:

$$T' = \gamma T, \quad \text{donde } \gamma = 1/\sqrt{1 - \beta^2} \text{ y } \beta = v/c$$

donde v es la velocidad del kaón en el laboratorio y c es la velocidad de la luz.

5. Calcular el rango r y el punto de desintegración x_d :

$$r = \beta c T' \quad \text{y} \quad x_d = x_0 + r$$

6. Verificar que la desintegración esté dentro del área fiducial, es decir, que

$$d_1 \leq x_d < d_2$$

Si no es así, marcar el evento como fallido; de lo contrario, marcar el evento como exitoso.

7. Omitir este paso.
8. Incrementar los contadores de eventos y registrar solo los eventos exitosos. Si se ha alcanzado el número deseado de eventos, terminar el cálculo; de lo contrario, ir al paso 1 para comenzar a generar el siguiente evento.

Las propiedades de las dos gaussianas y las otras constantes del cálculo se enumeran en la Tabla 5.4. Nótese que debemos usar como entrada a nuestro programa un valor razonable de la vida media del kaón, la cantidad que estamos intentando medir. Si la cantidad solo se hubiera medido deficientemente

antes, o quizás no se hubiera medido en absoluto, podría ser necesario ejecutar el programa de Monte Carlo con varios valores de prueba diferentes de τ , abarcando el valor esperado.

Para este ejemplo, generamos 4000 eventos de los cuales 2355 pasaron el corte fiducial. La Figura 5.5 muestra la distribución de los tiempos de vuelo T (o vidas útiles) en el sistema de reposo del kaón para eventos exitosos. La curva muestra la distribución esperada de los tiempos de vuelo si no se hubiera rechazado ningún evento. Obtenemos la eficiencia del sistema en función del tiempo de vuelo T calculando la relación entre el número $N'(T)$ de eventos exitosos y el número total $N(T)$ generado

$$\epsilon(T) = N'(T)/N(T) \quad (5.31)$$

Observamos que hay grandes pérdidas de eventos en tiempos cortos, por debajo de aproximadamente $T = 0,5 \times 10^{-10}$ s, causadas por el espacio entre el vértice de producción V_1 y el comienzo de la región fiducial d_1 , y pérdidas más pequeñas, pero significativas, en tiempos largos de eventos que se desintegraron más allá del final de la región fiducial, d_2 .

Para corregir los datos obtenidos en un experimento real y distribuidos como $N_{\text{exp}}(T)$, primero debemos ejecutar el Monte Carlo para generar números suficientes de eventos de modo que las incertidumbres en los $N'(T)$ sean despreciables en comparación con las incertidumbres en la muestra de datos experimental. Luego debemos seleccionar una región continua de nuestra muestra de datos donde la eficiencia sea razonablemente buena (¡y definitivamente no cero!) y corregir las mediciones escalando $N_{\text{exp}}(T)$ por $1/\epsilon(T)$. Nótese que las incertidumbres estadísticas en los datos medidos también deben escalarse, por lo que hay poco sentido en incluir datos de regiones de muy baja eficiencia de la muestra. Luego podemos obtener nuestra estimación de la vida media del kaón a partir de un ajuste por mínimos cuadrados de la Ecuación (5.27) a los datos corregidos. (Un recordatorio: Aunque la distribución general de eventos en este ejemplo es exponencial, la distribución esperada de eventos en cada intervalo individual sigue la distribución de Poisson, como se discutió en la Sección 4.4.)

Una discusión más detallada de las técnicas de análisis para este experimento se encuentra en el Capítulo 10.

5.5 Generación Eficiente de Monte Carlo

Debido a que el error relativo en un resultado calculado por el método de Monte Carlo es inversamente proporcional a la raíz cuadrada del número de eventos exitosos generados, es importante, especialmente para un cálculo largo, tener la mayor eficiencia posible del programa. Los eventos rechazados no mejoran la precisión estadística y se debe hacer todo lo posible para reducir el tiempo dedicado a cálculos que conducen a “fallos” en lugar de “aciertos”. Hay varias formas de mejorar la eficiencia de generación:

1. No sea un purista. El método de Monte Carlo es básicamente una forma de hacer integrales multidimensionales complicadas. Si puede ahorrar tiempo haciendo parte del problema mediante métodos analíticos, hágalo.

2. Programe cuidadosamente. No repita cálculos si los resultados pueden guardarse para su uso posterior.
3. Si es posible, pruebe las secciones de bajo rendimiento de la simulación temprano y corte tan pronto como ocurra un “fallo”. Excepto para estudios de pérdida particulares, generalmente no es rentable seguir el cálculo de un evento que se sabe que termina en fracaso.
4. Intente reducir la varianza de los resultados limitando los rangos siempre que sea posible. Una aplicación de esta técnica puede ilustrarse en el Ejemplo 5.1, donde el área de un círculo de radio r_c se calcula inscribiéndolo dentro de un cuadrado. Hacer el lado del cuadrado más grande que el diámetro del círculo sería un desperdicio y aumentaría la varianza de la determinación del área.
5. Al repetir un cálculo para encontrar los efectos de variar un parámetro, considere configurar el programa de tal manera que se repita la secuencia idéntica de números aleatorios en todo el cálculo, excepto para los cálculos específicamente asociados con el cambio. Esta técnica no mejorará la varianza del cálculo general, pero reducirá la varianza de la diferencia de resultados de dos cálculos.
6. Inspeccione cada función de probabilidad cuidadosamente antes de comenzar un cálculo y estime la resolución y el detalle que se requerirán en el cálculo. Si una distribución tiene una estructura fina, intente determinar si dicha estructura es de interés y debe preservarse. Si es necesario, considere dividir los cálculos en regiones separadas y variar la sensibilidad de muestreo según corresponda para cada región.
7. Sea crítico. Examine sus variables generadas para ver que caen dentro de los rangos esperados y siguen las distribuciones esperadas. En un programa grande, los errores que afectan los resultados de maneras sutiles pueden estar enterrados dentro del programa y ser muy difíciles de detectar. La única forma de prevenir problemas es hacer comprobaciones detalladas en cada etapa del programa.

Resumen

- **Números pseudoaleatorios:** Números creados por un algoritmo de computadora de tal manera que los números sucesivos parecen no estar correlacionados con los números anteriores. Se les denomina números aleatorios o desviaciones aleatorias.
- **Desviaciones uniformes:** Números pseudoaleatorios que se distribuyen uniformemente entre 0 y 1:

$$p(r) = \begin{cases} 1 & \text{para } 0 \leq r < 1 \\ 0 & \text{en otro caso} \end{cases}$$

- **Distribución normalizada:** Una distribución que se escala de modo que su integral en un rango especificado sea igual a la unidad.
- **Integral de transformación:** Transforma la variable r extraída aleatoriamente de la distribución uniforme en una variable x extraída aleatoriamente de la distribución $P(x)$:

$$\int_0^r 1 \, dr = \int_{-\infty}^x P(x) \, dx$$

- **Método de rechazo:** Un método para generar números aleatorios extraídos de distribuciones particulares rechazando aquellos que caen fuera de los límites geométricos de la distribución especificada.
- **Desviación gaussiana:** Número aleatorio extraído de una distribución gaussiana.
- **Desviación gaussiana rápida:** La suma de N números aleatorios se distribuye aproximadamente como una gaussiana con $\mu = N/2$ y $\sigma = \sqrt{N/12}$. Elija $N = 12$ y calcule $r_G = \sum r_i - N/2$ para obtener r_G extraído de la distribución gaussiana estándar con $\mu = 0$ y $\sigma = 1$.
- **Método de Box-Muller para desviaciones gaussianas:** Seleccione r_1 y r_2 de la distribución uniforme y calcule

$$z_1 = \sqrt{-2 \ln r_1} \cos 2\pi r_2 \quad \text{y} \quad z_2 = \sqrt{-2 \ln r_1} \sin 2\pi r_2$$

para obtener z_1 y z_2 extraídos de la distribución gaussiana estándar.

- **Dispersión de datos:** Método para añadir variaciones aleatorias a los cálculos para simular los efectos de errores de medición finitos, $T'_i = T_i + \sigma_i r_i$.
- **Números aleatorios de la distribución exponencial:** Para obtener un número aleatorio t_i extraído de la distribución exponencial, calcule $t_i = -\tau \ln r_i$ a partir de una desviación aleatoria r_i .

Ejercicios

Ejercicio 5.1

Escriba un programa de computadora que incorpore el generador de números pseudo-aleatorios de Wichmann y Hill y utilícelo para generar 100 números aleatorios comenzando con las semillas $s_1 = 13$, $s_2 = 117$ y $s_3 = 2019$. Haga un histograma de los números y dibuje una línea que represente el número esperado de eventos en cada intervalo. Calcule χ^2 para la concordancia entre el número esperado y el generado de eventos y encuentre la probabilidad asociada.

Solución: Este ejercicio requiere programación. El algoritmo de Wichmann-Hill es:

$$\begin{aligned} x_{i+1} &= 171x_i \quad \text{mód } 30269 \\ y_{i+1} &= 172y_i \quad \text{mód } 30307 \\ z_{i+1} &= 170z_i \quad \text{mód } 30323 \\ r_i &= \left(\frac{x_i}{30269} + \frac{y_i}{30307} + \frac{z_i}{30323} \right) \quad \text{mód } 1 \end{aligned}$$

Con semillas dadas, se generan 100 números. Luego se agrupan en intervalos (por ejemplo, 10 intervalos de 0 a 1) y se comparan las frecuencias observadas con las esperadas (10 por intervalo). El χ^2 se calcula y se compara con la distribución con 9 grados de libertad. No podemos dar un resultado numérico sin ejecutar el programa.

Ejercicio 5.2

- (a) Genere 1000 números aleatorios uniformemente distribuidos entre $-\pi$ y $+\pi$.
- (b) Genere 1000 números aleatorios entre $x = 0$ y 1 , distribuidos según la función de distribución $P(x) = (5x + 3)$. Use el método de transformación con una integración analítica.
- (c) Encuentre la media y la desviación estándar de cada distribución y compárelas con los valores predichos.
- (d) Haga un histograma de 20 intervalos de cada distribución y trace en cada uno la distribución predicha.
- (e) Calcule χ^2 para comparar cada distribución generada con su distribución parental.

Solución:

- (a) Para generar números uniformes entre $-\pi$ y π , usamos $x = -\pi + 2\pi r$, donde r es uniforme en $[0,1)$.
- (b) Para $P(x) = 5x + 3$ en $[0,1]$, primero normalizamos: $\int_0^1 (5x + 3)dx = [\frac{5}{2}x^2 + 3x]_0^1 = \frac{5}{2} + 3 = \frac{11}{2} = 5,5$. Por tanto, la densidad normalizada es $p(x) = \frac{2}{11}(5x + 3)$. La CDF es $F(x) = \int_0^x p(t)dt = \frac{2}{11}[\frac{5}{2}t^2 + 3t]_0^x = \frac{2}{11}(\frac{5}{2}x^2 + 3x) = \frac{5}{11}x^2 + \frac{6}{11}x$. Igualamos $F(x) = r$, entonces $\frac{5}{11}x^2 + \frac{6}{11}x - r = 0$. Resolvemos la cuadrática: $5x^2 + 6x - 11r = 0$. La solución positiva es $x = \frac{-6 + \sqrt{36 + 220r}}{10}$. Así generamos x a partir de r .
- (c) La media de la distribución uniforme en $[-\pi, \pi]$ es 0 , varianza $\sigma^2 = \frac{(2\pi)^2}{12} = \frac{\pi^2}{3} \approx 3,29$. Para la distribución $P(x)$, la media es $\int_0^1 x \frac{2}{11}(5x + 3)dx = \frac{2}{11} \int_0^1 (5x^2 + 3x)dx = \frac{2}{11}[\frac{5}{3}x^3 + \frac{3}{2}x^2]_0^1 = \frac{2}{11}(\frac{5}{3} + \frac{3}{2}) = \frac{2}{11}(\frac{10}{6} + \frac{9}{6}) = \frac{2}{11} \cdot \frac{19}{6} = \frac{38}{66} = \frac{19}{33} \approx 0,5758$. Varianza: $\int_0^1 x^2 p(x)dx - \mu^2$. $\int_0^1 x^2 p(x)dx = \frac{2}{11} \int_0^1 (5x^3 + 3x^2)dx = \frac{2}{11}[\frac{5}{4}x^4 + x^3]_0^1 = \frac{2}{11}(\frac{5}{4} + 1) = \frac{2}{11} \cdot \frac{9}{4} = \frac{18}{44} = \frac{9}{22} \approx 0,4091$. Entonces $\sigma^2 = 0,4091 - (0,5758)^2 = 0,4091 - 0,3315 = 0,0776$, $\sigma \approx 0,2786$. Las medias y varianzas de las muestras generadas deben aproximarse a estos valores.
- (d) Se realiza un histograma y se superpone la curva teórica.
- (e) χ^2 se calcula como $\sum (O - E)^2 / E$ con 20 intervalos (19 grados de libertad si se usa la normalización de la muestra).

Ejercicio 5.3

Escriba una rutina general para generar enteros aleatorios extraídos de la distribución binomial mediante el método de transformación. Use la rutina para generar 1000 eventos correspondientes a la distribución de caras o cruces cuando se lanza una moneda 50 veces. Trace sus resultados y compárelos con la predicción directa de la Ecuación (2.4).

Solución: Para la binomial con $n = 50$, $p = 0,5$, la probabilidad $P(k) = \binom{50}{k}(0,5)^{50}$. El método de transformación requiere calcular la CDF $F(k) = \sum_{i=0}^k P(i)$ y luego para cada r uniforme encontrar el k tal que $F(k-1) \leq r < F(k)$. Se generan 1000 valores y se comparan con las probabilidades teóricas. Se puede trazar un histograma y superponer la curva binomial.

Ejercicio 5.4

Escriba una rutina de Monte Carlo para simular 200 lanzamientos de un par de dados y encuentre la frecuencia de ocurrencias de cada suma posible. Trace un histograma de las ocurrencias con barras de error estadísticas y trace la predicción de la distribución binomial. Calcule χ^2 para la concordancia entre la predicción y los datos, y encuentre la probabilidad de χ^2 . Compare sus resultados con el cálculo de probabilidad exacta del Ejercicio 2.4.

Solución: Se simulan 200 lanzamientos de dos dados. Para cada lanzamiento, se generan dos números enteros aleatorios entre 1 y 6 (usando $\lfloor 6r \rfloor + 1$), se suma y se incrementa el contador correspondiente. Luego se comparan las frecuencias observadas con las esperadas (dadas por las probabilidades del Ejercicio 2.4 multiplicadas por 200). Se calcula χ^2 con 11 grados de libertad (12 sumas posibles, menos 1 por normalización) y se obtiene la probabilidad.

Ejercicio 5.5

Haga un histograma de 200 números aleatorios que sigan la distribución gaussiana encontrando la distribución de las sumas de grupos de 12 variables aleatorias extraídas de la distribución uniforme. Calcule la media y la desviación estándar de los números generados y la incertidumbre en la media.

Solución: Se generan 200 números gaussianos aproximados usando el método de la suma de 12 uniformes: para cada uno, se suman 12 números r_i uniformes en $[0,1]$ y se resta 6. Esto da una media 0 y desviación estándar 1. Se calcula la media muestral y la desviación estándar de los 200 números, y el error estándar de la media. Deberían aproximarse a 0 y 1.

Ejercicio 5.6

Genere 1000 números aleatorios entre $x = -3$ y $+3$, distribuidos según la distribución lorentziana con media $\mu = 0$ y semiancho $\Gamma = 1,0$. Use el método de transformación con una integración numérica e interpolación. (Véanse los Apéndices A.1 y A.3.) Haga un histograma de 20 intervalos de los números generados y trace la curva lorentziana en la distribución. Calcule χ^2 para comparar la distribución generada con la distribución parental.

Solución: La lorentziana tiene CDF $F(x) = \frac{1}{2} + \frac{1}{\pi} \arctan\left(\frac{x-\mu}{\Gamma/2}\right)$. Para generar, se resuelve $F(x) = r$ para x , es decir, $x = \mu + \frac{\Gamma}{2} \tan\left(\pi(r - \frac{1}{2})\right)$. Se generan 1000 valores, se agrupan en 20 intervalos entre -3 y 3, y se comparan con las frecuencias esperadas (integral de la lorentziana en cada intervalo). Se calcula χ^2 con 19 grados de libertad.

Ejercicio 5.7

Use el método de transformación para producir una secuencia de 200 números aleatorios x extraídos de la distribución

$$P(x) = \sin x \quad \text{para } 0 \leq x < \pi$$
$$= 0 \quad \text{en otro caso}$$

Haga un histograma de los eventos y compárelo con la distribución esperada. Nótese que el cálculo puede hacerse analíticamente y requiere una función trigonométrica inversa.

Solución: Primero normalizamos: $\int_0^\pi \sin x dx = 2$. Por tanto, la densidad normalizada es $p(x) = \frac{1}{2} \sin x$. La CDF es $F(x) = \int_0^x \frac{1}{2} \sin t dt = \frac{1}{2}(1 - \cos x)$. Igualamos a r : $\frac{1}{2}(1 - \cos x) = r \Rightarrow 1 - \cos x = 2r \Rightarrow \cos x = 1 - 2r \Rightarrow x = \arccos(1 - 2r)$. Así generamos x a partir de r uniforme.

Ejercicio 5.8

Use el método de rechazo para generar 500 desviaciones aleatorias entre $x = 0$ y $x = 1$, extraídas de la distribución $y(x) = a_1 + a_2 x^2$, con $a_1 = 3,4$ y $a_2 = 12,1$. Encuentre la media y la desviación estándar de los números generados y compárelos con los valores esperados.

Solución: Primero, la función no está normalizada. El valor máximo de $y(x)$ en $[0,1]$ es en $x = 1$: $y_{\max} = 3,4 + 12,1 = 15,5$. Generamos x' uniforme en $[0,1]$ y y' uniforme en $[0, 15,5]$. Si $y' < y(x')$, aceptamos x' . Repetimos hasta tener 500 aceptados. Luego calculamos la media y varianza de los x aceptados. La distribución normalizada esperada es $p(x) = \frac{y(x)}{\int_0^1 y(x) dx}$. La integral es $\int_0^1 (3,4 + 12,1x^2) dx = [3,4x + 12,1x^3/3]_0^1 = 3,4 + 4,0333 = 7,4333$. La media esperada es $\int_0^1 xp(x) dx = \frac{1}{7,4333} \int_0^1 (3,4x + 12,1x^3) dx = \frac{1}{7,4333} [1,7x^2 + 12,1x^4/4]_0^1 = \frac{1}{7,4333} (1,7 + 3,025) = \frac{4,725}{7,4333} \approx 0,6357$. La varianza esperada se calcula de manera similar.

Ejercicio 5.9

Escriba un programa de Monte Carlo para generar 200 cubos con lados $a = 2,0 \pm 0,1$ cm, $b = 3,0 \pm 0,1$ cm y $c = 4,0 \pm 0,2$ cm. Trace la distribución de los volúmenes de los cubos y encuentre el volumen medio, la desviación estándar de la distribución y la incertidumbre en la media. Compare la desviación estándar de la distribución con el valor predicho por la ecuación de propagación de errores.

Solución: Se generan 200 valores de a como $a = 2,0 + 0,1r_a$, donde r_a es gaussiano de media 0 y desviación 1 (o se puede usar uniforme para simular incertidumbre rectangular, pero aquí se asume gaussiana). Similar para b y c . Se calcula el volumen $V = abc$. Luego se calcula la media y desviación estándar de los 200 volúmenes. La propagación de errores da $\sigma_V/V = \sqrt{(\sigma_a/a)^2 + (\sigma_b/b)^2 + (\sigma_c/c)^2}$. Con $\sigma_a = 0,1$, $a = 2$, $\sigma_a/a = 0,05$; $\sigma_b/b = 0,1/3 = 0,0333$; $\sigma_c/c = 0,2/4 = 0,05$. Entonces $\sigma_V/V = \sqrt{0,0025 + 0,001111 + 0,0025} = \sqrt{0,006111} = 0,0782$. Volumen medio nominal $V = 2 \times 3 \times 4 = 24$, $\sigma_V \approx 24 \times 0,0782 = 1,877$. La desviación estándar de la muestra generada debería aproximarse a este valor.

Ejercicio 5.10

Un triángulo de Pascal proporciona una ilustración interesante de la relación entre las distribuciones de probabilidad binomial y gaussiana. Suponga una disposición de clavijas en forma de triángulo como se ilustra. (Imagen: una pirámide de clavijas, con una bola que cae desde arriba y se distribuye en compartimentos en la parte inferior.)

- Encuentre una expresión general para la probabilidad de que una bola caiga en un compartimento dado después de caer a través de N filas de clavijas.
- Suponga que se dejan caer 512 bolas sobre la clavija superior. Encuentre el número de bolas en cada compartimento inferior para un dispositivo con tres filas de clavijas sobre los compartimentos. Repita para dispositivos con cuatro, cinco y seis filas de clavijas.

- (c) Encuentre la desviación estándar de la distribución de bolas para cada ejemplo; es decir, suponga que el número de compartimento es la variable independiente de modo que $\bar{x} = 0$.
- (d) Trace histogramas de la distribución de las bolas con curvas gaussianas con las medias y desviaciones estándar determinadas en (c).

Solución:

- (a) La probabilidad de que una bola caiga en el compartimento k (comenzando desde 0) después de N filas es la binomial: $P(k) = \binom{N}{k}(1/2)^N$.
- (b) Para $N = 3$, las probabilidades son $\binom{3}{k}/8$: $k = 0 : 1/8$, $k = 1 : 3/8$, $k = 2 : 3/8$, $k = 3 : 1/8$. Con 512 bolas, los números son: 64, 192, 192, 64. Para $N = 4$: $\binom{4}{k}/16$: 1,4,6,4,1; números: 32,128,192,128,32. Para $N = 5$: $\binom{5}{k}/32$: 1,5,10,10,5,1; números: 16,80,160,160,80,16. Para $N = 6$: $\binom{6}{k}/64$: 1,6,15,20,15,6,1; números: 8,48,120,160,120,48,8.
- (c) La desviación estándar de la distribución binomial es $\sigma = \sqrt{N/4}$. Para $N = 3$, $\sigma = \sqrt{0,75} \approx 0,866$; para $N = 4$, $\sigma = 1$; para $N = 5$, $\sigma = \sqrt{1,25} \approx 1,118$; para $N = 6$, $\sigma = \sqrt{1,5} \approx 1,225$.
- (d) Se trazan los histogramas y se superpone la gaussiana correspondiente con $\mu = N/2$ y σ calculado.

Ejercicio 5.11

Escriba un programa de Monte Carlo para simular el dispositivo del triángulo de Pascal descrito en el ejercicio anterior. Compare los resultados obtenidos con los dos métodos.

Solución: Se simula el proceso: para cada bola, se simula su camino a través de N filas: en cada fila, se genera un número aleatorio para decidir si va a la izquierda o derecha. Se cuenta en qué compartimento cae. Se repite para 512 bolas y se comparan las frecuencias obtenidas con las binomiales teóricas. Se puede calcular χ^2 para evaluar la concordancia.

Capítulo 6: Ajuste por Mínimos Cuadrados a una Línea Recta

6.1 Variables Dependientes e Independientes

A menudo deseamos determinar una característica y de un experimento en función de alguna otra cantidad x . Es decir, en lugar de hacer una serie de mediciones de una sola cantidad x , hacemos una serie de N mediciones del par (x_i, y_i) , una para cada uno de varios valores del índice i , que va de 1 a N . Nuestro objetivo es encontrar una función $y = y(x)$ que describa la relación entre estas dos variables medidas. En este capítulo consideramos el problema de pares de variables (x_i, y_i) que están relacionadas linealmente entre sí, y nos referimos a datos de dos experimentos de laboratorio de pregrado como ejemplos. En los siguientes capítulos, discutiremos métodos para encontrar relaciones que no son lineales.

Ejemplo 6.1. Un estudiante está estudiando corrientes eléctricas y diferencias de potencial. Se le ha proporcionado un cable de alambre de níquel-plata de 1 m montado en una tabla, una batería de plomo-ácido y un voltímetro analógico. Conecta celdas de la batería a través del cable y mide la diferencia de potencial o voltaje entre el extremo negativo y varias posiciones a lo largo del cable. Al examinar el medidor, estima la incertidumbre en cada medición de potencial como 0.05 V. La incertidumbre en la posición de la sonda es inferior a 1 mm y se considera despreciable.

Los datos se enumeran en la Tabla 6.1 y se representan en la Figura 6.1 para mostrar la diferencia de potencial en función de la longitud del cable x . La incertidumbre común estimada en cada diferencia de potencial medida se indica en el gráfico mediante las barras de error verticales. A partir de estas mediciones, deseamos encontrar la función lineal $y(x)$ (mostrada como una línea sólida) que describe la forma en que el voltaje V varía en función de la posición x a lo largo del cable.

Ejemplo 6.2. En otro experimento, se proporciona a un estudiante una fuente radiactiva encerrada en un pequeño disco de plástico de 8 mm de diámetro y un contador Geiger con una ventana frontal de 1 cm de diámetro. Su objetivo es investigar la ley de $1/r^2$ registrando mediciones del contador Geiger durante un período de tiempo fijo a varias distancias de la fuente entre 20 y 100 cm. Debido a que no se espera que la tasa de conteo varíe de una medición a otra, excepto por fluctuaciones estadísticas, el estudiante puede registrar datos durante el tiempo suficiente para obtener buena estadística en todo el rango del experimento. Utiliza un sistema de registro automático y registra cuentas durante treinta intervalos de 15 segundos en cada posición. Para el análisis en este experimento, suma las cuentas de cada conjunto de 30 mediciones para obtener el número de cuentas en intervalos de 7,5 m. Las mediciones separadas de intervalos de 15 segundos en cada posición pueden usarse en otros estudios estadísticos.

Los datos se enumeran en la Tabla 6.2 y se representan frente a $x = 1/r^2$ en la Figura 6.2. Las barras de error verticales en los puntos de datos representan las incertidumbres estadísticas en los números de cuentas medidos y son iguales a las raíces cuadradas de los números de cuentas. Se supuso que las incertidumbres en las mediciones de las distancias desde la fuente al contador eran despreciables.

Aproximación Lineal

En ambos ejemplos, la relación funcional entre las variables dependiente e independiente puede aproximarse mediante una línea recta de la forma

$$y(x) = a + bx \quad (6.1)$$

Consideraremos en este capítulo un método para determinar los valores más probables para los coeficientes a y b .

Incertidumbres de Medición

Si hiciéramos una serie de mediciones de la cantidad dependiente y_i para un valor particular x_i de la cantidad independiente, encontraríamos que los valores medidos se distribuyen alrededor de una media de la manera discutida en el Capítulo 5, con una probabilidad de aproximadamente el 68 % de que cualquier medición única de y_i esté dentro de 1 desviación estándar de la media. Haciendo una serie de mediciones para cada valor de la cantidad independiente x_i , podríamos determinar los valores medios $\bar{y}_i$ con cualquier precisión deseada. Por lo general, sin embargo, solo podemos hacer una medición y_i para cada valor de $x = x_i$, por lo que debemos determinar el valor de y correspondiente a ese valor de x con una incertidumbre que se caracteriza por la desviación estándar σ_i de la distribución de datos para ese punto.

Supondremos por simplicidad en todas las discusiones siguientes que podemos atribuir toda la incertidumbre en cada medición a la variable dependiente. Esto equivale a suponer que la precisión de la determinación de x es considerablemente mayor que la de y . Esta diferencia se ilustra en las Figuras 6.1 y 6.2 por el hecho de que las incertidumbres se indican mediante barras de error para las variables dependientes pero no para las variables independientes.

Nuestra condición, que despreciamos las incertidumbres en x y consideramos solo las incertidumbres en y , será válida solo si las incertidumbres en y que serían producidas por variaciones en x correspondientes a las incertidumbres en la medición de x son mucho más pequeñas que las incertidumbres en la medición de y . Esto equivale, en primer orden, al requisito en cada punto medido de que

$$\sigma_x \left| \frac{dy}{dx} \right| \ll \sigma_y$$

donde dy/dx es la pendiente de la función $y = y(x)$.

No siempre estamos justificados para atribuir todas las incertidumbres al parámetro dependiente. A veces las incertidumbres en la determinación de ambas cantidades x e y son casi iguales. Pero nuestro procedimiento de ajuste seguirá siendo bastante preciso si estimamos la contribución indirecta $\sigma_{y/I}$ de la incertidumbre σ_x en x a la incertidumbre total en y mediante la relación de primer orden

$$\sigma_{y/I} = \sigma_x \left| \frac{dy}{dx} \right| \quad (6.2)$$

y combinamos esto con la contribución directa $\sigma_{y/D}$, que es la incertidumbre de medición en y , para obtener

$$\sigma_y^2 = \sigma_{y/I}^2 + \sigma_{y/D}^2 \quad (6.3)$$

Para ambos Ejemplos 6.1 y 6.2, la condición sería razonable porque predecimos una dependencia lineal de y con x . Con la suposición lineal, tratamos las incertidumbres en nuestros datos como si estuvieran solo en la variable dependiente, mientras nos damos cuenta de que las fluctuaciones correspondientes pueden haberse derivado originalmente de incertidumbres en las determinaciones tanto de las variables dependientes como de las independientes.

En aquellos casos en que las incertidumbres en la determinación de la cantidad independiente son considerablemente mayores que las de la cantidad dependiente, podría ser aconsejable intercambiar la definición de las dos cantidades.

6.2 Método de Mínimos Cuadrados

Nuestros datos consisten en pares de mediciones (x_i, y_i) de una variable independiente x y una variable dependiente y . Deseamos encontrar valores de los parámetros a y b que minimicen la discrepancia entre los valores medidos y_i y los valores calculados $y(x)$. No podemos determinar los parámetros exactamente con solo un número finito de observaciones, pero podemos esperar extraer las estimaciones más probables para los coeficientes de la misma manera que extrajimos la estimación más probable de la media en el Capítulo 4.

Antes de proceder, debemos definir nuestros criterios para minimizar la discrepancia entre los valores medidos y predichos y_i . Para cualesquiera valores arbitrarios de a y b , podemos calcular las desviaciones Δy_i entre cada uno de los valores observados y_i y los valores correspondientes calculados o ajustados

$$\Delta y_i = y_i - y(x_i) = y_i - a - bx_i \quad (6.4)$$

Con parámetros bien elegidos, estas desviaciones deberían ser relativamente pequeñas. Sin embargo, la suma de estas desviaciones no es una buena medida de qué tan bien nuestra línea recta calculada se aproxima a los datos porque las grandes desviaciones positivas pueden equilibrarse con negativas para producir una suma pequeña incluso cuando el ajuste de la función $y(x)$ a los datos es malo. Podríamos considerar en cambio sumar los valores absolutos de las desviaciones, pero esto conduce a dificultades para obtener una solución analítica. En su lugar, sumamos los cuadrados de las desviaciones.

No existe un método único correcto para optimizar los parámetros válido para todos los problemas. Existe, sin embargo, un método que puede justificarse bastante bien, que es simple y directo, y que está bien establecido experimentalmente. Este es el método de mínimos cuadrados, similar al método discutido en el Capítulo 4, pero extendido para incluir más de una variable. Puede considerarse como un caso especial del método más general de máxima verosimilitud.

Método de Máxima Verosimilitud

Nuestros datos consisten en una muestra de observaciones extraídas de una distribución parental que determina la probabilidad de hacer cualquier observación particular. Para el problema particular de una relación lineal esperada entre las variables dependiente e independiente, definimos parámetros parentales a_0 y b_0 tales que la relación real entre y y x viene dada por

$$y_0(x) = a_0 + b_0x \quad (6.5)$$

Supondremos que cada valor medido individual de y_i se extrae a su vez de una distribución gaussiana con media $y_0(x_i)$ y desviación estándar σ_i . Debemos ser conscientes de que la suposición gaussiana puede no ser siempre exactamente cierta. En el Ejemplo 6.2, los $y_i = C_i$ se obtuvieron en un experimento de conteo y, por lo tanto, siguen una distribución de Poisson. Sin embargo, para un número suficientemente grande de cuentas y_i , la distribución puede considerarse gaussiana. Discutiremos el ajuste con estadística de Poisson en la Sección 6.6.

Con la suposición gaussiana, la probabilidad P_i de hacer la medición observada y_i con desviación estándar σ_i para las observaciones alrededor del valor real $y_0(x_i)$ es

$$P_i = \frac{1}{\sigma_i \sqrt{2\pi}} \exp \left\{ -\frac{1}{2} \left[\frac{y_i - y_0(x_i)}{\sigma_i} \right]^2 \right\} \quad (6.6)$$

La probabilidad de hacer el conjunto observado de mediciones de los N valores de y_i es el producto de las probabilidades para cada observación:

$$P(a_0, b_0) = \prod P_i = \prod \left(\frac{1}{\sigma_i \sqrt{2\pi}} \right) \exp \left\{ -\frac{1}{2} \sum \left[\frac{y_i - y_0(x_i)}{\sigma_i} \right]^2 \right\} \quad (6.7)$$

donde el producto $\prod$ se toma con i variando de 1 a N y el producto de las exponenciales se ha expresado como la exponencial de la suma de los argumentos. En estos productos y sumas, las cantidades $1/\sigma_i^2$ actúan como factores de ponderación.

De manera similar, para cualesquiera valores estimados de los parámetros a y b , podemos calcular la probabilidad de obtener el conjunto observado de mediciones

$$P(a, b) = \prod \left(\frac{1}{\sigma_i \sqrt{2\pi}} \right) \exp \left[-\frac{1}{2} \sum \left[\frac{y_i - y(x_i)}{\sigma_i} \right]^2 \right] \quad (6.8)$$

con $y(x)$ definida por la Ecuación (6.1) y evaluada en cada uno de los valores x_i .

Suponemos que el conjunto observado de mediciones es más probable que provenga de la distribución parental de la Ecuación (6.5) que de cualquier otra distribución similar con diferentes coeficientes y, por lo tanto, la probabilidad de la Ecuación (6.7) es la probabilidad máxima alcanzable con la Ecuación (6.8). Por lo tanto, las estimaciones de máxima verosimilitud para a y b son aquellos valores que maximizan la probabilidad de la Ecuación (6.8).

Debido a que el primer factor en el producto de la Ecuación (6.8) es una constante, independiente de los valores de a y b , maximizar la probabilidad $P(a, b)$ equivale a minimizar la suma en la exponencial. Definimos esta suma como nuestro parámetro de bondad de ajuste χ^2 :

$$\chi^2 = \sum \left[\frac{y_i - y(x_i)}{\sigma_i} \right]^2 = \sum \left[\frac{1}{\sigma_i} (y_i - a - bx_i) \right]^2 \quad (6.9)$$

Usamos el mismo símbolo χ^2 , definido anteriormente en la Ecuación (4.32), porque esta es esencialmente la misma definición en un contexto diferente.

Nuestro método para encontrar el ajuste óptimo a los datos será encontrar valores de a y b que minimicen esta suma ponderada de los cuadrados de las desviaciones χ^2 y, por lo tanto, encontrar el ajuste que produce la suma más pequeña de los cuadrados o el ajuste de mínimos cuadrados. La magnitud de χ^2 está determinada por cuatro factores:

1. Fluctuaciones en los valores medidos de las variables y_i , que son muestras aleatorias de una población parental con valores esperados $y_0(x_i)$.
2. Los valores asignados a las incertidumbres σ_i en las variables medidas y_i . La asignación incorrecta de las incertidumbres σ_i conducirá a valores incorrectos de χ^2 .
3. La selección de la función analítica $y(x)$ como una aproximación a la función “verdadera” $y_0(x)$. Podría ser necesario ajustar varias funciones diferentes para encontrar la función apropiada para un conjunto particular de datos.
4. Los valores de los parámetros de la función $y(x)$. Nuestro objetivo es encontrar los “mejores valores” de estos parámetros.

6.3 Minimización de χ^2

Para encontrar los valores de los parámetros a y b que producen el valor mínimo para χ^2 , igualamos a cero las derivadas parciales de χ^2 con respecto a cada uno de los parámetros

$$\frac{\partial \chi^2}{\partial a} = -2 \sum \frac{1}{\sigma_i^2} (y_i - a - bx_i) = 0 \quad (6.10a)$$

$$\frac{\partial \chi^2}{\partial b} = -2 \sum \frac{1}{\sigma_i^2} x_i (y_i - a - bx_i) = 0 \quad (6.10b)$$

Esto produce dos ecuaciones lineales en las dos incógnitas a y b :

$$a \sum \frac{1}{\sigma_i^2} + b \sum \frac{x_i}{\sigma_i^2} = \sum \frac{y_i}{\sigma_i^2} \quad (6.11a)$$

$$a \sum \frac{x_i}{\sigma_i^2} + b \sum \frac{x_i^2}{\sigma_i^2} = \sum \frac{x_i y_i}{\sigma_i^2} \quad (6.11b)$$

La solución de estas ecuaciones simultáneas para a y b se puede escribir en forma de determinantes como

$$a = \frac{\begin{vmatrix} \sum y_i/\sigma_i^2 & \sum x_i/\sigma_i^2 \\ \sum x_i y_i/\sigma_i^2 & \sum x_i^2/\sigma_i^2 \end{vmatrix}}{\begin{vmatrix} \sum 1/\sigma_i^2 & \sum x_i/\sigma_i^2 \\ \sum x_i/\sigma_i^2 & \sum x_i^2/\sigma_i^2 \end{vmatrix}} \quad (6.12a)$$

$$b = \frac{\begin{vmatrix} \sum 1/\sigma_i^2 & \sum y_i/\sigma_i^2 \\ \sum x_i/\sigma_i^2 & \sum x_i y_i/\sigma_i^2 \end{vmatrix}}{\begin{vmatrix} \sum 1/\sigma_i^2 & \sum x_i/\sigma_i^2 \\ \sum x_i/\sigma_i^2 & \sum x_i^2/\sigma_i^2 \end{vmatrix}} \quad (6.12b)$$

Si las incertidumbres son todas iguales, $\sigma_i = \sigma$, las ecuaciones se simplifican a

$$a = \frac{\begin{vmatrix} \sum y_i & \sum x_i \\ \sum x_i y_i & \sum x_i^2 \end{vmatrix}}{\begin{vmatrix} N & \sum x_i \\ \sum x_i & \sum x_i^2 \end{vmatrix}} \quad (6.13a)$$

$$b = \frac{\begin{vmatrix} N & \sum y_i \\ \sum x_i & \sum x_i y_i \end{vmatrix}}{\begin{vmatrix} N & \sum x_i \\ \sum x_i & \sum x_i^2 \end{vmatrix}} \quad (6.13b)$$

Ejemplos

Para los datos del Ejemplo 6.1 (Tabla 6.1), suponemos que las incertidumbres en los voltajes medidos V son todas iguales y que las incertidumbres en x_i son despreciables. Por lo tanto, podemos usar la Ecuación (6.13). Acumulamos cuatro sumas $\sum x_i$, $\sum y_i = \sum V_i$, $\sum x_i^2$ y $\sum x_i y_i = \sum x_i V_i$ y las combinamos según la Ecuación (6.13) para encontrar valores numéricos para a y b . Los pasos del cálculo se ilustran en la Tabla 6.1, y el ajuste resultante se muestra como una línea sólida en la Figura 6.1.

La determinación de los parámetros a y b a partir de la Ecuación (6.12) es algo más tediosa, porque deben incluirse las incertidumbres σ_i . La Tabla 6.2 muestra los pasos en el cálculo de los datos del Ejemplo 6.2 con las incertidumbres σ_i en los números de cuentas C_i determinadas por la estadística de Poisson, de modo que $\sigma_i^2 = C_i$. Los valores de a y b encontrados en este cálculo se utilizaron para calcular la línea recta a través de los puntos de datos en la Figura 6.2.

Es importante notar que el valor de C_i que se utilizará para determinar la incertidumbre σ_i debe ser el número real de eventos observados. Si, por ejemplo, el estudiante hubiera decidido mejorar su estadística recolectando datos a distancias mayores durante períodos de tiempo más largos Δt_i y normalizar todos sus datos a un intervalo de tiempo común Δt_c ,

$$C'_i = C_i \times \Delta t_c / \Delta t_i$$

entonces la incertidumbre estadística en C' vendría dada por

$$\sigma'_i = \sqrt{C'_i} \times \Delta t_c / \Delta t_i$$

Programa 6.1. FITLINE (Apéndice E) Solución de las Ecuaciones (6.11) mediante el método de determinantes de la Ecuación (6.12).

El programa utiliza rutinas en las unidades de programa FITVARS, FITUTIL y GENUTIL, que también son utilizadas por otros programas de ajuste. Los programas de muestra utilizan variables de precisión simple por simplicidad, aunque se recomienda encarecidamente la precisión doble o superior.

El Programa 6.1 utiliza la Ecuación (6.12) para resolver ambos Ejemplos 6.1 y 6.2, aunque escribir rutinas separadas para cada problema sería ligeramente más eficiente. Debido a que las mediciones del Ejemplo 6.1 tienen errores comunes, podríamos, por ejemplo, aumentar la velocidad de ajuste utilizando las Ecuaciones (6.13) en lugar de las Ecuaciones (6.12). De manera similar, para el Ejemplo 6.2, podríamos simplificar la rutina de ajuste reemplazando los errores estadísticos por la expresión explícita para $\sqrt{y_i}$. Sin embargo, en la mayoría de los cálculos que involucran errores estadísticos, también hay otros errores a considerar, como los que surgen de las sustracciones de fondo, por lo que la pérdida de generalidad compensaría más que cualquier aumento en la eficiencia de los cálculos.

Programa 6.2. FITVARS (sitio web) Archivo de inclusión de constantes, variables y matrices para ajustes por mínimos cuadrados.

Programa 6.3. FITUTIL (sitio web) Rutinas de utilidad para programas de ajuste. Rutinas de entrada/salida, cálculo de χ^2 , densidad de χ^2 y probabilidad integral de χ^2 .

6.4 Estimación de Errores

Incertidumbres Comunes

Si se desconocen las desviaciones estándar σ_i para los puntos de datos y_i , pero podemos suponer que todas son iguales, $\sigma_i^2 = \sigma^2$, entonces podemos estimarlas a partir de los datos y los resultados de nuestro ajuste. El requisito de errores iguales puede cumplirse si las incertidumbres son instrumentales y todos los datos se registran con el mismo instrumento y en la misma escala, como se supuso en el Ejemplo 6.1.

En el Capítulo 2 obtuvimos, para nuestra mejor estimación de la varianza de la muestra de datos,

$$\sigma^2 \simeq s^2 = \frac{1}{N-m} \sum (y_i - \bar{y})^2 \quad (6.14)$$

donde $N - m$ es el número de grados de libertad y es igual al número de mediciones menos el número de parámetros determinados a partir del ajuste. En la Ecuación (6.14) identificamos y_i con el valor medido de la variable dependiente, y para $\bar{y}$ el valor medio esperado de y_i , utilizamos el valor calculado a partir de la Ecuación (6.1) para cada punto de datos con los parámetros ajustados a y b . Por lo tanto, nuestra estimación $\sigma_i = \sigma$ para la desviación estándar de una medición individual es

$$\sigma^2 \simeq s^2 = \frac{1}{N-2} \sum (y_i - a - bx_i)^2 \quad (6.15)$$

Comparando la Ecuación (6.15) con la Ecuación (6.9), vemos que es precisamente esta incertidumbre común la que hemos minimizado en el procedimiento de ajuste por mínimos cuadrados. Por lo tanto, podemos obtener el error común en nuestras mediciones de y a partir del ajuste, aunque a expensas de cualquier información sobre la calidad del ajuste.

Incrtidumbres Variables

En general, las incertidumbres σ_i en las variables dependientes y_i no serán todas iguales. Si, por ejemplo, la cantidad y representa el número de cuentas en un detector por unidad de tiempo (como en el Ejemplo 6.2), entonces los errores son estadísticos y la incertidumbre en cada medición y_i está directamente relacionada con la magnitud de y (como se discutió en la Sección 4.2), y las desviaciones estándar σ_i asociadas con estas mediciones son

$$\sigma_i^2 = C_i \quad (6.16)$$

En principio, el valor de y_i que debería usarse para calcular las desviaciones estándar σ_i mediante la Ecuación (6.16) es el valor $y_0(x_i)$ de la población parental. En la práctica, usamos los valores medidos que son solo muestras de esa población. En el límite de un número infinito de determinaciones, el promedio de todas las mediciones se aproximaría mucho al valor parental, pero generalmente no podemos hacer más de una medición de cada valor de x_i , y mucho menos un número infinito. Podríamos aproximar el valor parental $y_0(x)$ utilizando el valor calculado $y(x)$ de nuestro ajuste, pero eso complicaría el procedimiento de ajuste. Discutiremos esta posibilidad más a fondo en la siguiente sección.

Las contribuciones de las incertidumbres instrumentales y de otro tipo pueden modificar la forma simple de raíz cuadrada de los errores estadísticos. Por ejemplo, las incertidumbres en la medición del intervalo de tiempo durante el cual se registraron los eventos del Ejemplo 6.2 podrían contribuir, aunque las fluctuaciones estadísticas generalmente dominan en los experimentos de conteo. Las sustracciones de fondo son otra fuente de incertidumbre. En muchos experimentos de conteo, hay un fondo debajo de los datos que puede eliminarse mediante sustracción, o puede incluirse en el ajuste. En el Ejemplo 6.2, los rayos cósmicos y otros fondos contribuyen a una tasa de conteo incluso cuando la fuente se aleja mucho del detector, como lo indica la intersección no nula de la línea ajustada de la Figura 6.2 en el eje C . Si el estudiante hubiera elegido registrar las cuentas de fondo de radiación C_b en una medición separada y restar C_b de cada una de sus mediciones C_i para obtener

$$C'_i = C_i - C_b$$

entonces la incertidumbre en C' habría estado dada combinando en cuadratura las incertidumbres en las dos mediciones:

$$\sigma_i'^2 = \sigma_i^2 + \sigma_b^2$$

Probabilidad de χ^2

Para aquellos datos para los que conocemos las incertidumbres σ_i en los valores medidos y_i , podemos calcular el valor de χ^2 a partir de la Ecuación (6.9) y probar la bondad de nuestro ajuste. Para nuestro ajuste de dos parámetros a una línea recta, el número de grados de libertad será $N - 2$. Entonces, para los datos del Ejemplo 6.2, deberíamos esperar obtener $\chi^2 \approx 10 - 2 = 8$. El valor real, $\chi^2 = 11,1$, se enumera en la Tabla 6.2, junto con la probabilidad ($p = 20\%$). (Véase la Tabla C.4). Interpretamos esta probabilidad de la siguiente manera. Supongamos que hemos obtenido una probabilidad de χ^2 del $p\%$ para un cierto conjunto de datos. Entonces, deberíamos esperar que, si repitiéramos el experimento muchas veces, aproximadamente el $p\%$ de los experimentos arrojarían valores de χ^2 tan altos como el que obtuvimos o más altos. Este tema se discutirá más a fondo en el Capítulo 11.

En el Ejemplo 6.1, obtuvimos un valor de $\chi^2 = 1,95$ para 7 grados de libertad, correspondiente a una probabilidad de aproximadamente el 96%. Aunque esta probabilidad puede parecer gratificadamente alta, el valor muy bajo de χ^2 da una fuerte indicación de que la incertidumbre común en los datos puede haber sido sobreestimada y podría ser aconsejable usar el valor de χ^2 para obtener una mejor estimación de la incertidumbre común. A partir de las Ecuaciones (6.15) y (6.9), obtenemos una expresión para la incertidumbre común revisada σ'_c en términos de χ^2 y la estimación original, σ_c :

$$\sigma_c'^2 \approx \sigma_i^2 \times \chi^2 / (N - 2) \quad (6.17)$$

o, más generalmente,

$$\sigma_c'^2 \approx \sigma_i^2 \times \chi_\nu^2 \quad (6.18)$$

donde $\chi_\nu^2 = \chi^2/\nu$ y ν es el número de grados de libertad en el ajuste. Por lo tanto, para el Ejemplo 6.1, encontramos $\sigma_c'^2 = 0,05^2 \times 1,95/7 = 0,0025 \times 0,2786 = 0,000696$, o $\sigma'_c \approx 0,026$ V.

Incetidumbres en los Parámetros

Podemos encontrar las incertidumbres en los parámetros a y b por propagación de errores. Las incertidumbres en los parámetros surgen de las incertidumbres en los puntos de datos individuales y_i . Aplicando la fórmula general de propagación de errores, Ecuación (4.10), a las Ecuaciones (6.12) y (6.13), podemos expresar las varianzas de a y b en términos de las varianzas de los puntos de datos y_i . Suponiendo que no hay correlaciones entre las mediciones, encontramos

$$\sigma_a^2 = \frac{\sum (x_i^2 / \sigma_i^2)}{\Delta} \quad (6.19a)$$

$$\sigma_b^2 = \frac{\sum(1/\sigma_i^2)}{\Delta} \quad (6.19b)$$

donde Δ es el determinante del denominador en la Ecuación (6.12):

$$\Delta = \left(\sum \frac{1}{\sigma_i^2} \right) \left(\sum \frac{x_i^2}{\sigma_i^2} \right) - \left(\sum \frac{x_i}{\sigma_i^2} \right)^2 \quad (6.20)$$

Las expresiones correspondientes para la covarianza de a y b son

$$\sigma_{ab}^2 = -\frac{\sum(x_i/\sigma_i^2)}{\Delta} \quad (6.21)$$

Si las incertidumbres no son iguales, las incertidumbres en los parámetros se obtienen de las Ecuaciones (6.19). Para el caso especial de incertidumbres comunes en y_i , $\sigma_i = \sigma$, estas ecuaciones se reducen a

$$\sigma_a^2 = \frac{\sigma^2}{\Delta'} \sum x_i^2 \quad \text{y} \quad \sigma_b^2 = N \frac{\sigma^2}{\Delta'} \quad (6.22)$$

con σ dado por la Ecuación (6.15) y Δ' dado por

$$\Delta' = N \sum x_i^2 - \left(\sum x_i \right)^2 \quad (6.13)$$

Las incertidumbres en los parámetros, σ_a y σ_b , calculadas a partir de las estimaciones de error originales, se enumeran en las Tablas 6.1 y 6.2. Para el Ejemplo 6.1, también se enumeran las incertidumbres revisadas σ'_a y σ'_b , basadas en la incertidumbre común de los datos revisada calculada a partir de la Ecuación (6.18).

6.5 Algunas Limitaciones del Método de Mínimos Cuadrados

Cuando se ajusta una curva mediante el método de mínimos cuadrados a una colección de datos de conteo estadístico, los datos primero deben ser histogramados; es decir, se debe formar un histograma de los datos corregidos, ya sea durante o después de la recolección de datos. En el Ejemplo 6.2, los datos se recolectaron en intervalos de tiempo Δt , con el tamaño del intervalo elegido para asegurar que se recolectara un número razonable de cuentas en cada intervalo de tiempo. Para datos que varían linealmente con la variable independiente, este tratamiento no plantea problemas especiales, pero uno podría imaginar un problema más complejo en el que los detalles finos de la variación de la variable dependiente y con la variable independiente x sean importantes. Tales detalles bien podrían perderse si el agrupamiento fuera demasiado grueso. Por otro lado, si el intervalo de agrupamiento fuera demasiado fino, podría no haber suficientes cuentas en cada intervalo para justificar la hipótesis de probabilidad gaussiana. ¿Cómo se elige el tamaño de intervalo apropiado para los datos?

Una regla general útil cuando se considera la distribución de Poisson es suponer que grande es igual a 10. Una comparación de las distribuciones gaussiana y de Poisson para una media $\mu \approx 10$ y desviación estándar $\sigma = \sqrt{\mu}$ (véanse las Figuras 2.4 y 2.5) muestra muy poca diferencia entre las dos distribuciones. Podríamos esperar esto porque la media está a más de 3 desviaciones estándar del origen. Por lo tanto, podemos tener una confianza razonable en los resultados de un ajuste si ningún histograma contiene menos de diez cuentas y si no estamos depositando una confianza excesiva en el valor real de χ^2 obtenido del ajuste. Si un intervalo tiene menos del número mínimo permitido de cuentas, puede

ser posible fusionar ese intervalo con uno adyacente. Nótese que no hay requisito de que los intervalos en la abscisa sean iguales, aunque debemos tener cuidado en nuestra elección del valor apropiado de x_i para el intervalo fusionado. También debemos ser conscientes de que tales fusiones reducen necesariamente la resolución de nuestros datos y pueden, al ajustar funciones más complicadas que una línea recta, oscurecer algunas características interesantes.

En general, la elección del ancho del intervalo será un compromiso entre la necesidad de suficiente estadística para mantener un error relativo pequeño en los valores de y_i y, por lo tanto, en los parámetros ajustados, y la necesidad de preservar la estructura interesante en los datos. Cuando deban preservarse todos los detalles de cualquier estructura en los datos, podría ser aconsejable aplicar el método de máxima verosimilitud directamente a los datos, evento por evento, en lugar de utilizar el método de mínimos cuadrados con su necesario agrupamiento de los datos. Volveremos a este tema en el Capítulo 10.

También hay una cuestión sobre nuestro uso de los errores experimentales en el proceso de ajuste, en lugar de los errores predichos por nuestra estimación de la distribución parental. Para el Ejemplo 6.2, esto corresponde a elegir $\sigma_i^2 = y_i$ en lugar de $\sigma_i^2 = y(x_i) = a + bx_i$. Consideraremos la posibilidad de usar errores de nuestra estimación de la distribución parental, así como la aplicación directa de la función de probabilidad de Poisson, en la siguiente sección.

Otro punto importante a considerar al ajustar curvas a datos es la posibilidad de errores de redondeo, que pueden reducir la precisión de los resultados. Con cálculos manuales, es importante evitar redondear los números hasta el final del cálculo. Con computadoras, pueden surgir problemas debido a la longitud de palabra finita de la computadora. Este problema puede ser especialmente grave con los cálculos de matrices y determinantes, que a menudo implican tomar pequeñas diferencias entre números grandes. Dependiendo de la computadora y el software, puede ser necesario usar variables de doble precisión en la rutina de ajuste.

Discutimos en el Capítulo 7 la interacción de parámetros en un ajuste multiparamétrico. Por ahora, vale la pena señalar que, para una distribución de datos nominalmente “plana”, la intersección obtenida de un ajuste a una línea recta puede no ser idéntica al valor medio de los puntos de datos en la ordenada. Véase el Ejercicio 6.7 para un ejemplo de este efecto.

6.6 Métodos de Ajuste Alternativos

En esta sección intentamos resolver el problema de ajustar una línea recta a una colección de puntos de datos utilizando errores determinados a partir de la distribución parental estimada en lugar de a partir de las mediciones, y aplicando directamente la estadística de Poisson, en lugar de la estadística gaussiana. Debido a que no es posible derivar un conjunto de ecuaciones lineales independientes para los parámetros con estas condiciones, no se pueden obtener expresiones explícitas para los parámetros a y b . Sin embargo, con computadoras rápidas, resolver ecuaciones acopladas no lineales no es difícil, aunque la claridad y elegancia del método directo de mínimos cuadrados pueden perderse.

Incertidumbres de Poisson

Consideremos una colección de datos puramente estadísticos que obedecen a la estadística de Poisson (como en el Ejemplo 6.2), de modo que las incertidumbres pueden expresarse mediante la Ecuación (6.16). Comenzamos sustituyendo la aproximación

$\sigma_i^2 = y(x_i) = a + bx_i$ en la definición de χ^2 en la Ecuación (6.9), que se basa en la probabilidad gaussiana, y minimizando el valor de χ^2 como en las Ecuaciones (6.10). El resultado es un par de ecuaciones simultáneas que pueden resolverse para a y b :

$$\begin{aligned}\sum \frac{y_i}{(a + bx_i)^2} &= \sum \frac{1}{a + bx_i} \\ \sum \frac{x_i y_i}{(a + bx_i)^2} &= \sum \frac{x_i}{a + bx_i}\end{aligned}\quad (6.24)$$

Probabilidad de Poisson

A continuación, reemplacemos la probabilidad gaussiana $P(a, b)$ de la Ecuación (6.8) por la probabilidad correspondiente de observar y_i cuentas a partir de una distribución de Poisson con media $\mu_i = y(x_i)$,

$$P(a, b) = \prod \left(\frac{[y(x_i)]^{y_i}}{y_i!} e^{-y(x_i)} \right) \quad (6.25)$$

y apliquemos el método de máxima verosimilitud a esta probabilidad. Es más fácil y equivalente maximizar el logaritmo natural de la probabilidad con respecto a cada uno de los parámetros a y b :

$$\ln P(a, b) = \sum [y_i \ln y(x_i)] - \sum y(x_i) + \text{constante} \quad (6.26)$$

donde el término constante es independiente de los parámetros a y b . El resultado de tomar derivadas parciales de la Ecuación (6.26) es un par de ecuaciones simultáneas similares a las de la Ecuación (6.24),

$$\begin{aligned}\sum \frac{y_i}{a + bx_i} &= N \\ \sum \frac{x_i y_i}{a + bx_i} &= \sum x_i\end{aligned}\quad (6.27)$$

pero con menos énfasis en el ajuste de los valores más grandes de y_i .

Ni las ecuaciones simultáneas acopladas (6.24) ni las Ecuaciones (6.27) pueden resolverse directamente para a y b , pero cada par puede resolverse mediante un método iterativo en el que se eligen valores de a y b y luego se ajustan hasta que se satisfagan las dos ecuaciones simultáneas. (Véase el Apéndice A.5).

Ejemplo 6.3. Debido a que esperamos que los métodos discutidos aquí sean equivalentes al método estándar para muestras de datos grandes, seleccionamos una muestra de baja estadística para enfatizar las diferencias. Elegimos de las mediciones del Ejemplo 6.2 solo aquellos eventos recolectados en cada posición del detector durante el primer intervalo de 15 segundos, un total de 128 eventos en diez posiciones diferentes. Los resultados de (i) cálculos mediante el método estándar, (ii) cálculos con estadística gaussiana y con errores dados por $\sigma_i = \sqrt{y(x_i)} = \sqrt{a + bx_i}$ y (iii) cálculos con estadística de Poisson con errores como en el método (ii) se enumeran en la Tabla 6.3 y se ilustran en la Figura 6.3. Observamos que el método (i) parece subestimar el número de eventos en la muestra, mientras que el método (ii) sobreestima el número. El método (iii) con estadística de Poisson y errores calculados como en el método (ii) encuentra el número exacto.

Podemos evitar las cuestiones del agrupamiento finito y la elección de la estadística haciendo uso directo del método de máxima verosimilitud, tratando la función de ajuste como una distribución de probabilidad. Este método también permite un manejo detallado de problemas en los que la probabilidad asociada con mediciones individuales varía de manera compleja de una observación a otra. Perseguiremos este tema más a fondo en el Capítulo 10.

En general, sin embargo, la simplicidad del método de mínimos cuadrados y la dificultad de resolver las ecuaciones que resultan de otros métodos, particularmente con funciones de ajuste más complicadas, nos lleva a elegir el método estándar de mínimos cuadrados para la mayoría de los problemas. Hacemos las siguientes dos suposiciones para simplificar el cálculo:

1. Suponemos que la función de ajuste es una aproximación adecuada a la función “verdadera”; cualquier desviación es pequeña en comparación con el error experimental.
2. Suponemos que los errores experimentales se distribuyen normalmente; si no es así, entonces las probabilidades asociadas con χ^2 ya no serán precisas. La distribución de χ^2 no es particularmente sensible a la forma de la distribución de errores; sin embargo, el criterio para minimizar χ^2 sigue siendo válido incluso si la distribución de errores no es gaussiana.

Resumen

- **Ajuste por mínimos cuadrados a una línea recta $y = a + bx$:**

$$a = \frac{\begin{vmatrix} \sum y_i/\sigma_i^2 & \sum x_i/\sigma_i^2 \\ \sum x_i y_i/\sigma_i^2 & \sum x_i^2/\sigma_i^2 \end{vmatrix}}{\begin{vmatrix} \sum 1/\sigma_i^2 & \sum x_i/\sigma_i^2 \\ \sum x_i/\sigma_i^2 & \sum x_i^2/\sigma_i^2 \end{vmatrix}}$$

$$b = \frac{\begin{vmatrix} \sum 1/\sigma_i^2 & \sum y_i/\sigma_i^2 \\ \sum x_i/\sigma_i^2 & \sum x_i y_i/\sigma_i^2 \end{vmatrix}}{\begin{vmatrix} \sum 1/\sigma_i^2 & \sum x_i/\sigma_i^2 \\ \sum x_i/\sigma_i^2 & \sum x_i^2/\sigma_i^2 \end{vmatrix}}$$

- **Incertidumbres en los parámetros:**

$$\sigma_a^2 = \frac{\sum (x_i^2/\sigma_i^2)}{\Delta}, \quad \sigma_b^2 = \frac{\sum (1/\sigma_i^2)}{\Delta}, \quad \sigma_{ab}^2 = -\frac{\sum (x_i/\sigma_i^2)}{\Delta}$$

$$\text{con } \Delta = (\sum 1/\sigma_i^2)(\sum x_i^2/\sigma_i^2) - (\sum x_i/\sigma_i^2)^2.$$

- **Para incertidumbres iguales $\sigma_i = \sigma$:**

$$a = \frac{\sum y_i \sum x_i^2 - \sum x_i \sum x_i y_i}{N \sum x_i^2 - (\sum x_i)^2}$$

$$b = \frac{N \sum x_i y_i - \sum x_i \sum y_i}{N \sum x_i^2 - (\sum x_i)^2}$$

$$\sigma_a^2 = \frac{\sigma^2 \sum x_i^2}{N \sum x_i^2 - (\sum x_i)^2}, \quad \sigma_b^2 = \frac{N \sigma^2}{N \sum x_i^2 - (\sum x_i)^2}$$

- χ^2 del ajuste: $\chi^2 = \sum \left(\frac{y_i - a - bx_i}{\sigma_i} \right)^2$
- Grados de libertad: $\nu = N - 2$
- Estimación de la varianza común a partir del ajuste: $s^2 = \frac{1}{N-2} \sum (y_i - a - bx_i)^2$

Ejercicios

Ejercicio 6.1

Ajuste los datos del Ejemplo 6.2 como si todos los datos tuvieran incertidumbres iguales $\sigma_i = \bar{\sigma} = 18,5$, donde $\bar{\sigma}$ es el promedio de los valores dados de σ . Nótese que los parámetros ajustados son independientes del valor de $\bar{\sigma}$, pero los valores de χ^2 , σ_a y σ_b no lo son.

Solución: Usando los datos de la Tabla 6.2, si tomamos $\sigma_i = 18,5$ para todos los puntos, entonces los pesos son iguales. Calculamos las sumas necesarias: $\sum x_i = 25,00 + 16,00 + 11,11 + 8,16 + 6,25 + 4,94 + 4,00 + 2,78 + 1,78 + 1,00 = 81,02$ (aproximadamente, de la tabla). $\sum y_i = 901 + 652 + 443 + 339 + 283 + 281 + 240 + 220 + 180 + 154 = 3693$? Revisemos la tabla: $C_i : 901, 652, 443, 339, 283, 281, 240, 220, 180, 154$. Suma : $901 + 652 = 1553, +443 = 1996, +339 = 2335, +283 = 2618, +281 = 2899, +240 = 3139, +220 = 3359, +180 = 3539, +154 = 3693$. $\sum x_i^2 : 625, 256, 123.43, 66.59, 39.06, 24.40, 16.00, 7.73, 3.17, 1.00$. Suma $625+256=881, +123.43=1004.43, +66.59=1071.02, +39.06=1110.08, +24.40=1134.48, +16.00=1150.48, +7.73=1158.21, +3.17=1161.38, +1.00=1162.38$. $\sum x_i y_i : 25*901=22525, 16*652=10432, 11.11*443=4921.73, 8.16*339=2766.24, 6.25*283=1768.75, 4.94*281=1388.14, 4*240=960, 2.78*220=611.6, 1.78*180=320.4, 1*154=154$. Suma: $22525+10432=32957, +4921.73=37878.73, +2766.24=40644.97, +1768.75=42413.72, +1388.14=43801.86, +960=44761.86, +611.6=45373.46, +320.4=45693.86, +154=45847.86$. $N = 10$, $\sum x_i = 81,02$, $\sum x_i^2 = 1162,38$, $\Delta' = N \sum x_i^2 - (\sum x_i)^2 = 10 * 1162,38 - 6564,24 = 11623,8 - 6564,24 = 5059,56$. $a = (\sum y_i \sum x_i^2 - \sum x_i \sum x_i y_i) / \Delta' = (3693 * 1162,38 - 81,02 * 45847,86) / 5059,56$. $3693 * 1162,38 \approx 4292000$, $81,02 * 45847,86 \approx 3715000$, diferencia 577000 , $a \approx 577000 / 5059,56 \approx 114,0$. $b = (N \sum x_i y_i - \sum x_i \sum y_i) / \Delta' = (10 * 45847,86 - 81,02 * 3693) / 5059,56 = (458478,6 - 299200) / 5059,56 = 159278,6 / 5059,56 \approx 31,48$. $\sigma^2 = \bar{\sigma}^2 = 342,25$, $\sigma_a^2 = \sigma^2 \sum x_i^2 / \Delta' = 342,25 * 1162,38 / 5059,56 \approx 397800 / 5059,56 \approx 78,6$, $\sigma_a \approx 8,87$. $\sigma_b^2 = N \sigma^2 / \Delta' = 10 * 342,25 / 5059,56 = 3422,5 / 5059,56 \approx 0,676$, $\sigma_b \approx 0,822$. χ^2 se calcularía con estos parámetros.

Ejercicio 6.2

Derive la Ecuación (6.22) a partir de las Ecuaciones (6.19) y (6.20).

Solución: Si $\sigma_i = \sigma$ constante, entonces $\sum 1/\sigma_i^2 = N/\sigma^2$, $\sum x_i/\sigma_i^2 = \sum x_i/\sigma^2$, $\sum x_i^2/\sigma_i^2 = \sum x_i^2/\sigma^2$. Entonces Δ (de 6.20) se convierte en $\Delta = \frac{N}{\sigma^2} \cdot \frac{\sum x_i^2}{\sigma^2} - \frac{(\sum x_i)^2}{\sigma^4} = \frac{1}{\sigma^4} (N \sum x_i^2 - (\sum x_i)^2) = \frac{\Delta'}{\sigma^4}$. Luego $\sigma_a^2 = \frac{\sum x_i^2/\sigma^2}{\Delta} = \frac{\sum x_i^2/\sigma^2}{\Delta'/\sigma^4} = \frac{\sigma^2 \sum x_i^2}{\Delta'}$. Similarmente, $\sigma_b^2 = \frac{N/\sigma^2}{\Delta'/\sigma^4} = \frac{N\sigma^2}{\Delta'}$.

Ejercicio 6.3

Demuestre que la Ecuación (6.12) se reduce a la Ecuación (6.13) si $\sigma_i = \sigma$.

Solución: Si $\sigma_i = \sigma$, entonces $\sum y_i/\sigma_i^2 = \sum y_i/\sigma^2$, etc. El determinante del numerador para a en (6.12a) es:

$$\begin{vmatrix} \sum y_i/\sigma^2 & \sum x_i/\sigma^2 \\ \sum x_i y_i/\sigma^2 & \sum x_i^2/\sigma^2 \end{vmatrix} = \frac{1}{\sigma^4} \begin{vmatrix} \sum y_i & \sum x_i \\ \sum x_i y_i & \sum x_i^2 \end{vmatrix}$$

El determinante del denominador es:

$$\begin{vmatrix} N/\sigma^2 & \sum x_i/\sigma^2 \\ \sum x_i/\sigma^2 & \sum x_i^2/\sigma^2 \end{vmatrix} = \frac{1}{\sigma^4} \begin{vmatrix} N & \sum x_i \\ \sum x_i & \sum x_i^2 \end{vmatrix}$$

Al dividir, los factores $1/\sigma^4$ se cancelan, dando la expresión en (6.13a). Similar para b .

Ejercicio 6.4

Derive una fórmula para hacer un ajuste lineal a datos con una intersección en el origen de modo que $y = bx$. Aplique su método para ajustar una línea recta a través del origen a los siguientes pares de coordenadas. Suponga incertidumbres uniformes $\sigma_i = 1,5$ en y_i . Encuentre χ^2 para el ajuste y la incertidumbre en b .

Datos:

x_i	2	4	6	8	10	12	14	16	18	20	22	24
y_i	5.3	14.4	20.7	30.1	35.0	41.3	52.7	55.7	63.0	72.1	80.5	87.9

Solución: Para el modelo $y = bx$, minimizamos $\chi^2 = \sum (y_i - bx_i)^2/\sigma_i^2$. Derivando respecto a b : $\frac{d\chi^2}{db} = -2 \sum x_i(y_i - bx_i)/\sigma_i^2 = 0$. Entonces $b = \frac{\sum x_i y_i/\sigma_i^2}{\sum x_i^2/\sigma_i^2}$. Con σ_i constante, $b = \frac{\sum x_i y_i}{\sum x_i^2}$. Calculamos las sumas: $\sum x_i y_i$: $2*5.3=10.6$, $4*14.4=57.6$, $6*20.7=124.2$, $8*30.1=240.8$, $10*35=350$, $12*41.3=495.6$, $14*52.7=737.8$, $16*55.7=891.2$, $18*63=1134$, $20*72.1=1442$, $22*80.5=1771$, $24*87.9=2109.6$. Suma: $10.6+57.6=68.2$, $+124.2=192.4$, $+240.8=433.2$, $+350=783.2$, $+495.6=1278.8$, $+737.8=2016.6$, $+891.2=2907.8$, $+1134=4041.8$, $+1442=5483.8$, $+1771=7254.8$, $+2109.6=9364.4$. $\sum x_i^2$: $4+16=20$, $+36=56$, $+64=120$, $+100=220$, $+144=364$, $+196=560$, $+256=816$, $+324=1140$, $+400=1540$, $+484=2024$, $+576=2600$. $b = 9364.4/2600 \approx 3,6017$. Incertidumbre: $\sigma_b^2 = \frac{1}{\sum (x_i^2/\sigma_i^2)} = \frac{\sigma^2}{\sum x_i^2} = \frac{2,25}{2600} \approx 0,0008654$, $\sigma_b \approx 0,0294$. $\chi^2 = \frac{1}{\sigma^2} \sum (y_i - bx_i)^2$. Calculamos residuos: $y_1 - bx_1 = 5,3 - 3,6017 * 2 = 5,3 - 7,2034 = -1,9034$, cuadrado 3.623; $y_2 - bx_2 = 14,4 - 3,6017 * 4 = 14,4 - 14,4068 = -0,0068$, cuadrado 0; $y_3 - bx_3 = 20,7 - 3,6017 * 6 = 20,7 - 21,6102 = -0,9102$, cuadrado 0.828; $y_4 - bx_4 = 30,1 - 3,6017 * 8 = 30,1 - 28,8136 = 1,2864$, cuadrado 1.655; $y_5 - bx_5 = 35 - 3,6017 = -1,017$, cuadrado 1.034; $y_6 - bx_6 = 41,3 - 43,2204 = -1,9204$, cuadrado 3.688; $y_7 - bx_7 = 52,7 - 50,4238 = 2,2762$, cuadrado 5.181; $y_8 - bx_8 = 55,7 - 57,6272 = -1,9272$, cuadrado 3.714; $y_9 - bx_9 = 63 - 64,8306 = -1,8306$, cuadrado 3.351; $y_{10} - bx_{10} = 72,1 - 72,034 = 0,066$, cuadrado 0.004; $y_{11} - bx_{11} = 80,5 - 79,2374 = 1,2626$, cuadrado 1.594; $y_{12} - bx_{12} = 87,9 - 86,4408 = 1,4592$, cuadrado 2.129. Suma de cuadrados $3.623+0+0.828+1.655+1.034+3.688+5.181+3.714+3.351+0.004+1.594+2.129 = 26.801$. $\chi^2 = 26,801/2,25 \approx 11,91$ con 11 grados de libertad (12 puntos menos 1 parámetro).

Ejercicio 6.5

Un estudiante cuelga masas de un resorte y mide la extensión del resorte en función de la fuerza aplicada para encontrar la constante del resorte k . Sus mediciones son:

Masa (kg)	200	300	400	500	600	700	800	900
Extensión (cm)	5.1	5.5	5.9	6.8	7.4	7.5	8.6	9.4

Hay una incertidumbre de 0.2 en cada medición de la extensión. La incertidumbre en las masas es despreciable. Para un resorte perfecto, la extensión ΔL del resorte estará relacionada con la fuerza aplicada por la relación $k\Delta L = F$, donde $F = mg$, y $\Delta L = L - L_0$ y L_0 es la longitud sin estirar del resorte. Use estos datos y el método de mínimos cuadrados para encontrar la constante del resorte k , la longitud sin estirar del resorte L_0 y sus incertidumbres. Encuentre χ^2 para el ajuste y la probabilidad asociada.

Solución: La relación es $L = L_0 + \frac{g}{k}m$. Sea $y = L$, $x = m$. Entonces $y = a + bx$ con $a = L_0$, $b = g/k$. $g = 9.8 \text{ m/s}^2$ pero cuidado con las unidades: masa en kg, extensión en cm, fuerza en N. La extensión está en cm, por lo que k tendrá unidades de N/cm. $b = g/k$ tendrá unidades de cm/kg. Usamos los datos en cm y kg. $N = 8$, $\sigma_y = 0.2 \text{ cm}$ constante. Calculamos sumas: $\sum x = 200 + 300 + 400 + 500 + 600 + 700 + 800 + 900 = 4400$
 $\sum y = 5.1 + 5.5 + 5.9 + 6.8 + 7.4 + 7.5 + 8.6 + 9.4 = 56.2$ $\sum x^2 = 200^2 + 300^2 + 400^2 + 500^2 + 600^2 + 700^2 + 800^2 + 900^2 = 40000 + 90000 + 160000 + 250000 + 360000 + 490000 + 640000 + 810000 = 2840000$ $\sum xy = 200 * 5.1 = 1020, 300 * 5.5 = 1650, 400 * 5.9 = 2360, 500 * 6.8 = 3400, 600 * 7.4 = 4440, 700 * 7.5 = 5250, 800 * 8.6 = 6880, 900 * 9.4 = 8460.$ $\text{Suma} = 1020 + 1650 = 2670, +2360 = 5030, +3400 = 8430, +4440 = 12870, +5250 = 18120, +6880 = 25000, +8460 = 33460.$ $\Delta' = N \sum x^2 - (\sum x)^2 = 8 * 2840000 - 4400^2 = 22720000 - 19360000 = 3360000.$ $a = (\sum y \sum x^2 - \sum x \sum xy) / \Delta' = (56.2 * 2840000 - 4400 * 33460) / 3360000.$ $56.2 * 2840000 = 159608000, 4400 * 33460 = 147224000,$ diferencia = 12384000, $a = 12384000 / 3360000 = 3.6857 \text{ cm}.$ $b = (N \sum xy - \sum x \sum y) / \Delta' = (8 * 33460 - 4400 * 56.2) / 3360000 = (267680 - 247280) / 3360000 = 20400 / 3360000 = 0.0060714 \text{ cm/kg}.$ Entonces $L_0 = a = 3.686 \text{ cm}.$ $k = g/b = 9.8 / 0.0060714 \approx 1614 \text{ N/cm}.$ Incertidumbres: $\sigma^2 = \sigma_y^2 = 0.04.$ $\sigma_a^2 = \sigma^2 \sum x^2 / \Delta' = 0.04 * 2840000 / 3360000 = 113600 / 3360000 = 0.03381,$ $\sigma_a = 0.184 \text{ cm}.$ $\sigma_b^2 = N \sigma^2 / \Delta' = 8 * 0.04 / 3360000 = 0.32 / 3360000 = 9.52e-8,$ $\sigma_b = 0.000309 \text{ cm/kg}.$ $\sigma_k = k^2 \sigma_b / g?$ Propagación: $k = g/b,$ $\sigma_k / k = \sigma_b / b,$ $\sigma_k = k \sigma_b / b = 1614 * 0.000309 / 0.0060714 \approx 1614 * 0.0509 \approx 82.1 \text{ N/cm}.$ Calculamos $\chi^2 = \sum (y_i - a - bx_i)^2 / \sigma^2.$ Primero los valores ajustados: $y_{fit} = 3.6857 + 0.0060714x.$ Para $x=200$: $3.6857 + 1.2143 = 4.9,$ residuo $5.1 - 4.9 = 0.2$ $x=300$: $3.6857 + 1.8214 = 5.5071,$ residuo $5.5 - 5.5071 = -0.0071$ $x=400$: $3.6857 + 2.4286 = 6.1143,$ residuo $5.9 - 6.1143 = -0.2143$ $x=500$: $3.6857 + 3.0357 = 6.7214,$ residuo $6.8 - 6.7214 = 0.0786$ $x=600$: $3.6857 + 3.6429 = 7.3286,$ residuo $7.4 - 7.3286 = 0.0714$ $x=700$: $3.6857 + 4.25 = 7.9357,$ residuo $7.5 - 7.9357 = -0.4357$ $x=800$: $3.6857 + 4.8571 = 8.5428,$ residuo $8.6 - 8.5428 = 0.0572$ $x=900$: $3.6857 + 5.4643 = 9.15,$ residuo $9.4 - 9.15 = 0.25$ Cuadrados: 0.04, 0.00005, 0.0459, 0.00618, 0.0051, 0.1898, 0.00327, 0.0625. Suma = 0.3528. $\chi^2 = 0.3528 / 0.04 = 8.82.$ Grados de libertad $\nu = 8 - 2 = 6.$ Probabilidad de chi-cuadrado con 6 grados para 8.82 es aproximadamente 0.18 (18%).

Ejercicio 6.6

Esboce un procedimiento para resolver las ecuaciones simultáneas (6.27). Refiérase al Apéndice A.

Solución: Las ecuaciones son:

$$\sum \frac{y_i}{a + bx_i} = N$$

$$\sum \frac{x_i y_i}{a + bx_i} = \sum x_i$$

Se pueden resolver iterativamente. Un método es reescribir la primera como $\sum \frac{y_i}{a+bx_i} - N = 0$. Se puede usar el método de Newton-Raphson en dos dimensiones. Otra forma es linealizar haciendo una sustitución, pero no es directo. Se puede usar un método de búsqueda en malla para a y b minimizando una función de discrepancia.

Ejercicio 6.7

Un estudiante mide la temperatura (T) del agua en un matraz aislado en tiempos (t) separados por 1 minuto y obtiene los siguientes valores:

t (s)	0	1	2	3	4	5	6	7	8
T (°C)	98.51	98.50	98.50	98.49	98.52	98.49	98.52	98.45	98.47

- Calcule la temperatura media y su error estándar.
- Para probar si el agua se está enfriando, trace un gráfico de las temperaturas versus el tiempo y haga un ajuste por mínimos cuadrados de una línea recta a los datos. ¿Hay una pendiente estadísticamente significativa en el gráfico?
- Nótese que la intersección no es idéntica al valor medio de la temperatura que calculó en (a). Ahora, desplace las coordenadas de tiempo en 4 s para que el tiempo medio sea 0. Vuelva a ajustar los datos con los nuevos valores de t . ¿Es ahora la intersección idéntica al valor medio de T ?
- Claramente, los resultados de este experimento no pueden depender del tiempo en que se realizaron las mediciones. Demuestre que, si el valor medio de x es igual a cero, entonces la intersección a calculada a partir de la Ecuación (6.13) es idénticamente igual al valor medio de y .

Solución:

- Media $\bar{T} = (98,51+98,50+98,50+98,49+98,52+98,49+98,52+98,45+98,47)/9$. Suma: $98,51+98,50=197,01$, $+98,50=295,51$, $+98,49=394,00$, $+98,52=492,52$, $+98,49=591,01$, $+98,52=689,53$, $+98,45=787,98$, $+98,47=886,45$. Media = $886,45/9 = 98,4944$. Desviación estándar: calculamos desviaciones: 0,0156, 0,0056, 0,0056, -0,0044, 0,0256, -0,0044, 0,0256, -0,0444, -0,0244. Cuadrados: 0,000243, 0,000031, 0,000031, 0,000019, 0,000655, 0,000019, 0,000655, 0,001971, 0,000595. Suma = 0,004219. Varianza $s^2 = 0,004219/8 = 0,0005274$, $s = 0,02297$. Error estándar $\sigma_{\bar{T}} = 0,02297/3 = 0,00766$.
- Ajuste lineal $T = a + bt$. Con t original, calculamos sumas: $\sum t = 0 + 1 + 2 + 3 + 4 + 5 + 6 + 7 + 8 = 36$ $\sum T = 886,45$ $\sum t^2 = 0 + 1 + 4 + 9 + 16 + 25 + 36 + 49 + 64 = 204$ $\sum tT = 0 * 98,51 + 1 * 98,50 + 2 * 98,50 + 3 * 98,49 + 4 * 98,52 + 5 * 98,49 + 6 * 98,52 + 7 * 98,45 + 8 * 98,47 = 0 + 98,5 + 197 + 295,47 + 394,08 + 492,45 + 591,12 + 689,15 + 787,76 = 98,5 + 197 = 295,5, +295,47 = 590,97, +394,08 = 985,05, +492,45 = 1477,5, +591,12 = 2068,62, +689,15 = 2757,77, +787,76 = 3545,53. $N = 9$, $\Delta' = 9 * 204 - 36^2 = 1836 - 1296 = 540$. $b = (N \sum tT - \sum t \sum T) / \Delta' = (9 * 3545,53 - 36 * 886,45) / 540 = (31909,77 - 31912,2) / 540 = -2,43 / 540 = -0,0045$. $a = (\sum T \sum t^2 - \sum t \sum tT) / \Delta' = (886,45 * 204 - 36 * 3545,53) / 540 = (180835,8 - 127639,08) / 540 = 53196,72 / 540 = 98,512$. La pendiente es negativa pero muy pequeña. El error en b : σ^2 estimado del ajuste? Primero calculamos χ^2 con σ_T de 0,02297. Los residuos: para $t=0$: $98,51-98,512 = -0,002$; $t=1$: $98,50 - (98,512 - 0,0045) = 98,50 - 98,5075 =$$

-0.0075; t=2: 98.50 - (98.512 - 0.009) = 98.50 - 98.503 = -0.003; t=3: 98.49 - (98.512 - 0.0135) = 98.49 - 98.4985 = -0.0085; t=4: 98.52 - (98.512 - 0.018) = 98.52 - 98.494 = 0.026; t=5: 98.49 - (98.512 - 0.0225) = 98.49 - 98.4895 = 0.0005; t=6: 98.52 - (98.512 - 0.027) = 98.52 - 98.485 = 0.035; t=7: 98.45 - (98.512 - 0.0315) = 98.45 - 98.4805 = -0.0305; t=8: 98.47 - (98.512 - 0.036) = 98.47 - 98.476 = -0.006. Suma de cuadrados 0.000004+0.000056+0.000009+0.000072+0.000676+0.00000025+0.001225+0.00093+0.000036 = 0.003008. $\chi^2 = 0,003008/(0,02297^2) = 0,003008/0,000527 = 5,71$ con 7 gl. $\sigma_b^2 = N\sigma^2/\Delta' = 9 * 0,000527/540 = 0,004743/540 = 8,78e - 6$, $\sigma_b = 0,00296$. La pendiente es -0.0045 ± 0.003 , no significativamente diferente de cero.

- (c) Desplazamos $t' = t - 4$. Nuevos t' : -4,-3,-2,-1,0,1,2,3,4. $\sum t' = 0$. Entonces de (6.13), $a = \sum T/N = 98,4944$, la media. Así la intersección es ahora la media.
- (d) Si $\bar{x} = 0$, entonces de (6.13a), $a = (\sum y_i \sum x_i^2 - \sum x_i \sum x_i y_i)/\Delta'$. Con $\sum x_i = 0$, esto se reduce a $a = \sum y_i \sum x_i^2 / (N \sum x_i^2) = \sum y_i / N = \bar{y}$.

Capítulo 7: Ajuste por Mínimos Cuadrados a un Polinomio

7.1 Solución por Determinantes

Hasta ahora hemos discutido el ajuste de una línea recta a un grupo de puntos de datos. Sin embargo, supongamos que nuestros datos (x_i, y_i) no fueran consistentes con un ajuste de línea recta. Podríamos construir una función más compleja con parámetros adicionales e intentar variar los parámetros de esta función para ajustar los datos más estrechamente. Una función muy útil para tal ajuste es un polinomio de series de potencias

$$y(x) = a_1 + a_2x + a_3x^2 + a_4x^3 + \cdots + a_mx^{m-1} \quad (7.1)$$

donde la variable dependiente y se expresa como una suma de series de potencias de la variable independiente x con coeficientes a_1, a_2, a_3, a_4 , y así sucesivamente.

Para problemas en los que la función de ajuste es lineal en los parámetros, el método de mínimos cuadrados se extiende fácilmente a cualquier número de términos m , limitado solo por nuestra capacidad para resolver m ecuaciones lineales con m incógnitas y por la precisión con la que se pueden realizar los cálculos. Podemos reescribir la Ecuación (7.1) como

$$y(x) = \sum_{k=1}^m a_k x^{k-1} \quad (7.2)$$

La expresión para χ^2 se convierte en

$$\chi^2 = \sum_{i=1}^N \frac{1}{\sigma_i^2} \left[y_i - \sum_{k=1}^m a_k x_i^{k-1} \right]^2 \quad (7.3)$$

Para minimizar χ^2 con respecto a los parámetros a_k , establecemos las derivadas parciales iguales a cero:

$$\frac{\partial \chi^2}{\partial a_j} = -2 \sum_{i=1}^N \frac{1}{\sigma_i^2} \left[y_i - \sum_{k=1}^m a_k x_i^{k-1} \right] x_i^{j-1} = 0 \quad (7.4)$$

Esto produce un conjunto de m ecuaciones lineales simultáneas:

$$\sum_{k=1}^m a_k \sum_{i=1}^N \frac{x_i^{j+k-2}}{\sigma_i^2} = \sum_{i=1}^N \frac{y_i x_i^{j-1}}{\sigma_i^2}, \quad j = 1, \dots, m \quad (7.5)$$

Si definimos las sumas

$$S_{jk} = \sum_{i=1}^N \frac{x_i^{j+k-2}}{\sigma_i^2} \quad \text{y} \quad T_j = \sum_{i=1}^N \frac{y_i x_i^{j-1}}{\sigma_i^2} \quad (7.6)$$

entonces las ecuaciones se convierten en

$$\sum_{k=1}^m a_k S_{jk} = T_j, \quad j = 1, \dots, m \quad (7.7)$$

Estas ecuaciones pueden resolverse mediante determinantes. Los parámetros están dados por

$$a_j = \frac{\Delta_j}{\Delta} \quad (7.8)$$

donde

$$\Delta = \begin{vmatrix} S_{11} & S_{12} & \cdots & S_{1m} \\ S_{21} & S_{22} & \cdots & S_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ S_{m1} & S_{m2} & \cdots & S_{mm} \end{vmatrix}, \quad \Delta_j = \begin{vmatrix} S_{11} & \cdots & S_{1,j-1} & T_1 & S_{1,j+1} & \cdots \\ S_{1m} & & & & & \\ S_{21} & \cdots & S_{2,j-1} & T_2 & S_{2,j+1} & \cdots \\ S_{2m} & & & & & \\ \vdots & \ddots & \vdots & \vdots & \vdots & \ddots \\ \vdots & & & & & \\ S_{m1} & \cdots & S_{m,j-1} & T_m & S_{m,j+1} & \cdots \\ S_{mm} & & & & & \end{vmatrix} \quad (7.9)$$

Para un polinomio de segundo grado ($m = 3$), podemos escribir las ecuaciones explícitamente como

$$\begin{aligned} a_1 \sum \frac{1}{\sigma_i^2} + a_2 \sum \frac{x_i}{\sigma_i^2} + a_3 \sum \frac{x_i^2}{\sigma_i^2} &= \sum \frac{y_i}{\sigma_i^2} \\ a_1 \sum \frac{x_i}{\sigma_i^2} + a_2 \sum \frac{x_i^2}{\sigma_i^2} + a_3 \sum \frac{x_i^3}{\sigma_i^2} &= \sum \frac{x_i y_i}{\sigma_i^2} \\ a_1 \sum \frac{x_i^2}{\sigma_i^2} + a_2 \sum \frac{x_i^3}{\sigma_i^2} + a_3 \sum \frac{x_i^4}{\sigma_i^2} &= \sum \frac{x_i^2 y_i}{\sigma_i^2} \end{aligned} \quad (7.10)$$

Ejemplo 7.1. En un experimento para determinar la respuesta de un termopar, se sumerge una unión en un baño de hielo (0°C) y la otra unión en aceite cuya temperatura se eleva lentamente. El voltaje de salida se mide con un potenciómetro. La temperatura del aceite se mide con un termómetro de

mercurio calibrado. Las lecturas del voltímetro analógico y del termómetro se registran a intervalos de 5° y se enumeran en la Tabla 7.1. Las fluctuaciones en las lecturas y el hecho de que sea difícil leer la escala del medidor con precisión indican que las incertidumbres en las mediciones son de aproximadamente 0,05 mV para todas las lecturas.

Los datos del experimento se enumeran en la Tabla 7.1 y se representan en la Figura 7.1. En una primera aproximación, la variación de V con T es lineal, pero una inspección más detallada del gráfico revela una ligera curvatura. Teóricamente, esperamos un buen ajuste a estos datos con una curva cuadrática de la forma $V = a_1 + a_2T + a_3T^2$.

Los parámetros para el ajuste a los datos del Ejemplo 7.1 se han obtenido evaluando las sumas y los determinantes de las Ecuaciones (7.9). Para un polinomio de segundo grado con 21 puntos de datos, la Ecuación (7.5) se convierte en

$$\chi^2 = \sum_{i=1}^{21} \frac{1}{\sigma_i^2} [y_i - a_1 - a_2x_i - a_3x_i^2]^2 \quad (7.11)$$

Los valores de χ^2 y los parámetros a_1, a_2 , y a_3 determinados a partir del ajuste se enumeran en la Tabla 7.1, así como los valores calculados de $V(T_i) = y(x_i)$. Los valores calculados de V también están representados por la línea sólida en el gráfico de la Figura 7.1. Obtenemos $\chi^2 = 26,6$ para este ajuste, o $\chi_\nu^2 = \chi^2/\nu = 1,5$, donde el número de grados de libertad ν está relacionado con el número de eventos N y el número de parámetros libres m por $\nu = N - m$. La probabilidad de obtener χ^2 tan alto o más alto se puede determinar a partir de la distribución de probabilidad de χ^2 (véase la Tabla C.4) y es aproximadamente 8,8 %, lo que indica un ajuste razonable a los datos.

Como alternativa a calcular χ^2 a partir del ajuste, podríamos extender la Ecuación (6.15) a tres parámetros y calcular la incertidumbre promedio en las lecturas de temperatura para obtener

$$\sigma^2 \approx s^2 = \frac{1}{N - m} \sum_{i=1}^{21} [(y_i - (a_1 + a_2x_i + a_3x_i^2))]^2 = \frac{\chi^2}{N - m} \quad (7.12)$$

que es simplemente el valor de la incertidumbre que haría $\chi_\nu^2 = 1$. Para el Ejemplo 7.1, obtenemos para una estimación de la varianza,

$$\sigma'^2 = \sigma^2 \times \chi^2/(N - m) = 0,05^2 \times 26,6/18 = 0,0025 \times 1,478 = 0,003695^\circ\text{C}$$

sugiriendo, quizás, que el estudiante subestimó ligeramente la incertidumbre en sus mediciones de V .

7.2 Solución Matricial

Las técnicas de ajuste por mínimos cuadrados se engloban bajo el nombre general de análisis de regresión. Debido a que solo hemos estado considerando problemas en los que la función de ajuste

$$y(x_i) = \sum_{k=1}^m a_k f_k(x_i) \quad (7.13)$$

es lineal en los parámetros a_k , estamos considerando solo regresión lineal o regresión lineal múltiple, generalmente abreviada como regresión múltiple. En el Capítulo 8 trataremos con técnicas para manejar problemas con funciones de ajuste que no son lineales en los parámetros.

Ecuaciones Matriciales

Aún no hemos determinado las incertidumbres en los tres parámetros que obtuvimos al ajustar la ecuación de segundo orden a los datos del Ejemplo 7.1. Podríamos encontrar las incertidumbres extendiendo el método utilizado para los ajustes lineales de los Ejemplos 6.1 y 6.2. Sin embargo, el álgebra se vuelve aún más tediosa a medida que aumenta el número de términos en la ecuación ajustada, y de hecho, nuestro método solo produjo estimaciones de las varianzas σ_k^2 y no de las covarianzas σ_{kl}^2 , que a menudo son importantes para los parámetros ajustados. En lugar de continuar con el método de determinantes, discutiremos inmediatamente el método matricial más elegante y general para resolver el problema de regresión múltiple. Algunas de las propiedades de las matrices se discuten en el Apéndice B.

Las Ecuaciones (7.7) pueden expresarse en forma matricial como la equivalencia entre una matriz fila β y el producto de una matriz fila $\mathbf{a}$ con una matriz simétrica α , todas de orden m :

$$\beta = \mathbf{a}\alpha \quad (7.14)$$

Los elementos de la matriz fila β se definen por

$$\beta_k = \sum_{i=1}^N \left[\frac{1}{\sigma_i^2} y_i f_k(x_i) \right] \quad (7.15)$$

los de la matriz simétrica α por

$$\alpha_{jk} = \sum_{i=1}^N \left[\frac{1}{\sigma_i^2} f_j(x_i) f_k(x_i) \right] \quad (7.16)$$

y los elementos de la matriz fila $\mathbf{a}$ son los parámetros del ajuste. Para $m = 3$, las matrices pueden escribirse como

$$\beta = [\beta_1 \ \beta_2 \ \beta_3], \quad \mathbf{a} = [a_1 \ a_2 \ a_3] \quad (7.17)$$

y

$$\alpha = \begin{bmatrix} \alpha_{11} & \alpha_{12} & \alpha_{13} \\ \alpha_{21} & \alpha_{22} & \alpha_{23} \\ \alpha_{31} & \alpha_{32} & \alpha_{33} \end{bmatrix} \quad (7.18)$$

Para resolver la matriz de parámetros $\mathbf{a}$ multiplicamos ambos lados de la Ecuación (7.14) a la derecha por la inversa ϵ de la matriz α , definida de modo que $\alpha\epsilon = \alpha\alpha^{-1} = I$, la matriz identidad. Obtenemos

$$\beta\epsilon = \mathbf{a}\alpha\epsilon = \mathbf{a} \quad (7.19)$$

lo que da

$$\mathbf{a} = \beta\epsilon = \beta\alpha^{-1} \quad (7.20)$$

La Ecuación (7.20) también puede expresarse como

$$a_l = \sum_{k=1}^m (\beta_k \epsilon_{kl}) = \sum_{k=1}^m \left[\epsilon_{kl} \sum_{i=1}^N \left[\frac{1}{\sigma_i^2} y_i f_k(x_i) \right] \right] \quad (7.21)$$

donde los β_k están dados por la Ecuación (7.15).

La solución de la Ecuación (7.20) requiere que la matriz α sea invertida. Esto generalmente no es un procedimiento simple, excepto para matrices de orden muy bajo, pero hay rutinas de computadora fácilmente disponibles. La inversión de una matriz se discute en el Apéndice B.

La matriz simétrica α se denomina matriz de curvatura debido a su relación con la curvatura de la función χ^2 en el espacio de parámetros. La relación se hace evidente cuando tomamos las segundas derivadas de χ^2 con respecto a los parámetros. De la Ecuación (7.3), tenemos para la derivada parcial de χ^2 con respecto a cualquier parámetro arbitrario a_l

$$\frac{\partial \chi^2}{\partial a_l} = -2 \sum_{i=1}^N \left[\frac{f_l(x_i)}{\sigma_i^2} \left[y_i - \sum_{k=1}^m a_k f_k(x_i) \right] \right] \quad (7.22)$$

y la segunda derivada parcial cruzada con respecto a dos parámetros tales es

$$\frac{\partial^2 \chi^2}{\partial a_l \partial a_k} = 2 \sum_{i=1}^N \left[\frac{1}{\sigma_i^2} f_l(x_i) f_k(x_i) \right] = 2\alpha_{lk} \quad (7.23)$$

Estimación de Errores

La varianza $\sigma_{a_l}^2$ de cualquier parámetro a_l es la suma de las varianzas de cada uno de los puntos de datos σ_i^2 multiplicada por el cuadrado del efecto que cada punto de datos tiene sobre la determinación del parámetro a_l [véase la Ecuación (6.19)]. De manera similar, la covarianza de dos parámetros a_j y a_l viene dada por

$$\sigma_{a_j a_l}^2 = \sum_{i=1}^N \left[\sigma_i^2 \frac{\partial a_j}{\partial y_i} \frac{\partial a_l}{\partial y_i} \right] \quad (7.24)$$

(que también da la varianza para $j = l$), donde hemos supuesto que no hay correlaciones entre las incertidumbres en las variables medidas y_i . Tomando las derivadas en la Ecuación (7.24) de a_j con respecto a y_i obtenemos

$$\frac{\partial a_j}{\partial y_i} = \sum_{k=1}^m \left[\epsilon_{jk} \frac{1}{\sigma_i^2} f_k(x_i) \right] \quad (7.25)$$

y, sustituyendo en la Ecuación (7.24), obtenemos para la suma ponderada de los cuadrados de las derivadas,

$$\begin{aligned}
\sigma_{a_j a_l}^2 &= \sum_{i=1}^N \left[\sigma_i^2 \sum_{k=1}^m \left[\epsilon_{jk} \frac{1}{\sigma_i^2} f_k(x_i) \right] \sum_{p=1}^m \left[\epsilon_{lp} \frac{1}{\sigma_i^2} f_p(x_i) \right] \right] \\
&= \sum_{k=1}^m \left[\epsilon_{jk} \sum_{p=1}^m \left[\epsilon_{lp} \sum_{i=1}^N \left(\frac{1}{\sigma_i^2} f_p(x_i) f_k(x_i) \right) \right] \right] \\
&= \sum_{k=1}^m \left[\epsilon_{jk} \sum_{p=1}^m [\epsilon_{lp} \alpha_{pk}] \right] \\
&= \sum_{k=1}^m [\epsilon_{jk} I_{lk}] = \epsilon_{jl}
\end{aligned} \tag{7.26}$$

donde hemos cambiado el orden de las sumas sobre los índices ficticios i, k y p y hemos utilizado el hecho de que, debido a que la matriz de curvatura α es simétrica, su inversa ϵ también debe ser simétrica, por lo que $\epsilon_{kj} = \epsilon_{jk}$. Los elementos de la matriz identidad, que resultan de los productos sumados de los elementos de α con su inversa ϵ , se representan por I_{lk} .

La matriz inversa $\epsilon \equiv \alpha^{-1}$ se denomina matriz de error o matriz de covarianza porque sus elementos son las varianzas y covarianzas de los parámetros ajustados $\sigma_{a_j a_l}^2 = \epsilon_{jl}$.

Ejemplo 7.2. El método matricial se ilustra mediante un ajuste de línea recta $V = a_1 + a_2 T$ a una selección de datos del Ejemplo 7.1. Para mostrar claramente cada paso del cálculo, hemos seleccionado solo seis puntos espaciados a intervalos de 25° entre 0 y 100° y hemos supuesto una incertidumbre común en la variable dependiente $\sigma_v = 0,05$ mV. Los datos se enumeran en las columnas 2 y 3 de la Tabla 7.2a.

Comenzamos calculando cada una de las funciones de ajuste $f_1 = 1$ y $f_2 = x$ en cada valor de la variable independiente T . Estos se enumeran en las columnas 4 y 5 de la Tabla 7.2a. Para cada valor medido de x , los valores de β_k , los elementos de la matriz fila β , y de α_{jk} , los elementos de la matriz simétrica α , se calculan según las Ecuaciones (7.15) y (7.16). Los términos individuales en el cálculo de β_1 y β_2 se enumeran en las columnas 6 y 7 de la Tabla 7.2a y los términos individuales en el cálculo de α_{jk} se enumeran en las columnas 8 a 10. (Suponemos simetría en α .) Las matrices resultantes se muestran en la Tabla 7.2b.

La matriz simétrica α se invierte para obtener la matriz de varianza ϵ con elementos ϵ_{kl} , mostrada en la Tabla 7.2b, y se calcula la matriz producto de los parámetros ajustados $\mathbf{a} = \beta \epsilon$ y se muestra en la Tabla 7.2b. Los valores calculados de la variable ajustada V para cada valor de la variable independiente T se enumeran en la última columna de la Tabla 7.2a.

Programa 7.1. MULTREG (Apéndice E) Ajuste por mínimos cuadrados con matrices.

Los problemas de regresión múltiple suelen resolverse mediante ordenador. El programa MULTREG llama a un conjunto de rutinas para ajustar cualquier función que sea lineal en los parámetros $a_1, a_2, \dots, a_m$ a un conjunto de N puntos de datos. Las ramas en el programa sobre la variable de carácter PAE permiten la selección de la función de ajuste para cada ejemplo de este capítulo, con PAE = 'P' para la serie de potencias en

x , PAE = 'A' para todos los términos de un polinomio de Legendre de cuarto orden, o PAE = 'E' para solo los términos pares en el polinomio de Legendre. El programa utiliza varias unidades de programa además de las mencionadas en el Capítulo 6.

Programa 7.2. FITFUNC7 (Apéndice E) Funciones de ajuste y cálculo de χ^2 .

En general, cada problema de ajuste requiere una rutina de este tipo. La función POWERFUNC calcula los términos individuales en una función de potencia de cualquier orden en x para el Ejemplo 7.2, o polinomios de Legendre para el Ejemplo 7.3.

Programa 7.3. MAKEAB7 (Apéndice E) Formar las matrices para α y β .

Programa B.1. MATRIX (Apéndice E) Productos de matrices e inversión.

Cuando usamos el método matricial para ajustar una función polinomial a una muestra de datos, los parámetros resultantes deben ser idénticos a los calculados por el método de determinantes, pero también obtenemos la matriz de error completa. La matriz de error obtenida ajustando un polinomio de segundo grado a la muestra de datos completa del Ejemplo 7.1 se enumera en la Tabla 7.3.

La matriz de error se puede utilizar para estimar la incertidumbre en un resultado calculado, incluyendo los efectos de las correlaciones de los errores. Como ejemplo, supongamos que deseamos encontrar el valor predicho del voltaje V y su incertidumbre para una temperatura de exactamente 80°C . Deberíamos calcular

$$V = a_1 + a_2T + a_3T^2 \quad (7.27)$$

utilizando los parámetros determinados por el ajuste a los datos. La incertidumbre en el valor calculado de V , que resulta de la incertidumbre en los parámetros, viene dada por la Ecuación (3.13),

$$\begin{aligned} s_V^2 &= \left(\frac{\partial V}{\partial a_1}\right)^2 \sigma_1^2 + \left(\frac{\partial V}{\partial a_2}\right)^2 \sigma_2^2 + \left(\frac{\partial V}{\partial a_3}\right)^2 \sigma_3^2 \\ &\quad + 2\left(\frac{\partial V}{\partial a_1} \frac{\partial V}{\partial a_2}\right) \sigma_{12}^2 + 2\left(\frac{\partial V}{\partial a_1} \frac{\partial V}{\partial a_3}\right) \sigma_{13}^2 + 2\left(\frac{\partial V}{\partial a_2} \frac{\partial V}{\partial a_3}\right) \sigma_{23}^2 \\ &= 1 \cdot \epsilon_{11} + T^2 \cdot \epsilon_{22} + T^4 \cdot \epsilon_{33} + 2(T \cdot \epsilon_{12} + T^2 \cdot \epsilon_{13} + T^3 \cdot \epsilon_{23}) \quad (7.28) \end{aligned}$$

donde ϵ_{12} y así sucesivamente son los términos de covarianza en la matriz de error simétrica. Si usáramos solo los términos diagonales en la matriz de error, nuestro resultado sería $V = (2,45 \pm 0,14)$ V. Sin embargo, los términos fuera de la diagonal son principalmente negativos, e incluirlos reduce la incertidumbre en casi un factor de 10 a 0.015, por lo que deberíamos citar $V = (2,45 \pm 0,02)$ V.

Ajuste Lineal por Mínimos Cuadrados con una Hoja de Cálculo

La Tabla 7.4 ilustra el uso de una hoja de cálculo (sin aprovechar la rutina de ajuste por mínimos cuadrados incorporada en la hoja de cálculo) para ajustar una línea recta a los datos del Ejemplo 7.2 mediante el método matricial. Ingresamos los datos en las columnas etiquetadas T , V , y σ_v y calculamos los términos componentes que se sumarán para β_1 , β_2 , y α_{11} , α_{12} , y α_{22} en las columnas etiquetadas usando las ecuaciones indicadas. Sumamos cada columna de α para formar los elementos de la matriz cuadrada α , y las columnas de β para formar la matriz lineal β . Las rutinas de manejo de matrices de la hoja de cálculo se aplicaron para invertir la matriz α para formar la matriz ϵ , y para multiplicar ϵ por β para encontrar la matriz de parámetros $\mathbf{a}$. Las incertidumbres en los parámetros se calcularon a partir de las raíces cuadradas de los términos diagonales en la

matriz ϵ . Aunque usamos direcciones de celda absolutas para ilustrar el procedimiento, podríamos haber simplificado el cálculo nombrando las matrices de celdas y utilizando las capacidades de manejo de matrices de la hoja de cálculo.

Puede parecer ineficiente escribir un programa para resolver un problema tan simple, que la mayoría de las hojas de cálculo pueden manejar con facilidad. Sin embargo, hay ventajas. En primer lugar, sería relativamente fácil expandir el programa para ajustar más parámetros, o para ajustar una serie de funciones más complicadas que simples potencias de la variable independiente. Una segunda ventaja es que la solución proporciona la matriz de error completa. Si bien la mayoría de los programas de ajuste deberían proporcionar las incertidumbres en los parámetros ajustados, es posible que las covarianzas no estén disponibles. En algunos problemas, son esenciales.

Utilizamos Quatro Pro para este ejemplo, pero el procedimiento con Excel es similar.

7.3 Parámetros Independientes

Supongamos que tomamos los datos del Ejemplo 6.1 o del Ejemplo 6.2 y les ajustamos la función polinomial cuadrática $y = a_1 + a_2x + a_3x^2$ como hicimos para el Ejemplo 7.1. Deberíamos esperar encontrar un resultado bastante pequeño y posiblemente sin significado para el coeficiente a_3 del término cuadrático, pero, debido a que a_3 no se estableció igual a cero por definición, como en el análisis del Capítulo 6, también podríamos encontrar que los valores de a_1 y a_2 han cambiado, a veces considerablemente, de los valores obtenidos en el ajuste lineal. En general, el procedimiento de ajuste polinomial que hemos considerado arrojará valores para los coeficientes que dependen del grado del polinomio ajustado a los datos.

Esta interdependencia surge del hecho de que hemos especificado nuestro sistema de coordenadas sin tener en cuenta la región del espacio de parámetros de la que se extraen nuestros puntos de datos. El valor de a_1 representa la intersección en el eje de ordenadas, el coeficiente a_2 representa la pendiente en este mismo punto, y otros coeficientes representan órdenes superiores de curvatura en este mismo punto de intersección. Si los datos no están agrupados alrededor de este punto de intersección, su ubicación podría depender en gran medida del polinomio utilizado para ajustar los datos.

Podríamos ser capaces de extraer información más significativa sobre los datos si determináramos en cambio coeficientes a'_1, a'_2, a'_3 , y así sucesivamente, que representan el valor promedio, la pendiente promedio, la curvatura promedio, y así sucesivamente, de los datos. Tales coeficientes serían independientes de nuestra elección del sistema de coordenadas y representarían características físicas de los datos que son independientes del grado del polinomio ajustado.

Polinomios Ortogonales

Queremos ajustar los datos a una función que es similar a la de la Ecuación (7.1) pero que produce la independencia deseada de los coeficientes. La función apropiada a utilizar es la suma de polinomios ortogonales, que tiene la forma

$$y(x) = a_1 + a_2(x - \beta) + a_3(x - \gamma_1)(x - \gamma_2) + a_4(x - \delta_1)(x - \delta_2)(x - \delta_3) + \dots \quad (7.29)$$

Siguiendo el desarrollo de la Sección 7.1, debemos minimizar χ^2 para determinar los coeficientes a_1, a_2, a_3, a_4 , y así sucesivamente, con el criterio adicional de que la adición

de términos de orden superior al polinomio no afectará la evaluación de los términos de orden inferior. Este criterio se utilizará para determinar los parámetros extra $\beta, \gamma_1, \gamma_2$, y así sucesivamente.

El parámetro de bondad de ajuste χ^2 se define como

$$\chi^2 = \sum \left[\frac{\Delta y_i}{\sigma_i} \right]^2 = \sum \left[\frac{1}{\sigma_i^2} [y_i - y(x_i)]^2 \right] \quad (7.30)$$

Estableciendo las derivadas de χ^2 con respecto a cada uno de los m coeficientes a_1, a_2 , y así sucesivamente en 0 se obtienen m ecuaciones simultáneas

$$\begin{aligned} \sum y_i &= Na_1 + a_2 \sum (x_i - \beta) + a_3 \sum (x_i - \gamma_1)(x_i - \gamma_2) \\ &+ a_4 \sum (x_i - \delta_1)(x_i - \delta_2)(x_i - \delta_3) + \dots \end{aligned} \quad (7.31)$$

$$\begin{aligned} \sum x_i y_i &= a_1 \sum x_i + a_2 \sum x_i (x_i - \beta) + a_3 \sum x_i (x_i - \gamma_1)(x_i - \gamma_2) \\ &+ a_4 \sum x_i (x_i - \delta_1)(x_i - \delta_2)(x_i - \delta_3) + \dots \end{aligned} \quad (7.32)$$

$$\begin{aligned} \sum x_i^2 y_i &= a_1 \sum x_i^2 + a_2 \sum x_i^2 (x_i - \beta) + a_3 \sum x_i^2 (x_i - \gamma_1)(x_i - \gamma_2) \\ &+ a_4 \sum x_i^2 (x_i - \delta_1)(x_i - \delta_2)(x_i - \delta_3) + \dots \end{aligned} \quad (7.33)$$

$$\begin{aligned} \sum x_i^3 y_i &= a_1 \sum x_i^3 + a_2 \sum x_i^3 (x_i - \beta) + a_3 \sum x_i^3 (x_i - \gamma_1)(x_i - \gamma_2) \\ &+ a_4 \sum x_i^3 (x_i - \delta_1)(x_i - \delta_2)(x_i - \delta_3) + \dots \end{aligned} \quad (7.34)$$

donde hemos omitido un factor de σ_i^2 en el denominador por claridad.

Parámetros Adicionales

Examinemos la Ecuación (7.31). Si nos restringimos a un polinomio de grado cero, es decir, a solo un coeficiente a_1 , todos los otros coeficientes son iguales a 0 por definición. El coeficiente a_1 , por lo tanto, está especificado completamente por el primer término del lado derecho de la Ecuación (7.31):

$$a_1 = \frac{1}{N} \sum y_i = \bar{y} \quad (7.35)$$

Si nos restringimos a un polinomio de primer grado, el coeficiente a_2 del segundo término de la Ecuación (7.31) no es 0. Sin embargo, si a_1 debe ser independiente del valor de a_2 , el segundo término mismo debe ser 0. Por lo tanto, el requisito de que

$$\sum (x_i - \beta) = 0$$

conduce al valor para β

$$\beta = \frac{1}{N} \sum x_i = \bar{x} \quad (7.36)$$

y a_2 puede determinarse directamente a partir de la Ecuación (7.32) sustituyendo los valores de a_1 y β con los coeficientes de orden superior (a_3, a_4 , etc.) establecidos en 0.

De manera similar, si consideramos una función cuadrática, el tercer término de la Ecuación (7.31) debe ser 0 incluso cuando el coeficiente a_3 no es 0. Esta restricción conduce

a una ecuación cuadrática en γ_1 y γ_2 que no es suficiente para especificar cualquiera de los parámetros. Tenemos la restricción adicional, sin embargo, de que el coeficiente a_2 debe estar especificado completamente por las Ecuaciones (7.31) y (7.32). Por lo tanto, el tercer término tanto en las Ecuaciones (7.31) como en la (7.32) debe ser 0 independientemente del valor del coeficiente a_3 , y tenemos dos ecuaciones cuadráticas simultáneas para los parámetros γ_1 y γ_2

$$\sum (x_i - \gamma_1)(x_i - \gamma_2) = 0 \quad \text{y} \quad \sum x_i(x_i - \gamma_1)(x_i - \gamma_2) = 0 \quad (7.37)$$

De manera similar, el coeficiente a_3 debe determinarse completamente por la Ecuación (7.33) (y los valores predeterminados de a_1 y a_2), y esta restricción produce tres ecuaciones simultáneas para los parámetros δ_1, δ_2 , y δ_3 :

$$\begin{aligned} \sum (x_i - \delta_1)(x_i - \delta_2)(x_i - \delta_3) &= 0 \\ \sum x_i(x_i - \delta_1)(x_i - \delta_2)(x_i - \delta_3) &= 0 \\ \sum x_i^2(x_i - \delta_1)(x_i - \delta_2)(x_i - \delta_3) &= 0 \end{aligned} \quad (7.38)$$

La extrapolación a orden superior es directa. (Nótese que estos parámetros adicionales son funciones solo de la variable independiente x_i .)

Estimaciones de los Coeficientes

Una vez que los parámetros β, γ, δ , y así sucesivamente han sido determinados por las ecuaciones de restricción, las estimaciones de los coeficientes a_1, a_2 , y así sucesivamente pueden encontrarse a partir de las $m+1$ ecuaciones simultáneas resultantes. El valor para el primer coeficiente a_1 está especificado completamente por la minimización de χ^2 con respecto a a_1 en la Ecuación (7.31) y se da en la Ecuación (7.35). El valor del segundo coeficiente a_2 se determina minimizando χ^2 con respecto a a_1 y a_2 en las Ecuaciones (7.31) y (7.32) y sustituyendo el valor de a_1 de la Ecuación (7.35) en la Ecuación (7.32). De manera similar, el valor de a_3 puede determinarse a partir de la Ecuación (7.33) después de sustituir los valores de a_1 y a_2 determinados a partir de las Ecuaciones (7.31) y (7.32). Cada ecuación sucesiva da un valor para el coeficiente de orden superior siguiente.

Nótese que el valor determinado para cualquier coeficiente es, por lo tanto, independiente del valor especificado para cualquier coeficiente de orden superior, pero no es independiente del valor de los coeficientes de orden inferior. Los parámetros, que representan nuestras mejores estimaciones de los coeficientes, están dados por

$$\begin{aligned} a_1 &= \frac{1}{N} \sum y_i = \bar{y} \\ a_2 &= \frac{\sum y_i(x_i - \beta)}{\sum (x_i - \beta)^2} \\ a_3 &= \frac{\sum y_i(x_i - \gamma_1)(x_i - \gamma_2)}{\sum [(x_i - \gamma_1)(x_i - \gamma_2)]^2} \\ a_4 &= \frac{\sum y_i(x_i - \delta_1)(x_i - \delta_2)(x_i - \delta_3)}{\sum [(x_i - \delta_1)(x_i - \delta_2)(x_i - \delta_3)]^2} \end{aligned} \quad (7.39)$$

y así sucesivamente.

Simplificación

Para el caso general de puntos de datos (x_i, y_i) elegidos arbitrariamente, este procedimiento es engorroso incluso con técnicas informáticas porque requiere la solución de ecuaciones acopladas no lineales. Existe, sin embargo, un tipo especial de datos para el cual los cálculos pueden simplificarse considerablemente, a saber, los datos que cumplen los dos criterios siguientes: (1) las variables independientes x_i están igualmente espaciadas, y (2) las incertidumbres son constantes, $\sigma_i = \sigma$, y por lo tanto pueden ignorarse.

Consideremos los experimentos de los Ejemplos 6.1 (medición de temperatura versus posición) y 7.1 (voltaje versus temperatura). Esos datos satisfacen las condiciones requeridas y, por lo tanto, podríamos usar un método simplificado de parámetros independientes para obtener un ajuste. Los valores resultantes de los coeficientes para estos experimentos particulares podrían no tener una gran significación física (es decir, $a_1 = \bar{T}$ la temperatura promedio de los puntos de datos en el Ejemplo 6.1 no es un número particularmente útil), pero al usar esta técnica de ajuste de polinomios ortogonales podríamos intentar ajustar polinomios de grado superior sin cambiar los valores de los coeficientes ya calculados para un ajuste lineal o cuadrático. El experimento del Ejemplo 6.2 (la desintegración de un estado radiactivo) cumple solo el primero de los dos criterios, porque los puntos de datos x están igualmente espaciados pero las incertidumbres son estadísticas, de modo que no podemos ignorar el factor de σ_i^2 que pertenece a los denominadores de las ecuaciones de ajuste (7.31) a (7.34).

Para un experimento similar al del Ejemplo 7.1, donde hemos hecho N mediciones de valores igualmente espaciados de la variable independiente x que van desde x_1 hasta x_N en pasos de Δ ,

$$\Delta = x_{i+1} - x_i$$

y las incertidumbres se deben a errores instrumentales con una desviación estándar común $\sigma_i = \sigma$, las Ecuaciones (7.36) a (7.38) se reducen a

$$\begin{aligned}\beta &= \frac{1}{N} \sum x_i = \bar{x} = \frac{1}{2}(x_1 + x_N) \\ \gamma &= \beta \pm \sqrt{\frac{1}{N} \sum (x_i - \beta)^2} = \beta \pm \Delta \sqrt{\frac{1}{12}(N^2 - 1)} \\ \delta &= \beta, \beta \pm \sqrt{\frac{\sum [x_i(x_i - \beta)^3]}{\sum [x_i(x_i - \beta)]}} = \beta, \beta \pm \Delta \sqrt{\frac{1}{20}(3N^2 - 7)}\end{aligned}\tag{7.40}$$

Se puede encontrar una lista más completa de parámetros para polinomios ortogonales en Anderson y Houseman (1942).

La Tabla 7.5 muestra los coeficientes a_1, a_2, a_3 y a_4 , así como los valores de χ^2 y la probabilidad de χ^2 obtenidos al ajustar los datos del Ejemplo 7.1 mediante el método estándar de mínimos cuadrados y mediante el método de parámetros independientes de la Ecuación (7.40). Hemos realizado ajustes separados con polinomios de primer, segundo y tercer grado ($m = 2, 3$, y 4). Como se esperaba, agregar términos adicionales no cambia los valores de los coeficientes de orden inferior obtenidos por el método de parámetros independientes y, por lo tanto, los mostramos solo una vez en la Tabla 7.5. Hay una mejora marcada en χ^2 al pasar de los ajustes de dos parámetros (lineales) a los de tres parámetros (cuadráticos). A menos que una razón teórica dicte que nuestros datos deben seguir una distribución cúbica, no hay justificación para hacer un ajuste de cuatro parámetros (cúbico) a estos datos, porque el valor de χ^2 para $m = 3$ es satisfactorio (26.6 para 18 grados de

libertad, correspondiente a $P = 8,8\%$), y agregar más términos no mejora el ajuste. Si una función cúbica hubiera sido predicha por consideraciones teóricas, estaríamos obligados a decir que nuestros datos no son sensibles a la presencia de un término cúbico.

Polinomios de Legendre

Aunque el método de ajuste a polinomios ortogonales descrito en la sección anterior puede ser tedioso, existen conjuntos predefinidos de polinomios ortogonales que a menudo son útiles para ajustar datos. Un conjunto importante son los polinomios de Legendre

$$y(x) = a_0P_0(x) + a_1P_1(x) + \cdots = \sum_{L=0}^{m-1} [a_L P_L(x)] \quad (7.41)$$

donde $x = \cos \theta$ y los términos $P_L(x)$ en la función están dados por

$$\begin{aligned} P_0(x) &= 1, & P_1(x) &= x, \\ P_2(x) &= \frac{1}{2}(3x^2 - 1), & P_3(x) &= \frac{1}{2}(5x^3 - 3x) \end{aligned} \quad (7.42)$$

y los términos de orden superior pueden determinarse a partir de la relación de recurrencia

$$P_L(x) = \frac{1}{L}[(2L-1)xP_{L-1}(x) - (L-1)P_{L-2}(x)] \quad (7.43)$$

Los polinomios de Legendre son ortogonales cuando se promedian sobre todos los valores de $x = \cos \theta$:

$$\int_{-1}^1 P_L(x)P_M(x)dx = \begin{cases} \frac{2}{2L+1} & \text{para } L = M \\ 0 & \text{para } L \neq M \end{cases} \quad (7.44)$$

Ejemplo 7.3. Consideremos un experimento en el que se bombardea ^{13}C con protones de 4.5 MeV. En la reacción subsiguiente, algunos de los protones son capturados por el núcleo de ^{13}C , que luego se desintegra mediante emisión gamma, produciendo rayos gamma con energías de hasta 11 MeV. Una medición de la distribución angular de los rayos gamma emitidos proporciona información sobre los estados de momento angular de los niveles de energía en el núcleo residual ^{14}N .

La Tabla 7.6 enumera datos simulados para este experimento. Se registraron recuentos de rayos gamma en 17 ángulos de 0 a 160°. Las columnas 1 a 4 enumeran los ángulos en los que se realizaron las mediciones, el coseno del ángulo ($x = \cos \theta$), el número medido de recuentos (C_i) y las incertidumbres σ_{C_i} en los recuentos. Se supone que las incertidumbres son puramente estadísticas. Estos datos se representan en la Figura 7.2 en función del ángulo θ . Parece haber simetría alrededor de $\theta = 90^\circ$, y la consideración del proceso de reacción predice que los datos deben ser descritos por un polinomio de Legendre de cuarto orden con solo términos pares:

$$C = a_0P_0(x) + a_2P_2(x) + a_4P_4(x) \quad \text{con } x = \cos \theta \quad (7.45)$$

Aplicemos el método matricial de mínimos cuadrados de la Sección 7.2 a este problema para ajustar la serie de polinomios de Legendre de la Ecuación (7.42) a estos datos. Primero ajustaremos un polinomio de Legendre de cuarto orden que incluya términos pares e impares. La función de ajuste es de la forma

$$y(x) = a_0 f_0(x) + a_1 f_1(x) + \cdots + a_{m-1} f_{m-1}(x) \quad (7.46)$$

que es lineal en los parámetros de ajuste, los coeficientes a_i .

Los ajustes por ordenador Las rutinas utilizadas para ajustar una serie de polinomios de Legendre a estos datos se incluyen en el Programa 7.1. El procedimiento LEGPOLY en la unidad de programa FITFUNC7 calcula los términos de los polinomios de Legendre hasta el décimo orden. El procedimiento se selecciona a través de una rama en la variable PAE en la función Funct con $\mathbf{PAE} = \mathbf{\Lambda}'\mathbf{A}'$ para todos los términos hasta el orden $n = m - 1$, o $\mathbf{PAE} = \mathbf{\Lambda}'\mathbf{E}'$ para ajustar solo con los términos pares. Nótese que el índice k del término en la función de ajuste, en general, no corresponde al orden L del polinomio de Legendre.

La eficiencia del cálculo (y por lo tanto la velocidad del cálculo de regresión lineal) podría mejorarse de varias maneras. El cambio más simple sería calcular las funciones una vez para cada valor de la variable independiente y almacenar los valores calculados en una matriz.

Los parámetros obtenidos ajustando una serie en polinomios de Legendre para términos hasta $L = 4$ se enumeran en la Tabla 7.7. Se realizaron ajustes separados con todos los términos y con solo los términos pares en la serie. Como se esperaba, los coeficientes de los términos que involucran órdenes impares son comparables a sus incertidumbres y despreciables en comparación con los que involucran polinomios pares. La matriz de error completa para el ajuste con términos pares se enumera en la Tabla 7.8.

En vista del fuerte argumento teórico de que solo se requieren polinomios de Legendre pares para esta reacción, sería apropiado ajustar una serie que incluya solo los términos pares. Los parámetros obtenidos en este ajuste también se muestran en la Tabla 7.7, y los números de recuentos calculados a partir de estos parámetros se enumeran. La función calculada con términos pares se ilustra como una curva en los datos de la Figura 7.2.

Debido a que estamos ajustando con funciones ortogonales, podríamos haber esperado obtener valores idénticos para el coeficiente a_0 de ambos ajustes. (Esperamos que los coeficientes pares de orden superior cambien porque la presencia o ausencia de coeficientes de orden inferior debe afectar a los coeficientes superiores). El hecho de que haya cierta dependencia de a_0 en los términos de orden superior es un resultado de que un experimento dado no muestrea uniformemente todo el rango del polinomio de Legendre, por lo que la relación de ortogonalidad de la Ecuación (7.44) no es satisfecha por un conjunto finito de datos. Esto es en contraste con la situación en la sección anterior, donde configuramos funciones ortogonales basadas en los propios datos. Sin embargo, generalmente es una buena práctica utilizar funciones de ajuste ortogonales siempre que sea posible para minimizar tanto las correlaciones entre coeficientes como la dependencia de los coeficientes superiores en la presencia de los inferiores.

Los valores de χ^2 y la probabilidad de χ^2 para los dos ajustes también se dan en la Tabla 7.7. Observamos que χ^2 para el ajuste de tres parámetros es necesariamente mayor que el del ajuste de cinco parámetros, pero χ^2 por grado de libertad es menor y la probabilidad de χ^2 es mayor.

7.4 Funciones No Lineales

En todos los procedimientos desarrollados hasta ahora hemos supuesto que la función de ajuste era lineal en los coeficientes. Con esto queremos decir que la función puede expresarse como una suma de términos separados, cada uno multiplicado por un solo coeficiente. ¿Cómo podemos ajustar datos con una función que no es lineal en los coeficientes? Por ejemplo, supongamos que hemos medido la distribución de tiempos de desintegración de un estado inestable y que la distribución puede representarse mediante la función normalizada $P(t) = (1/\tau)e^{-t/\tau}$, donde τ es la vida media del estado. ¿Podemos encontrar el parámetro τ mediante el método de mínimos cuadrados? El método de mínimos cuadrados no proporciona una solución analítica directa para tales funciones. En el Capítulo 8 investigaremos métodos de búsqueda en el espacio de parámetros para encontrar valores de los coeficientes que minimicen el criterio de bondad de ajuste χ^2 . Aquí consideramos soluciones aproximadas a tales problemas utilizando técnicas de regresión lineal.

Linealización

Es posible transformar algunas funciones en funciones lineales. Por ejemplo, si quisiéramos ajustar un problema de desintegración exponencial de la forma

$$y = ae^{-bx} \quad (7.47)$$

donde a y b son los parámetros desconocidos, parecería razonable tomar logaritmos de ambos lados y ajustar la ecuación de línea recta resultante

$$\ln y = \ln a - bx \quad (7.48)$$

El método de mínimos cuadrados minimiza el valor de χ^2 con respecto a cada uno de los coeficientes $\ln a$ y $\ln b$ donde χ^2 está dado por

$$\chi^2 = \sum \left\{ \frac{1}{\sigma_i^2} [\ln y_i + \ln a - bx_i]^2 \right\} \quad (7.49)$$

donde debemos usar incertidumbres ponderadas σ'_i en lugar de σ_i para tener en cuenta la transformación de la variable dependiente:

$$\sigma'_i = \frac{d(\ln y_i)}{dy} \sigma_i = \frac{1}{y_i} \sigma_i \quad (7.50)$$

La importancia de ponderar las incertidumbres se ilustra en la Figura 7.3, que muestra la función de la Ecuación (7.47) graficada tanto en escala lineal como logarítmica. (Para graficar, usamos logaritmos en base 10 en lugar de logaritmos naturales). Las incertidumbres están dadas por $\sigma_i = \sqrt{y_i}$ y, por lo tanto, aumentan al aumentar y_i . Sin embargo, en la escala logarítmica, parecen disminuir al aumentar y_i y son muy grandes para $\ln y_i$ muy pequeño. Si ignoráramos este efecto al ajustar la Ecuación (7.48), sobreenfatizaríamos las incertidumbres para valores pequeños de y_i .

En general, si ajustamos la función $f(y)$ en lugar de y , las incertidumbres σ_i en las cantidades medidas deben modificarse mediante

$$\sigma'_i = \left| \frac{df(y)}{dy_i} \right| \sigma_i \quad (7.51)$$

Errores en los Parámetros

Si modificamos la función de ajuste de modo que en lugar de ajustar los puntos de datos y_i con los coeficientes $a, b, \dots$, ajustamos puntos de datos modificados $y'_i = f(y_i)$ con coeficientes $a', b', \dots$, entonces nuestras estimaciones de los errores en los coeficientes se referirán a las incertidumbres en los coeficientes modificados $a', b', \dots$, en lugar de a los coeficientes deseados $a, b, \dots$. Si la relación entre los dos conjuntos de coeficientes se define como

$$a' = f_a(a), \quad b' = f_b(b) \quad (7.52)$$

entonces la correspondencia entre las incertidumbres $\sigma'_a, \sigma'_b, \dots$ en los coeficientes modificados y las incertidumbres $\sigma_a, \sigma_b, \dots$ en los coeficientes deseados se obtiene de manera similar a la de σ'_i y σ_i en la Ecuación (7.51):

$$\sigma'_a = \left| \frac{df_a(a)}{da} \right| \sigma_a, \quad \sigma'_b = \left| \frac{df_b(b)}{db} \right| \sigma_b \quad (7.53)$$

Por lo tanto, si el coeficiente modificado es $a' = \ln a$, el error estimado en a se determina a partir del error estimado en a' , según la Ecuación (7.53) con $f_a = \ln a$:

$$\sigma'_a = \left| \frac{d(\ln a)}{da} \right| \sigma_a = \frac{\sigma_a}{a} \quad (7.54)$$

Los valores de χ^2 para probar la bondad del ajuste deben determinarse a partir de las incertidumbres originales de los datos σ , y a partir de la ecuación no modificada, aunque la Ecuación (7.49) debería dar resultados aproximadamente equivalentes cuando se pondera con las incertidumbres modificadas σ'_i .

En el Ejemplo 6.2, consideramos un experimento para verificar la disminución en el número de cuentas C en función de la distancia r de una fuente radiactiva. Esperábamos una relación de la forma

$$C(r) = b/r^2 \quad (7.55)$$

y por lo tanto cambiamos la variable independiente a $x = 1/r^2$ y ajustamos una línea recta a los datos de C versus x . Debido a que las incertidumbres se asignaron solo a la variable dependiente C , el ajuste no se distorsionó por esa transformación.

Supongamos, en cambio, que nuestro objetivo hubiera sido determinar el exponente a en la expresión para C :

$$C(r) = br^{-a} \quad (7.56)$$

Tomando logaritmos de ambos lados, obtenemos la ecuación lineal

$$\ln(C) = \ln(b) - a \ln r$$

o

$$C'_i = b' - ar'_i \quad (7.57)$$

con $C' = \ln C$, $r' = \ln r$, y $b' = \ln b$. Las incertidumbres σ' en C' estarían dadas por la Ecuación (7.50) como

$$\sigma' = \frac{\sigma}{C}$$

y podríamos encontrar el exponente a ajustando una línea recta a la Ecuación (7.57) usando estas incertidumbres ponderadas.

Aunque el método de tomar logaritmos de una función exponencial o de potencia para producir una función que es lineal en los parámetros puede ser conveniente para estimaciones rápidas, con ordenadores rápidos es generalmente mejor resolver tales problemas mediante uno de los métodos de aproximación desarrollados para ajustar funciones no lineales. Estos métodos se explorarán en el Capítulo 8.

Resumen

- **Función lineal:** Función que es lineal en sus parámetros a_k :

$$y(x) = \sum_{k=1}^m a_k f_k(x)$$

- **Ajuste por mínimos cuadrados a una función que es lineal en sus parámetros:** Las ecuaciones normales están dadas por

$$\sum_{k=1}^m a_k \sum_{i=1}^N \frac{x_i^{j+k-2}}{\sigma_i^2} = \sum_{i=1}^N \frac{y_i x_i^{j-1}}{\sigma_i^2}, \quad j = 1, \dots, m$$

- **Solución por determinantes:**

$$a_j = \frac{\Delta_j}{\Delta}$$

donde Δ es el determinante de la matriz de coeficientes S_{jk} y Δ_j es el determinante con la columna j -ésima reemplazada por T_j .

- **Chi-cuadrado:**

$$\chi^2 = \sum_{i=1}^N \frac{1}{\sigma_i^2} \left[y_i - \sum_{k=1}^m a_k f_k(x_i) \right]^2$$

- **Varianza muestral σ^2 :**

$$\sigma^2 \simeq s^2 = \frac{1}{N-m} \sum_{i=1}^N [y_i - y(x_i)]^2$$

- **Solución matricial:** $\mathbf{a} = \beta \epsilon = \beta \alpha^{-1}$ donde

$$\beta_k = \sum_{i=1}^N \left[\frac{1}{\sigma_i^2} y_i f_k(x_i) \right], \quad \alpha_{jk} = \sum_{i=1}^N \left[\frac{1}{\sigma_i^2} f_j(x_i) f_k(x_i) \right]$$

- **Matriz de error o de varianza:** Los elementos diagonales de la matriz cuadrada $\epsilon = \alpha^{-1}$ son las varianzas de los parámetros a_k y los elementos fuera de la diagonal son las covarianzas:

$$\sigma_{a_j}^2 = \epsilon_{jj}, \quad \sigma_{a_j a_k}^2 = \epsilon_{jk}$$

- **Polinomios ortogonales:**

$$y(x) = a_1 + a_2(x - \beta) + a_3(x - \gamma_1)(x - \gamma_2) + a_4(x - \delta_1)(x - \delta_2)(x - \delta_3) + \dots$$

Ejercicios

Ejercicio 7.1

Derive las ecuaciones normales, Ecuación (7.5), para el polinomio de segundo grado de la Ecuación (7.1). Demuestre que son equivalentes a la Ecuación (7.10).

Solución: Para $m = 3$, $y(x) = a_1 + a_2x + a_3x^2$. Entonces

$$\chi^2 = \sum_{i=1}^N \frac{1}{\sigma_i^2} (y_i - a_1 - a_2x_i - a_3x_i^2)^2.$$

Derivando respecto a a_1 :

$$\begin{aligned} \frac{\partial \chi^2}{\partial a_1} &= -2 \sum \frac{1}{\sigma_i^2} (y_i - a_1 - a_2x_i - a_3x_i^2) = 0 \\ \Rightarrow a_1 \sum \frac{1}{\sigma_i^2} + a_2 \sum \frac{x_i}{\sigma_i^2} + a_3 \sum \frac{x_i^2}{\sigma_i^2} &= \sum \frac{y_i}{\sigma_i^2}. \end{aligned}$$

Derivando respecto a a_2 :

$$\begin{aligned} \frac{\partial \chi^2}{\partial a_2} &= -2 \sum \frac{x_i}{\sigma_i^2} (y_i - a_1 - a_2x_i - a_3x_i^2) = 0 \\ \Rightarrow a_1 \sum \frac{x_i}{\sigma_i^2} + a_2 \sum \frac{x_i^2}{\sigma_i^2} + a_3 \sum \frac{x_i^3}{\sigma_i^2} &= \sum \frac{x_i y_i}{\sigma_i^2}. \end{aligned}$$

Derivando respecto a a_3 :

$$\begin{aligned} \frac{\partial \chi^2}{\partial a_3} &= -2 \sum \frac{x_i^2}{\sigma_i^2} (y_i - a_1 - a_2x_i - a_3x_i^2) = 0 \\ \Rightarrow a_1 \sum \frac{x_i^2}{\sigma_i^2} + a_2 \sum \frac{x_i^3}{\sigma_i^2} + a_3 \sum \frac{x_i^4}{\sigma_i^2} &= \sum \frac{x_i^2 y_i}{\sigma_i^2}. \end{aligned}$$

Estas son las Ecuaciones (7.10).

Ejercicio 7.2

Ajuste los datos de la Tabla 7.6 mediante el método de mínimos cuadrados a la función

$$y(x) = a_1 + a_2x + a_3L(x; \mu_1, \Gamma_1) + a_4L(x; \mu_2, \Gamma_2)$$

con $\mu_1 = 102,1$, $\Gamma_1 = 30$, $\mu_2 = 177,9$, y $\Gamma_2 = 20$. La función $L(x; \mu, \Gamma)$ es la función lorentziana de la Ecuación (2.32). Suponga incertidumbres estadísticas ($\sigma_i = \sqrt{y_i}$). Encuentre χ^2 para el ajuste y la matriz de error completa.

Solución: Este ejercicio requiere un ajuste no lineal, ya que los parámetros de las lorentzianas están fijos, pero la función es lineal en a_1, a_2, a_3, a_4 . Por lo tanto, podemos usar el método de mínimos cuadrados lineales con las funciones base $f_1 = 1$, $f_2 = x$, $f_3 = L(x; 102,1, 30)$, $f_4 = L(x; 177,9, 20)$. Con los datos de la Tabla 7.6, se construyen las matrices α y β con pesos $1/\sigma_i^2 = 1/y_i$. Luego se invierte α para obtener la matriz de error. El cálculo es extenso, pero se puede realizar con un programa de ordenador. El resultado sería una matriz de 4x4 y un valor de χ^2 .

Ejercicio 7.3

A partir de los parámetros enumerados en la Tabla 7.7 para el ajuste de términos pares a los datos del Ejemplo 7.3, determine el valor predicho de la sección transversal para $\theta = 90^\circ$ y su incertidumbre. Calcule la incertidumbre a partir de los errores diagonales, enumerados en la Tabla 7.7 y a partir de la matriz de error completa enumerada en la Tabla 7.8 y compare los dos resultados.

Solución: Para $\theta = 90^\circ$, $x = \cos 90^\circ = 0$. Entonces $P_0(0) = 1$, $P_2(0) = \frac{1}{2}(3 \cdot 0 - 1) = -\frac{1}{2}$, $P_4(0)$ se calcula: $P_4(x) = \frac{1}{8}(35x^4 - 30x^2 + 3)$, con $x = 0$ da $P_4(0) = 3/8 = 0,375$. Por tanto, $C(90^\circ) = a_0 + a_2(-0,5) + a_4(0,375)$. De la Tabla 7.7, $a_0 = 938,1 \pm 7,5$, $a_2 = 261 \pm 14$, $a_4 = 161 \pm 16$. Entonces $C = 938,1 - 130,5 + 60,375 = 867,975$. Incertidumbre solo con diagonales: $\sigma_C^2 = \sigma_{a_0}^2 + (-0,5)^2 \sigma_{a_2}^2 + (0,375)^2 \sigma_{a_4}^2 = 7,5^2 + 0,25 * 14^2 + 0,140625 * 16^2 = 56,25 + 0,25 * 196 + 0,140625 * 256 = 56,25 + 49 + 36 = 141,25$, $\sigma_C = 11,89$. Con la matriz de error completa (Tabla 7.8), necesitamos también las covarianzas. La matriz ϵ es:

$$\begin{bmatrix} 56,24 & -5,256 & -6,272 \\ -5,256 & 186,5 & -26,90 \\ -6,272 & -26,90 & 279,8 \end{bmatrix}$$

Entonces $\sigma_C^2 = \epsilon_{11} + (-0,5)^2 \epsilon_{22} + (0,375)^2 \epsilon_{33} + 2(-0,5) \epsilon_{12} + 2(0,375) \epsilon_{13} + 2(-0,5)(0,375) \epsilon_{23}$. Calculamos: $\epsilon_{11} = 56,24$, $\epsilon_{22} = 186,5$, $0,25 * 186,5 = 46,625$, $\epsilon_{33} = 279,8$, $0,140625 * 279,8 = 39,36$, $2(-0,5) \epsilon_{12} = -1 * (-5,256) = 5,256$, $2(0,375) \epsilon_{13} = 0,75 * (-6,272) = -4,704$, $2(-0,5)(0,375) \epsilon_{23} = -0,375 * (-26,90) = 10,0875$. Suma: $56,24 + 46,625 = 102,865$, $+39,36 = 142,225$, $+5,256 = 147,481$, $-4,704 = 142,777$, $+10,0875 = 152,8645$. $\sigma_C \approx 12,36$. La incertidumbre es ligeramente mayor al incluir covarianzas.

Ejercicio 7.4

Ajuste polinomios de series de potencias de cuarto grado en lugar de polinomios de Legendre a los datos del Ejemplo 7.3. Sea $x = \cos \theta$ y ajuste un polinomio con todos los términos hasta x^4 y otro polinomio con solo los términos pares. Compare sus resultados con los obtenidos del ajuste a polinomios de Legendre mostrados en la Tabla 7.7.

Solución: Se trata de un ajuste lineal con funciones base $1, x, x^2, x^3, x^4$ para el primer caso, y $1, x^2, x^4$ para el segundo. Se realizan los cálculos matriciales con los datos de la Tabla 7.6. Los coeficientes resultantes serán diferentes a los de Legendre, pero el valor de χ^2 debe ser similar. La comparación muestra la ventaja de usar funciones ortogonales para reducir correlaciones.

Ejercicio 7.5

Derive la expresión para γ_1 y γ_2 de la Ecuación (7.37).

Solución: Las condiciones son $\sum (x_i - \gamma_1)(x_i - \gamma_2) = 0$ y $\sum x_i(x_i - \gamma_1)(x_i - \gamma_2) = 0$. Expandimos la primera: $\sum (x_i^2 - (\gamma_1 + \gamma_2)x_i + \gamma_1\gamma_2) = 0 \Rightarrow \sum x_i^2 - (\gamma_1 + \gamma_2) \sum x_i + N\gamma_1\gamma_2 = 0$. La segunda: $\sum (x_i^3 - (\gamma_1 + \gamma_2)x_i^2 + \gamma_1\gamma_2x_i) = 0 \Rightarrow \sum x_i^3 - (\gamma_1 + \gamma_2) \sum x_i^2 + \gamma_1\gamma_2 \sum x_i = 0$. Estas son dos ecuaciones para $S = \gamma_1 + \gamma_2$ y $P = \gamma_1\gamma_2$. Resolviendo, obtenemos S y P , y luego γ_1, γ_2 son las raíces de $t^2 - St + P = 0$. Para datos igualmente espaciados, se puede obtener una forma cerrada.

Ejercicio 7.6

Derive una expresión para $P_4(\cos \theta)$. [Véase la Ecuación (7.43).]

Solución: Usando la relación de recurrencia (7.43) con $L = 4$: $P_4(x) = \frac{1}{4}[(2 \cdot 4 - 1)xP_3(x) - (4 - 1)P_2(x)] = \frac{1}{4}[7xP_3(x) - 3P_2(x)]$. Ya tenemos $P_3(x) = \frac{1}{2}(5x^3 - 3x)$ y $P_2(x) = \frac{1}{2}(3x^2 - 1)$. Entonces: $7xP_3(x) = 7x \cdot \frac{1}{2}(5x^3 - 3x) = \frac{7}{2}(5x^4 - 3x^2)$. $3P_2(x) = 3 \cdot \frac{1}{2}(3x^2 - 1) = \frac{3}{2}(3x^2 - 1)$. Por tanto, $P_4(x) = \frac{1}{4}[\frac{7}{2}(5x^4 - 3x^2) - \frac{3}{2}(3x^2 - 1)] = \frac{1}{8}[7(5x^4 - 3x^2) - 3(3x^2 - 1)] = \frac{1}{8}[35x^4 - 21x^2 - 9x^2 + 3] = \frac{1}{8}(35x^4 - 30x^2 + 3)$.

Ejercicio 7.7

Demuestre mediante integración directa que $P_0(x)$, $P_1(x)$ y $P_2(x)$ son ortogonales y obedecen la Ecuación (7.44).

Solución: $P_0 = 1$, $P_1 = x$, $P_2 = \frac{1}{2}(3x^2 - 1)$. Calculamos $\int_{-1}^1 P_0 P_0 dx = \int_{-1}^1 1 dx = 2 = 2/(2 \cdot 0 + 1) = 2$, correcto. $\int_{-1}^1 P_1 P_1 dx = \int_{-1}^1 x^2 dx = [x^3/3]_{-1}^1 = 2/3 = 2/(2 \cdot 1 + 1) = 2/3$, correcto. $\int_{-1}^1 P_2 P_2 dx = \frac{1}{4} \int_{-1}^1 (3x^2 - 1)^2 dx = \frac{1}{4} \int_{-1}^1 (9x^4 - 6x^2 + 1) dx = \frac{1}{4}[9x^5/5 - 6x^3/3 + x]_{-1}^1 = \frac{1}{4}[(9/5 - 2 + 1) - (-9/5 + 2 - 1)] = \frac{1}{4}[(9/5 - 1) - (-9/5 + 1)] = \frac{1}{4}[(4/5) - (-4/5)] = \frac{1}{4} \cdot \frac{8}{5} = \frac{2}{5} = 2/(2 \cdot 2 + 1) = 2/5$, correcto. Productos cruzados: $\int_{-1}^1 P_0 P_1 dx = \int_{-1}^1 x dx = 0$. $\int_{-1}^1 P_0 P_2 dx = \frac{1}{2} \int_{-1}^1 (3x^2 - 1) dx = \frac{1}{2}[x^3 - x]_{-1}^1 = \frac{1}{2}[(1 - 1) - ((-1) - (-1))] = 0$. $\int_{-1}^1 P_1 P_2 dx = \frac{1}{2} \int_{-1}^1 x(3x^2 - 1) dx = \frac{1}{2} \int_{-1}^1 (3x^3 - x) dx = 0$ por ser funciones impares.

Ejercicio 7.8

En un experimento para medir la distribución angular de partículas dispersadas elásticamente, un haz de partículas incide sobre un blanco de hidrógeno líquido y se registran cuentas en ángulos seleccionados con respecto a la dirección del haz incidente. Se realizan mediciones tanto con el blanco lleno de hidrógeno líquido (blanco lleno) como con el blanco vacío (blanco vacío). Las mediciones de blanco vacío se realizaron con la mitad del número de partículas incidentes utilizadas para la señal de blanco lleno. Restando la señal de blanco vacío, convenientemente escalada, de la señal de blanco lleno, se puede determinar la distribución angular de la dispersión en hidrógeno puro.

Suponga que se obtuvieron los siguientes datos en dicho experimento. Las incertidumbres en los números de cuentas son estadísticas.

$\cos \theta$ (límite inferior)	-1.0	-0.8	-0.6	-0.4	-0.2	0.0	0.2	0.4	0.6	0.8
$\cos \theta$ (límite superior)	-0.8	-0.6	-0.4	-0.2	0.0	0.2	0.4	0.6	0.8	1.0
Cuentas, blanco lleno	184	128	99	49	53	55	70	81	136	216
Cuentas, blanco vacío	54	41	31	49	8	7				

- Escale los datos de blanco vacío al mismo número de antiprotones incidentes utilizados para registrar los datos de blanco lleno y realice una resta para obtener el número de interacciones en el hidrógeno. Preste especial atención a las incertidumbres en la diferencia.
- Utilice el método de mínimos cuadrados para ajustar la función

$$y(x) = a_1 P_0(x) + a_2 P_1(x) + a_3 P_2(x)$$

a los datos restados, para obtener los coeficientes a_1 , a_2 y a_3 , donde las funciones $P_L(x)$ son los polinomios de Legendre definidos en la Ecuación (7.42).

Solución:

- (a) Los datos de blanco vacío se tomaron con la mitad de partículas incidentes, por lo que para escalarlos al mismo número que el blanco lleno, multiplicamos por 2. Pero cuidado: las cuentas de blanco vacío son más pequeñas y tienen incertidumbre estadística $\sigma = \sqrt{N}$. Al multiplicar por 2, la incertidumbre también se multiplica por 2. Luego, la señal neta es $S = N_{\text{lleno}} - 2N_{\text{vacío}}$. La incertidumbre es $\sigma_S = \sqrt{\sigma_{\text{lleno}}^2 + (2\sigma_{\text{vacío}})^2} = \sqrt{N_{\text{lleno}} + 4N_{\text{vacío}}}$. Calculamos para cada intervalo donde hay datos de vacío: Para el primer intervalo (-1.0 a -0.8): $S = 184 - 2 * 54 = 184 - 108 = 76$, $\sigma = \sqrt{184 + 4 * 54} = \sqrt{184 + 216} = \sqrt{400} = 20$. Segundo: $S = 128 - 2 * 41 = 128 - 82 = 46$, $\sigma = \sqrt{128 + 4 * 41} = \sqrt{128 + 164} = \sqrt{292} = 17,09$. Tercero: $S = 99 - 2 * 31 = 99 - 62 = 37$, $\sigma = \sqrt{99 + 124} = \sqrt{223} = 14,93$. Cuarto: $S = 49 - 2 * 49 = 49 - 98 = -49$, $\sigma = \sqrt{49 + 196} = \sqrt{245} = 15,65$. Este resultado es negativo, lo cual es físicamente posible (puede haber fluctuaciones). Quinto: $S = 53 - 2 * 8 = 53 - 16 = 37$, $\sigma = \sqrt{53 + 32} = \sqrt{85} = 9,22$. Sexto: $S = 55 - 2 * 7 = 55 - 14 = 41$, $\sigma = \sqrt{55 + 28} = \sqrt{83} = 9,11$. Para los intervalos restantes, no hay datos de vacío, por lo que la señal neta es simplemente la del blanco lleno, con su incertidumbre original.
- (b) Ahora tenemos 10 puntos de datos con sus incertidumbres. Ajustamos la función lineal en los parámetros a_1, a_2, a_3 con funciones base P_0, P_1, P_2 . Se construyen las matrices α y β con pesos $1/\sigma_i^2$. Luego se resuelve para los coeficientes.

Ejercicio 7.9

Siga el procedimiento descrito en la Sección 7.4 para encontrar el exponente a en la Ecuación (7.56), utilizando los datos del Ejemplo 6.2 (Tabla 6.2).

Solución: Tomamos los datos de C y r . Calculamos $y' = \ln C$ y $x' = \ln r$. Las incertidumbres en y' son $\sigma' = \sigma/C = 1/\sqrt{C}$. Luego ajustamos una línea recta $y' = b' - ax'$ usando mínimos cuadrados ponderados con estos σ' . El coeficiente a es el exponente buscado. Con los datos de la Tabla 6.2, se obtiene un valor cercano a 2.

Ejercicio 7.10

Una placa de plástico de 1 m de largo con marcas a intervalos de 10 cm se deja caer a través de una fotopuerta para medir la aceleración de la gravedad g en un experimento de laboratorio de pregrado. El tiempo se registra a medida que cada marca pasa a través de la puerta. El paso de la primera marca inicia el temporizador. Los datos de dicho experimento se tabulan. El tiempo registrado está relacionado con la distancia que ha caído la regla por $y = y_0 - v_0 t - \frac{1}{2}gt^2$. Nótese que ni la altura inicial y_0 ni la velocidad inicial v_0 son conocidas.

Marca #	0	1	2	3	4	5	6	7	8	9	10
Tiempo (s)	0.000	0.079	0.132	0.174	0.212	0.244	0.271	0.301	0.325	0.349	0.373

Utilice el método de mínimos cuadrados con un polinomio de segundo grado para encontrar g y su incertidumbre. Mida y desde la fotopuerta de modo que pueda establecer $y = 0$ cuando la marca 0 pasa por la puerta, $y = 1$ cuando la marca 1 pasa, y así sucesivamente. Elija t como la variable independiente e y como la variable dependiente. Suponga una incertidumbre uniforme en t de 0.001 s y una incertidumbre despreciable en y . Debido a que la incertidumbre está en la variable independiente, debe transformarse

a la variable dependiente mediante el método discutido en la Sección 6.1. Esto requerirá estimaciones iniciales de g y v_0 . Después de realizar el ajuste, es posible que desee repetir el ajuste utilizando estimaciones de g y v_0 del ajuste anterior para mejorar los resultados.

Solución: La ecuación es $y = y_0 + v_0 t + \frac{1}{2}gt^2$ con signo? Dado que cae, la distancia aumenta con el tiempo, pero si y es la distancia desde la fotopuerta hacia abajo, entonces cuando la marca 0 pasa, $y = 0$, y luego aumenta. La ecuación del movimiento es $y = v_0 t + \frac{1}{2}gt^2$, con $y_0 = 0$ por nuestra elección. Entonces ajustamos $y = at + bt^2$ con $a = v_0$ y $b = g/2$. Pero cuidado: el tiempo t es el registrado desde la marca 0. Entonces para la marca i , $y_i = i \cdot 0,1$ m (asumiendo marcas cada 10 cm). Así que $y_i = 0,1, 0,2, \dots, 1,0$ m para $i = 1, \dots, 10$. Tenemos incertidumbre en t de 0.001 s. Para transformar esta incertidumbre a y , necesitamos una estimación inicial de la derivada. Podemos hacer una estimación inicial de v_0 y g a partir de los datos. Aproximadamente, la velocidad media es $1\text{ m}/0,373\text{ s} \approx 2,68\text{ m/s}$. La aceleración es aproximadamente $2 \times \text{distancia}/\text{tiempo}^2$? Podemos usar una estimación simple. Luego, para cada punto, la incertidumbre en y debida a la incertidumbre en t es $\sigma_y = |dy/dt|\sigma_t = (v_0 + gt)\sigma_t$. Esto requiere valores de v_0 y g . Procedemos iterativamente: primero ajustamos con σ_y constante (ignorando el error en t) para obtener valores iniciales de v_0 y g . Luego recalculamos σ_y para cada punto y repetimos el ajuste hasta converger.

Para el ajuste de segundo grado $y = at + bt^2$, las ecuaciones normales son:

$$a \sum t_i^2 + b \sum t_i^3 = \sum y_i t_i$$

$$a \sum t_i^3 + b \sum t_i^4 = \sum y_i t_i^2$$

(sin término constante porque $y_0 = 0$). Calculamos las sumas con los datos. Luego $g = 2b$. La incertidumbre en b se obtiene de la matriz de error, y luego $\sigma_g = 2\sigma_b$.

Capítulo 8: Ajuste por Mínimos Cuadrados a una Función Arbitraria

8.1 Ajuste No Lineal

Los métodos de mínimos cuadrados y regresión múltiple desarrollados en los capítulos anteriores están restringidos a funciones de ajuste que son lineales en los parámetros como en la Ecuación (7.3):

$$y(x) = \sum_{j=1}^m [a_j f_j(x)] \quad (8.1)$$

Esta limitación está impuesta por el hecho de que, en general, minimizar χ^2 puede producir un conjunto de ecuaciones acopladas que son lineales en las m incógnitas solo si las funciones de ajuste $y(x)$ son en sí mismas lineales en los parámetros. Distinguiremos entre los dos tipos de problemas refiriéndonos como ajuste lineal para problemas que involucren ecuaciones que son lineales en los parámetros, como las discutidas en los Capítulos 6 y 7, y ajuste no lineal para aquellos problemas que son no lineales en los parámetros.

Ejemplo 8.1. En un experimento popular de laboratorio de física de pregrado, se irradia una moneda de plata real con neutrones térmicos para crear

dos isótopos de vida corta de la plata, ${}_{47}\text{Ag}^{108}$ y ${}_{47}\text{Ag}^{110}$, que posteriormente se desintegran por emisión beta. Los estudiantes cuentan las partículas beta emitidas en intervalos de 15 segundos durante aproximadamente 4 minutos para obtener una curva de desintegración. Los datos recolectados de dicho experimento se enumeran en la Tabla 8.1 y se representan en un gráfico semilogarítmico en la Figura 8.1. Los datos se informan al final de cada intervalo de 15 segundos, tal como fueron registrados por un escalador. Los puntos de datos no caen en una línea recta en el gráfico semilogarítmico, lo que indica que la curva de desintegración no puede describirse mediante una sola exponencial. Por lo tanto, debemos considerar que los datos provienen de una combinación de dos exponenciales de vida corta, más un fondo constante de rayos cósmicos y otras radiaciones de fondo. Esperamos que la función de ajuste sea de la forma

$$y(t) = a_1 + a_2 e^{-t/a_4} + a_3 e^{-t/a_5} \quad (8.2)$$

Esta función contiene cinco parámetros: la constante de fondo a_1 , las intensidades a_2 y a_3 de las dos exponenciales, y las constantes de tiempo a_4 y a_5 . La función no es lineal en los parámetros a_4 y a_5 , ya que aparecen en el exponente. Por lo tanto, este es un problema de ajuste no lineal.

Debido a que los métodos analíticos de ajuste por mínimos cuadrados no pueden utilizarse para problemas de ajuste no lineal, debemos considerar métodos de aproximación y realizar búsquedas en el espacio de parámetros. En las siguientes secciones discutimos cuatro métodos de ajuste no lineal: un método simple de búsqueda en malla en el que simplemente calculamos χ^2 en valores de prueba de los parámetros, y buscamos aquellos valores de los parámetros que produzcan un valor mínimo de χ^2 ; un método de búsqueda por gradiente que utiliza la pendiente de la función para mejorar la eficiencia de la búsqueda; y dos métodos semianalíticos que hacen uso del método matricial desarrollado en el Capítulo 7, con una aproximación lineal a las funciones no lineales. Como ejemplos, determinaremos los parámetros $(a_1 \dots a_5)$ ajustando la Ecuación (8.2) a los datos del Ejemplo 8.1 utilizando cada uno de los cuatro métodos. La curva en la Figura 8.1 es el resultado de dicho ajuste.

Método de Mínimos Cuadrados

Podemos generalizar la función de probabilidad, o función de verosimilitud, de la Ecuación (6.7) a cualquier número de parámetros,

$$P(a_1, a_2, \dots, a_m) = \prod \left[\frac{1}{\sigma_i \sqrt{2\pi}} \right] \exp \left\{ -\frac{1}{2} \sum \left[\frac{y_i - y(x_i)}{\sigma_i} \right]^2 \right\} \quad (8.3)$$

y, como en los capítulos anteriores, maximizar la verosimilitud con respecto a los parámetros minimizando el exponente, o el parámetro de bondad de ajuste χ^2 :

$$\chi^2 = \sum \left\{ \frac{1}{\sigma_i^2} [y_i - y(x_i)]^2 \right\} \quad (8.4)$$

donde x_i y y_i son las variables medidas, σ_i es la incertidumbre en y_i , e $y(x_i)$ son los valores de la función calculados en x_i . Según el método de mínimos cuadrados, los valores

óptimos de los parámetros a_i se obtienen minimizando χ^2 simultáneamente con respecto a cada parámetro,

$$\begin{aligned}\frac{\partial \chi^2}{\partial a_i} &= \frac{\partial}{\partial a_i} \sum \left\{ \frac{1}{\sigma_i^2} [y_i - y(x_i)]^2 \right\} = 0 \\ &= -2 \sum \left\{ \frac{1}{\sigma_i^2} [y_i - y(x_i)] \frac{\partial y(x_i)}{\partial a_i} \right\} \quad (8.5)\end{aligned}$$

Tomar derivadas parciales de χ^2 con respecto a cada uno de los m parámetros a_i producirá m ecuaciones acopladas en las m incógnitas a_i como en la Sección 7.1. Si estas ecuaciones no son lineales en todos los parámetros, debemos, en general, tratar χ^2 como una función continua de los m parámetros, describiendo una hipersuperficie en un espacio m -dimensional, como se expresa en la Ecuación (8.4), y buscar ese espacio en busca del valor mínimo apropiado de χ^2 . La Figura 8.2 ilustra dicho hiperespacio para una función de dos parámetros. Alternativamente, podemos aplicar a las m ecuaciones obtenidas a partir de las Ecuaciones (8.5) métodos de aproximación desarrollados para encontrar raíces de ecuaciones acopladas no lineales. A menudo se utiliza una combinación de ambos métodos.

Variación de χ^2 Cerca de un Mínimo

Para una muestra de eventos suficientemente grande, la función de verosimilitud se convierte en una función gaussiana de cada parámetro centrada en aquellos valores a'_j que minimizan χ^2 :

$$P(a_j) = A e^{-(a_j - a'_j)^2 / 2\sigma_j^2} \quad (8.6)$$

donde A es una función de los otros parámetros, pero no de a_j . Comparando la Ecuación (8.3) para la función de verosimilitud con la Ecuación (8.4) para χ^2 , observamos que podemos expresar χ^2 como

$$\chi^2 = -2 \ln[P(a_1, a_2, \dots, a_m)] + 2 \sum \ln(\sigma_i \sqrt{2\pi}) \quad (8.7)$$

Entonces, a partir de la Ecuación (8.6), podemos escribir

$$\chi^2 = \frac{(a_j - a'_j)^2}{\sigma_j^2} + C \quad (8.8)$$

para mostrar la variación de χ^2 con cualquier parámetro único a_j en las proximidades de un mínimo con respecto a ese parámetro. La constante C es una función de las incertidumbres σ_i y de los parámetros a_k para $k \neq j$. Por lo tanto, χ^2 varía como el cuadrado de la distancia desde un mínimo, y un aumento de 1 desviación estándar (σ) en el parámetro desde el valor a'_j en el mínimo aumenta χ^2 en 1. Para una demostración más general, véase Arndt y MacGregor (1966), apéndice II.

Podemos ver que este resultado es consistente con el obtenido a partir de una expansión de Taylor de segundo orden de χ^2 alrededor de los valores a'_j , donde los valores de χ^2 y sus derivadas en $a = a'$ se escriben como χ_0^2 , $\partial \chi_0^2 / \partial a_j$, y así sucesivamente:

$$\chi^2 \simeq \chi_0^2 + \sum_{j=1}^m \left\{ \frac{\partial \chi_0^2}{\partial a_j} (a_j - a'_j) \right\} + \frac{1}{2} \sum_{k=1}^m \sum_{j=1}^m \left\{ \frac{\partial^2 \chi_0^2}{\partial a_k \partial a_j} (a_k - a'_k)(a_j - a'_j) \right\} \quad (8.9)$$

Debido a que la condición para minimizar χ^2 es que la primera derivada parcial con respecto a cada parámetro se anule (es decir, $\partial\chi^2/\partial a_j = 0$), podemos esperar que cerca de un mínimo local en cualquier parámetro a_j , χ^2 será una función cuadrática de ese parámetro.

Podemos obtener otra relación útil a partir de la Ecuación (8.8) tomando la segunda derivada de χ^2 con respecto al parámetro a_j para obtener

$$\frac{\partial^2 \chi^2}{\partial a_j^2} = \frac{2}{\sigma_j^2} \quad (8.10)$$

Obtenemos la siguiente expresión para la incertidumbre en el parámetro en términos de la curvatura de la función χ^2 en la región del mínimo:

$$\sigma_j^2 = 2 \left(\frac{\partial^2 \chi^2}{\partial a_j^2} \right)^{-1} \quad (8.11)$$

Observamos que para parámetros no correlacionados, la Ecuación (8.11) es equivalente a la Ecuación (7.22) con la Ecuación (7.25) para obtener las incertidumbres a partir de la matriz de curvatura.

También podemos usar la relación cuadrática para encontrar la ubicación aproximada de un mínimo de χ^2 considerando la ecuación de una parábola que pasa por tres puntos que flanquean el mínimo, y resolviendo para el valor del parámetro en el mínimo, como se ilustra en la Figura 8.3. Si hemos calculado tres valores de χ^2 , $\chi_1^2 = \chi^2(a_{j1})$, $\chi_2^2 = \chi^2(a_{j2})$, y $\chi_3^2 = \chi^2(a_{j3})$, donde $a_{j2} = a_{j1} + \Delta a_j$ y $a_{j3} = a_{j2} + \Delta a_j$, entonces el valor a'_j del parámetro en el mínimo de la parábola viene dado por

$$a'_j = a_{j3} - \Delta a_j \left[\frac{\chi_3^2 - \chi_2^2}{\chi_1^2 - 2\chi_2^2 + \chi_3^2} + \frac{1}{2} \right] \quad (8.12)$$

Además, podemos estimar los errores en los parámetros de ajuste a_j variando cada parámetro alrededor de su mínimo para aumentar χ^2 en 1 desde el valor mínimo. La variación σ_j en el parámetro a_j , que aumentará χ^2 en 1 desde su valor en el mínimo de la parábola, está dada por

$$\sigma_j = \Delta a_j \sqrt{2(\chi_1^2 - 2\chi_2^2 + \chi_3^2)^{-1}} \quad (8.13)$$

Alternativamente, podemos intentar calcular la segunda derivada de χ^2 en el mínimo y encontrar la desviación estándar a partir de la Ecuación (8.11).

Si los parámetros están correlacionados, el método resumido en la Ecuación (8.13) para determinar las incertidumbres en los parámetros es válido solo bajo la condición de que, con $a_j = a'_j \pm \sigma_j$, χ^2 se minimice con respecto a todos los demás parámetros. Esta condición limita severamente la utilidad de este procedimiento para determinar las incertidumbres. Proporcionamos una discusión más detallada en la Sección 11.5. Cuando los términos de covarianza en la matriz de error son importantes, es mejor obtener la matriz de error completa mediante el método descrito en la Sección 7.2.

8.2 Búsqueda en el Espacio de Parámetros

El método de mínimos cuadrados consiste en determinar los valores de los parámetros a_j de la función $y(x)$ que producen un mínimo para la función χ^2 dada en la Ecuación (8.4). Para problemas de ajuste no lineal, hay varias formas de encontrar este valor mínimo. En

las Secciones 8.3 y 8.4 discutimos métodos de aproximación para encontrar soluciones a las m ecuaciones acopladas no lineales con m incógnitas que resultan del procedimiento de minimización de la Ecuación (8.5).

Valores Iniciales y Mínimos Locales

Ajustar funciones no lineales a muestras de datos a veces parece ser más un arte que una ciencia. En parte, esto está en la naturaleza del proceso de aproximación, donde la velocidad de convergencia hacia una solución puede depender de la elección del método para encontrar soluciones, la elección de los valores iniciales para los parámetros y posiblemente la elección del tamaño de paso. Para utilizar cualquiera de estos métodos, primero debemos determinar los valores iniciales, estimaciones que serán utilizadas por la rutina de ajuste para los cálculos iniciales de la función y de chi-cuadrado. Para los métodos de búsqueda pura, también debemos definir los tamaños de paso, las variaciones iniciales de los parámetros. Ni los valores iniciales ni los tamaños de paso, por supuesto, se necesitan en el ajuste lineal.

Otro problema en el ajuste no lineal es la existencia de múltiples soluciones o mínimos locales. Para una función arbitraria, puede haber más de un mínimo de la función χ^2 dentro de un rango razonable de valores para los parámetros y, por lo tanto, más de un conjunto de soluciones de las m ecuaciones acopladas. Una elección desafortunada del punto de partida puede “conducir” la solución hacia un mínimo local en lugar del mínimo absoluto que buscamos. Antes de intentar un ajuste de mínimos cuadrados no lineal, por lo tanto, es útil buscar en el espacio de parámetros para localizar los mínimos principales e identificar el rango deseado de parámetros sobre el cual refinar la búsqueda.

El primer paso es encontrar valores iniciales para los parámetros. Un enfoque conveniente, para el cual un programa de gráficos por computadora es muy útil, es hacer gráficos de los datos con curvas calculadas a partir de valores de prueba de los parámetros. Mediante inspección visual, a menudo se pueden determinar valores iniciales aceptables con poco o ningún cálculo adicional. Un requisito básico es que el área bajo la curva trazada sea aproximadamente la misma que bajo los datos.

Otro enfoque es mapear el espacio de parámetros y buscar valores de los parámetros que minimicen aproximadamente χ^2 . En el procedimiento de mapeo por fuerza bruta más simple, el rango permisible de cada parámetro a_j se divide en p incrementos iguales Δa_j de modo que el espacio de m parámetros se divide en $\prod_{j=1}^m p_j$ hipercubos. El valor de χ^2 se evalúa entonces en los vértices de cada hipercubo. Este procedimiento produce un mapa grueso del comportamiento de χ^2 en función de todos los parámetros a_j . En el vértice para el cual χ^2 tiene su valor más bajo, el tamaño de la malla puede reducirse para obtener valores más precisos de los parámetros. Para un ajuste simple de dos o tres parámetros, los parámetros obtenidos mediante este procedimiento pueden ser suficientemente precisos sin necesidad de más búsqueda. Para más de tres parámetros, el mapeo es bastante tedioso y visualizar el mapa de malla es difícil.

Una variación del método de malla regular es una búsqueda de Monte Carlo del espacio m -dimensional. Se generan valores de prueba de los parámetros aleatoriamente a partir de distribuciones uniformes de los parámetros, seleccionados dentro de rangos predefinidos, y se determina un valor de χ^2 para cada prueba. Después de varias pruebas, el conjunto de valores de prueba que da el valor más bajo de χ^2 puede usarse como valores iniciales. El método general de Monte Carlo se discutió en el Capítulo 5.

Un método más sofisticado para localizar los diversos mínimos de la hipersuperficie de χ^2 implica recorrer la superficie de mínimo a mínimo por la ruta de menor valor de

χ^2 , como un río sigue una quebrada para viajar del lago al océano. Comenzando en un punto en el espacio m -dimensional, la búsqueda recorre la longitud del mínimo local, luego continúa en la misma dirección general pero en una dirección que minimiza los nuevos valores de χ^2 . Cuando se descubre un nuevo mínimo local, la búsqueda repite el proceso hasta que se hayan localizado todos los mínimos locales en la región especificada del espacio.

Para problemas de ajuste relativamente simples, debería ser suficiente trazar los datos, hacer una estimación razonable de los parámetros que se utilizarán como valores iniciales en el procedimiento de búsqueda y realizar el ajuste mediante uno o más de los métodos descritos en las siguientes secciones. Como precaución, se deben variar los valores iniciales de los parámetros para probar si los diferentes ajustes convergen a los mismos valores de los parámetros, dentro de las incertidumbres esperadas. Si la dimensionalidad del espacio es lo suficientemente baja, se puede usar una malla de puntos de partida. Para dimensionalidad más alta, se puede usar un método de Monte Carlo para seleccionar puntos de partida aleatorios.

Límites en los Parámetros

A partir de un conjunto particular de valores iniciales para los parámetros, la búsqueda puede converger hacia soluciones que son físicamente irrazonables. En el Ejemplo 8.1, los valores negativos para los parámetros no son aceptables, y el valor de prueba actual de uno de los parámetros a_2 o a_3 , puede limitar la posibilidad de determinar valores de los otros. Por ejemplo, si a_2 se vuelve muy pequeño o 0, a_4 no puede determinarse en absoluto. Si no es posible encontrar valores iniciales para los parámetros que impidan que la búsqueda se desvíe hacia estas regiones ilegales, puede ser necesario colocar límites sobre ellos en el procedimiento de búsqueda para mantenerlos dentro de rangos físicamente permitidos. Pueden ser suficientes simples sentencias if then en las rutinas. Se debe tener cuidado de que el valor final de cualquier parámetro no esté en uno de estos límites impuestos artificialmente.

Selección y Ajuste de los Tamaños de Paso

No hay reglas fijas para seleccionar los tamaños de paso para los métodos de búsqueda. Claramente, los pasos serán diferentes para diferentes parámetros y deben estar relacionados con la pendiente de la función χ^2 . Tamaños de paso muy pequeños resultan en una convergencia lenta, mientras que tamaños de paso demasiado grandes sobrepasarán los mínimos locales y requerirán un reajuste constante para encerrarlos en los valles. En las rutinas de muestra de la Sección 8.7, elegimos tamaños de paso iniciales proporcionales a los valores iniciales de los parámetros y los reajustamos si es necesario después de encontrar cada mínimo local. En el cálculo de búsqueda en malla simple, ajustamos los tamaños de paso para que sean aquellos valores que aumentan χ^2 en aproximadamente 2 desde su valor en el mínimo local.

Condición de Convergencia

Un cambio en χ^2 por grado de libertad (χ^2/dof) de menos de aproximadamente 1 % de un conjunto de parámetros de prueba al siguiente probablemente no sea significativo. Sin embargo, debido a los problemas de mínimos locales y valles muy planos en el espacio

de parámetros, puede no ser suficiente establecer una condición arbitraria para la convergencia, iniciar una búsqueda y dejarla ejecutarse hasta su finalización. Si los parámetros iniciales no se eligen con mucho cuidado, la búsqueda puede detenerse en un valle plano con un valor inapropiadamente grande de χ^2 . Si esto sucede, hay varias formas posibles de proceder. Podemos elegir diferentes valores iniciales y volver a intentar el ajuste, como se sugirió en las secciones anteriores, o podemos establecer requisitos de convergencia más estrictos (por ejemplo, $\Delta\chi^2/\text{dof} < 0,1\%$) y volver a ejecutar la búsqueda con la esperanza de que el programa escape del valle y alcance el mínimo apropiado. Un enfoque conveniente para problemas pequeños es observar el proceso de la búsqueda y cortarlo manualmente cuando parezca que se ha encontrado un mínimo estable. Si no se puede encontrar un mínimo adecuado, entonces se deben probar diferentes valores iniciales. Al ajustar curvas a varias muestras de datos similares, podemos encontrar satisfactorio establecer parámetros iniciales adecuados, tamaños de paso y un criterio de corte para el primer conjunto, y emplear un método automático para los conjuntos restantes.

Ilustración por Computadora de Métodos de Ajuste No Lineal

En las siguientes secciones discutimos e ilustramos con rutinas de computadora cuatro métodos de ajuste de la Ecuación (8.2) a los datos del Ejemplo 8.1.

Programa 8.0. NONLINFT (Apéndice E) Rutina de llamada común para probar los cuatro métodos de ajuste diferentes. Repite los cálculos hasta que se encuentra un mínimo de χ^2 . Las variables se definen en el programa hasta F1TVARS y el manejo de entrada y salida de datos se realiza en la unidad de programa F1TUTIL como en los programas de ajuste de los Capítulos 6 y 7. F1TFUNC8 calcula la función de ajuste.

Los tamaños de paso para el ajuste se establecen inicialmente en la rutina FETCHPARAMETERS como una fracción de los valores iniciales de los parámetros. (Los tamaños de paso no deben escalarse a los parámetros a lo largo del cálculo, sin embargo, para que no se conviertan en 0 cuando un parámetro es 0, lo que detendría la búsqueda en ese parámetro).

Las Tablas 8.2, 8.3, 8.4 y 8.5 muestran los valores de χ^2 y los parámetros a_1 a a_5 para varias etapas del cálculo al principio, en medio y al final de cada uno de los cuatro tipos de búsqueda. Las tablas incluyen el tiempo para encontrar la solución en relación con el tiempo para el procedimiento más rápido.

Programa 8.1. GRIDSEAR (Apéndice E) La rutina GRIDLS ilustra el método de búsqueda en malla.

Programa 8.2. GRADSEAR (Apéndice E) La rutina GRADLS ilustra el método de búsqueda por gradiente.

Programa 8.3. EXPNDFIT (Apéndice E) La rutina CHIFIT ilustra el ajuste mediante expansión de la función de ajuste.

Programa 8.4. MARQFT (Apéndice E) La rutina MARQUARDT ilustra el ajuste mediante el algoritmo de gradiente-expansión.

Programa 8.5. FITFUN8 (Apéndice E) Función de ajuste y cálculo de χ^2 para todos los ajustes llamados desde el Programa 8.0.

Programa 8.6. MAKEAB8 (Apéndice E) Configuración de matrices para ajustes no lineales.

Programa 8.7. NUMDERIV (Sitio web) Derivadas numéricas.

Programa B.1. MATRIX (Apéndice E) Productos de matrices e inversión.

8.3 Método de Búsqueda en Malla

Si la variación de χ^2 con cada parámetro a_j no es muy sensible a los valores de los otros parámetros, entonces los valores óptimos de los parámetros pueden obtenerse más simplemente minimizando χ^2 con respecto a cada uno de los parámetros por separado. Este es el método de búsqueda en malla. El procedimiento consiste simplemente en seleccionar valores iniciales de los parámetros, encontrar el valor de uno de los parámetros que minimiza χ^2 con respecto a ese parámetro, establecer el parámetro en ese valor y repetir el procedimiento para cada parámetro por turno. Luego se repite todo el proceso hasta obtener un mínimo estable de χ^2 .

Búsqueda en malla. El procedimiento para una búsqueda en malla puede resumirse como sigue:

1. Seleccionar valores iniciales a_j y tamaños de paso o incremento Δa_j para cada parámetro y calcular χ^2 con los parámetros iniciales.
2. Incrementar un parámetro a_j en $\pm \Delta a_j$ y calcular χ^2 , donde el signo se elige de modo que χ^2 disminuya.
3. Repetir el paso 2 hasta que χ^2 deje de disminuir y comience a aumentar. El aumento en χ^2 indica que la búsqueda ha cruzado un valle y ha comenzado a subir por el otro lado.
4. Usar los últimos tres valores de a_j (que encierran el mínimo) y los valores asociados de χ^2 para determinar el mínimo de la parábola que pasa por los tres puntos, como se ilustra en la Figura 8.3. [Véase la Ecuación (8.12).]
5. Repetir para minimizar χ^2 con respecto a cada parámetro por turno.
6. Continuar repitiendo el procedimiento hasta que la última iteración produzca una disminución predefinida despreciable en χ^2 .

La principal ventaja del método de búsqueda en malla es su simplicidad. Con iteraciones sucesivas de la búsqueda, el mínimo absoluto de la función χ^2 en el espacio de parámetros puede localizarse con cualquier precisión deseada.

La principal desventaja es que, si las variaciones de χ^2 con los parámetros están fuertemente correlacionadas, entonces la aproximación al mínimo puede ser muy lenta. Considere, por ejemplo, el gráfico de contorno de χ^2 como una función de dos parámetros en la Figura 8.4. Los contornos de χ^2 son generalmente aproximadamente elípticos cerca del mínimo. El grado de correlación de los parámetros está indicado por la inclinación de la elipse. Si dos parámetros no están correlacionados, de modo que la variación de χ^2 con cada parámetro es independiente de la variación con el otro, entonces los ejes de la elipse serán paralelos a los ejes de coordenadas. Por lo tanto, si se inicia una búsqueda en malla cerca de un extremo de una elipse inclinada, la búsqueda puede seguir un camino en zigzag como lo indica la línea sólida en la Figura 8.4 y la búsqueda será muy ineficiente. Sin embargo, la simplicidad de los cálculos involucrados en una búsqueda en malla a menudo compensa esta ineficiencia.

Programa 8.1. GRIDSEAR (Apéndice E) La rutina GRIDLS ilustra el método de búsqueda en malla.

La rutina de búsqueda principal, GRIDLS, se ingresa con el valor de χ^2 (CHISQR) como argumento. En un bucle sobre cada uno de los m parámetros por turno, el valor del

parámetro se varía hasta que χ^2 haya pasado por un mínimo local en el parámetro. Los tres valores más recientes de χ^2 que encierran el mínimo se almacenan en las variables CHISQ1, CHISQ2 y CHISQ3. La mejor estimación del parámetro en esta etapa del cálculo se determina a partir del mínimo de la parábola que pasa por los tres puntos. El tamaño de paso (DELTA(J)) se ajusta entonces para que sea ese valor que aumenta χ^2 en 2 desde su valor en el mínimo local.

Un paso a través de GRIDLS corresponde a un solo zigzag a lo largo del camino de la Figura 8.4. La búsqueda se repite hasta que χ^2 no cambie en más del nivel preestablecido, CHICUT.

Una llamada a la función SIGPARAB en la unidad de programa FITUTIL al final de la búsqueda devuelve una estimación de la incertidumbre en cada parámetro por turno a partir de un cálculo de la variación independiente necesaria para aumentar χ^2 en 1 desde su valor mínimo.

La Tabla 8.2 muestra los valores de χ^2 y los parámetros a_1 a a_5 para varias etapas del cálculo al principio, en medio y al final de la búsqueda. La búsqueda es relativamente lenta, pero eventualmente se encuentra una solución satisfactoria. Nótese que las incertidumbres calculadas corresponden a los términos diagonales en la matriz de error para parámetros no correlacionados. Si se considera que las correlaciones son importantes, los métodos de inversión de matrices discutidos en las siguientes secciones podrían usarse para encontrar mejores aproximaciones a las incertidumbres.

8.4 Método de Búsqueda por Gradiente

La búsqueda podría mejorarse si la dirección de zigzag de la Figura 8.4 se reemplazara por un vector más directo hacia el mínimo apropiado. En el método de búsqueda por gradiente de mínimos cuadrados, todos los parámetros a_i se incrementan simultáneamente, con magnitudes relativas ajustadas de modo que la dirección resultante de viaje en el espacio de parámetros sea a lo largo del gradiente (o dirección de máxima variación) de χ^2 .

El gradiente $\nabla\chi^2$ es un vector que apunta en la dirección en la que χ^2 aumenta más rápidamente y tiene componentes en el espacio de parámetros iguales a la tasa de cambio de χ^2 a lo largo de cada eje:

$$\nabla\chi^2 = \sum_{i=1}^m \left[\frac{\partial\chi^2}{\partial a_i} \hat{a}_i \right] \quad (8.14)$$

donde $\hat{a}_i$ indica un vector unitario en la dirección del eje de coordenadas a_i . Para determinar el gradiente, estimamos las derivadas parciales numéricamente como se discute en el Apéndice A:

$$(\nabla\chi^2)_j = \frac{\partial\chi^2}{\partial a_j} \cong \frac{\chi^2(a_j + f\Delta a_j) - \chi^2(a_j)}{f\Delta a_j} \quad (8.15)$$

donde f es una fracción del tamaño de paso Δa_j en la que se cambia a_j para determinar la derivada.

El gradiente tiene tanto magnitud como dimensiones y, si las dimensiones de los diversos parámetros a_j no son todas iguales (lo que suele ser el caso), los componentes del gradiente ni siquiera tienen las mismas dimensiones. Definamos parámetros adimensionales b_j reescalando cada uno de los parámetros a_j a un tamaño que caracterice la variación

de χ^2 con a_j de manera más aproximada. Usaremos los tamaños de paso Δa_j como las constantes de escala, de modo que

$$b_j = \frac{a_j}{\Delta a_j} \quad (8.16)$$

La derivada con respecto a b_j se convierte entonces en

$$\frac{\partial \chi^2}{\partial b_j} = \frac{\partial \chi^2}{\partial a_j} \Delta a_j \quad (8.17)$$

que puede calcularse numéricamente como

$$\frac{\partial \chi^2}{\partial b_j} = \frac{\chi^2(a_j + f \Delta a_j) - \chi^2(a_j)}{f \Delta a_j} \Delta a_j = \frac{\chi^2(a_j + f \Delta a_j) - \chi^2(a_j)}{f} \quad (8.18)$$

Podemos entonces definir un gradiente adimensional γ , con magnitud unitaria y componentes

$$\gamma_j = \frac{\partial \chi^2 / \partial b_j}{\sqrt{\sum_{j=1}^m (\partial \chi^2 / \partial b_j)^2}} \quad (8.19)$$

En el cálculo numérico de la Ecuación (8.18), las cantidades Δa_j y f ocurren solo en el argumento de χ^2 y no como factores de escala.

La dirección que sigue el método de búsqueda por gradiente es la dirección de máxima pendiente descendente, que es opuesta al gradiente γ . La búsqueda comienza incrementando todos los parámetros simultáneamente en una cantidad δa_j , con valor relativo dado por la componente correspondiente γ_j del gradiente adimensional y magnitud absoluta dada por la constante de tamaño Δa_j :

$$\delta a_j = -\gamma_j \Delta a_j \quad (8.20)$$

El signo menos asegura que el valor de χ^2 disminuya. La constante de tamaño Δa_j de la Ecuación (8.20) es la misma que la de la Ecuación (8.16).

Hay varios métodos posibles para continuar la búsqueda por gradiente después de un primer paso. El más directo es volver a calcular el gradiente después de cada cambio en los parámetros. Una desventaja de este método es que es difícil acercarse asintóticamente al fondo del mínimo porque el gradiente tiende a 0 en el mínimo. Otra desventaja es que el nuevo cálculo del gradiente en cada paso para tamaños de paso pequeños resulta en una búsqueda ineficiente, pero el uso de tamaños de paso más grandes hace que la localización del mínimo sea menos precisa.

Una variación razonable del método es buscar a lo largo de una dirección del gradiente original en pasos pequeños, calculando solo el valor de χ^2 hasta que χ^2 comience a aumentar nuevamente. En este punto, se vuelve a calcular el gradiente y la búsqueda continúa en la nueva dirección. Siempre que la búsqueda se sitúe sobre un mínimo, se utiliza una interpretación parabólica de χ^2 para mejorar la determinación del mínimo.

Un enfoque más sofisticado sería utilizar derivadas parciales segundas de χ^2 para determinar cambios en el gradiente a lo largo de la ruta de búsqueda:

$$\left. \frac{\partial \chi^2}{\partial a_j} \right|_{a_j + \delta a_j} \approx \left. \frac{\partial \chi^2}{\partial a_j} \right|_{a_j} + \sum_{k=1}^m \left(\frac{\partial^2 \chi^2}{\partial a_j \partial a_k} \delta a_k \right) \quad (8.21)$$

Si la búsqueda ya está bastante cerca del mínimo, este método sí disminuye el número de pasos necesarios, pero a expensas de un cálculo más elaborado. Si la búsqueda no está lo suficientemente cerca del mínimo, este método puede en realidad aumentar el número de pasos requeridos cuando las perturbaciones de primer orden en el gradiente no son válidas.

La eficiencia de la búsqueda por gradiente disminuye notablemente a medida que la búsqueda se acerca a un mínimo porque la evaluación de la derivada según el método de la Ecuación (8.18) implica tomar diferencias entre números casi iguales. De hecho, en el mínimo de χ^2 , estas diferencias deberían desaparecer. Por esta razón, uno de los métodos discutidos en las siguientes secciones puede utilizarse para localizar el mínimo real una vez que la búsqueda por gradiente se ha acercado bastante a él.

Programa 8.2. GRADSEAR (Apéndice E) La rutina GRADLS ilustra el método de búsqueda por gradiente.

En cada entrada a la rutina de búsqueda principal, GRADLS, los componentes del gradiente GRADLS(J) se calculan numéricamente a partir de la Ecuación (8.18) en el procedimiento CALCGRAD. El argumento FRACT de esta rutina, correspondiente a la variable f de la Ecuación (8.18), determina la fracción del tamaño de paso (DELTA) utilizada en el cálculo numérico de la derivada parcial. Cada parámetro A(J) se cambia entonces en la cantidad STEPDOWN * DELTA(J) * GRAD(J), donde STEPDOWN es un factor de escala que se establece inicialmente en el programa principal y se reajusta después de cada etapa al tamaño necesario para localizar el mínimo.

Los valores iniciales de DELTA(J) determinan hasta cierto punto la velocidad de ejecución de cada paso a través de la rutina GRADLS, y el valor de CHICUT determina cuándo se detendrá la búsqueda. Debido al pequeño gradiente cerca del mínimo de χ^2 , pueden ser necesarios muchos pasos para alcanzar un valor razonable de χ^2 , y el corte, CHICUT, puede tener que establecerse en un valor muy bajo. Para tales casos, se puede proporcionar una intervención del usuario como método alternativo para detener la búsqueda.

Al concluir la búsqueda, las incertidumbres en los parámetros se estiman en la función SIGPARAB como en la rutina GRADLS.

La Tabla 8.3 muestra los valores de χ^2 y los parámetros a_i a a_5 para varias etapas del cálculo al principio, en medio y al final de la búsqueda. Para el Ejemplo 8.1, la búsqueda por gradiente es considerablemente más rápida que el enfoque de búsqueda en malla porque todos los parámetros se varían juntos en cada paso. Sin embargo, el método de búsqueda por gradiente tiene una desventaja que no se ilustra. Si los valores iniciales de los parámetros están demasiado alejados de los valores finales, la búsqueda en malla tiene una buena probabilidad de avanzar lentamente hasta alcanzar la solución correcta. La búsqueda por gradiente, por otro lado, puede tender a atascarse en mínimos locales que corresponden a un valle largo y plano en el espacio de parámetros.

8.5 Métodos de Expansión

En lugar de buscar en la hipersuperficie de χ^2 para mapear la variación de χ^2 con los parámetros, deberíamos ser capaces de encontrar una función analítica aproximada que describa la hipersuperficie de χ^2 y usar esta función para localizar el mínimo, con métodos desarrollados para el ajuste lineal por mínimos cuadrados. Las aproximaciones introducirán errores en los valores calculados de los parámetros, pero iteraciones sucesivas del método analítico deberían acercarse al mínimo de χ^2 con precisión creciente. La principal

ventaja de tal enfoque es que el número de puntos en la hipersuperficie de χ^2 en los que se deben realizar cálculos será menor que para una búsqueda en malla o por gradiente. Esta ventaja se ve algo compensada por el hecho de que los cálculos en cada punto son considerablemente más complicados. Sin embargo, la solución analítica esencialmente elige su propio tamaño de paso y, por lo tanto, el usuario se ahorra el problema de tratar de optimizar el tamaño de paso para la velocidad y la precisión.

Expansión Parabólica de χ^2

En la Ecuación (8.9) expandimos χ^2 hasta segundo orden en los parámetros alrededor de un mínimo local χ_0^2 donde $a_j = a'_j$:

$$\chi^2 \simeq \chi_0^2 + \sum_{j=1}^m \left[\frac{\partial \chi_0^2}{\partial a_j} \delta a_j \right] + \frac{1}{2} \sum_{k=1}^m \sum_{j=1}^m \left[\frac{\partial^2 \chi_0^2}{\partial a_j \partial a_k} \delta a_j \delta a_k \right] \quad (8.22)$$

que equivale a aproximar la hipersuperficie de χ^2 por una superficie parabólica. Aquí definimos $\delta a_j = a_j - a'_j$, y χ_0^2 está dado por

$$\chi_0^2 = \sum \left[\frac{1}{\sigma_i^2} [y_i - y'(x_i)]^2 \right] \quad (8.23)$$

donde $y'(x_i)$ es el valor de la función cuando $\delta a_j = 0$.

Aplicando el método de mínimos cuadrados, minimizamos χ^2 como se expresa en la Ecuación (8.22) con respecto a los incrementos (δa_j) en los parámetros, y resolvemos para los valores óptimos de estos incrementos para obtener

$$\frac{\partial \chi^2}{\partial (\delta a_k)} = \frac{\partial \chi_0^2}{\partial a_k} + \sum_{j=1}^m \left[\frac{\partial^2 \chi_0^2}{\partial a_k \partial a_j} \delta a_j \right] = 0 \quad k = 1, m \quad (8.24)$$

El resultado es un conjunto de m ecuaciones lineales en δa_j que podemos escribir como

$$\beta_k - \sum_{j=1}^m (\delta a_j \alpha_{jk}) = 0 \quad k = 1, m \quad (8.25)$$

con

$$\beta_k = -\frac{1}{2} \frac{\partial \chi_0^2}{\partial a_k} \quad \text{y} \quad \alpha_{jk} = \frac{1}{2} \frac{\partial^2 \chi_0^2}{\partial a_j \partial a_k} \quad (8.26)$$

Los factores $\pm \frac{1}{2}$ se incluyen para concordar con las definiciones convencionales de estas cantidades.

Como en el Capítulo 7, podemos tratar la Ecuación (8.25) como una ecuación matricial:

$$\beta = \delta \mathbf{a} \alpha \quad (8.27)$$

donde β y $\delta \mathbf{a}$ son matrices fila y α es una matriz simétrica de orden m . Encontraremos que α es la matriz de curvatura discutida en la Sección 7.2, así llamada porque mide la curvatura de la hipersuperficie de χ^2 .

Método de Cálculo

La solución de la Ecuación (8.27) puede obtenerse mediante inversión de matrices como en la Sección 7.2:

$$\delta \mathbf{a} = \beta \epsilon, \quad \delta a_k = \sum_{j=1}^m (\epsilon_{kj} \beta_j) \quad (8.28)$$

donde la matriz de error $\epsilon = \alpha^{-1}$ es la inversa de la matriz de curvatura.

Si los parámetros son independientes entre sí, es decir, si la variación de χ^2 con respecto a cada parámetro es independiente de los valores de los otros parámetros, entonces las derivadas parciales cruzadas α_{jk} ($j \neq k$) serán 0 en el límite de una muestra de datos muy grande y la matriz α será diagonal. La matriz inversa ϵ también será diagonal y la Ecuación (8.27) degenerará en m ecuaciones separadas:

$$\delta a_j \approx \frac{\beta_j}{\alpha_{jj}} = \frac{\partial \chi_0^2}{\partial a_j} / \frac{\partial^2 \chi_0^2}{\partial a_j^2} \quad (8.29)$$

El cálculo de los elementos de la matriz mediante la Ecuación (8.26) requiere el conocimiento de las primeras y segundas derivadas de χ^2 evaluadas en los valores actuales de los parámetros. Las formas analíticas de las derivadas son generalmente las más rápidas de calcular, pero pueden ser difíciles o engorrosas de derivar. Si no es conveniente o posible proporcionar formas analíticas de las derivadas, entonces pueden calcularse mediante el método de diferencias finitas (véase el Apéndice A). En las siguientes expresiones, usamos diferencias hacia adelante para cálculos eficientes. Los intervalos Δa_j deben elegirse lo suficientemente grandes para evitar errores de redondeo pero lo suficientemente pequeños para proporcionar valores razonablemente precisos de las derivadas cerca del mínimo:

$$\begin{aligned} \frac{\partial \chi_0^2}{\partial a_j} &\simeq \frac{\chi_0^2(a_j + \Delta a_j, a_k) - \chi_0^2(a_j, a_k)}{\Delta a_j} \\ \frac{\partial^2 \chi_0^2}{\partial a_j^2} &\simeq 4 \left[\frac{\chi_0^2(a_j, a_k) - 2\chi_0^2(a_j + \Delta a_j/2, a_k) + \chi_0^2(a_j + \Delta a_j, a_k)}{(\Delta a_j)^2} \right] \\ \frac{\partial^2 \chi_0^2}{\partial a_j \partial a_k} &\simeq [\chi_0^2(a_j, a_k) - \chi_0^2(a_j + \Delta a_j, a_k) - \chi_0^2(a_j, a_k + \Delta a_k) \\ &\quad + \chi_0^2(a_j + \Delta a_j, a_k + \Delta a_k)] / [\Delta a_j \Delta a_k] \quad (8.30) \end{aligned}$$

En la práctica real, los cálculos son más rápidos y, en general, más precisos si los elementos de la matriz α se determinan a partir de la expansión de primer orden (que se discutirá en el texto siguiente), que involucra solo primeras derivadas de $y(x)$ con respecto a los parámetros, en lugar de las segundas derivadas de χ^2 como se expresa en la Ecuación (8.30).

Procedimiento de Ajuste

Dentro de los límites de la aproximación de la hipersuperficie de χ^2 mediante una extrapolación parabólica, podemos resolver la Ecuación (8.27) directamente para producir incrementos de parámetros δa_j tales que χ^2 debería minimizarse para $a'_j + \delta a_j$. Si el punto de partida está lo suficientemente cerca del mínimo como para que los términos de orden superior en la expansión puedan despreciarse, esto se convierte en un método preciso y exacto. Pero si el punto de partida no está lo suficientemente cerca, la aproximación

parabólica de la hipersuperficie de χ^2 no es válida y los resultados serán erróneos. De hecho, si el punto de partida está tan lejos del mínimo que la curvatura de χ^2 es negativa, la solución tenderá hacia un máximo en lugar de un mínimo. Durante el cálculo, por lo tanto, los elementos diagonales α_{jj} de la matriz α deben establecerse como positivos, lo sean o no. La magnitud resultante para δa_j será incorrecta, pero el signo será correcto.

Expansión de la Función de Ajuste

Una alternativa a expandir la función χ^2 para desarrollar una descripción analítica para la hipersuperficie es expandir la función de ajuste $y(x)$ en los parámetros a_j y usar el método de mínimos cuadrados lineales para determinar el valor óptimo para los incrementos de parámetros δa_j . Si llevamos a cabo la derivación rigurosamente y despreciamos los términos de orden superior, deberíamos lograr el mismo resultado que para la expansión de χ^2 a primer y segundo orden.

Expansión de Primer Orden

Expandamos la función de ajuste $y(x)$ en una serie de Taylor alrededor del punto a'_j , hasta primer orden en los incrementos de parámetros $\delta a_j = a_j - a'_j$:

$$y(x) \approx y'(x) + \sum_{j=1}^m \left[\frac{\partial y'(x)}{\partial a_j} \delta a_j \right] \quad (8.31)$$

donde $y'(x)$ es el valor de la función de ajuste cuando los parámetros tienen los valores del punto de partida a'_j y las derivadas se evalúan en el punto de partida. El resultado es una función lineal en los incrementos de parámetros δa_j a la que podemos aplicar el método de mínimos cuadrados lineales desarrollado en el Capítulo 7.

En esta aproximación, χ^2 puede expresarse explícitamente como una función de los incrementos de parámetros δa_j :

$$\chi^2 = \sum \left(\frac{1}{\sigma_i^2} \left\{ y_i - y'(x_i) - \sum_{j=1}^m \left[\frac{\partial y'(x_i)}{\partial a_j} \delta a_j \right] \right\}^2 \right) \quad (8.32)$$

Siguiendo el método de mínimos cuadrados, minimizamos χ^2 con respecto a cada uno de los incrementos de parámetros δa_j estableciendo las derivadas iguales a 0:

$$\frac{\partial \chi^2}{\partial \delta a_k} = -2 \sum \left(\frac{1}{\sigma_i^2} \left\{ y_i - y'(x_i) - \sum_{j=1}^m \left[\frac{\partial y'(x_i)}{\partial a_j} \delta a_j \right] \right\} \frac{\partial y'(x_i)}{\partial a_k} \right) = 0 \quad (8.33)$$

Como antes, esto produce el conjunto de m ecuaciones simultáneas (8.25), que pueden expresarse como la ecuación matricial (8.27):

$$\beta = \delta \mathbf{a} \alpha \quad (8.34)$$

donde β_k se define como en la Ecuación (8.26) y α_{jk} está dado por

$$\alpha_{jk} \approx \sum \left[\frac{1}{\sigma_i^2} \frac{\partial y'(x_i)}{\partial a_j} \frac{\partial y'(x_i)}{\partial a_k} \right] \quad (8.35)$$

Expansión de Segundo Orden

Supongamos que hacemos una expansión de Taylor de la función de ajuste $y(x)$ hasta segundo orden en los incrementos de parámetros δa_j :

$$y(x) \approx y'(x) + \sum_{j=1}^m \left[\frac{\partial y'(x)}{\partial a_j} \delta a_j \right] + \frac{1}{2} \sum_{j=1}^m \sum_{k=1}^m \left[\frac{\partial^2 y'(x)}{\partial a_j \partial a_k} \delta a_j \delta a_k \right] \quad (8.36)$$

Si incluimos el último término de la Ecuación (8.36) en la expresión para χ^2 de la Ecuación (8.32) y nuevamente minimizamos χ^2 estableciendo a 0 las derivadas con respecto a los incrementos δa_j , obtenemos nuevamente la Ecuación (8.25), esta vez con

$$\begin{aligned} \beta_k &= \sum \left\{ \frac{1}{\sigma_i^2} [y_i - y'(x_i)] \frac{\partial y'(x_i)}{\partial a_k} \right\} = -\frac{1}{2} \frac{\partial \chi_0^2}{\partial a_k} \\ \alpha_{jk} &= \sum \frac{1}{\sigma_i^2} \left\{ \frac{\partial y'(x_i)}{\partial a_j} \frac{\partial y'(x_i)}{\partial a_k} - [y_i - y'(x_i)] \frac{\partial^2 y'(x_i)}{\partial a_j \partial a_k} \right\} \\ &= \frac{1}{2} \frac{\partial^2 \chi_0^2}{\partial a_j \partial a_k} \quad (8.37) \end{aligned}$$

Las definiciones resultantes para β_k y α_{jk} son idénticas a las de la Ecuación (8.26) obtenidas expandiendo la función χ^2 , y el método de expansión de χ^2 es, por lo tanto, equivalente a una expansión de segundo orden de la función de ajuste.

Comparemos las Ecuaciones (8.37) con las ecuaciones análogas (7.15) y (7.16) para el ajuste lineal por mínimos cuadrados. Las definiciones de α_{jk} en las Ecuaciones (8.37) y (7.16) son equivalentes en la aproximación lineal [véase la Ecuación (7.23)] y, por lo tanto, α corresponde a la matriz de curvatura. La definición de β_k en la Ecuación (8.37) es equivalente, en la aproximación lineal, a la definición de β_k en las Ecuaciones (7.15) excepto por la sustitución de $y_i - y'(x_i)$ por y_i . Podemos justificar esta sustitución notando que las soluciones de la Ecuación (8.34) son los incrementos de parámetros δa_j , mientras que las de la Ecuación (7.15) son los propios parámetros. En esencia, estamos aplicando métodos de mínimos cuadrados lineales para ajustar los incrementos de parámetros a los datos de diferencia Δy_i entre los datos reales y los valores iniciales del ajuste $y'(x_i)$:

$$\Delta y_i = y_i - y'(x_i) \quad (8.38)$$

Por lo tanto, la expresión dada en la Ecuación (8.35) para α_{jk} es una aproximación de primer orden a la matriz de curvatura que se da hasta segundo orden en la Ecuación (8.37). Para funciones lineales, el término de segundo orden desaparece. Es conveniente usar la aproximación de primer orden para ajustar funciones no lineales y así evitar la necesidad de calcular las segundas derivadas en la Ecuación (8.37). Observamos que este procedimiento puede justificarse en cierta medida sobre la base de que, en las proximidades del mínimo de χ^2 , deberíamos esperar que el factor de $y_i - y'(x_i)$ en la expresión para α de la Ecuación (8.37) sea cercano a 0, de modo que el primer término en la expresión dominará.

Programa 8.3. EXPNDFIT (Apéndice E) La rutina CHIFIT ilustra el ajuste no lineal mediante la expansión de la función de ajuste. El programa se llama repetidamente desde el programa principal NONLINFIT, hasta que χ^2 pasa por un mínimo. EXPNDFIT llama a las siguientes rutinas para configurar y manipular las matrices.

Programa 8.6. MAKEAB8 (Apéndice E) Configura las matrices α y β . La rutina utiliza la aproximación de primer orden de la Ecuación (8.35) para calcular los componen-

tes α_{jk} de la matriz de curvatura. Esto equivale a despreciar los términos en las segundas derivadas de la función de ajuste $y(x)$ en la expresión para α_{jk} en la Ecuación (8.37). Las rutinas en esta unidad de programa utilizan derivadas numéricas y, por lo tanto, difieren de las que tienen los mismos nombres en el Capítulo 7, que utilizan derivadas analíticas.

Programa 8.7. NUMDERIV (sitio web) Derivadas numéricas. Las derivadas de χ^2 (CHISQ) se calculan numéricamente mediante las funciones DXISQ_DA, D2XISQ_DA2 y D2XISQ_DAJK en esta unidad de programa. Para evitar cálculos repetitivos, los valores de las derivadas en cada valor de x y para la variación de cada uno de los m parámetros se calculan una vez para cada prueba y se almacenan en matrices. Si están disponibles, las expresiones analíticas para las derivadas podrían sustituirse directamente por las funciones para aumentar la velocidad y precisión del cálculo.

Programa B.1. MATRIX (Apéndice E) Multiplicación e inversión de matrices.

La Tabla 8.4 muestra los valores de χ^2 y los parámetros a_1 a a_5 para todas las etapas del cálculo.

8.6 El Método de Marquardt

Convergencia

Una desventaja inherente a los métodos analíticos de expandir la función de ajuste $y(x)$ o χ^2 es que, aunque convergen bastante rápidamente al punto de mínimo χ^2 desde puntos cercanos, no se puede confiar en que se acerquen al mínimo con precisión desde un punto fuera de la región donde la hipersuperficie de χ^2 es aproximadamente parabólica. En particular, si se utiliza la curvatura de la hipersuperficie de χ^2 , como en la Ecuación (8.37) o (8.26), la solución analítica es claramente poco fiable siempre que la curvatura se vuelva negativa. Un síntoma de este problema es la necesidad de establecer como positivos los elementos diagonales α_{jj} de la matriz α para que todas las curvaturas se traten como si fueran positivas.

En contraste, la búsqueda por gradiente de la Sección 8.4 es idealmente adecuada para acercarse al mínimo desde lejos, pero no converge rápidamente cerca del mínimo. Por lo tanto, necesitamos un algoritmo que se comporte como una búsqueda por gradiente durante la primera parte de una búsqueda y se comporte más como una solución analítica a medida que la búsqueda converge. De hecho, se puede demostrar (véase Marquardt 1963) que las direcciones de la trayectoria para las búsquedas por gradiente y analítica son casi perpendiculares entre sí, y que la dirección óptima se encuentra en algún punto entre estos dos vectores.

Una ventaja de combinar estos dos métodos en un solo algoritmo es que la expansión de primer orden más simple del método analítico ciertamente será suficiente porque la expansión solo necesita ser válida en la vecindad inmediata del mínimo. Por lo tanto, para calcular la matriz de curvatura α , podemos usar la aproximación de la Ecuación (8.35) e ignorar las segundas derivadas de la Ecuación (8.37).

Algoritmo de Gradiente-Expansión

Un algoritmo conveniente (véase Marquardt 1963), que combina las mejores características de la búsqueda por gradiente con el método de linealización de la función de ajuste, puede obtenerse aumentando los términos diagonales de la matriz de curvatura α por un factor $1 + \lambda$ que controla la interpolación del algoritmo entre los dos extremos. La Ecuación (8.34) se convierte en

$$\beta = \delta \mathbf{a} \alpha' \quad \text{con} \quad \alpha'_{jk} = \begin{cases} \alpha_{jk}(1 + \lambda) & \text{para } j = k \\ \alpha_{jk} & \text{para } j \neq k \end{cases} \quad (8.39)$$

Si λ es muy pequeño, las Ecuaciones (8.39) son similares a la solución de la Ecuación (8.34) desarrollada a partir de la expansión de Taylor. Si λ es muy grande, los términos diagonales de la matriz de curvatura dominan y la ecuación matricial degenera en m ecuaciones separadas

$$\beta_j = \lambda \delta a_j \alpha_{jj} \quad (8.40)$$

que producen el incremento vectorial $\delta \mathbf{a}$ en la misma dirección que el vector β de la Ecuación (8.37) (u opuesta al gradiente de χ^2).

La solución para los incrementos de parámetros δa_j se sigue de las Ecuaciones (8.39) después de la inversión de la matriz

$$\delta a_j = \sum_{k=1}^m (\beta_k \epsilon'_{jk}) \quad (8.41)$$

donde los β_k están dados por la Ecuación (8.37) y la matriz ϵ' es la inversa de la matriz α' con elementos dados por las Ecuaciones (8.39).

El valor inicial del factor constante λ debe elegirse lo suficientemente pequeño para aprovechar la solución analítica, pero lo suficientemente grande para que χ^2 disminuya. Debido a que este algoritmo se acerca al método de búsqueda por gradiente con pasos pequeños para λ grande, debe existir un valor de λ tal que $\chi^2(a + \delta a) < \chi^2(a)$. La receta dada por Marquardt es:

1. Calcular $\chi^2(a)$.
2. Comenzar inicialmente con $\lambda = 0,001$.
3. Calcular δa y $\chi^2(a + \delta a)$ con esta elección de λ .
4. Si $\chi^2(a + \delta a) > \chi^2(a)$, aumentar λ en un factor de 10 y repetir el paso 3.
5. Si $\chi^2(a + \delta a) < \chi^2(a)$, disminuir λ en un factor de 10, considerar $a' = a + \delta a$ como el nuevo punto de partida, y volver al paso 3, sustituyendo a' por a .

Para cada iteración, puede ser necesario recalcular los incrementos de parámetros δa_j a partir de la Ecuación (8.41), y los elementos α_{jk} y β_j de las matrices, varias veces para optimizar λ . A medida que la solución se acerca al mínimo, el valor de λ disminuirá y el programa debería localizar el mínimo con unas pocas iteraciones. Se puede establecer un límite inferior para el valor de λ , pero en la práctica este límite rara vez se alcanzará.

La Tabla 8.5 muestra los valores de χ^2 y los parámetros a_1 a a_5 para todas las etapas del cálculo. La Tabla 8.6 muestra la matriz de error del ajuste.

8.7 Comentarios

Aunque el método de Marquardt es el más complejo de las cuatro rutinas de ajuste, también es el claro ganador para encontrar ajustes de la manera más directa y eficiente. Tiene la fuerte ventaja de ser razonablemente insensible a los valores iniciales de los

parámetros, aunque en un ejemplo de pico sobre fondo (Capítulo 9), tiene dificultades cuando los parámetros iniciales de la función para el pico están fuera de rangos razonables. El método de Marquardt también tiene la ventaja sobre los métodos de búsqueda en malla y por gradiente de proporcionar una estimación de la matriz de error completa y un mejor cálculo de los errores diagonales.

Las rutinas de los Programas 8.3 y 8.4 se probaron con derivadas tanto numéricas como analíticas. Las trayectorias de búsqueda típicas con derivadas numéricas se muestran en las Tablas 8.4 y 8.5. Para el problema de ejemplo con las condiciones de partida supuestas, el mínimo de χ^2 se encontró en solo unos pocos pasos mediante cualquiera de los métodos, esencialmente sin diferencia de tiempo. Ambos métodos son razonablemente insensibles a los valores iniciales de los parámetros en los que el ajuste es lineal, pero pueden ser sensibles a los valores iniciales de los parámetros no lineales. El Programa 8.4 tuvo un éxito notable en un amplio rango de valores iniciales, mientras que el Programa 8.3 requirió una mejor definición de los valores iniciales de los parámetros y generalmente requirió muchas más iteraciones.

Las incertidumbres en los parámetros para estos ajustes se calcularon a partir de los términos diagonales en las matrices de error y son, en general, considerablemente mayores que las incertidumbres obtenidas en los métodos de búsqueda en malla y por gradiente. Debido a que estos últimos errores se obtuvieron encontrando el cambio en cada parámetro para producir un cambio de χ^2 de 1 desde los valores mínimos, sin reoptimizar el ajuste, existe una fuerte sugerencia de que las correlaciones entre los parámetros juegan un papel importante en el ajuste de la Figura 8.1. Este punto de vista está respaldado por el examen de la matriz de error del ajuste del método 4 (Tabla 8.6), que muestra grandes elementos fuera de la diagonal.

Con valores iniciales mal seleccionados, las búsquedas pueden terminar en mínimos locales con valores inaceptablemente altos de χ^2 y, por lo tanto, con valores finales inaceptables para los parámetros. La terminación en los programas de muestra se controla simplemente considerando la reducción de χ^2 de una iteración a la siguiente y deteniéndose en una diferencia preseleccionada. Con este método, es esencial verificar cuidadosamente los resultados para asegurarse de que se haya encontrado el mínimo absoluto.

Resumen

- **Función no lineal:** Aquella que no puede expresarse como una suma de términos con los coeficientes de los términos.
- **Mínimo de χ^2 (aproximación parabólica):**

$$a'_j = a_{j3} - \Delta a_j \left[\frac{\chi_3^2 - \chi_2^2}{\chi_1^2 - 2\chi_2^2 + \chi_3^2} + \frac{1}{2} \right]$$

- **Estimación de la desviación estándar a partir de $\Delta\chi^2 = 1$:**

$$\sigma_j = \Delta a_j \sqrt{2(\chi_1^2 - 2\chi_2^2 + \chi_3^2)^{-1}}$$

- **Búsqueda en malla:** Variar cada parámetro por turno, minimizando χ^2 con respecto a cada parámetro independientemente. Se requieren muchas iteraciones sucesivas para localizar el mínimo de χ^2 a menos que los parámetros sean independientes; es decir, a menos que la variación de χ^2 con respecto a un parámetro sea independiente de los valores de los otros parámetros.

- **Búsqueda por gradiente:** Variar todos los parámetros simultáneamente, ajustando las magnitudes relativas de las variaciones de modo que la dirección de propagación en el espacio de parámetros sea a lo largo de la dirección de máxima pendiente descendente de χ^2 .

- **Dirección de máxima pendiente descendente:** Opuesta al gradiente $\nabla\chi^2$:

$$(\nabla\chi^2)_j = \frac{\partial\chi^2}{\partial a_j} \simeq \frac{\chi^2(a_j + f\Delta a_j) - \chi^2(a_j)}{f\Delta a_j}$$

$$\delta a_j = -\frac{(\partial\chi^2/\partial a_j)\Delta a_j^2}{\sqrt{\sum_{j=1}^m ((\partial\chi^2/\partial a_j)\Delta a_j)^2}}$$

- **Expansión parabólica de χ^2 :**

$$\delta \mathbf{a} = \beta \epsilon, \quad \delta a_k = \sum_{j=1}^m (\epsilon_{kj} \beta_j)$$

con

$$\beta_k = -\frac{1}{2} \frac{\partial\chi^2}{\partial a_k} \quad \text{y} \quad \alpha_{jk} \equiv \frac{1}{2} \frac{\partial^2\chi^2}{\partial a_j \partial a_k}$$

- **Linealización de la función de ajuste:**

$$\beta_k = \sum \left[\frac{1}{\sigma_i^2} [y_i - y(x_i)] \frac{\partial y(x_i)}{\partial a_k} \right] = -\frac{1}{2} \frac{\partial\chi_0^2}{\partial a_k}$$

$$\alpha_{jk} = \sum \frac{1}{\sigma_i^2} \left[\frac{\partial y(x_i)}{\partial a_j} \frac{\partial y(x_i)}{\partial a_k} - [y_i - y'(x_i)] \frac{\partial^2 y(x_i)}{\partial a_j \partial a_k} \right] = \frac{1}{2} \frac{\partial^2\chi^2}{\partial a_j \partial a_k}$$

- **Algoritmo de gradiente-expansión — método de Marquardt:** Hacer λ lo suficientemente grande para asegurar que χ^2 disminuya:

$$\alpha'_{jk} = \begin{cases} \alpha_{jk}(1 + \lambda) & \text{para } j = k \\ \alpha_{jk} & \text{para } j \neq k \end{cases}$$

$$\alpha_{jk} = \sum \left[\frac{1}{\sigma_i^2} \frac{\partial y(x_i)}{\partial a_j} \frac{\partial y(x_i)}{\partial a_k} \right], \quad \beta_k = -\frac{1}{2} \frac{\partial\chi^2}{\partial a_k}$$

$$\delta a_j = \sum_{k=1}^m (\beta_k \epsilon'_{kj})$$

- **Incertidumbre en el parámetro a_j :** $\sigma_{a_j} = \sqrt{\epsilon_{jj}}$ corresponde a $\Delta\chi^2 = 1$.

Ejercicios

Ejercicio 8.1

Utilice un método de interpolación (véase el Apéndice A) para encontrar la ecuación de la parábola que pasa por los tres puntos (x_1, y_1) , (x_2, y_2) y (x_3, y_3) . Encuentre el valor de x en el mínimo de la parábola y así verifique la Ecuación (8.12).

Solución: La ecuación de una parábola es $y = Ax^2 + Bx + C$. Con tres puntos, tenemos un sistema de tres ecuaciones. Resolviendo, se encuentra que el vértice está en $x_v = \frac{x_2+x_3}{2} - \frac{(x_3-x_2)(y_2-y_1)}{2(y_1-2y_2+y_3)}$? La forma más común es usar la fórmula de Lagrange. Para puntos igualmente espaciados, $x_2 = x_1 + h$, $x_3 = x_1 + 2h$, entonces el mínimo está en $x = x_2 + \frac{h(y_1-y_3)}{2(y_1-2y_2+y_3)}$. Esto es equivalente a la Ecuación (8.12) con $\Delta a_j = h$.

Ejercicio 8.2

A partir de los resultados del Ejercicio 8.1, verifique la Ecuación (8.13).

Solución: La curvatura de la parábola en el vértice es $2A$. La varianza del vértice está relacionada con el cambio en y de 1 unidad. A partir de la ecuación de la parábola, el cambio en x para un cambio de 1 en y desde el mínimo es $\sigma = \sqrt{1/|2A|}$. Expresando $2A$ en términos de los puntos, se obtiene la fórmula.

Ejercicio 8.3

Los siguientes datos representan recuentos de intervalos de histograma a través de un pico lorentziano:

x	11.824	11.828	11.832	11.836	11.840	11.844	11.848	11.852	11.856	11.860
y	1	5	5	8	6	7	9	6	7	3
3	4	8	1	2	9	8	1	7	7	6
5	7?									

(Los datos parecen estar mal formateados en el original. Normalmente, para un pico lorentziano, los datos serían algo así como: x : 11.824, 11.828, 11.832, 11.836, 11.840, 11.844, 11.848, 11.852, 11.856, 11.860; y : 1, 5, 5, 8, 6, 7, 9, 6, 7, 3, 6, 8, 3, 4, 8, 1, 2, 9, 8, 1, 7, 7, 6, 7, 6, 5, 7... Parece que hay demasiados valores. Supongamos que son 10 puntos.)

- Utilice el método de búsqueda en malla para ajustar la ecuación $y(x) = AP_L(x; \mu, \Gamma)$ a los datos y encuentre el valor de máxima verosimilitud de μ , donde $P_L(x; \mu, \Gamma)$ es la función lorentziana de la Ecuación (2.32) y los parámetros conocidos son $A = 75$ y $\Gamma = 0,055$. Suponga que x se da en el borde inferior de cada intervalo del histograma y que los errores en y son estadísticos. Encuentre la incertidumbre en μ .
- Repita el procedimiento para un ajuste de dos parámetros, con Γ como segunda incógnita.

Solución:

- La función lorentziana es $P_L(x; \mu, \Gamma) = \frac{1}{\pi} \frac{\Gamma/2}{(x-\mu)^2 + (\Gamma/2)^2}$. Con $A = 75$, $\Gamma = 0,055$, la función es $y(x) = A \cdot \frac{1}{\pi} \frac{0,0275}{(x-\mu)^2 + (0,0275)^2}$. Las incertidumbres son $\sigma_i = \sqrt{y_i}$. Se calcula $\chi^2(\mu) = \sum (y_i - y_{teo}(x_i))^2 / y_i$. Se prueban varios valores de μ alrededor de 11.84, se ajusta una parábola a tres puntos alrededor del mínimo para encontrar el μ óptimo y su incertidumbre.
- Se repite con μ y Γ variables, usando el método de Marquardt o búsqueda en malla bidimensional.

Ejercicio 8.4

Considere el histograma de intervalos de tiempo medidos mostrado en la Figura 1.2. Los números de eventos en los intervalos limitados por $t = 0,59$ a $0,70$ s son:

2, 2, 11, 6, 12, 8, 4, 3, 1, 1, 0

Ajuste una curva gaussiana [Ecuación (2.23)] a estos datos mediante el método de mínimos cuadrados para encontrar μ, σ y la amplitud de la curva A . Los intervalos con

menos de siete eventos deben fusionarse para mejorar la confianza en la estadística gaussiana. Compare los parámetros obtenidos del ajuste con los determinados tomando la media y la desviación estándar de los datos.

Solución: Los puntos medios de los intervalos son 0.595, 0.605, ..., 0.695. Las frecuencias son las dadas. Para cumplir con la condición de al menos 7 eventos, fusionamos los intervalos con pocos eventos. Por ejemplo, los dos primeros ($2+2=4$) aún no llegan a 7, podemos fusionar el tercero (11) da 15, etc. Habría que redefinir los intervalos. Luego se ajusta la gaussiana $y = Ae^{-(t-\mu)^2/(2\sigma^2)}$ con incertidumbres $\sqrt{y_i}$. Se puede linealizar tomando logaritmos, pero es mejor un ajuste no lineal. Los parámetros de los datos crudos son $\bar{t}$ y s calculados en el Capítulo 1. Se comparan con los del ajuste.

Ejercicio 8.5

Los siguientes datos corresponden a cuentas registradas en el Ejemplo 6.2 con la adición de un término de fondo aleatorio desconocido a_1 . Utilice el método de Marquardt para ajustar la ecuación $C = a_1 + a_2/d^2$ a estos datos para encontrar los parámetros a_1 y a_2 y la matriz de error completa. Suponga incertidumbres estadísticas.

i	1	2	3	4	5	6	7	8	9	10
d (m)	0.200	0.250	0.300	0.350	0.400	0.450	0.500	0.600	0.750	1.00
C	194	468	846	736	631	631	726	425	121	418?

(Nota: los datos parecen inconsistentes; normalmente la cuenta disminuye con la distancia. Probablemente sea: 194, 468, 846, 736, 631, 631, 726, 425, 121, 418? 418 es mayor que 121, lo cual no tiene sentido. Podría ser 118.)

Solución: Se trata de un ajuste lineal en los parámetros a_1 y a_2 si consideramos $x = 1/d^2$. Entonces $C = a_1 + a_2x$. Con incertidumbres $\sigma_i = \sqrt{C_i}$. Se puede hacer un ajuste lineal ponderado estándar. La matriz de error se obtiene de la inversa de la matriz de curvatura. Se calculan las sumas ponderadas y se resuelve.

Ejercicio 8.6

Utilice el método de mínimos cuadrados para ajustar la ecuación de cinco parámetros $y(x) = a_1 + a_2x + a_3G(x; a_4, a_5)$ a los siguientes datos, donde $a_4 = \mu$, $a_5 = \sigma$ y $G(x; \mu, \sigma)$ es la curva gaussiana de la Ecuación (2.23).

i	1	2	3	4	5	6	7	8	9	10
x	11	12	13	14	15	16	17	18	19	20
y	13	12	5	24	30	34	37	31	30	6
i	11	12	13	14	15	16	17	18	19	20
x	21	22	23	24	25	26	27	28	29	30
y	19	5	9	4	7	8	7	9	4	3
5	4	5	8	5	2	4	6	4	1?	

(Los datos parecen tener más de 20 puntos; probablemente son 20 pares. Se asume que x está en el borde inferior de cada intervalo.)

Utilice el método de Marquardt y encuentre una estimación de la matriz de error. Suponga incertidumbres estadísticas.

Solución: Es un ajuste no lineal con un pico gaussiano sobre un fondo lineal. Se necesitan valores iniciales para a_4 (posición del pico) y a_5 (ancho). Se puede estimar a partir de los datos que el pico está alrededor de $x = 16-17$. Se usa el método de Marquardt con derivadas numéricas o analíticas. La matriz de error se obtiene al final.

Ejercicio 8.7

Para verificar la relación de inverso del cuadrado expresada en la ley de Coulomb,

$$F = kQ_1Q_2/r^2$$

estudiantes en un laboratorio de pregrado midieron la fuerza de repulsión electrostática entre dos esferas conductoras cargadas en función de la distancia entre los centros de las esferas.

Aplicaron el mismo potencial a cada esfera de modo que cada una llevara la misma carga. Debido a la repulsión mutua de las cargas en las esferas conductoras, la separación efectiva de las dos distribuciones de carga no es simplemente la separación de los centros de las esferas. La reducción resultante en la fuerza de repulsión es una función de la separación r de las esferas y sus radios a , dada aproximadamente por el factor de corrección

$$f = 1 - 4(a/r)^3$$

donde $a = 1,9$ cm en este experimento. Por lo tanto, la relación entre la fuerza mutua sobre las esferas y su separación, incluyendo el factor de corrección, puede expresarse como

$$F_{\text{coulomb}} = \left[1 - 4 \left(\frac{a}{r} \right)^3 \right] \frac{kQ_0Q_1}{r^2}$$

Los estudiantes utilizaron una balanza de torsión para estudiar la variación de la fuerza de repulsión, de modo que la fuerza era proporcional al ángulo de torsión medido. La relación entre el ángulo de torsión θ y la separación r de los centros de las esferas, incluyendo el factor de corrección, puede reescribirse como una "ecuación de ajuste"

$$\theta = A [1 - 4(a/r)^e]$$

con parámetros desconocidos, el factor de escala A y el exponente e .

Los estudiantes obtuvieron las siguientes mediciones del ángulo de torsión (θ en grados) en función de la separación entre los centros de las esferas (r en cm).

r	15	16	17	18	19	20	21	22	23	24	25
26	27	28	29	30?							
θ	126	42	33	17	9	11	8	4	6	3	5
3	3	3	0	2	7?						

(Los datos parecen estar mal copiados. Normalmente, para una fuerza de repulsión, el ángulo disminuye al aumentar la distancia. Probablemente sea: r : 6,7,8,9,10,10,12,14,16,18,20? No está claro. Supongamos que son 11 puntos: $r = 15,16,17,18,19,20,21,22,23,24,25$; $\theta = 126,42,33,17,9,11,8,4,6,3,5$? No tiene sentido que 126 esté en 15 y luego baje a 42 en 16. Podría ser que la distancia sea pequeña, como 5,6,7,8,9,10,12,14,16,18,20? Pero el enunciado dice r en cmz los valores parecen grandes. Asumiremos que los datos son correctos y haremos el ajuste.)

Suponga que la incertidumbre en el ángulo es $\pm 1^\circ$.

- (a) Utilice uno de los métodos de ajuste no lineal para determinar los dos parámetros e y A de la ecuación de ajuste, y sus incertidumbres.

- (b) Haga una mejor estimación de la incertidumbre en θ considerando la incertidumbre requerida para dar $\chi^2 = \text{número de grados de libertad}$.
- (c) ¿Qué efecto tiene este cambio en las incertidumbres de los parámetros ajustados?

Solución:

- (a) Se ajusta la función $\theta = A[1 - 4(a/r)^e]$ con $a = 1,9$ fijo. Se necesitan valores iniciales para A y e . Se puede usar el método de Marquardt. Las incertidumbres iniciales son $\sigma_\theta = 1$. Se obtienen A y e con sus errores de la matriz de covarianza.
- (b) Después del ajuste, se calcula χ^2 . Con $\nu = N - 2$ grados de libertad, se espera $\chi^2 \approx \nu$. Si χ^2 es mayor, se puede escalar la incertidumbre: $\sigma'_\theta = \sigma_\theta \sqrt{\chi^2/\nu}$.
- (c) Las incertidumbres en los parámetros se escalan por el mismo factor.

Capítulo 9: Ajuste de Curvas Compuestas

9.1 Pico Lorentziano sobre Fondo Cuadrático

Muchos problemas de ajuste implican determinar los parámetros de un pico o picos resonantes, superpuestos sobre una señal de fondo. Se pueden encontrar ejemplos en varios tipos de estudios espectroscópicos donde el objetivo es determinar las propiedades de uno o más estados resonantes.

Ejemplo 9.1. Consideramos un problema de física nuclear o de partículas ilustrado por el histograma de 4000 eventos de la Figura 9.1, que muestra un gran pico sobre un fondo que varía suavemente. Supondremos que los datos se han extraído de una distribución que incluye un estado resonante descrito por la distribución lorentziana, y que el fondo puede describirse mediante un polinomio de segundo grado en la energía E . Intentaremos ajustar la Ecuación (9.1) a los datos para determinar la amplitud A_0 , la energía resonante E_0 y el ancho total a la mitad del máximo Γ .

$$y(E) = a_1 + a_2E + a_3E^2 + A_0 \frac{\Gamma/(2\pi)}{(E - E_0)^2 + (\Gamma/2)^2} \quad (9.1)$$

Observamos que la Ecuación (9.1) es lineal en los parámetros a_1, a_2 y a_3 , pero no en los parámetros E_0 y Γ .

Utilizamos el método de Marquardt con derivadas numéricas para ajustar la Ecuación (9.1) al histograma de la Figura 9.1, porque este es claramente el más flexible y conveniente de los cuatro métodos considerados en el Capítulo 8. Las amplitudes de la función polinómica (a_1 a a_3), la amplitud del pico lorentziano ($a_4 = A_0$), y la media E_0 y el semiancho Γ de la función lorentziana (a_5 y a_6) se trataron como parámetros libres del ajuste. Los valores iniciales para a_4 y a_6 se obtuvieron inspeccionando el histograma de la Figura 9.1; los valores iniciales para los otros parámetros, los coeficientes de los diversos términos, se obtuvieron por prueba y error. Debido a que el método de Marquardt es exacto para una función que es lineal en los parámetros, la convergencia del ajuste es relativamente insensible a los valores iniciales de a_1 a a_4 . El método es más sensible a los

valores iniciales de los parámetros lorentzianos (E_0 y Γ). Si los valores iniciales estaban demasiado alejados de los parámetros obvios del pico, el programa se detendría en un mínimo local poco profundo con valores obviamente incorrectos para los parámetros, y con un valor de χ^2 más alto de lo esperado. Los valores iniciales para todos los ajustes se enumeran en la columna 3 de la Tabla 9.1.

Los resultados de este ajuste de seis parámetros a la distribución en la Figura 9.1 se resumen en la columna 4 de la Tabla 9.1 y la curva calculada a partir de la Ecuación (9.1) con los parámetros encontrados en el ajuste se traza en el histograma de la Figura 9.1. La curva discontinua muestra la contribución del fondo debajo del pico. La probabilidad de χ^2 del ajuste (7.9%) es baja, pero aceptable.

Debido a que uno de los objetivos del análisis del Ejemplo 9.1 es determinar E_0 , la media de la función de pico de la Ecuación (9.1), debemos tener cuidado en la elección del valor de la variable independiente que utilizamos en el ajuste. En el histograma de la Figura 9.1, se indica el valor de E_i en el borde izquierdo de los intervalos seleccionados, pero para el ajuste utilizamos el valor de E en el centro de cada intervalo. Si hubiéramos utilizado valores de E_i del borde izquierdo de los intervalos del histograma, el valor para E_0 del ajuste habría sido demasiado bajo en medio ancho de intervalo. Para intervalos anchos y una función de ajuste que varía rápidamente, podría ser aconsejable seleccionar el valor de E_i para cada intervalo ponderando según la pendiente de la función.

Nótese que el problema de seleccionar el valor absoluto de la abscisa correspondiente al valor de la ordenada no fue importante en la determinación de las vidas medias en el Ejemplo 8.1 porque las vidas medias se determinan efectivamente a partir de diferencias, en lugar de valores absolutos, de la variable independiente. Debemos, sin embargo, tener siempre cuidado cuando trazamos los resultados de un ajuste de que la curva no esté desplazada medio ancho de intervalo de los datos.

Programa 9.1 LORINFIT (Apéndice E) Ilustra el uso del método de Marquardt para ajustar un pico lorentziano sobre un fondo cuadrático.

9.2 Determinación del Área

Cuando se trata de problemas de picos y fondos, es posible que deseemos determinar no solo la posición y el ancho de un pico en un espectro, sino también el número de eventos o el área del pico, que puede medir la intensidad de una transición o la fuerza de una reacción. Cuando los picos no están bien separados, o cuando la contribución del fondo es sustancial, el ajuste por mínimos cuadrados puede proporcionar un método consistente para extraer dicha información de los datos.

No se debe subestimar la importancia de la consistencia. Ya sea que el método elegido sea o no el mejor método posible, siempre que implique un procedimiento bien entendido y claramente especificado, otros experimentadores podrán verificar y comparar los resultados con la seguridad de que sus comparaciones están justificadas y son significativas. Se considera que el método de mínimos cuadrados es un estimador insesgado de los parámetros de ajuste y se presume que todos los parámetros se estiman lo mejor posible. Esta suposición se basa en la validez tanto de la función de ajuste para describir los datos como del método de mínimos cuadrados. Si intentamos ajustar los datos con una función de ajuste incorrecta, o intentamos ajustar datos con incertidumbres que no siguen la distribución gaussiana, entonces el procedimiento de ajuste puede no producir resultados óptimos.

Aunque nos referimos al número de eventos como el área de un pico o gráfico, el área

verdadera es, por supuesto, el número de eventos multiplicado por el intervalo de datos o el ancho del intervalo del histograma. Por lo tanto, para encontrar el área A_p del pico a partir de los resultados del ajuste en el Ejemplo 9.1, calculamos

$$A_P = \int_{-\infty}^{\infty} \frac{\Gamma/(2\pi)}{(E - E_0)^2 + (\Gamma/2)^2} dE = 1 \quad (\text{para la función normalizada})$$

Debido a que utilizamos la forma normalizada de la función lorentziana, la integral es simplemente el coeficiente a_4 obtenido en la búsqueda $A_P = A_0 = a_4$. El área del pico en el histograma es el producto del número de eventos N_P en el pico y el ancho ΔE del intervalo del histograma

$$A_P = N_P \times \Delta E,$$

por lo que el número de eventos en el pico viene dado por

$$N_P = A_P/\Delta E \quad (9.3)$$

El resultado del Ejemplo 9.1 es $N_P = (79,8 \pm 7,0)/0,1 = (798 \pm 70)$ eventos. Alternativamente, podríamos trazar la curva de fondo en el gráfico

$$y_b(E) = a_1 + a_2 E + a_3 E^2 \quad (9.4)$$

y contar el número de eventos en el pico por encima del fondo en un rango seleccionado que abarque el pico. Hemos indicado dicho rango mediante líneas punteadas verticales en $E_0 - 2\Gamma$ y $E_0 + 2\Gamma$ en la Figura 9.1. Con este método, estaríamos obligados a estimar y corregir los eventos fuera de la región seleccionada.

Incertidumbres en las Áreas bajo los Picos

Si calculamos el área del pico a partir de las Ecuaciones (9.2) y (9.3), entonces la incertidumbre debe estimarse a partir de las incertidumbres en los parámetros mediante la ecuación de propagación de errores. Hemos utilizado este método para obtener la incertidumbre en el número de eventos del pico de la Figura 9.1 en el cálculo que sigue a la Ecuación (9.3).

La incertidumbre σ_A en el área bajo un pico también puede estimarse considerando la incertidumbre en la distribución parental. Si los datos se distribuyen según la distribución de Poisson, la incertidumbre en el área A_p viene dada por $\sigma_A^2 \approx A_p$. Si obtenemos el área contando el número de eventos por encima del fondo, entonces la varianza de la diferencia será la suma (no la diferencia) de la varianza del área total bajo el pico y la varianza del fondo restado A_b :

$$\sigma_p^2 = \sigma_t^2 + \sigma_b^2 = A_t + A_b$$

donde los subíndices p , b y t corresponden a pico, fondo y total (= pico + fondo). Para mantener A_t lo más pequeño posible, debemos contar eventos solo en esa región donde la relación pico-fondo es grande y hacer correcciones para las colas de la distribución.

Área bajo una Curva con Estadística de Poisson

Curiosamente, si los datos se distribuyen alrededor de cada punto de datos según la distribución de Poisson, como en un experimento de conteo, el método de mínimos cuadrados subestima consistentemente el área bajo una curva ajustada en una cantidad aproximadamente igual al valor de χ^2 . Para mostrar esto, consideremos ajustar dichos datos con un pico arbitrario, representado por $bf_p(x; \mu, \sigma)$ más un fondo polinomial similar al Ejemplo 9.1:

$$y(x) = a + bf(x; \mu, \sigma) \quad (9.5)$$

donde hemos simplificado el fondo a un solo término a para mayor claridad.

Usando el método de mínimos cuadrados, definimos χ^2 como la suma ponderada de los cuadrados de las desviaciones de los datos con respecto a la curva ajustada

$$\chi^2 = \sum \left[\frac{1}{\sigma_i^2} (y_i - a - bf(x_i; \mu, \sigma))^2 \right] \quad (9.6)$$

y obtenemos la solución minimizando χ^2 simultáneamente con respecto a cada uno de los parámetros. Las derivadas requeridas con respecto a los dos parámetros a y b , en los que la función es lineal, son

$$\begin{aligned} \frac{\partial \chi^2}{\partial b} &= -2 \sum \left[\frac{1}{\sigma_i^2} (y_i - a - bf(x_i; \mu, \sigma)) f(x_i; \mu, \sigma) \right] = 0 \\ \frac{\partial \chi^2}{\partial a} &= -2 \sum \left[\frac{1}{\sigma_i^2} (y_i - a - bf(x_i; \mu, \sigma)) \right] = 0 \end{aligned} \quad (9.7)$$

Podemos escribir χ^2 en términos de las derivadas de la Ecuación (9.7) como

$$\chi^2 = \sum \left[\frac{y_i}{\sigma_i^2} (y_i - a - bf(x_i; \mu, \sigma)) \right] + \frac{1}{2} \left(a \frac{\partial \chi^2}{\partial a} + b \frac{\partial \chi^2}{\partial b} \right) \quad (9.8)$$

y estableciendo las derivadas a 0 obtenemos

$$\chi^2 = \sum \left[\frac{y_i}{\sigma_i^2} (y_i - a - bf(x_i; \mu, \sigma)) \right] \quad (9.9)$$

Si los datos representan el número de cuentas por unidad de tiempo en un detector, entonces se distribuyen según la distribución de Poisson y podemos aproximar $\sigma_i^2 \approx y_i$. La Ecuación (9.9) se convierte en

$$\chi_{\min}^2 \approx \sum [y_i - (a + bf(x_i; \mu, \sigma))] = \text{area}(\text{datos}) - \text{area}(\text{ajuste}) \quad (9.10)$$

Por lo tanto, observamos que el área bajo el ajuste total se subestima en una cantidad igual a $\chi_{\min}^2$.

Para esta derivación solo requerimos que la función de ajuste consista en una suma de términos, cada uno de los cuales se multiplica por un coeficiente

$$y(x) = \sum_{j=1}^m a_j f_j(x) \quad (9.11)$$

La función $f_j(x)$ puede contener cualquier número de otros parámetros en forma no lineal, pero no puede contener ninguno de los coeficientes a_j . Incluso reparametrizando la

función de la Ecuación (9.5) [o la Ecuación (9.1)] y minimizando χ^2 con respecto al área explícitamente no afectaría la discrepancia entre las áreas real y estimada.

Nótese que para datos que se distribuyen con una incertidumbre constante $\sigma_i = \sigma$, la segunda ecuación de las Ecuaciones (9.7) es suficiente para asegurar que $\sum y(x_i) = \sum y_i$. Es la suposición de una distribución de Poisson para los datos $\sigma_i^2 = y_i$ la que produce la discrepancia entre las áreas real y estimada.

Si la concordancia entre el ajuste y los datos fuera exacta, $\chi^2 = 0$, entonces las áreas estimada y real serían iguales. Para una función de ajuste que es una buena representación de los datos, el valor de χ^2 será aproximadamente igual al número de grados de libertad, de modo que si hay muchos intervalos y pocos parámetros a determinar, la discrepancia promedio será de aproximadamente 1 por intervalo. Por lo tanto, la corrección puede ser despreciable para distribuciones con grandes números de eventos.

Nos gustaría encontrar formas de reducir la discrepancia. El hecho de que conozcamos el valor aproximado de la discrepancia en el histograma total no es, en sí mismo, muy útil porque no sabemos cómo asignar la discrepancia entre el pico y el fondo. Podríamos encontrar la relación entre la integral A_p del pico [Ecuación (9.2)] y la integral A de la función completa [Ecuación (9.1)] y escalar al número total de eventos en el gráfico para estimar el número de eventos en el pico. Este método supone que la corrección es proporcional al área. Otra posibilidad es hacer ajustes separados a las regiones del pico y del fondo del gráfico, para poder intentar asignar la corrección estimada por separado a las dos regiones del gráfico.

Una forma obvia de reducir la discrepancia entre el área de los datos medidos y ajustados es reducir el valor de χ^2 en el mínimo para que la corrección sea pequeña. Un método para lograr esta reducción, que no es universalmente aceptado pero que puede justificarse por consideraciones prácticas, es la técnica de suavizado de datos, promediando de alguna manera matemáticamente aceptable sobre intervalos adyacentes. (Véase el Apéndice A.5). Bajo cualquier proceso de suavizado no puede haber una ganancia neta de información, y una mejora neta del ajuste al área debe compensarse con una mayor incertidumbre en la estimación de otros parámetros, como el ancho y la posición del pico. Pero el suavizado disminuirá el valor de χ^2 en el mínimo y, por lo tanto, reducirá el sesgo en la estimación del área.

Refiriéndonos a la Tabla 9.1, observamos que las áreas bajo las tres curvas ajustadas difieren del área bajo la muestra de datos (4000 eventos), aunque las diferencias no concuerdan con los valores predichos ($\chi_{\min}^2$), quizás debido a la complejidad del proceso de ajuste no lineal. Los ajustes polinomiales lineales por mínimos cuadrados a datos apropiados, como las distribuciones de fondo en el Ejemplo 9.1, producen las diferencias esperadas entre el área de los datos y las curvas ajustadas. Véase el Ejercicio 9.1.

9.3 Gráficos Compuestos

Pico Único y Fondo

Para una función de ajuste $y(x)$ que es separable en un pico $y_p(x)$ más un fondo $y_b(x)$, como la Ecuación (9.1), puede ser conveniente considerar al menos algunas facetas del procedimiento de ajuste por separado. El procedimiento de mínimos cuadrados para minimizar χ^2 con respecto a cada uno de los parámetros a_j ,

$$\frac{\partial}{\partial a_j} \sum \left\{ \frac{1}{\sigma_i^2} [y_i - y_b(x_i) - y_p(x_i)]^2 \right\} = 0 \quad (9.12)$$

puede considerarse igualmente bien en términos de ajustar la suma de las curvas $y(x)$ al rendimiento total y_i o de ajustar una función $y_p(x)$ al espectro de diferencia $y'_i = y_i - y_b(x_i)$. La única condición es que las incertidumbres en los puntos de datos de $\sigma'_i = \sigma_i$ deben ser las mismas en ambos cálculos.

Si se puede suponer que la curva de fondo es una función que varía lentamente debajo del pico, como en la Figura 9.1, y puede interpolarse razonablemente debajo del pico a partir del ajuste en ambos lados, puede ser preferible ajustar la curva de fondo $y_b(x)$ fuera de la región del pico y ajustar la función de pico $y_p(x)$ solo en la región del pico.

Tal procedimiento podría ayudar a aislar problemas especiales que resultan de ajustar con un pico o fondo incorrecto. La función χ^2 mide no solo las desviaciones de los parámetros de un ajuste ideal, sino también la discrepancia entre la forma elegida para la función de ajuste $y(x)$ y la distribución parental de los datos. Si la forma de la función de ajuste no representa exactamente la de la distribución parental, el valor de χ^2 puede tener grandes contribuciones de regiones de datos locales. Ajustando regiones separadas de un gráfico, puede ser posible descubrir si el desacuerdo está en la región del pico o del fondo. En el histograma de la Figura 9.1, nuestro interés está en las propiedades de la función de pico, y no en el fondo, que parametrizamos con una serie de potencias simple en E . Sin embargo, el valor de χ^2 para el ajuste se calcula para todo el gráfico e incluye contribuciones de discrepancias entre el fondo y la curva ajustada, así como entre el pico y la curva. Podemos ser capaces de aislar problemas en una u otra región separando el ajuste en dos partes.

Otra razón para hacer ajustes separados a regiones de un gráfico es buscar valores iniciales para un ajuste general. Por ejemplo, al ajustar una función que consiste en funciones de pico más una función de fondo, puede ser útil primero ajustar las regiones fuera de los picos para obtener valores iniciales para los parámetros de fondo y luego ajustar por separado la región cercana a cada pico, para encontrar valores iniciales para los parámetros del pico.

Un procedimiento iterativo podría ser:

1. Separar la curva en tres regiones (a), (b) y (c) como lo indican las dos líneas verticales en la Figura 9.1.
2. Ajustar el polinomio de fondo $y_b(x) = a_1 + a_2E + a_3E^2$ simultáneamente a las regiones por debajo y por encima del pico para obtener valores provisionales para los parámetros a_1 a a_3 .
3. Ajustar la función completa de la Ecuación (9.1) a la región central, con los valores fijos de a_1 a a_3 obtenidos en el paso 2 para obtener valores para los parámetros a_4 , a_5 y a_6 .
4. Ajustar la función completa de la Ecuación (9.1) simultáneamente a las regiones (a) y (c), con los valores iniciales de los parámetros a_4 a a_6 establecidos en los valores obtenidos en los pasos 2 y 3 para obtener nuevos valores de los parámetros a_1 a a_3 .

Si los parámetros continúan cambiando significativamente en cada iteración, el proceso puede repetirse desde el paso 2 según sea necesario. Alternativamente, puede ser suficiente omitir el paso 3 y ajustar todos los parámetros después del paso 2.

Al ajustar las funciones de pico y fondo sobre diferentes partes del espectro, es importante notar que la función completa $y(E)$ de la Ecuación (9.1) debe ajustarse a ambas regiones; es decir, en la región fuera del pico donde se está ajustando el fondo, el cálculo de la cola del pico debe incluirse, y debajo del pico, los términos de fondo deben incluirse.

Múltiples Picos

La separación de picos estrechamente espaciados es un problema importante en muchos campos de investigación. Aunque no debemos intentar extraer información de nuestros datos ordenándolos en intervalos más pequeños que las incertidumbres en nuestras mediciones, y no debemos usar anchos de intervalo tan estrechos que los números de eventos en los intervalos sean demasiado pequeños para satisfacer la estadística gaussiana, tampoco debemos errar en la otra dirección y arriesgarnos a suprimir detalles importantes. La selección de tamaños de intervalo óptimos es crítica. Para algunas muestras de datos, pueden ser apropiados diferentes anchos de intervalo para diferentes regiones de la muestra de datos.

Ejemplo 9.2. Hemos observado que, aunque la probabilidad del 4,4 % para el ajuste a los datos del Ejemplo 9.1 es bastante baja, podría ser aceptable. Sin embargo, debido a que los datos se representaron en intervalos bastante gruesos ($\Delta E = 0,1$ GeV), es posible que se haya suprimido algo de información. Para comprobarlo, representamos los datos en intervalos más pequeños ($\Delta E = 0,05$ GeV) como se ilustra en la Figura 9.2. (Nótese que al trazar la Figura 9.2 hemos eliminado algunos intervalos de los bordes inferior y superior del histograma para mejorar la visualización; los 60 intervalos están incluidos en los ajustes.)

Representado en intervalos más pequeños, el gran pico cerca de $E = 1,00$ GeV parece ser considerablemente más estrecho de lo indicado en la Figura 9.1. También hay una sugerencia de un posible exceso de eventos en el intervalo centrado en $E = 0,825$ GeV en el lado de baja energía del pico principal. Como lo ilustra la curva en la Figura 9.2, un ajuste de la ecuación de dos picos (9.13) a los datos de intervalo estrecho parece confirmar la existencia de un segundo pico. Para obtener este ajuste, elegimos como valores iniciales para la masa y el ancho del segundo pico, 0.825 y 0.05 GeV, respectivamente, sugeridos por el examen de la Figura 9.2.

$$y(E) = a_1 + a_2 E + a_3 E^2 + A_0 \frac{\Gamma_0/(2\pi)}{(E - E_0)^2 + (\Gamma_0/2)^2} + A_1 \frac{\Gamma/(2\pi)}{(E - E_1)^2 + (\Gamma/2)^2} \quad (9.13)$$

Los resultados del ajuste se enumeran en la columna 6 de la Tabla 9.1. La probabilidad de chi-cuadrado del 29,4 % para este ajuste es una mejora notable respecto al 4,4 % para el ajuste de un solo pico. El recuadro en la Figura 9.2 muestra la región del pico más pequeño con una curva calculada ajustando la ecuación de un solo pico (9.1) a toda la muestra de datos de la Figura 9.2. Los parámetros determinados en este ajuste se enumeran en la columna 5 de la Tabla 9.1.

Podemos estimar la significación estadística del pico más pequeño en el Ejemplo 9.2 contando el número total de eventos por encima del fondo de un solo pico (mostrado en el recuadro) y considerando si el exceso es consistente con una fluctuación estadística. Hay 102 eventos en el intervalo del pico sobre un fondo de 69.5 eventos, correspondiente a una fluctuación de $(102 - 69,5)/\sqrt{69,5} = 32,5/8,34 = 3,9$ desviaciones estándar en la señal de fondo. Refiriéndonos a la Tabla C.2, inferimos que hay una probabilidad de

$(1 - 0,99990) = 0,00010$, o 0,01 %, de que obtengamos un resultado tan grande o mayor a partir de una fluctuación estadística. Por lo tanto, el pico más pequeño parece estar muy bien establecido.

Pero debemos esperar antes de apresurarnos a publicar; nuestro análisis no ha terminado. Calculamos la probabilidad de encontrar una fluctuación de 3.9 desviaciones estándar en un intervalo particular. Sin embargo, hay 60 intervalos en esta muestra de datos, y la fluctuación podría haber aparecido en cualquiera de ellos. La probabilidad de que una fluctuación de 3.9 desviaciones estándar no aparezca en ninguno de los 60 intervalos es $0,9999^{60}$, por lo que la probabilidad de observar la fluctuación en cualquiera de los intervalos es $1 - 0,9999^{60} \sim 0,6\%$. Esta probabilidad es lo suficientemente baja como para darnos una confianza considerable de que el pico más pequeño no es una fluctuación. Si tuviéramos alguna razón a priori, como una predicción teórica o evidencia de otro experimento, para creer que el pico más pequeño debería ubicarse en la región de energía particular donde aparece, entonces el argumento en contra de una fluctuación estadística sería aún más convincente.

Si bien parece haber un fuerte apoyo estadístico para un segundo pico en los datos del Ejemplo 9.2, ese apoyo depende en gran medida de nuestra comprensión de las contribuciones en la región del segundo pico a partir de la distribución de fondo suave y la cola del pico grande. Si, por ejemplo, las cuentas de fondo fueran un 10 % más altas, disminuyendo el exceso en un 10 %, la fluctuación disminuiría de 3.9 a 2.9 desviaciones estándar y la probabilidad de una fluctuación de esta magnitud en cualquier intervalo aumentaría de aproximadamente 1 % a 20 %, un número considerablemente menos convincente.

¿Hay más pruebas que podamos hacer en nuestra muestra de datos para ayudarnos a comprender la importancia de nuestro resultado? Para problemas como este, donde la significación estadística de un resultado puede estar en duda, el método de Monte Carlo (Capítulo 5) proporciona una herramienta poderosa para un examen más detallado. Utilizaremos esta técnica en el Capítulo 11 para hacer una prueba estadística simple de estos datos. Un programa completo de Monte Carlo, que incorpora todos los detalles conocidos o estimados involucrados en la creación de la muestra de datos, es invaluable en la planificación y análisis de un experimento serio.

Resumen

- **Sustracción de fondo:**

$$y_P(x) = y(x) - y_b(x) \quad (y_P \rightarrow \text{pico}; y_b \rightarrow \text{fondo})$$

- **Incertidumbre en el área del pico:**

$$\sigma_{A_P}^2 = \sigma_A^2 + \sigma_{A_b}^2 \quad (\simeq A + A_B \text{ para estadística de Poisson})$$

- **Área bajo la curva de pico ajustada:**

$$A_P = \int_{-\infty}^{+\infty} y_P(x) dx$$

- **Discrepancia en el área bajo una curva con estadística de Poisson:**

$$\chi_{\min}^2 = \sum \left[\frac{y_i}{\sigma_i^2} (y_i - y(x_i)) \right] \simeq \text{area}(\text{datos}) - \text{area}(\text{ajuste})$$

Ejercicios

Ejercicio 9.1

Los siguientes datos se extraen de la distribución de fondo ilustrada por la curva discontinua en la Figura 9.1. Los puntos de datos corresponden a los números de cuentas en 15 intervalos de histograma, que son de 0.2 GeV de ancho, cada uno centrado en el valor indicado de E .

E (GeV)	0.1	0.3	0.5	0.7	0.9	1.1	1.3	1.5	1.7	1.9	2.1	2.3	2.5	2.7
N	4	30	49	71	87	91	120	136	147	133	130	118	142	122

Trace un gráfico de los datos. Utilice una técnica de ajuste lineal, como las descritas en el Capítulo 7, para ajustar un polinomio de segundo orden a estos datos. Suponga incertidumbres estadísticas en las cuentas. Compare el número de eventos en el histograma con el número determinado por el ajuste. ¿Es la diferencia consistente con la predicción de la Ecuación (9.10)?

Solución: Primero, calculamos el número total de eventos en el histograma: $4 + 30 + 49 + 71 + 87 + 91 + 120 + 136 + 147 + 133 + 130 + 118 + 142 + 122 =$ sumamos: $4+30=34$, $+49=83$, $+71=154$, $+87=241$, $+91=332$, $+120=452$, $+136=588$, $+147=735$, $+133=868$, $+130=998$, $+118=1116$, $+142=1258$, $+122=1380$. Total 1380 eventos.

Ajustamos un polinomio de segundo grado $y = a_0 + a_1 E + a_2 E^2$ con incertidumbres $\sigma_i = \sqrt{N_i}$. Usamos mínimos cuadrados ponderados. Calculamos las sumas necesarias con los pesos $w_i = 1/N_i$. Los cálculos son tediosos pero se pueden hacer con una hoja de cálculo. Después del ajuste, obtenemos los valores ajustados $\hat{N}_i$. La suma de los valores ajustados es el área bajo la curva de ajuste. La diferencia con 1380 debe ser aproximadamente χ^2 del ajuste. La Ecuación (9.10) predice que la diferencia es $\chi_{\min}^2$. Por lo tanto, se compara la diferencia con el valor de χ^2 obtenido.

Ejercicio 9.2

Encuentre el área del pico en la Figura 9.1 contando el área entre las líneas punteadas verticales y restando el fondo estimado. Refiérase a los datos en el Ejercicio 9.4. Estime la corrección para las colas. Estime la incertidumbre en su determinación del área.

Solución: El rango entre las líneas punteadas es de $E_0 - 2\Gamma$ a $E_0 + 2\Gamma$. A partir de los parámetros del ajuste, $E_0 \approx 1,0$ GeV, $\Gamma \approx 0,1$ GeV (de la Tabla 9.1, columna 4, $\Gamma = 0,197$ para el ajuste de seis parámetros, pero en la Figura 9.1 probablemente sea otro valor). Usaremos $\Gamma = 0,1$ para este cálculo. El rango es de 0.8 a 1.2 GeV. Los datos del Ejercicio 9.4 proporcionan las cuentas en intervalos de 0.05 GeV. Sumamos las cuentas en ese rango y restamos el fondo estimado (integral del polinomio de fondo en ese rango). La corrección para las colas (fuera de $\pm 2\Gamma$) se puede estimar integrando la función lorentziana desde $-\infty$ hasta $E_0 - 2\Gamma$ y desde $E_0 + 2\Gamma$ hasta ∞ . Para una lorentziana, el área en las colas más allá de 2Γ es aproximadamente el 10 % del total. La incertidumbre se estima por propagación de errores.

Ejercicio 9.3

Refiérase a los datos del Ejercicio 8.6. Ajuste el histograma mediante el método descrito en la Sección 9.3 con ajustes separados del polinomio de fondo de segundo orden a las regiones fuera del pico y de la función gaussiana a la región del pico.

Solución: Los datos del Ejercicio 8.6 tienen un pico alrededor de $x = 16 - 17$. Se identifican las regiones fuera del pico, por ejemplo, $x \leq 14$ y $x \geq 19$ (dependiendo de los datos). Se ajusta un polinomio cuadrático a esas regiones para obtener el fondo. Luego se resta el fondo de todos los datos, y en la región del pico (por ejemplo, $x = 15 - 18$) se ajusta una gaussiana a los datos de diferencia. Se comparan los parámetros con los obtenidos en el ajuste global del Ejercicio 8.6.

Ejercicio 9.4

La tabla adjunta enumera los números de eventos en los intervalos del histograma del Ejemplo 9.1 desde $E = 0,0$ hasta $3,0$ GeV en pasos de 0.05 GeV.

(Los datos son una larga lista de números. Se proporcionan en el texto original. Aquí los reproducimos aproximadamente:)

E (GeV)	0.0	0.05	0.10	...	3.0																								
N	7	2	6	12	15	18	31	29	27	41	35	37	37	63	71	102	95	115	202	190	113	86	68	74	79	85	87	68	70
79	85	87	68	70	89	77	70	71	62	85	62	73	70	59	61	77	61	62	73	67	71	75	66	73	79	85	87	68	70

(Nota: la lista parece tener más de 60 números. Se deben contar correctamente.)

- Ajuste la Ecuación (9.1) a los datos para obtener los parámetros para esta distribución. Compare con los valores de los parámetros enumerados en la columna 5 de la Tabla 9.1.
- Repita el ajuste con intervalos adyacentes fusionados (es decir, combine los intervalos 1 y 2, los intervalos 3 y 4, etc.) y observe el efecto sobre el valor de χ^2 , la determinación del área del pico y la determinación de la media y el semiancho del pico. Suponga incertidumbres estadísticas.

Solución:

- Se realiza un ajuste no lineal de 6 parámetros usando el método de Marquardt. Los datos tienen incertidumbres $\sigma_i = \sqrt{N_i}$. Se obtienen los parámetros y se comparan con los de la Tabla 9.1 (columna 5, que son para el ajuste de un solo pico con intervalos de 0.05 GeV). Deberían ser similares.
- Al fusionar intervalos, los nuevos anchos son de 0.1 GeV. Se suman las cuentas de dos intervalos adyacentes y las incertidumbres se combinan en cuadratura: $\sigma_{\text{nuevo}} = \sqrt{N_i + N_{i+1}}$. Se repite el ajuste. Se espera que χ^2 disminuya (menos puntos) y que los parámetros sean más estables, pero con menor resolución.

Capítulo 10: Aplicación Directa del Método de Máxima Verosimilitud

El método de mínimos cuadrados es una herramienta poderosa para extraer parámetros de datos experimentales. Sin embargo, antes de que se pueda realizar un ajuste por mínimos cuadrados a un conjunto de datos que consiste en mediciones o eventos individuales, los eventos deben clasificarse en un histograma, lo que puede oscurecer alguna

estructura detallada en los datos. Debido a que el método de mínimos cuadrados se derivó del principio de máxima verosimilitud, podría ser mejor en algunos casos utilizar el método de máxima verosimilitud directamente para comparar datos experimentales con predicciones teóricas, sin la necesidad de agrupar los datos en histogramas con la consiguiente pérdida de información.

Ya hemos utilizado el método en el Capítulo 4 para encontrar estimaciones de la media y la desviación estándar de datos obtenidos en mediciones repetidas de una sola variable, donde hemos supuesto que las mediciones se distribuyen según la probabilidad gaussiana. Ahora, extendemos el método a otras funciones de distribución y a ajustes multiparamétricos. Los métodos de máxima verosimilitud pueden aplicarse directamente a muchos problemas de "ajuste de curvas", y dicho ajuste es casi tan fácil de usar como el método de mínimos cuadrados, y considerablemente más flexible. Sin embargo, el método de máxima verosimilitud directo requiere cálculos para cada evento medido, en lugar de para cada intervalo de histograma como en el ajuste por mínimos cuadrados, y por lo tanto la técnica puede ser demasiado lenta para muestras de datos muy grandes.

Los cálculos de máxima verosimilitud directa tienen una ventaja sobre el método de mínimos cuadrados para dos tipos particulares de problemas: (1) experimentos de baja estadística con datos insuficientes para satisfacer el requisito de estadística gaussiana para intervalos de histograma individuales, y (2) experimentos en los que la función de ajuste corresponde a una función de densidad de probabilidad diferente para cada evento medido, de modo que agrupar los datos conduce a una reducción de la información y una pérdida de sensibilidad en la determinación de los parámetros. Si el conjunto de datos es suficientemente grande, entonces el método de mínimos cuadrados puede aplicarse a problemas de cualquiera de los dos tipos, y ese método es generalmente preferido en vista de su menor requerimiento de cálculo. En cualquier caso, no es posible extraer más que la información mínima de un conjunto de datos muy pequeño, por lo que debemos esperar que el método de máxima verosimilitud directa sea más útil para problemas intermedios con muestras de datos modestas.

10.1 Introducción a la Máxima Verosimilitud

El procedimiento básico de máxima verosimilitud es relativamente simple. Supongamos que tenemos una colección de N eventos correspondientes a la medición de una variable independiente x_i y una variable dependiente y_i , donde i va de 1 a N . Deseamos obtener los parámetros, $a_1, a_2, \dots, a_m$, de una función de ajuste $y(x_i) = y(x_i; a_1, a_2, \dots, a_m)$ a partir de estos datos. Para cada evento, convertimos $y(x_i)$ en una función de densidad de probabilidad normalizada

$$P_i = P(x_i; a_1, a_2, \dots, a_m) \quad (10.1)$$

evaluada en el valor observado x_i . La función de verosimilitud $\mathcal{L}(a_1, a_2, \dots, a_m)$ es el producto de las densidades de probabilidad individuales

$$\mathcal{L}(a_1, a_2, \dots, a_m) = \prod_{i=1}^N P_i \quad (10.2)$$

y los valores de máxima verosimilitud de los parámetros se obtienen maximizando $\mathcal{L}(a_1, a_2, \dots, a_m)$ con respecto a los parámetros.

En muchos experimentos, la función de densidad de probabilidad P_i estará compuesta por dos componentes: un factor teórico correspondiente al principio subyacente que se está probando y un factor experimental correspondiente a los sesgos introducidos por las condiciones experimentales.

Ejemplo 10.1. En el Ejemplo 5.7 presentamos un programa de Monte Carlo para estudiar los sesgos que podrían surgir en un experimento para medir la vida media del mesón K_S^0 de vida corta (o kaón). El ejemplo incluye detalles del experimento y la Figura 5.4 ilustra esquemáticamente el aparato experimental.

En resumen, el experimento implica medir la distancia entre el punto de producción y el punto de desintegración del kaón, determinar la velocidad del mesón y calcular el tiempo de vuelo del mesón desde la producción hasta la desintegración. Después de la corrección por el sesgo introducido por el tamaño finito del aparato experimental, la vida media del kaón podría determinarse a partir de mediciones de muchos de estos eventos.

El rectángulo discontinuo en la Figura 5.4 indica la región en la que se recolectan los eventos, la región fiducial para el experimento. Seleccionamos vértices de desintegración solo dentro de esta región para asegurar mediciones precisas tanto de la separación de los dos vértices como de las trayectorias de las partículas secundarias de la desintegración del kaón. Estas últimas mediciones determinan el momento, y por lo tanto la velocidad, del kaón. La pérdida de eventos que no caen dentro de la región fiducial sesga el cálculo final de la vida media y, por lo tanto, debemos comprender los sesgos y hacer correcciones.

En los siguientes ejemplos, suponemos que se han determinado las coordenadas de los dos vértices y la magnitud del momento del kaón en desintegración.

Utilizamos el programa de Monte Carlo del Ejemplo 5.7, con la vida media del kaón establecida en su valor nominal de $\tau_K = 0,894 \times 10^{-10}$ s, para generar 40,000 eventos con el fin de estudiar la eficiencia del detector con una precisión razonablemente alta. Es importante que las incertidumbres estadísticas introducidas en la determinación de la función de eficiencia sean despreciables en comparación con las incertidumbres estadísticas y de otro tipo en el experimento real. La distribución de los 23,565 eventos generados que sobrevivieron a los cortes fiduciales se muestra como cruces en la Figura 10.1, con la distribución exponencial esperada de la muestra total de 40,000 eventos mostrada como una curva suave.

En la Figura 10.2 hemos representado la eficiencia resultante en función de los tiempos de vuelo de los kaones (el tiempo propio) en sus sistemas de reposo individuales, con la función de eficiencia definida como la relación de eventos observados a eventos esperados [o la relación punto por punto $\epsilon(T) = N'(T)/N(T)$] a partir de la Ecuación (5.31). La línea punteada en la Figura 10.2 ilustra la región sobre la cual la eficiencia puede suponerse razonablemente como 100 %.

También utilizamos el programa de Monte Carlo, con diferentes semillas de números aleatorios y el mismo valor nominal de τ_K , para generar un pequeño “conjunto de datos” de 1000 eventos, de los cuales 598 sobrevivieron al corte fiducial, para usar en la prueba de nuestros procedimientos de análisis.

Discutiremos varios aspectos del análisis de tales datos en los siguientes ejemplos.

Ejemplo 10.1a: Método de Mínimos Cuadrados La Figura 10.3 muestra en un gráfico semilogarítmico la distribución, como cruces (x), de los 598 eventos que sobrevivieron a los cortes fiduciales de la muestra total de 1000 eventos generados en el Ejemplo 10.1. La línea recta muestra la distribución esperada si no hubiera habido pérdidas de eficiencia. Para extraer la vida media del kaón de estos datos, aplicamos la función de eficiencia ilustrada en la Figura 10.2 para corregir las pérdidas. Los puntos de datos corregidos se representan en la Figura 10.3 como puntos de datos con barras de error verticales correspondientes a las incertidumbres estadísticas en los datos, escaladas por el factor de eficiencia. (Las incertidumbres en el factor de corrección fueron despreciables). Se supuso que la eficiencia era del 100 % en la región indicada por la línea punteada horizontal en la Figura 10.2. Las barras de error muy grandes en los puntos “corregidos” en los dos extremos del gráfico resultan de escalar puntos de datos de baja estadística e ilustran el problema de usar datos en regiones de baja eficiencia. Generalmente, es aconsejable eliminar de la muestra los puntos que requieren correcciones tan grandes, porque contribuyen poco al resultado general y dependen en gran medida de las correcciones.

A partir de la pendiente lineal del gráfico logarítmico, ilustrada por la línea recta a través de los puntos de datos, obtenemos una vida media “experimental” $\tau = (0,925 \pm 0,058) \times 10^{-10}$ s. Alternativamente, podríamos haber utilizado una técnica de ajuste no lineal por mínimos cuadrados para determinar τ directamente a partir de un gráfico lineal de los datos.

Máxima Verosimilitud Directa

La mayoría de los experimentos reales son más complejos y tienen funciones de eficiencia que son considerablemente más complicadas que la ilustrada por nuestro ejemplo. Para tales problemas, la aplicación de la máxima verosimilitud directa puede ser el método preferible para encontrar la mejor estimación de los parámetros. Para aplicar este método, debemos definir una función de probabilidad para cada evento registrado.

La probabilidad de observar un solo evento que sobrevive durante un tiempo t_i es

$$P_i = A_i p(t_i; \tau) \quad (10.3)$$

El primer factor A_i representa la eficiencia de detección, o probabilidad de que la partícula se desintegre dentro de un volumen fiducial predefinido dentro de nuestro aparato, de modo que se pueda realizar una medición satisfactoria de su tiempo de vuelo. Este factor depende de las coordenadas de los vértices de producción y desintegración de la partícula en desintegración, su vector de momento y la geometría del volumen fiducial. El segundo factor $p(t_i; \tau)$ es proporcional a la probabilidad de que una partícula con vida media τ se desintegre entre el tiempo t_i y $t_i + dt$ y, por lo tanto, es proporcional a $e^{-t/\tau}$. La Ecuación (10.3) se convierte en

$$P_i = A_i e^{-t_i/\tau} \quad (10.4)$$

Podría parecer que los dos factores en la Ecuación (10.3) son independientes, de modo que el factor de eficiencia de detección es independiente de la probabilidad de desintegra-

ción, pero, como hemos observado en el ejemplo anterior, esto no es generalmente cierto. Debido al tamaño finito de nuestro aparato de medición, podemos perder preferentemente eventos que sobreviven durante tiempos muy cortos, de modo que no podemos hacer mediciones precisas de sus trayectorias de vuelo, así como aquellos que sobreviven durante tiempos muy largos y, por lo tanto, se desintegran fuera de los límites aceptables de nuestros detectores. Las pérdidas de ambos tipos dependen de la vida media que estamos intentando determinar, la “ τ ” en el segundo factor de la Ecuación (10.3). Para cada partícula que se observa que se desintegra dentro del aparato, podemos definir una longitud de trayectoria potencial como la distancia que recorrería si no se hubiera desintegrado. Debido a que cada partícula en desintegración tiene una longitud de trayectoria potencial diferente, debemos calcular factores geométricos para corregir aquellas partículas que se desintegran fuera del detector. Los factores de corrección dependerán de los parámetros y serán una función de las coordenadas de producción y desintegración y los vectores de momento de cada partícula en desintegración. Claramente, un elemento de un buen diseño experimental debería ser minimizar la dependencia de estos factores de corrección geométrica de los parámetros buscados en el experimento.

Normalización para la Máxima Verosimilitud

El factor A_i en la Ecuación (10.4) corresponde a una normalización para cada medición para asegurar la probabilidad unitaria de observar en este experimento cualquier evento que tenga la vida media, coordenadas y cinemática de la partícula en desintegración observada. Para determinar el factor de normalización A_i nos referimos a la Figura 5.4 y consideramos el volumen fiducial de nuestro aparato, indicado por el rectángulo discontinuo. A partir de las coordenadas de producción y el vector de momento de cada partícula, podemos determinar la distancia mínima d_1 que la partícula debe viajar para entrar en la región y la distancia máxima d_2 que puede viajar antes de salir de la región. (Podemos, por supuesto, observar algunos eventos fuera del volumen fiducial, pero los rechazamos porque no pueden medirse con precisión). Estas distancias mínima y máxima d_1 y d_2 deben convertirse en tiempos de vuelo t_1 y t_2 en el sistema de reposo de las partículas en desintegración, y los factores de normalización A_i pueden entonces determinarse a partir de la condición

$$\int_{t_1}^{t_2} P_i dt_i = A_i \int_{t_1}^{t_2} e^{-t_i/\tau} dt_i = 1 \quad (10.5)$$

Con esta normalización, la probabilidad de evento individual P_i de la Ecuación (10.4) se convierte en la densidad de probabilidad para observar un solo evento. La probabilidad conjunta normalizada o la función de verosimilitud para observar N tales eventos en nuestro experimento es simplemente el producto de las funciones de probabilidad individuales:

$$\mathcal{L}(\tau) = \prod_{i=1}^N P_i = \prod_{i=1}^N A_i e^{-t_i/\tau} \quad (10.6)$$

Búsqueda de Parámetros

Nuestro objetivo es encontrar el valor del parámetro τ que maximiza esta función de verosimilitud. Debido a que la probabilidad de observar cualquier evento particular es menor que 1, el producto de un gran número de tales probabilidades (una para cada evento

medido) puede ser un número muy pequeño y puede, de hecho, ser demasiado pequeño para que la computadora lo maneje. Para evitar problemas, generalmente es preferible maximizar el logaritmo de la función de verosimilitud

$$M = \ln \mathcal{L} \quad (10.7)$$

en lugar de la propia función de verosimilitud, de modo que el producto de la Ecuación (10.6) se convierta en una suma. Los logaritmos deben ser números razonables y negativos. Para nuestro ejemplo particular, el logaritmo de la función de verosimilitud de la Ecuación (10.6) viene dado por

$$M(\tau) = \ln[\mathcal{L}(\tau)] = \sum \left[\ln A_i - \frac{t_i}{\tau} \right] \quad (10.8)$$

con A_i definido por la Ecuación (10.5). Nótese que A_i es una función del parámetro desconocido τ , así como de las coordenadas de producción, el vector de momento y el volumen fiducial, y debe calcularse por separado para cada evento, y para cada valor de prueba de τ .

En general, este problema, como el problema de ajuste no lineal por mínimos cuadrados correspondiente, no puede resolverse en forma cerrada. Sin embargo, tanto el método de búsqueda en malla como el de búsqueda por gradiente para minimizar la función χ^2 discutidos en el Capítulo 8 pueden adaptarse directamente. Solo es necesario buscar un máximo de M (o un valor mínimo de $-M$) con las mismas rutinas que usamos en el Capítulo 8 para encontrar un mínimo de χ^2 .

Podemos notar una correspondencia entre la cantidad $M(\tau)$, determinada en la Ecuación (10.7) a partir de la función de verosimilitud para eventos individuales, y el parámetro de bondad de ajuste χ^2 , determinado por la Ecuación (8.7) a partir de la función de verosimilitud $P(a)$ para datos agrupados:

$$\chi^2 = -2 \ln[\mathcal{L}(\tau)] + \text{constante} \quad (10.9)$$

En el límite de un gran número de eventos, los dos métodos deben producir el mismo valor τ' para la estimación de máxima verosimilitud del parámetro τ . En ambos casos, la función de verosimilitud será una función gaussiana del parámetro cerca del valor óptimo

$$\mathcal{L}(\tau) \propto \exp \left(-\frac{(\tau - \tau')^2}{2\sigma^2} \right) \quad (10.10)$$

por lo que podemos esperar que $M(\tau)$, al igual que $\chi^2(\tau)$, varíe cuadráticamente con el parámetro τ en las proximidades de τ' .

Ejemplo 10.1b. Consideremos la forma más simple de este problema. Supongamos que la vida media desconocida es suficientemente corta para que nuestro aparato sea lo suficientemente grande como para incluir muchas vidas medias y, por lo tanto, la pérdida de partículas que se desintegran en tiempos muy largos es despreciable. Supongamos también que nuestro equipo puede detectar partículas en tiempos muy cortos así como en tiempos muy largos. Entonces los límites en la integral de normalización de la Ecuación (10.5) se convierten en $t_1 = 0$ y $t_2 = \infty$ y A_i es el mismo para cada evento y viene dado por $A_i = 1/\tau$. La función de verosimilitud se convierte en

$$\mathcal{L}(\tau) = \prod A_i e^{-t_i/\tau} = \prod \frac{e^{-t_i/\tau}}{\tau} \quad (10.11)$$

con logaritmo

$$M(\tau) = \ln[\mathcal{L}(\tau)] = -\frac{1}{\tau} \sum t_i - N \ln \tau \quad (10.12)$$

Podemos obtener el máximo de la Ecuación (10.12) tomando la derivada de $M(\tau)$ con respecto a τ y estableciéndola en 0:

$$\frac{dM}{d\tau} = \frac{d}{d\tau} \left[-\frac{1}{\tau} \sum t_i - N \ln \tau \right] = \frac{1}{\tau^2} \sum t_i - \frac{N}{\tau} = 0 \quad (10.13)$$

La solución es $\tau = \sum t_i / N$; es decir, la estimación de máxima verosimilitud de la vida media es simplemente la media de las mediciones de vida individuales. Habríamos llegado al mismo resultado si hubiéramos encontrado el máximo de $\mathcal{L}(\tau)$ a partir de la Ecuación (10.11).

Ejemplo 10.1c. Supongamos que repetimos el experimento, pero con una resolución experimental más pobre, de modo que no podemos distinguir el vértice de desintegración (x_2, y_2, z_2) del vértice de creación (x_1, y_1, z_1) a menos que estén separados por una distancia d_1 . Por simplicidad, suponemos que las partículas en desintegración se producen todas con la misma velocidad, de modo que el límite inferior de distancia d_1 se traduce en el mismo límite inferior de tiempo t_1 para todos los eventos. (En un experimento real, por supuesto, las partículas en desintegración se producirían con varias velocidades, de modo que el tiempo de corte inferior calculado t_1 variaría de un evento a otro.)

Para este ejemplo, la integral de normalización de la Ecuación (10.5) se convierte en

$$A_i \int_{t_1}^{\infty} e^{-t_i/\tau} dt_i = 1 \quad (10.14)$$

lo que da

$$A_i = \frac{e^{t_1/\tau}}{\tau} \quad (10.15)$$

La función de verosimilitud se convierte en

$$\mathcal{L}(\tau) = \prod_{i=1}^N A_i e^{-t_i/\tau} = \prod_{i=1}^N \frac{e^{t_1/\tau}}{\tau} e^{-t_i/\tau} = \prod_{i=1}^N \frac{e^{(t_1-t_i)/\tau}}{\tau} \quad (10.16)$$

con logaritmo

$$M(\tau) = \ln \mathcal{L}(\tau) = \frac{N t_1}{\tau} - \frac{1}{\tau} \sum t_i - N \ln \tau \quad (10.17)$$

Maximizando con respecto a τ ,

$$\frac{dM}{d\tau} = -\frac{Nt_1}{\tau^2} + \frac{\sum t_i}{\tau^2} - \frac{N}{\tau} = 0 \quad (10.18)$$

o

$$\tau = \frac{\sum t_i - Nt_1}{N} = \bar{t} - t_1 \quad (10.19)$$

Por lo tanto, la estimación de máxima verosimilitud de la vida media se obtiene restando el tiempo de corte inferior t_1 de la media de los tiempos medidos.

Ejemplo 10.1d. En la situación más general, donde cada evento tiene sus propios límites superior e inferior t_{1i} y t_{2i} , la función de verosimilitud es

$$\mathcal{L}(\tau) = \prod_{i=1}^N \frac{e^{-t_i/\tau}}{\tau (e^{-t_{1i}/\tau} - e^{-t_{2i}/\tau})} \quad (10.20)$$

El logaritmo de la verosimilitud es

$$M(\tau) = -\frac{1}{\tau} \sum t_i - N \ln \tau - \sum \ln (e^{-t_{1i}/\tau} - e^{-t_{2i}/\tau}) \quad (10.21)$$

Esta función debe maximizarse numéricamente para encontrar τ .

Búsqueda del Máximo de Verosimilitud

En la práctica, para problemas de máxima verosimilitud directa, a menudo es más conveniente trabajar con el logaritmo de la verosimilitud, M , y buscar su máximo utilizando técnicas similares a las de la minimización de χ^2 . Dado que M es una función de los parámetros, podemos usar los mismos métodos de búsqueda en malla, gradiente o Marquardt, pero cambiando el signo para maximizar en lugar de minimizar.

Una consideración importante es que la función de verosimilitud puede tener una forma que no es parabólica cerca del máximo, especialmente para muestras pequeñas. En tales casos, la estimación de las incertidumbres a partir de la segunda derivada puede no ser precisa. Un método más robusto es encontrar el intervalo de parámetros para el cual M disminuye en una cantidad determinada, por ejemplo, 0.5 para un intervalo de confianza del 68 % (ya que $-2 \ln \mathcal{L}$ se comporta como χ^2).

10.2 Ejemplo por Computadora

Ejemplo 10.2. Implementemos el método de máxima verosimilitud para el problema de la vida media del kaón con cortes fiduciales. Generamos un conjunto de datos de 1000 eventos usando el programa de Monte Carlo del Ejemplo 5.7. Para cada evento, conocemos el tiempo de vida t_i en el sistema de reposo, y los tiempos de corte t_{1i} y t_{2i} calculados a partir de la geometría. La función de verosimilitud es la de la Ecuación (10.20). Buscamos el valor de τ que maximiza $M(\tau)$.

Podemos usar una búsqueda unidimensional en τ . Calculamos $M(\tau)$ para una serie de valores de τ alrededor del valor nominal. Ajustamos una parábola a los puntos cercanos al máximo para estimar el mejor valor y su incertidumbre. La incertidumbre se estima a partir del cambio en τ que reduce M en 0.5 desde el máximo (para un parámetro, el intervalo de confianza del 68 % corresponde a $\Delta M = 0,5$).

Resumen

- **Método de máxima verosimilitud:** Los parámetros se estiman maximizando la función de verosimilitud

$$\mathcal{L}(a_1, \dots, a_m) = \prod_{i=1}^N P(x_i; a_1, \dots, a_m)$$

donde P es la densidad de probabilidad de los datos.

- **Log-verosimilitud:** $M = \ln \mathcal{L}$. Maximizar M es equivalente a maximizar $\mathcal{L}$.
- **Relación con χ^2 :** Para datos gaussianos, $-2 \ln \mathcal{L} = \chi^2 + \text{constante}$.
- **Incertidumbres:** Para un parámetro, el intervalo de confianza del 68 % corresponde a un cambio de 0.5 en M desde el máximo. Para varios parámetros, se utiliza la matriz de información de Fisher.
- **Ventajas:** No requiere agrupar los datos; maneja naturalmente eficiencias dependientes del evento; funciona bien con muestras pequeñas.
- **Desventajas:** Puede ser computacionalmente intensivo; requiere una función de probabilidad bien definida para cada evento.

Ejercicios

Ejercicio 10.1

Derive la función de verosimilitud para el ajuste de una línea recta $y = a + bx$ a puntos (x_i, y_i) con incertidumbres gaussianas σ_i en y . Demuestre que maximizar la verosimilitud es equivalente a minimizar χ^2 .

Solución: Para cada punto, la probabilidad es

$$P_i = \frac{1}{\sigma_i \sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{y_i - a - bx_i}{\sigma_i} \right)^2 \right]$$

La verosimilitud es $\mathcal{L} = \prod P_i$. Tomando logaritmo,

$$\ln \mathcal{L} = -\frac{1}{2} \sum \left(\frac{y_i - a - bx_i}{\sigma_i} \right)^2 + \text{constante}$$

Maximizar $\ln \mathcal{L}$ es equivalente a minimizar la suma de cuadrados, que es χ^2 .

Ejercicio 10.2

Para los datos del Ejemplo 10.1b (sin cortes), demuestre que la estimación de máxima verosimilitud de τ es la media de los tiempos, y que la varianza de esta estimación es τ^2/N .

Solución: De la Ecuación (10.12), $M = -N \ln \tau - \sum t_i/\tau$. Derivando e igualando a cero: $-N/\tau + \sum t_i/\tau^2 = 0 \Rightarrow \tau = \sum t_i/N$. La segunda derivada es $d^2M/d\tau^2 = N/\tau^2 - 2\sum t_i/\tau^3$. En el óptimo, $\sum t_i = N\tau$, entonces $d^2M/d\tau^2 = N/\tau^2 - 2N\tau/\tau^3 = -N/\tau^2$. Por lo tanto, la varianza de τ es el inverso de la información de Fisher: $\sigma_\tau^2 = -1/(d^2M/d\tau^2) = \tau^2/N$.

Ejercicio 10.3

Para el Ejemplo 10.1c, derive la expresión para la incertidumbre en τ .

Solución: De la Ecuación (10.19), $\tau = \bar{t} - t_1$. La varianza de $\bar{t}$ es $\sigma_{\bar{t}}^2/N$. Por lo tanto, $\sigma_\tau^2 = \sigma_{\bar{t}}^2/N$. Pero $\sigma_{\bar{t}}^2$ es la varianza de los tiempos individuales. En el límite de grandes N , $\sigma_{\bar{t}}^2 \approx \tau^2$ (para una distribución exponencial). Entonces $\sigma_\tau \approx \tau/\sqrt{N}$.

Ejercicio 10.4

Escriba un programa de computadora para generar N eventos a partir de una distribución exponencial con vida media $\tau = 1,0$, y luego estime τ usando el método de máxima verosimilitud. Compare la distribución de las estimaciones para diferentes N (por ejemplo, $N = 10, 100, 1000$) con la predicción teórica de que $\hat{\tau}$ está distribuido alrededor de τ con desviación estándar $\tau/\sqrt{N}$.

Solución: Se genera una muestra de N números exponenciales usando $t = -\tau \ln r$ con r uniforme. Se calcula la media muestral $\hat{\tau}$. Se repite muchas veces y se construye un histograma de $\hat{\tau}$. La desviación estándar de los $\hat{\tau}$ debe aproximarse a $1/\sqrt{N}$.

Ejercicio 10.5

En el experimento del kaón, suponga que los límites fiduciales son tales que $t_{1i} = 0,2$ y $t_{2i} = 4,0$ para todos los eventos (en unidades de 10^{-10} s). Genere 100 eventos a partir de una distribución exponencial con $\tau = 0,9$, pero solo acepte aquellos con $0,2 < t < 4,0$. Estime τ usando máxima verosimilitud con la función de verosimilitud truncada. Compare con la estimación ingenua de la media de los tiempos aceptados.

Solución: La función de verosimilitud para datos truncados es $\mathcal{L} = \prod \frac{e^{-t_i/\tau}}{\tau(e^{-0,2/\tau} - e^{-4,0/\tau})}$. Se maximiza numéricamente. La media de los tiempos aceptados estará sesgada hacia abajo porque se pierden eventos cortos y largos. La estimación de máxima verosimilitud corrige este sesgo.

Ejercicio 10.6

Derive la función de verosimilitud para el ajuste de una gaussiana a datos, con media μ y desviación estándar σ desconocidas. Demuestre que las estimaciones de máxima verosimilitud son $\hat{\mu} = \bar{x}$ y $\hat{\sigma}^2 = \frac{1}{N} \sum (x_i - \bar{x})^2$ (sin el factor $N - 1$).

Solución: Para una muestra iid de una gaussiana,

$$\mathcal{L} = \prod \frac{1}{\sigma\sqrt{2\pi}} e^{-(x_i - \mu)^2/(2\sigma^2)} = (2\pi\sigma^2)^{-N/2} e^{-\sum (x_i - \mu)^2/(2\sigma^2)}$$

Tomando logaritmo,

$$\ln \mathcal{L} = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2$$

Derivando respecto a μ : $\frac{\partial}{\partial \mu} \sum (x_i - \mu)^2 = -2 \sum (x_i - \mu) = 0 \Rightarrow \mu = \bar{x}$. Derivando respecto a σ^2 : $\frac{\partial}{\partial \sigma^2} \ln \mathcal{L} = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2 = 0 \Rightarrow \sigma^2 = \frac{1}{N} \sum (x_i - \mu)^2$. Nótese que esta es la varianza muestral con divisor N , no $N - 1$. Por lo tanto, la estimación de máxima verosimilitud de la varianza está sesgada.

Capítulo 11: Pruebas del Ajuste

11.1 Prueba de χ^2 para la Bondad del Ajuste

En los capítulos anteriores hemos utilizado el parámetro χ^2 como una medida de la bondad del ajuste entre los datos y una función teórica. En esta sección, profundizaremos en la interpretación de χ^2 y cómo puede usarse para probar si un modelo teórico proporciona una descripción adecuada de los datos.

Recordemos la definición de χ^2 para un ajuste:

$$\chi^2 = \sum_{i=1}^N \left(\frac{y_i - y(x_i; \mathbf{a})}{\sigma_i} \right)^2 \quad (11.1)$$

donde y_i son los puntos de datos, $y(x_i; \mathbf{a})$ son los valores predichos por el modelo con parámetros $\mathbf{a}$, y σ_i son las incertidumbres en y_i . Si el modelo es correcto y las incertidumbres están bien estimadas, entonces el valor esperado de χ^2 es igual al número de grados de libertad $\nu = N - m$, donde m es el número de parámetros ajustados. Además, la distribución de χ^2 alrededor de este valor esperado está dada por la función de densidad de probabilidad de χ^2 .

La probabilidad de obtener un valor de χ^2 mayor o igual que un valor observado χ_{obs}^2 se denomina valor p o probabilidad de χ^2 :

$$p = P(\chi^2 \geq \chi_{\text{obs}}^2 \mid \nu) = \int_{\chi_{\text{obs}}^2}^{\infty} f(\chi^2; \nu) d\chi^2 \quad (11.2)$$

donde $f(\chi^2; \nu)$ es la función de densidad de la distribución de χ^2 con ν grados de libertad. Los valores de esta probabilidad están tabulados en la Tabla C.4.

Un valor p pequeño (típicamente $p < 0,05$ o $p < 0,01$) indica que es poco probable obtener un valor de χ^2 tan grande por azar si el modelo es correcto. Por lo tanto, un valor p pequeño sugiere que el modelo puede ser inadecuado o que las incertidumbres están subestimadas. Por el contrario, un valor p muy grande (cercano a 1) puede indicar que las incertidumbres están sobreestimadas o que los datos han sido "sobreajustados".

Es importante tener en cuenta que la prueba de χ^2 no es una prueba de la verdad del modelo, sino una prueba de la consistencia de los datos con el modelo. Un valor p grande no prueba que el modelo sea correcto; solo indica que los datos no proporcionan evidencia en su contra.

Interpretación de χ^2 reducido

A menudo se utiliza el χ^2 reducido, definido como $\chi_\nu^2 = \chi^2/\nu$. Su valor esperado es 1. Valores de χ_ν^2 significativamente mayores que 1 indican un mal ajuste o incertidumbres subestimadas. Valores significativamente menores que 1 pueden indicar sobreestimación de las incertidumbres o correlaciones no consideradas.

Sin embargo, la interpretación de χ_ν^2 debe hacerse con precaución, especialmente para un número pequeño de grados de libertad. Por ejemplo, para $\nu = 2$, un valor de $\chi_\nu^2 = 2$ corresponde a una probabilidad $p \approx 0,14$, que no es extremadamente baja.

11.2 Coeficiente de Correlación Lineal

Cuando ajustamos una línea recta a datos, a menudo queremos saber qué tan bien se correlacionan linealmente las variables x e y . El coeficiente de correlación lineal de Pearson, denotado por r , mide la fuerza y la dirección de una relación lineal entre dos variables. Se define como

$$r = \frac{\sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^N (x_i - \bar{x})^2 \sum_{i=1}^N (y_i - \bar{y})^2}} \quad (11.3)$$

El coeficiente r varía entre -1 y 1. Un valor de $r = 1$ indica una correlación lineal positiva perfecta, $r = -1$ indica una correlación lineal negativa perfecta, y $r = 0$ indica que no hay correlación lineal.

Para datos que siguen una distribución normal bivalente, la significación de r puede probarse mediante el estadístico

$$t = r \sqrt{\frac{N-2}{1-r^2}} \quad (11.4)$$

que sigue una distribución t de Student con $N-2$ grados de libertad bajo la hipótesis nula de que la correlación verdadera es cero.

Advertencias sobre la correlación

- La correlación no implica causalidad. Dos variables pueden estar correlacionadas sin que una cause la otra.
- El coeficiente de correlación es sensible a valores atípicos.
- Solo mide relaciones lineales. Dos variables pueden tener una relación fuerte no lineal y, sin embargo, tener un coeficiente de correlación cercano a cero.

11.3 Correlaciones Multivariantes

En problemas con más de dos variables, a menudo estamos interesados en las correlaciones entre pares de variables, así como en correlaciones parciales que miden la relación entre dos variables después de eliminar el efecto de otras variables.

La matriz de correlación para m variables es una matriz simétrica cuyos elementos son los coeficientes de correlación entre cada par de variables:

$$\mathbf{R} = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1m} \\ r_{21} & 1 & \cdots & r_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ r_{m1} & r_{m2} & \cdots & 1 \end{pmatrix} \quad (11.5)$$

donde r_{jk} es el coeficiente de correlación entre la variable j y la variable k .

La correlación parcial entre las variables j y k , manteniendo constantes todas las demás variables, puede calcularse a partir de la inversa de la matriz de correlación:

$$r_{jk \cdot \text{resto}} = -\frac{R^{jk}}{\sqrt{R^{jj}R^{kk}}} \quad (11.6)$$

donde R^{jk} son los elementos de la inversa de $\mathbf{R}$.

11.4 Prueba F

La prueba F se utiliza para comparar las varianzas de dos poblaciones o para evaluar la significación de grupos de parámetros en un modelo de regresión. En el contexto del ajuste de curvas, la prueba F puede usarse para determinar si la inclusión de parámetros adicionales mejora significativamente el ajuste.

Supongamos que tenemos dos modelos: un modelo simple con m_1 parámetros y un modelo más complejo con $m_2 > m_1$ parámetros. Ajustamos ambos modelos a los mismos datos y obtenemos sus respectivos valores de χ^2 , χ_1^2 y χ_2^2 . La mejora en el ajuste al usar el modelo más complejo se cuantifica mediante

$$F = \frac{(\chi_1^2 - \chi_2^2)/(m_2 - m_1)}{\chi_2^2/(N - m_2)} \quad (11.7)$$

Bajo la hipótesis nula de que el modelo más simple es correcto, este estadístico sigue una distribución F con grados de libertad $\nu_1 = m_2 - m_1$ y $\nu_2 = N - m_2$. Un valor grande de F indica que el modelo más complejo proporciona una mejora significativa.

11.5 Intervalos de Confianza

Hasta ahora, hemos citado las incertidumbres en los parámetros como desviaciones estándar, que corresponden a intervalos de confianza de aproximadamente el 68 % si la distribución de los estimadores es gaussiana. Sin embargo, a veces deseamos intervalos de confianza con diferentes niveles de probabilidad, como el 90 % o el 95 %.

Para un parámetro a_j estimado a partir de un ajuste, un intervalo de confianza del 100(1 - α) % puede construirse como

$$a_j \pm t_{\alpha/2, \nu} \sigma_{a_j} \quad (11.8)$$

donde $t_{\alpha/2, \nu}$ es el valor crítico de la distribución t de Student con ν grados de libertad para una prueba de dos colas. Para muestras grandes, $t_{\alpha/2, \nu}$ se aproxima al valor correspondiente de la distribución normal estándar (por ejemplo, 1.96 para un intervalo del 95 %).

Para varios parámetros simultáneamente, la región de confianza conjunta es una elipsoide en el espacio de parámetros definida por

$$(\mathbf{a} - \hat{\mathbf{a}})^T \epsilon^{-1} (\mathbf{a} - \hat{\mathbf{a}}) \leq \chi_{\alpha, m}^2 \quad (11.9)$$

donde ϵ es la matriz de covarianza y $\chi_{\alpha, m}^2$ es el valor crítico de la distribución de χ^2 con m grados de libertad para el nivel de confianza deseado.

11.6 Pruebas de Monte Carlo

Las pruebas de Monte Carlo proporcionan una forma flexible y poderosa de evaluar la significación estadística de los resultados, especialmente cuando las distribuciones teóricas son complicadas o las suposiciones de normalidad no se cumplen.

La idea básica es simular muchos conjuntos de datos bajo la hipótesis nula (por ejemplo, que un modelo simple es correcto) y luego ajustar el modelo de interés a cada conjunto de datos simulado. La distribución de los estadísticos de prueba (por ejemplo, χ^2 , F , o las estimaciones de los parámetros) obtenida de las simulaciones puede compararse con el valor observado en los datos reales. El valor p de Monte Carlo es la fracción de simulaciones que producen un estadístico de prueba tan extremo o más que el observado.

Las ventajas de las pruebas de Monte Carlo incluyen:

- No requieren suposiciones de normalidad.
- Pueden manejar situaciones complejas donde las distribuciones teóricas no están disponibles.
- Permiten evaluar la significación de características como picos en un histograma, teniendo en cuenta el problema de las múltiples pruebas (por ejemplo, la probabilidad de que un pico aparezca en cualquier lugar del histograma).

Las desventajas incluyen el costo computacional y la necesidad de especificar correctamente el proceso de generación de datos bajo la hipótesis nula.

Resumen

- **Prueba de χ^2 :** Compara el χ^2 observado con la distribución teórica. Un valor p pequeño indica un posible mal ajuste o incertidumbres subestimadas.
- **Coefficiente de correlación lineal r :** Mide la fuerza de la relación lineal entre dos variables. Su significación puede probarse con una prueba t .
- **Correlaciones multivariantes:** La matriz de correlación y las correlaciones parciales describen las relaciones entre múltiples variables.
- **Prueba F :** Compara modelos anidados para determinar si la inclusión de parámetros adicionales mejora significativamente el ajuste.
- **Intervalos de confianza:** Proporcionan rangos para los parámetros con un nivel de confianza especificado. Pueden ser univariantes (usando la distribución t) o conjuntos (usando la distribución χ^2).
- **Pruebas de Monte Carlo:** Simulan datos bajo la hipótesis nula para evaluar la significación estadística sin depender de aproximaciones teóricas.

Ejercicios

Ejercicio 11.1

Un ajuste de una línea recta a 10 puntos de datos produce un χ^2 de 15.2. ¿Cuál es la probabilidad de obtener un valor de χ^2 tan grande o mayor si el modelo es correcto? ¿Qué concluye sobre la calidad del ajuste?

Solución: Grados de libertad $\nu = 10 - 2 = 8$. Buscamos en la tabla de χ^2 (Tabla C.4) el valor crítico para $\nu = 8$. El valor 15.2 está entre 13.36 ($p=0.10$) y 15.51 ($p=0.05$). Interpolando, la probabilidad es aproximadamente 0.055. Esto está en el límite de la significación estadística ($p < 0.05$ sería significativo). Por lo tanto, hay alguna evidencia de un posible mal ajuste, pero no es concluyente.

Ejercicio 11.2

Calcule el coeficiente de correlación lineal para los siguientes pares de datos:

x	1	2	3	4	5	6
y	2.1	3.9	6.2	7.8	10.1	11.9

Pruebe la significación de la correlación.

Solución: Calculamos las medias: $\bar{x} = 3,5$, $\bar{y} = (2,1 + 3,9 + 6,2 + 7,8 + 10,1 + 11,9)/6 = 42/6 = 7,0$. Suma de productos cruzados: $\sum(x_i - \bar{x})(y_i - \bar{y}) = (1 - 3,5)(2,1 - 7) + (2 - 3,5)(3,9 - 7) + (3 - 3,5)(6,2 - 7) + (4 - 3,5)(7,8 - 7) + (5 - 3,5)(10,1 - 7) + (6 - 3,5)(11,9 - 7) = (-2,5)(-4,9) = 12,25 + (-1,5)(-3,1) = 4,65 + (-0,5)(-0,8) = 0,4 + (0,5)(0,8) = 0,4 + (1,5)(3,1) = 4,65 + (2,5)(4,9) = 12,25$. Suma = $12,25 + 4,65 = 16,9$, $+0,4 = 17,3$, $+0,4 = 17,7$, $+4,65 = 22,35$, $+12,25 = 34,6$. Suma de cuadrados de x : $\sum(x_i - \bar{x})^2 = (-2,5)^2 + (-1,5)^2 + (-0,5)^2 + (0,5)^2 + (1,5)^2 + (2,5)^2 = 6,25 + 2,25 + 0,25 + 0,25 + 2,25 + 6,25 = 17,5$. Suma de cuadrados de y : $\sum(y_i - \bar{y})^2 = (-4,9)^2 + (-3,1)^2 + (-0,8)^2 + (0,8)^2 + (3,1)^2 + (4,9)^2 = 24,01 + 9,61 + 0,64 + 0,64 + 9,61 + 24,01 = 68,52$. $r = \frac{34,6}{\sqrt{17,5 \times 68,52}} = \frac{34,6}{\sqrt{1199,1}} = \frac{34,6}{34,63} \approx 0,999$. $t = r\sqrt{\frac{N-2}{1-r^2}} \approx 0,999\sqrt{\frac{4}{1-0,998}} = 0,999\sqrt{4/0,002} = 0,999\sqrt{2000} \approx 0,999 \times 44,72 = 44,68$. Con 4 grados de libertad, este valor es extremadamente significativo (p mucho menor que 0.001). La correlación es altamente significativa.

Ejercicio 11.3

En un ajuste de una parábola a 20 puntos de datos, se obtienen los siguientes valores de χ^2 para modelos con diferente número de parámetros:

- Lineal ($m = 2$): $\chi^2 = 45,6$
- Cuadrático ($m = 3$): $\chi^2 = 38,2$
- Cúbico ($m = 4$): $\chi^2 = 37,9$

Utilice la prueba F para determinar si la inclusión del término cuadrático mejora significativamente el ajuste, y si la inclusión del término cúbico mejora significativamente respecto al cuadrático.

Solución: Primero, comparamos lineal vs cuadrático: $\Delta\chi^2 = 45,6 - 38,2 = 7,4$, con $\Delta m = 1$ grado de libertad. $\chi^2_{\text{cuad}} = 38,2$ con $\nu = 20 - 3 = 17$. $F = \frac{7,4/1}{38,2/17} = \frac{7,4}{2,247} = 3,29$.

Buscamos en tablas $F_{1,17,0,05} \approx 4,45$. Como $3,29 \nless 4,45$, la mejora no es significativa al nivel del 5 %.

Ahora, cuadrático vs cúbico: $\Delta\chi^2 = 38,2 - 37,9 = 0,3$, con $\Delta m = 1$. $\chi^2_{\text{cub}} = 37,9$ con $\nu = 20 - 4 = 16$. $F = \frac{0,3/1}{37,9/16} = \frac{0,3}{2,36875} = 0,1266$. Claramente no significativo. El término cúbico no mejora el ajuste.

Ejercicio 11.4

Para los datos del Ejemplo 6.2 (Tabla 6.2), calcule el intervalo de confianza del 95 % para la pendiente b del ajuste lineal.

Solución: De la Tabla 6.2, $b = 30,7$, $\sigma_b = \sqrt{1,07} = 1,034$, y $\nu = 10 - 2 = 8$. El valor crítico de t para 8 grados de libertad y 95 % de confianza (bilateral) es $t_{0,025,8} = 2,306$. Por lo tanto, el intervalo de confianza es $30,7 \pm 2,306 \times 1,034 = 30,7 \pm 2,38$. Es decir, $[28,32, 33,08]$.

Ejercicio 11.5

Utilice una prueba de Monte Carlo para evaluar la significación del segundo pico en el Ejemplo 9.2. Genere 1000 histogramas bajo la hipótesis nula de un solo pico (usando los parámetros ajustados para el modelo de un pico) y cuente en cuántos de ellos aparece una fluctuación de al menos 3.9 desviaciones estándar en algún intervalo.

Solución: Se necesita un programa de Monte Carlo. Los pasos son:

1. Ajustar el modelo de un pico (Ecuación 9.1) a los datos reales para obtener los parámetros de fondo y pico.
2. Para cada simulación, generar un histograma con el mismo número total de eventos que el original, usando la distribución de probabilidad del modelo de un pico. Las cuentas en cada intervalo se generan como Poisson alrededor del valor esperado.
3. Para cada simulación, calcular el exceso en cada intervalo como $(N_i - N_{\text{esperado},i}) / \sqrt{N_{\text{esperado},i}}$ y encontrar el máximo exceso.
4. Contar cuántas simulaciones tienen un exceso máximo $\geq 3,9$.
5. La fracción de simulaciones con tal exceso es el valor p de Monte Carlo.

Si esta fracción es pequeña (por ejemplo, $\nless 0,05$), se rechaza la hipótesis nula de un solo pico.

Ejercicio 11.6

Derive la expresión para el intervalo de confianza conjunto de dos parámetros, mostrando que la región es una elipse definida por

$$(\mathbf{a} - \hat{\mathbf{a}})^T \epsilon^{-1} (\mathbf{a} - \hat{\mathbf{a}}) = \chi^2_{\alpha,2}$$

Solución: Para un modelo con dos parámetros, la función de verosimilitud cerca del máximo se aproxima por una gaussiana bidimensional:

$$\mathcal{L}(\mathbf{a}) \propto \exp \left[-\frac{1}{2} (\mathbf{a} - \hat{\mathbf{a}})^T \epsilon^{-1} (\mathbf{a} - \hat{\mathbf{a}}) \right]$$

La región de confianza al nivel $1 - \alpha$ es el conjunto de puntos $\mathbf{a}$ para los cuales el exponente es mayor que un cierto valor, es decir,

$$(\mathbf{a} - \hat{\mathbf{a}})^T \epsilon^{-1} (\mathbf{a} - \hat{\mathbf{a}}) \leq c$$

Para determinar c , notamos que si los datos son gaussianos, entonces $-2 \ln(\mathcal{L}/\mathcal{L}_{\max})$ sigue una distribución χ^2 con 2 grados de libertad. Por lo tanto, el valor crítico es $\chi_{\alpha,2}^2$. La región es una elipse centrada en $\hat{\mathbf{a}}$ con ejes dados por los autovectores de ϵ .

Ejercicio 11.7

Para el ajuste del Ejemplo 7.3 (Tabla 7.7), calcule la región de confianza conjunta del 68 % para los parámetros a_0 y a_2 . Utilice la matriz de error de la Tabla 7.8.

Solución: La matriz de error es

$$\epsilon = \begin{pmatrix} 56,24 & -5,256 \\ -5,256 & 186,5 \end{pmatrix}$$

Su inversa es

$$\epsilon^{-1} = \frac{1}{56,24 \times 186,5 - (-5,256)^2} \begin{pmatrix} 186,5 & 5,256 \\ 5,256 & 56,24 \end{pmatrix}$$

El determinante es $56,24 \times 186,5 = 10488,76$, menos $27,63 = 10461,13$. Por lo tanto,

$$\epsilon^{-1} = \frac{1}{10461,13} \begin{pmatrix} 186,5 & 5,256 \\ 5,256 & 56,24 \end{pmatrix} = \begin{pmatrix} 0,01782 & 0,000502 \\ 0,000502 & 0,005376 \end{pmatrix}$$

La región de confianza del 68 % para dos parámetros corresponde a $\chi_{0,32,2}^2 = 2,30$ (ya que el área fuera de la elipse es 0.32). Por lo tanto, la elipse está definida por

$$0,01782(a_0 - 938,1)^2 + 2 \times 0,000502(a_0 - 938,1)(a_2 - 261) + 0,005376(a_2 - 261)^2 = 2,30$$

Esta es una elipse inclinada centrada en $(938,1, 261)$.

Ejercicio 11.8

Explique cómo usaría una prueba de Monte Carlo para determinar si un valor atípico en un conjunto de datos es estadísticamente significativo.

Solución: Supongamos que tenemos un conjunto de datos y sospechamos que un punto es un valor atípico. Podemos proceder de la siguiente manera:

1. Ajustar el modelo a todos los datos, incluyendo el punto sospechoso.
2. Calcular el residuo estandarizado $r_i = (y_i - \hat{y}_i)/\sigma_i$ para el punto sospechoso.
3. Generar muchos conjuntos de datos simulados bajo el modelo ajustado (con los mismos valores de x_i y las mismas incertidumbres σ_i), y para cada simulación, ajustar el modelo y calcular el residuo estandarizado máximo (o el residuo en la misma posición x_i).
4. Comparar el residuo observado con la distribución de los residuos máximos de las simulaciones. El valor p es la fracción de simulaciones con un residuo máximo mayor o igual que el observado.

Si este valor p es pequeño, el punto atípico es estadísticamente significativo.

Ejercicio 11.9

Derive la relación entre la prueba F y la prueba t para comparar dos modelos con un parámetro de diferencia.

Solución: Cuando se compara un modelo con m parámetros y otro con $m+1$ parámetros, la prueba F tiene $\nu_1 = 1$ y $\nu_2 = N - m - 1$. El estadístico F es

$$F = \frac{(\chi_m^2 - \chi_{m+1}^2)/1}{\chi_{m+1}^2/(N - m - 1)}$$

Por otro lado, la significación del parámetro adicional puede evaluarse mediante una prueba t sobre su estimación. El estadístico t es

$$t = \frac{a_{m+1}}{\sigma_{a_{m+1}}}$$

Se puede demostrar que $F = t^2$. Por lo tanto, ambas pruebas son equivalentes. El valor crítico de t para dos colas y ν grados de libertad está relacionado con el valor crítico de F por $t_{\alpha/2, \nu}^2 = F_{\alpha, 1, \nu}$.

Apéndice A: Métodos Numéricos

A.1 Interpolación Polinomial

La interpolación polinomial se utiliza para estimar el valor de una función entre puntos de datos conocidos. Dado un conjunto de $n+1$ puntos (x_i, y_i) con x_i distintos, existe un único polinomio de grado $\leq n$ que pasa por todos ellos. Este polinomio puede escribirse en la forma de Lagrange:

$$P(x) = \sum_{i=0}^n y_i \prod_{j \neq i} \frac{x - x_j}{x_i - x_j} \quad (\text{A.1})$$

Para fines prácticos, a menudo se utiliza la interpolación lineal (grado 1) o cuadrática (grado 2) cuando los puntos están igualmente espaciados.

Para puntos igualmente espaciados con separación h , la fórmula de interpolación de Newton hacia adelante es útil. Si $x = x_0 + sh$, entonces

$$P(x) = y_0 + s\Delta y_0 + \frac{s(s-1)}{2!}\Delta^2 y_0 + \frac{s(s-1)(s-2)}{3!}\Delta^3 y_0 + \dots \quad (\text{A.2})$$

donde $\Delta y_0 = y_1 - y_0$, $\Delta^2 y_0 = \Delta y_1 - \Delta y_0$, etc.

A.2 Cálculo Básico: Diferenciación e Integración

Derivadas

La derivada de una función $f(x)$ en un punto x puede aproximarse numéricamente mediante diferencias finitas:

- Diferencia hacia adelante: $f'(x) \approx \frac{f(x+h) - f(x)}{h}$
- Diferencia hacia atrás: $f'(x) \approx \frac{f(x) - f(x-h)}{h}$

- Diferencia central: $f'(x) \approx \frac{f(x+h)-f(x-h)}{2h}$

La diferencia central es generalmente más precisa, con un error de orden $O(h^2)$.
Para derivadas de segundo orden:

$$f''(x) \approx \frac{f(x+h) - 2f(x) + f(x-h)}{h^2} \quad (\text{A.3})$$

Integrales

La integral definida $\int_a^b f(x)dx$ puede aproximarse numéricamente mediante varias reglas:

- Regla del rectángulo: $\int_a^b f(x)dx \approx h \sum_{i=0}^{n-1} f(x_i)$
- Regla del trapecio: $\int_a^b f(x)dx \approx h \left[\frac{1}{2}f(x_0) + \sum_{i=1}^{n-1} f(x_i) + \frac{1}{2}f(x_n) \right]$
- Regla de Simpson: $\int_a^b f(x)dx \approx \frac{h}{3} \left[f(x_0) + 4 \sum_{i=1,3,5}^{n-1} f(x_i) + 2 \sum_{i=2,4,6}^{n-2} f(x_i) + f(x_n) \right]$
(requiere n par)

La regla de Simpson tiene un error de orden $O(h^4)$.

A.3 Diferenciación e Integración Numéricas

Derivadas numéricas de mayor orden

Para mayor precisión, se pueden usar fórmulas con más puntos. Por ejemplo, la derivada central de cinco puntos:

$$f'(x) \approx \frac{f(x-2h) - 8f(x-h) + 8f(x+h) - f(x+2h)}{12h} \quad (\text{A.4})$$

con error $O(h^4)$.

Integración numérica adaptativa

Cuando la función varía rápidamente en algunas regiones y lentamente en otras, es eficiente usar métodos adaptativos que subdividen el intervalo donde el error estimado es grande.

A.4 Splines Cúbicos

Los splines cúbicos proporcionan una interpolación suave entre puntos de datos. Un spline cúbico es una función por tramos que consiste en polinomios cúbicos en cada intervalo entre puntos consecutivos, con continuidad de la función, la primera derivada y la segunda derivada en los puntos de unión.

Para $n+1$ puntos (x_i, y_i) con $i = 0, \dots, n$, definimos en cada intervalo $[x_i, x_{i+1}]$ un polinomio cúbico:

$$S_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3 \quad (\text{A.5})$$

Las condiciones de continuidad y las condiciones de contorno (por ejemplo, segunda derivada cero en los extremos para el spline natural) determinan los coeficientes.

Los splines cúbicos son útiles para suavizar datos y para interpolación cuando se requiere una curva suave.

A.5 Raíces de Ecuaciones No Lineales

Encontrar la raíz de una ecuación $f(x) = 0$ es un problema común en análisis numérico. Varios métodos iterativos están disponibles.

Método de bisección

Si $f(a)$ y $f(b)$ tienen signos opuestos, entonces hay al menos una raíz en $[a, b]$. El método de bisección divide repetidamente el intervalo a la mitad y selecciona el subintervalo donde ocurre el cambio de signo. Es robusto pero lento.

Método de Newton-Raphson

Dada una aproximación inicial x_0 , la iteración de Newton-Raphson es

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)} \quad (\text{A.6})$$

Converge rápidamente (cuadráticamente) si la aproximación inicial es buena, pero puede fallar si la derivada es cero o la función no es suave.

Método de la secante

Cuando la derivada no está disponible, se puede aproximar por diferencias finitas, dando el método de la secante:

$$x_{n+1} = x_n - f(x_n) \frac{x_n - x_{n-1}}{f(x_n) - f(x_{n-1})} \quad (\text{A.7})$$

Converge superlinealmente (orden $\approx 1,618$).

A.6 Suavizado de Datos

El suavizado de datos se utiliza para reducir el ruido estadístico y revelar tendencias subyacentes. Sin embargo, debe usarse con precaución, ya que puede distorsionar la información.

Medias móviles

La media móvil simple reemplaza cada punto por el promedio de un número impar de puntos vecinos:

$$y_i^{\text{suav}} = \frac{1}{2k+1} \sum_{j=-k}^k y_{i+j} \quad (\text{A.8})$$

Suavizado binomial

Similar a la media móvil, pero con pesos que siguen coeficientes binomiales, lo que preserva mejor la forma de los picos.

Filtro de Savitzky-Golay

Ajusta un polinomio de bajo grado a una ventana de puntos por mínimos cuadrados y evalúa el polinomio en el punto central. Este método preserva mejor los momentos de la distribución.

Ejercicios del Apéndice A

Ejercicio A.1

Use la interpolación lineal para estimar el valor de y en $x = 2,5$ dados los puntos (2, 4) y (3, 9).

Solución: Interpolación lineal: $y = y_0 + \frac{x-x_0}{x_1-x_0}(y_1-y_0) = 4 + \frac{0,5}{1}(9-4) = 4 + 2,5 = 6,5$.

Ejercicio A.2

Use la fórmula de diferencias centrales con $h = 0,1$ para aproximar la derivada de $f(x) = \sin x$ en $x = 0,5$. Compare con el valor exacto.

Solución: $f(0,5) = \sin 0,5 \approx 0,479426$ $f(0,6) = \sin 0,6 \approx 0,564642$ $f(0,4) = \sin 0,4 \approx 0,389418$ Diferencia central: $f'(0,5) \approx \frac{0,564642-0,389418}{0,2} = \frac{0,175224}{0,2} = 0,87612$ Valor exacto: $\cos 0,5 \approx 0,877583$. Error $\approx 0,0015$.

Ejercicio A.3

Aproxime $\int_0^1 e^{-x^2} dx$ usando la regla del trapecio con $n = 5$ intervalos ($h = 0,2$). Compare con el valor exacto (aproximado 0.746824).

Solución: $x_i : 0, 0,2, 0,4, 0,6, 0,8, 1,0$ $f(x_i) : 1, e^{-0,04} = 0,960789, e^{-0,16} = 0,852144, e^{-0,36} = 0,697676, e^{-0,64} = 0,527292, e^{-1} = 0,367879$ Regla del trapecio: $h[\frac{1}{2}f(0) + f(0,2) + f(0,4) + f(0,6) + f(0,8) + \frac{1}{2}f(1)] = 0,2[0,5 + 0,960789 + 0,852144 + 0,697676 + 0,527292 + 0,18394] = 0,2[0,5 + 0,960789 + 0,852144 + 0,697676 + 0,527292 + 0,18394] = 0,2[3,537901] = 0,7075802$ Error $\approx 0,039244$.

Ejercicio A.4

Encuentre la raíz de $f(x) = x^3 - 2x - 5$ en el intervalo [2,3] usando el método de bisección. Realice tres iteraciones.

Solución: $f(2) = 8 - 4 - 5 = -1$, $f(3) = 27 - 6 - 5 = 16$. Hay raíz. Iter1: $x = 2,5$, $f(2,5) = 15,625 - 5 - 5 = 5,625 > 0$. Nueva raíz en [2,2.5]. Iter2: $x = 2,25$, $f(2,25) = 11,390625 - 4,5 - 5 = 1,890625 > 0$. Nueva raíz en [2,2.25]. Iter3: $x = 2,125$, $f(2,125) = 9,5957 - 4,25 - 5 = 0,3457 > 0$. Nueva raíz en [2,2.125]. La raíz está entre 2 y 2.125, aproximadamente 2.094.

Ejercicio A.5

Use el método de Newton-Raphson para encontrar la raíz de $f(x) = x^3 - 2x - 5$ comenzando con $x_0 = 2$. Realice tres iteraciones.

Solución: $f'(x) = 3x^2 - 2$. $x_0 = 2$, $f(2) = -1$, $f'(2) = 12 - 2 = 10$, $x_1 = 2 - (-1)/10 = 2,1$. $x_1 = 2,1$, $f(2,1) = 9,261 - 4,2 - 5 = 0,061$, $f'(2,1) = 13,23 - 2 = 11,23$, $x_2 = 2,1 - 0,061/11,23 = 2,1 - 0,00543 = 2,09457$. $x_2 = 2,09457$, $f = 2,09457^3 = 9,194$, $-4,18914 - 5 = 0,00486$, $f' = 3 * 4,388 - 2 = 13,164 - 2 = 11,164$, $x_3 = 2,09457 - 0,00486/11,164 = 2,09457 - 0,000435 = 2,094135$. Converge rápidamente.

Ejercicio A.6

Aplique un suavizado de media móvil de 3 puntos a los siguientes datos: 5, 7, 6, 8, 9, 10, 8, 7, 6, 5.

Solución: Para los puntos interiores, la media móvil es el promedio de los tres puntos centrados en el punto: y_2 (índice 2, valor 7) suavizado $= (5+7+6)/3 = 18/3 = 6$ y_3 (6) $= (7+6+8)/3 = 21/3 = 7$ y_4 (8) $= (6+8+9)/3 = 23/3 = 7.67$ y_5 (9) $= (8+9+10)/3 = 27/3 = 9$ y_6 (10) $= (9+10+8)/3 = 27/3 = 9$ y_7 (8) $= (10+8+7)/3 = 25/3 = 8.33$ y_8 (7) $= (8+7+6)/3 = 21/3 = 7$ y_9 (6) $= (7+6+5)/3 = 18/3 = 6$ Los extremos generalmente no se suavizan o se tratan con menos puntos. Así, la serie suavizada es: 5, 6, 7, 7.67, 9, 9, 8.33, 7, 6, 5.

Apéndice B: Matrices

B.1 Determinantes

El determinante de una matriz cuadrada A de orden n es un número escalar que se calcula recursivamente. Para una matriz 2×2 :

$$\det \begin{pmatrix} a & b \\ c & d \end{pmatrix} = ad - bc \quad (\text{B.1})$$

Para una matriz 3×3 :

$$\det \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} = a_{11}(a_{22}a_{33} - a_{23}a_{32}) - a_{12}(a_{21}a_{33} - a_{23}a_{31}) + a_{13}(a_{21}a_{32} - a_{22}a_{31}) \quad (\text{B.2})$$

Para matrices de orden superior, se utiliza el desarrollo por cofactores o métodos numéricos como la eliminación gaussiana.

B.2 Solución de Ecuaciones Simultáneas por Determinantes (Regla de Cramer)

Dado un sistema de n ecuaciones lineales con n incógnitas:

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n &= b_n \end{aligned}$$

La regla de Cramer establece que la solución para x_j es

$$x_j = \frac{\det(A_j)}{\det(A)} \quad (\text{B.3})$$

donde A_j es la matriz A con la columna j -ésima reemplazada por el vector de términos independientes $(b_1, b_2, \dots, b_n)^T$.

La regla de Cramer es útil para sistemas pequeños, pero ineficiente para sistemas grandes.

B.3 Inversión de Matrices

La inversa de una matriz cuadrada A es una matriz A^{-1} tal que $AA^{-1} = A^{-1}A = I$, donde I es la matriz identidad. La inversa existe si y solo si $\det(A) \neq 0$.

Para una matriz 2×2 :

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}, \quad A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix} \quad (\text{B.4})$$

Para matrices más grandes, se utilizan métodos numéricos como la eliminación de Gauss-Jordan o la descomposición LU.

Propiedades de la matriz inversa:

- $(A^{-1})^{-1} = A$
- $(AB)^{-1} = B^{-1}A^{-1}$
- $(A^T)^{-1} = (A^{-1})^T$

Ejercicios del Apéndice B

Ejercicio B.1

Calcule el determinante de la matriz

$$A = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 3 & 2 \\ 0 & 2 & 4 \end{pmatrix}$$

Solución: Usando la fórmula para 3×3 : $\det A = 2(3 \times 4 - 2 \times 2) - 1(1 \times 4 - 2 \times 0) + 0(1 \times 2 - 3 \times 0) = 2(12 - 4) - 1(4 - 0) + 0 = 2 \times 8 - 4 = 16 - 4 = 12$.

Ejercicio B.2

Resuelva el sistema de ecuaciones usando la regla de Cramer:

$$\begin{cases} 2x + y = 5 \\ x - 3y = 6 \end{cases}$$

Solución: En forma matricial: $\begin{pmatrix} 2 & 1 \\ 1 & -3 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 5 \\ 6 \end{pmatrix}$. $\det A = 2(-3) - 1(1) = -6 - 1 = -7$. $\det A_x = \begin{vmatrix} 5 & 1 \\ 6 & -3 \end{vmatrix} = 5(-3) - 1(6) = -15 - 6 = -21$. $\det A_y = \begin{vmatrix} 2 & 5 \\ 1 & 6 \end{vmatrix} = 2(6) - 5(1) = 12 - 5 = 7$. $x = \det A_x / \det A = (-21)/(-7) = 3$. $y = \det A_y / \det A = 7/(-7) = -1$. Solución: $x = 3, y = -1$.

Ejercicio B.3

Encuentre la inversa de la matriz

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix}$$

Solución: $\det A = 2 \times 3 - 1 \times 1 = 6 - 1 = 5$. $A^{-1} = \frac{1}{5} \begin{pmatrix} 3 & -1 \\ -1 & 2 \end{pmatrix} = \begin{pmatrix} 0,6 & -0,2 \\ -0,2 & 0,4 \end{pmatrix}$.

Ejercicio B.4

Demuestre que para una matriz diagonal D con elementos diagonales d_{ii} , la inversa es una matriz diagonal con elementos $1/d_{ii}$.

Solución: Sea $D = \text{diag}(d_1, d_2, \dots, d_n)$. Entonces $D \cdot \text{diag}(1/d_1, 1/d_2, \dots, 1/d_n) = \text{diag}(1, 1, \dots, 1) = I$. Por lo tanto, la inversa es la matriz diagonal con los recíprocos.

Ejercicio B.5

Calcule el producto de las matrices A y B :

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \quad B = \begin{pmatrix} 5 & 6 \\ 7 & 8 \end{pmatrix}$$

Solución: $AB = \begin{pmatrix} 1 \times 5 + 2 \times 7 & 1 \times 6 + 2 \times 8 \\ 3 \times 5 + 4 \times 7 & 3 \times 6 + 4 \times 8 \end{pmatrix} = \begin{pmatrix} 5 + 14 & 6 + 16 \\ 15 + 28 & 18 + 32 \end{pmatrix} = \begin{pmatrix} 19 & 22 \\ 43 & 50 \end{pmatrix}$.

Apéndice C: Gráficos y Tablas

Este apéndice contiene tablas de funciones estadísticas comúnmente utilizadas en el análisis de datos. Las tablas incluyen:

- Tabla C.1: Distribución de probabilidad gaussiana (densidad) $p(z)$ para valores de z de 0 a 3.
- Tabla C.2: Integral de la distribución gaussiana $P(z)$ (probabilidad de que una variable esté entre $-z$ y z).
- Tabla C.3: Coeficiente de correlación lineal: valores críticos para diferentes niveles de significación.
- Tabla C.4: Distribución de χ^2 : valores de χ^2 para diferentes grados de libertad ν y probabilidades.
- Tabla C.5: Distribución F : valores críticos para diferentes grados de libertad del numerador y denominador y niveles de significación.
- Tabla C.6: Distribución t de Student: valores críticos para diferentes grados de libertad y niveles de significación.

Estas tablas son esenciales para realizar pruebas de hipótesis y construir intervalos de confianza.

Ejercicios del Apéndice C

Ejercicio C.1

Usando la Tabla C.2, encuentre la probabilidad de que una variable aleatoria normal estándar esté entre -1.5 y 1.5.

Solución: Buscamos $P(1,5)$ en la tabla. Típicamente, $P(1,5) \approx 0,8664$. Por lo tanto, la probabilidad es 0.8664.

Ejercicio C.2

Usando la Tabla C.4, encuentre el valor crítico de χ^2 para $\nu = 5$ y un nivel de significación $\alpha = 0,05$.

Solución: Buscamos en la tabla de χ^2 para 5 grados de libertad y probabilidad 0.05 (cola superior). El valor es aproximadamente 11.07.

Ejercicio C.3

Usando la Tabla C.6, encuentre el valor crítico de t para 10 grados de libertad y un nivel de confianza del 95 % (prueba bilateral).

Solución: Para 10 grados de libertad y 95 % de confianza bilateral, el nivel de significación es $0.05/2 = 0.025$ en cada cola. El valor crítico es $t_{0,025,10} \approx 2,228$.

Ejercicio C.4

Usando la Tabla C.5, encuentre el valor crítico de F para $\nu_1 = 3$, $\nu_2 = 12$ y $\alpha = 0,05$.

Solución: Buscamos en la tabla F para 3 y 12 grados de libertad, nivel 0.05. El valor es aproximadamente 3.49.

Ejercicio C.5

Interprete el significado de un valor $p = 0,03$ en una prueba de hipótesis.

Solución: Un valor $p = 0,03$ significa que, si la hipótesis nula es verdadera, la probabilidad de obtener un resultado tan extremo o más que el observado es del 3 %. Esto proporciona evidencia en contra de la hipótesis nula, ya que el resultado observado es poco probable bajo la hipótesis nula. Típicamente, se rechaza la hipótesis nula si $p < 0,05$.

Apéndice D: Histogramas y Gráficos

La presentación efectiva de datos es una parte crucial del análisis científico. Un gráfico bien diseñado puede comunicar tendencias, patrones y excepciones de manera mucho más efectiva que una tabla de números. Este apéndice proporciona pautas para crear gráficos claros e informativos.

D.1 Elaboración de un Gráfico

Al preparar un gráfico, se deben considerar los siguientes elementos:

- **Ejes:** Los ejes deben estar claramente etiquetados con el nombre de la variable y las unidades. Las escalas deben elegirse para que los datos llenen la mayor parte

del área del gráfico. Generalmente, el eje horizontal (eje x) se usa para la variable independiente y el eje vertical (eje y) para la variable dependiente.

- **Puntos de datos:** Los puntos de datos deben ser claramente visibles. Use diferentes símbolos (círculos, cuadrados, triángulos) para diferentes conjuntos de datos en el mismo gráfico. Incluya barras de error que indiquen las incertidumbres en los datos.
- **Líneas y curvas:** Las líneas que conectan puntos de datos o las curvas ajustadas deben ser distinguibles de los puntos. Use líneas sólidas para curvas ajustadas y líneas discontinuas para extrapolaciones o curvas teóricas.
- **Leyenda:** Si hay múltiples conjuntos de datos o curvas, incluya una leyenda que identifique cada uno.
- **Título:** Un título descriptivo ayuda al lector a entender el contenido del gráfico.
- **Relación de aspecto:** La relación entre la longitud de los ejes debe elegirse para evitar distorsiones engañosas. Por ejemplo, una pendiente que parece pronunciada puede suavizarse estirando el eje horizontal.

D.2 Estimación Gráfica de Parámetros

A veces es útil estimar parámetros directamente a partir de un gráfico antes de realizar un ajuste formal. Por ejemplo:

- **Línea recta:** La pendiente y la intersección pueden estimarse dibujando una línea a ojo a través de los puntos. La pendiente se calcula como $\Delta y / \Delta x$ entre dos puntos en la línea.
- **Función exponencial:** En un gráfico semilogarítmico (escala logarítmica en el eje y), una función exponencial $y = ae^{bx}$ aparece como una línea recta con pendiente b .
- **Ley de potencias:** En un gráfico log-log (escala logarítmica en ambos ejes), una función de potencia $y = ax^b$ aparece como una línea recta con pendiente b .

Estas estimaciones gráficas pueden proporcionar valores iniciales para algoritmos de ajuste más precisos.

D.3 Histogramas y Gráficos de Frecuencia

Un histograma es una representación gráfica de la distribución de frecuencias de una variable. Para construir un histograma:

1. Divida el rango de la variable en intervalos (bins). El número de intervalos debe elegirse para que el histograma sea informativo: demasiados intervalos producen un gráfico ruidoso, muy pocos ocultan la estructura.
2. Cuente el número de observaciones que caen en cada intervalo.
3. Dibuje una barra para cada intervalo con altura igual a la frecuencia (o frecuencia relativa).

Los histogramas son útiles para visualizar la forma de una distribución, identificar valores atípicos y comparar con distribuciones teóricas.

D.4 Rutinas de Gráficos

Los programas de computadora modernos incluyen potentes capacidades de gráficos. En el contexto de este libro, las rutinas de gráficos se utilizan para trazar datos y curvas ajustadas. Aunque los listados de estas rutinas no se incluyen en el apéndice (para mantener la brevedad), los programas disponibles en el sitio web del libro incluyen llamadas a rutinas gráficas que pueden adaptarse a diferentes entornos (por ejemplo, Gnuplot, Matplotlib, etc.).

Ejercicios del Apéndice D

Ejercicio D.1

Construya un histograma para los siguientes datos: 3, 5, 4, 6, 7, 5, 4, 5, 6, 7, 8, 5, 4, 3, 5, 6, 7, 8, 9, 5. Use intervalos de ancho 1 desde 2 hasta 10.

Solución: Contamos las frecuencias: Intervalo 2-3: valores 3 (dos veces), 3 (otro) $\rightarrow$ 3? Revisemos: 3 aparece 2 veces? En la lista: 3,5,4,6,7,5,4,5,6,7,8,5,4,3,5,6,7,8,9,5. Los 3 están en las posiciones 1 y 14 $\rightarrow$ 2 veces. Intervalo 3-4: valor 4 aparece en posiciones 3,7,13 $\rightarrow$ 3 veces. Intervalo 4-5: valor 5 aparece en posiciones 2,6,8,12,15,20 $\rightarrow$ 6 veces. Intervalo 5-6: valor 6 aparece en posiciones 4,9,16 $\rightarrow$ 3 veces. Intervalo 6-7: valor 7 aparece en posiciones 5,10,17 $\rightarrow$ 3 veces. Intervalo 7-8: valor 8 aparece en posiciones 11,18 $\rightarrow$ 2 veces. Intervalo 8-9: valor 9 aparece en posición 19 $\rightarrow$ 1 vez. Intervalo 9-10: ninguno. El histograma tendría barras de alturas: 2,3,6,3,3,2,1.

Ejercicio D.2

En un gráfico semilogarítmico, los puntos (1, 2), (2, 5), (3, 12), (4, 30) parecen alinearse. Estime la pendiente y determine la función exponencial.

Solución: Tomamos logaritmos naturales: $\ln(2)=0.693$, $\ln(5)=1.609$, $\ln(12)=2.485$, $\ln(30)=3.401$. Ajustamos una línea recta a estos puntos (x, ln y). La pendiente es aproximadamente $(3.401-0.693)/(4-1)=2.708/3=0.903$. La intersección en $x=1$ es 0.693, por lo que la ecuación es $\ln y = 0.693 + 0.903(x-1) = -0.21 + 0.903x$. Por tanto, $y = e^{-0.21}e^{0.903x} = 0.81e^{0.903x}$. *Una función exponencial.*

Apéndice E: Rutinas de Computadora en Fortran

Este apéndice contiene listados de rutinas Fortran que ilustran los métodos descritos en el texto. Las rutinas están organizadas por capítulos y están disponibles para su descarga en el sitio web del libro. Aquí se proporcionan versiones simplificadas para facilitar la comprensión de los algoritmos.

E.1 Rutinas del Capítulo 5 (Monte Carlo)

[caption=Generador de números aleatorios de Wichmann-Hill] SUBROUTINE RANS-TART(ISEED1, ISEED2, ISEED3) C Inicializa las semillas para el generador Wichmann-Hill INTEGER ISEED1, ISEED2, ISEED3 COMMON /RANDOM/ IX, IY, IZ IX = ISEED1 IY = ISEED2 IZ = ISEED3 RETURN END

REAL FUNCTION RAN() C Genera un número aleatorio uniforme en [0,1) INTEGER IX, IY, IZ COMMON /RANDOM/ IX, IY, IZ IX = MOD(171 * IX, 30269) IY =

```
MOD(172 * IY, 30307) IZ = MOD(170 * IZ, 30323) RAN = MOD(FLOAT(IX)/30269.0
+ FLOAT(IY)/30307.0 + FLOAT(IZ)/30323.0, 1.0) RETURN END
```

[caption=Generador de números gaussianos (Box-Muller)] SUBROUTINE GAUSS(R1, R2, Z1, Z2) C Genera dos desviaciones gaussianas estándar a partir de dos uniformes REAL R1, R2, Z1, Z2 REAL PI PARAMETER (PI = 3.1415927) Z1 = SQRT(-2.0 * LOG(R1)) * COS(2.0 * PI * R2) Z2 = SQRT(-2.0 * LOG(R1)) * SIN(2.0 * PI * R2) RETURN END

[caption=Generador de Poisson] FUNCTION POISSON(MEAN) C Genera un entero de Poisson con media MEAN REAL MEAN REAL R, SUM, TERM INTEGER POISSON, I R = RAN() SUM = 0.0 I = 0 TERM = EXP(-MEAN) SUM = TERM DO WHILE (SUM .LT. R) I = I + 1 TERM = TERM * MEAN / FLOAT(I) SUM = SUM + TERM END DO POISSON = I RETURN END

E.2 Rutinas del Capítulo 6 (Ajuste lineal)

[caption=Ajuste de línea recta con errores comunes] SUBROUTINE FITLINE(N, X, Y, SIGMA, A, B, SIGA, SIGB, CHISQR) C Ajusta $y = a + bx$ con errores comunes SIGMA INTEGER N REAL X(N), Y(N), SIGMA REAL A, B, SIGA, SIGB, CHISQR REAL SX, SY, SXX, SXY, DENOM INTEGER I SX = 0.0 SY = 0.0 SXX = 0.0 SXY = 0.0 DO I = 1, N SX = SX + X(I) SY = SY + Y(I) SXX = SXX + X(I)**2 SXY = SXY + X(I)*Y(I) END DO DENOM = FLOAT(N) * SXX - SX**2 A = (SY * SXX - SX * SXY) / DENOM B = (FLOAT(N) * SXY - SX * SY) / DENOM SIGA = SIGMA * SQRT(SXX / DENOM) SIGB = SIGMA * SQRT(FLOAT(N) / DENOM) CHISQR = 0.0 DO I = 1, N CHISQR = CHISQR + ((Y(I) - A - B*X(I))/SIGMA)**2 END DO RETURN END

E.3 Rutinas del Capítulo 7 (Ajuste polinomial)

[caption=Ajuste polinomial por matrices] SUBROUTINE POLFIT(N, X, Y, SIGMAY, M, A, EPS, CHISQR) C Ajusta polinomio de grado M-1 usando matrices INTEGER N, M REAL X(N), Y(N), SIGMAY(N) REAL A(M), EPS(M,M), CHISQR REAL ALPHA(M,M), BETA(M) INTEGER I, J, K C Inicializar matrices DO J = 1, M BETA(J) = 0.0 DO K = 1, M ALPHA(J,K) = 0.0 END DO END DO C Acumular sumas DO I = 1, N DO J = 1, M BETA(J) = BETA(J) + Y(I) * X(I)**(J-1) / SIGMAY(I)**2 DO K = 1, M ALPHA(J,K) = ALPHA(J,K) + X(I)**(J+K-2) / SIGMAY(I)**2 END DO END DO END DO C Invertir ALPHA para obtener EPS CALL MATINV(ALPHA, EPS, M) C Calcular parámetros DO J = 1, M A(J) = 0.0 DO K = 1, M A(J) = A(J) + BETA(K) * EPS(K,J) END DO END DO C Calcular chi-cuadrado CHISQR = 0.0 DO I = 1, N YFIT = 0.0 DO K = 1, M YFIT = YFIT + A(K) * X(I)**(K-1) END DO CHISQR = CHISQR + ((Y(I) - YFIT)/SIGMAY(I))**2 END DO RETURN END

E.4 Rutinas del Capítulo 8 (Ajuste no lineal)

[caption=Método de Marquardt] SUBROUTINE MARQ(N, X, Y, SIGMAY, M, A, EPS, CHISQR, LAMBDA) C Un paso del método de Marquardt para ajuste no lineal INTEGER N, M REAL X(N), Y(N), SIGMAY(N) REAL A(M), EPS(M,M), CHISQR, LAMBDA REAL ALPHA(M,M), BETA(M), DA(M) REAL YFIT, DERIV(M) INTEGER I, J, K C Inicializar matrices DO J = 1, M BETA(J) = 0.0 DO K = 1, M

```

ALPHA(J,K) = 0.0 END DO END DO C Acumular sumas con derivadas numéricas
o analíticas DO I = 1, N CALL FUNC(X(I), A, YFIT, DERIV) DO J = 1, M BETA(J)
= BETA(J) + (Y(I)-YFIT) * DERIV(J) / SIGMAY(I)**2 DO K = 1, M ALPHA(J,K) =
ALPHA(J,K) + DERIV(J) * DERIV(K) / SIGMAY(I)**2 END DO END DO END DO C
Aplicar factor de Marquardt a la diagonal DO J = 1, M ALPHA(J,J) = ALPHA(J,J) * (1.0
+ LAMBDA) END DO C Invertir ALPHA para obtener EPS CALL MATINV(ALPHA,
EPS, M) C Calcular incrementos DO J = 1, M DA(J) = 0.0 DO K = 1, M DA(J) =
DA(J) + BETA(K) * EPS(K,J) END DO END DO C Actualizar parámetros DO J =
1, M A(J) = A(J) + DA(J) END DO C Recalcular chi-cuadrado con nuevos parámetros
CHISQR = 0.0 DO I = 1, N CALL FUNC(X(I), A, YFIT, DERIV) CHISQR = CHISQR
+ ((Y(I)-YFIT)/SIGMAY(I))**2 END DO RETURN END

```

E.5 Rutinas del Capítulo 9 (Ajuste de curvas compuestas)

[caption=Función lorentziana sobre fondo cuadrático] SUBROUTINE LORFIT(N, X, Y, SIGMAY, A, EPS, CHISQR) C Ajusta $y = a_1 + a_2x + a_3x^2 + a_4L(x; a_5, a_6)$ INTEGER N REAL X, Y, SIGMAY, A, EPS, CHISQR C Ajusta y = a1 + a2*x + a3*x^2 + a4*L(x; a5, a6) INTEGER N REAL X, A(6), YFIT, DERIV(6) REAL GAMMA, DENOM GAMMA = A(6) DENOM = (X - A(5))**2 + (GAMMA/2.0)**2 YFIT = A(1) + A(2)*X + A(3)*X**2 + A(4) * (GAMMA/(2.0*3.14159)) / DENOM DERIV(1) = 1.0 DERIV(2) = X DERIV(3) = X**2 DERIV(4) = (GAMMA/(2.0*3.14159)) / DENOM DERIV(5) = A(4) * (GAMMA/(2.0*3.14159)) * 2.0*(X-A(5)) / DENOM**2 DERIV(6) = A(4)/(2.0*3.14159) * ((X-A(5))**2 - (GAMMA/2.0)**2) / DENOM**2 RETURN END

E.6 Rutinas del Capítulo 10 (Máxima verosimilitud)

[caption=Búsqueda de máxima verosimilitud para vida media] FUNCTION LOGLIKELIFETIME(TAU, N, T, T1, T2) C Calcula el logaritmo de la verosimilitud para datos de vida con cortes INTEGER N REAL TAU, T(N), T1(N), T2(N) REAL LOGLIKELIFETIME REAL SUM INTEGER I SUM = 0.0 DO I = 1, N SUM = SUM + LOG(EXP(-T1(I)/TAU) - EXP(-T2(I)/TAU)) - T(I)/TAU END DO LOGLIKELIFETIME = SUM - FLOAT(N) * LOG(TAU) RETURN END

SUBROUTINE MAXLIKELIFETIME(N, T, T1, T2, TAU, SIGTAU) C Busca el valor de TAU que maximiza la log-verosimilitud INTEGER N REAL T(N), T1(N), T2(N) REAL TAU, SIGTAU REAL LOGL, LOGL1, LOGL2 REAL STEP, TAU1, TAU2, TAU3 C Búsqueda en malla simple TAU = 0.5 STEP = 0.1 LOGL = LOGLIKELIFETIME(TAU, N, T, T1, T2) 10 TAU1 = TAU - STEP TAU2 = TAU TAU3 = TAU + STEP LOGL1 = LOGLIKELIFETIME(TAU1, N, T, T1, T2) LOGL2 = LOGLIKELIFETIME(TAU3, N, T, T1, T2) IF (LOGL1.GT. LOGL) THEN TAU = TAU1 LOGL = LOGL1 GOTO 10 ELSE IF (LOGL2.GT. LOGL) THEN TAU = TAU3 LOGL = LOGL2 GOTO 10 END IF C Ajuste parabólico para estimar el máximo y la incertidumbre CALL PARABOLA(TAU1, TAU2, TAU3, LOGL1, LOGL, LOGL2, TAU, SIGTAU) RETURN END

E.7 Rutinas del Capítulo 11 (Pruebas estadísticas)

[caption=Cálculo de la probabilidad de chi-cuadrado] FUNCTION CHISQPROB(CHISQ, NU) C Calcula la probabilidad de chi-cuadrado (algoritmo aproximado) REAL CHISQ,

```
CHISQPROB INTEGER NU REAL GAMMP EXTERNAL GAMMP CHISQPROB =
1.0 - GAMMP(0.5*FLOAT(NU), 0.5*CHISQ) RETURN END
```

```
FUNCTION GAMMP(A, X) C Función gamma incompleta (aproximación) REAL A,
X, GAMMP REAL SUM, TERM INTEGER I IF (X .LT. A + 1.0) THEN SER = 1.0
/ A TERM = 1.0 / A I = 1 DO WHILE (TERM/SUM .GT. 1E-6) TERM = TERM *
X / (A + FLOAT(I)) SUM = SUM + TERM I = I + 1 END DO GAMMP = EXP(-X
+ A*LOG(X)) * SUM ELSE C = 1.0 / X SUM = 1.0 + C * (A-1.0) I = 2 DO WHILE
(ABS(C*SUMOLD - SUM).GT.1E-6)C = -C * (A - FLOAT(I))/X SUM = SUM +
CI = I+1ENDDOGAMMP = 1.0-EXP(-X+A*LOG(X))*SUMENDIFRETURNEND
```

```
[caption=Cálculo del coeficiente de correlación] SUBROUTINE CORREL(N, X, Y, R,
T, PROB) INTEGER N REAL X(N), Y(N) REAL R, T, PROB REAL SUMX, SUMY,
SUMXX, SUMYY, SUMXY REAL XBAR, YBAR, SXX, SYY, SXY INTEGER I SUMX
= 0.0 SUMY = 0.0 DO I = 1, N SUMX = SUMX + X(I) SUMY = SUMY + Y(I) END
DO XBAR = SUMX / FLOAT(N) YBAR = SUMY / FLOAT(N) SUMXX = 0.0 SUMYY
= 0.0 SUMXY = 0.0 DO I = 1, N SUMXX = SUMXX + (X(I) - XBAR)**2 SUMYY
= SUMYY + (Y(I) - YBAR)**2 SUMXY = SUMXY + (X(I) - XBAR)*(Y(I) - YBAR)
END DO R = SUMXY / SQRT(SUMXX * SUMYY) T = R * SQRT(FLOAT(N-2) /
(1.0 - R**2)) PROB = 2.0 * (1.0 - STUDENTT(ABS(T), N-2)) ! Probabilidad bilateral
RETURN END
```

Rutinas de utilidad general

```
[caption=Inversión de matrices] SUBROUTINE MATINV(A, AINV, N) C Invierte una
matriz simétrica NxN usando eliminación de Gauss-Jordan INTEGER N REAL A(N,N),
AINV(N,N) REAL AMAT(N,2*N) INTEGER I, J, K REAL FACTOR C Crear matriz
aumentada [A — I] DO I = 1, N DO J = 1, N AMAT(I,J) = A(I,J) END DO DO J = N+1,
2*N AMAT(I,J) = 0.0 END DO AMAT(I, N+I) = 1.0 END DO C Eliminación Gaussiana
DO I = 1, N IF (AMAT(I,I) .EQ. 0.0) THEN DO J = I+1, N IF (AMAT(J,I) .NE. 0.0)
THEN DO K = 1, 2*N TEMP = AMAT(I,K) AMAT(I,K) = AMAT(J,K) AMAT(J,K)
= TEMP END DO EXIT END IF END DO END IF FACTOR = 1.0 / AMAT(I,I) DO
K = 1, 2*N AMAT(I,K) = AMAT(I,K) * FACTOR END DO DO J = 1, N IF (J .NE. I)
THEN FACTOR = AMAT(J,I) DO K = 1, 2*N AMAT(J,K) = AMAT(J,K) - FACTOR
* AMAT(I,K) END DO END IF END DO END DO C Extraer la inversa DO I = 1, N
DO J = 1, N AINV(I,J) = AMAT(I, N+J) END DO END DO RETURN END
```

```
[caption=Cálculo de chi-cuadrado para un ajuste] SUBROUTINE CHISQCALC(N, X, Y, SIGMAY,
0,0DOI = 1, NCALLFUNC(X(I), A, YFIT)CHISQR = CHISQR+((Y(I)-YFIT)/SIGMAY(I))
*2ENDDORETURNEND
```

Instrucciones de uso

Los programas listados aquí están escritos en Fortran 77 y están disponibles en el sitio web del libro en versiones Fortran y C++. Para utilizarlos:

1. Descargue los archivos fuente del sitio web.
2. Compile los programas con un compilador Fortran (por ejemplo, gfortran).
3. Ejecute los programas con los datos apropiados.

Los programas están diseñados para ser modulares, con rutinas separadas para entrada/salida, cálculos y gráficos. Esto facilita su adaptación a diferentes problemas.